

Diseño completo de un máster en inteligencia artificial para liderazgo técnico, despliegue seguro y transformación empresarial

Alcance y benchmark

Este diseño no parte de un temario genérico. Está construido sobre un benchmark de programas con currículo público y contenido verificable, combinando agregadores de programas con currículos oficiales de másteres y especializaciones avanzadas. La muestra útil incluye, entre otros, los currículos de Carnegie Mellon University ¹, Stanford University ², University of Oxford ³, University College London ⁴, King's College London ⁵, University of Florida ⁶, ETH Zurich ⁷ y University of Sydney ⁸, además de recopilaciones de programas que permiten ampliar el universo comparado hasta unas cincuenta referencias con contenidos visibles. ⁹

Lo que aparece de forma recurrente en esa muestra es estable: fundamentos matemáticos y probabilísticos; aprendizaje automático y deep learning; PLN, visión, recuperación de información y, cada vez más, sistemas multiagente; ingeniería de sistemas y despliegue; seguridad, fiabilidad y evaluación; ética y regulación; y un proyecto final orientado a resolver problemas reales. El diseño propuesto cubre todos esos clústeres y añade capas que en muchos programas aparecen de forma dispersa o tangencial, pero que hoy son decisivas en empresa: LLMOps, economía del razonamiento, adopción organizativa, gobierno del dato, gestión del cambio, arquitectura de agentes, cumplimiento normativo y seguridad operativa. Tomando como unidad de análisis clústeres temáticos y no nombres exactos de asignaturas, la cobertura supera con holgura el umbral del 90% que pedías; esa afirmación es una inferencia de diseño basada en la comparación de currículos, no una métrica oficial de las universidades. ¹⁰

El resultado es un máster deliberadamente híbrido. No es solo un máster de ciencia de datos, ni solo un máster de LLMs, ni solo un máster de gobierno. Es un programa para profesionales cercanos a tecnología que deben ser capaces de entender cómo funciona la IA, decidir qué clase de IA necesitan, diseñar una solución cuando el mercado no la resuelve de forma directa, gobernarla con seguridad y llevarla a producción dentro de una empresa real. ¹¹

Perfil de egreso e itinerario

Propongo un programa de 120 ECTS equivalente a 18 meses, con un tramo cero de nivelación no creditado y seis módulos troncales más un capstone integrador. Esa duración recoge lo mejor de las estructuras de un año intensivo típicas de Reino Unido, de los diseños de 30 créditos profesionales en Estados Unidos y de los formatos de dos años o 120 ECTS más habituales en Europa continental. La elección no es arbitraria: la mezcla de teoría, laboratorio, seguridad, legislación, arquitectura y cambio organizativo exige más profundidad que un máster meramente aplicado a modelos predictivos. ¹²

Al terminar, el alumno debe ser capaz de formular un problema de negocio como problema de IA; distinguir cuándo conviene una regla simbólica, un modelo clásico de ML, un modelo profundo, un LLM con prompting avanzado, un RAG, un agente con herramientas o una arquitectura híbrida; seleccionar

entre soluciones comerciales y despliegue propio; diseñar una arquitectura segura; operar el ciclo de vida completo del modelo; auditar riesgos; y liderar la implantación organizativa de la solución con criterios de valor, cumplimiento y adopción. Esa salida profesional se alinea con el sesgo aplicado de programas como CMU y Florida, y con la amplitud metodológica visible en Stanford, Oxford, UCL y King's. ¹³

El itinerario progresivo queda así. En el tramo cero, el alumno homogeneiza Python, SQL, Git, Docker, estadística, álgebra lineal y lectura de papers. Después entra en una primera fase de fundamentos y modelado, donde aprende qué es un sistema de IA y cómo razona. La segunda fase se centra en ingeniería, evaluación, despliegue y agentes. La tercera fase incorpora seguridad, gobierno, regulación y transformación empresarial. El capstone final obliga a integrar todo: modelo, datos, arquitectura, control del riesgo, ROI, plan de adopción, documentación y defensa ejecutiva. ¹⁴

La evaluación no debe descansar solo en exámenes. Debe combinar laboratorios técnicos, informes de arquitectura, ejercicios de red-teaming, análisis de proveedores, dossiers regulatorios, memorias de MLOps/LLMOps y un proyecto final con entregables ejecutivos y técnicos. En un máster de esta naturaleza, la calidad se demuestra cuando el alumno puede pasar del paper al sistema y del sistema al comité de dirección sin perder rigor. ¹⁵

Fundamentos y modelado

Módulo de fundamentos ontológicos y razonamiento de máquinas

Objetivo del módulo. Este módulo construye la base mental del programa. El alumno deja de ver la IA como una “caja que predice” y empieza a verla como un conjunto de paradigmas con supuestos, límites y costes diferentes: representación simbólica, inferencia probabilística, lógica difusa, redes neuronales, modelos fundacionales y sistemas neuro-simbólicos. La inclusión de este bloque está plenamente justificada por los currículos benchmark, que combinan fundamentos matemáticos, teoría, decisión colectiva, juego, incertidumbre, visión y razonamiento agéntico. ¹⁶

Tema de matemáticas para IA. El objetivo es que el alumno pueda leer documentación técnica y papers sin depender siempre de explicaciones de segundo nivel. Aquí se estudian álgebra lineal para embeddings y atención; cálculo para backpropagation y optimización; probabilidad y estadística para inferencia, calibración y evaluación; teoría de la información para entropía y compresión; y complejidad computacional para entender por qué una solución conceptualmente elegante puede ser impracticable en producción. El caso de uso base es doble: predicción tabular de riesgo y clasificación documental, para mostrar que las mismas ideas matemáticas reaparecen en sistemas muy distintos. La práctica se realiza con Python, NumPy y PyTorch, pero el foco no es programar por programar, sino entender qué se está optimizando y qué compromisos se están aceptando. ¹⁷

Tema de paradigmas de razonamiento. El alumno compara el paradigma simbólico, el probabilístico, el difuso y el conexionista. Tiene que ser capaz de explicar cuándo una empresa necesita un motor de reglas auditable, cuándo conviene una red neuronal que aprenda de ejemplos, cuándo es mejor modelar incertidumbre explícita y cuándo interesa una combinación de enfoques. La parte neuro-simbólica se trabaja como arquitectura de fusión entre reconocimiento de patrones y restricciones lógicas. Un caso práctico ejemplar es la tramitación de siniestros o expedientes: la red identifica entidades y patrones en documentos e imágenes, y una capa simbólica aplica política de negocio, restricciones legales o umbrales de riesgo. Este punto es especialmente importante para sectores regulados porque mejora trazabilidad, control y robustez frente a errores puramente estadísticos. ¹⁸

Tema de representación, tokens y transformers. Aquí el alumno estudia embeddings, tokenización, ventanas de contexto y transformers. Debe entender por qué el modelo no “ve palabras” como un humano, sino secuencias tokenizadas; por qué la calidad de la respuesta depende del contexto disponible; por qué la recuperación externa sigue siendo necesaria aunque el modelo sea muy grande; y por qué el diseño del prompt y del contexto es una disciplina de ingeniería. La explicación profunda incluye atención, posición, compresión semántica y límites de conteo o precisión simbólica derivados de la propia tokenización. La práctica se apoya en Hugging Face y en análisis de prompts reales con distintos tokenizadores para mostrar cómo cambia el coste y el comportamiento. ¹⁹

Tema de modelos de razonamiento y economía del razonamiento. Este tema resuelve una de las preguntas que más valor aportan hoy en empresa: qué significa que un modelo “razone más”, cuánto cuesta y cuándo compensa. El alumno estudia cadenas de pensamiento, descomposición de problemas, auto-refinamiento, búsqueda deliberativa y uso de herramientas. Se enseña que en las APIs modernas de razonamiento aparecen tokens internos o presupuestos de deliberación adicionales a los tokens de entrada y salida. En la documentación de OpenAI ²⁰, por ejemplo, los modelos de razonamiento generan reasoning tokens internos, permiten configurar effort, esos tokens ocupan contexto y se facturan como output tokens; además, OpenAI recomienda reservar margen de contexto para razonamiento y salida. En la documentación de Google Cloud ²¹ también aparece la idea de “thinking budget” en modelos compatibles. El alumno aprende a convertir esto en una política empresarial: usar más cómputo deliberativo solo cuando las evals demuestren una mejora real en precisión, seguridad o capacidad de planificación. ²²

Fuentes base de la unidad. Currículos oficiales de Stanford, Oxford, UCL, King’s y Florida; survey y material neuro-simbólico; y documentación actual de razonamiento y presupuestos deliberativos de proveedores. ²³

Módulo de deep learning, PLN y modelado multimodal

Objetivo del módulo. El segundo módulo construye el “cómo modelar”. El alumno recorre desde ML clásico hasta modelos multimodales, y aprende a elegir la familia de modelo por estructura del problema, no por moda. Este bloque está respaldado por la recurrencia de ML, NLP, RL, multi-agent AI, vision y deep learning en UCL, Oxford, King’s y Florida. ²⁴

Tema de aprendizaje automático clásico. El objetivo es dominar los problemas supervisados, no supervisados y de recomendación cuando un LLM no es necesario. Se estudian regresión, árboles, boosting, clustering, reducción de dimensión, selección de variables, validación cruzada, métricas, interpretabilidad local y calibración. La clave didáctica es enseñar al alumno a no sobredimensionar una solución. Hay muchos problemas empresariales —scoring, fraude, churn, forecasting, mantenimiento predictivo tabular— que se resuelven mejor con modelos más simples, baratos, auditables y estables. El caso práctico base es una cartera de casos de uso donde el alumno decide si el baseline correcto es logística, gradient boosting o un transformador, y justifica por qué. ²⁵

Tema de deep learning en profundidad. Aquí se entra en CNN, modelos secuenciales, atención, representaciones latentes, regularización, normalización, transferencia, fine-tuning y evaluación robusta. La enseñanza no debe quedarse en “usar librerías”, sino explicar por qué ciertas arquitecturas capturan vecindad espacial, dependencia temporal o relaciones de largo alcance. El software base es PyTorch, complementado con librerías de entrenamiento y seguimiento experimental. El caso de uso ejemplar es la inspección visual industrial: desde un baseline de clasificación de defectos hasta un pipeline más maduro con datos etiquetados, aumento, control de drift y revisión humana. ²⁶

Tema de PLN, LLMs y prompting avanzado. El alumno estudia la transición de representaciones lingüísticas clásicas a modelos fundacionales, y aprende a operar con prompting como disciplina de ingeniería, no como truco. El temario incluye system prompting, ejemplos en contexto, CoT, least-to-most, prompting estructurado, salidas tipadas y uso de herramientas. El caso de uso principal es un asistente para conocimiento corporativo y otro para generación estructurada de propuestas o informes, con énfasis en evaluación y reducción de alucinaciones. Se insiste en que prompting no sustituye a datos, a evaluación ni a arquitectura; solo funciona bien cuando el problema, el contexto, la salida y el control de calidad están bien definidos. 27

Tema de visión, voz y multimodalidad. El alumno aprende cuándo conviene un sistema solo textual y cuándo hace falta combinar documentos, imagen, audio, vídeo o código. Se estudian pipelines de OCR, clasificación y extracción multimodal, modelos de visión-lenguaje y casos donde la IA debe operar sobre expedientes complejos, formularios, conversaciones y evidencias visuales. La documentación actual de modelos de frontier y de Gemini muestra que la multimodalidad ya no es un complemento, sino un supuesto de diseño en muchas plataformas empresariales. Los ejercicios incluyen intake documental, revisión de imágenes de parte, asistencia a operaciones y análisis de conversaciones de soporte. 28

Tema de recuperación, RAG y memoria documental. Este es uno de los bloques más críticos para empresa. El alumno aprende por qué un LLM base no debe ser la única fuente de conocimiento para procesos que dependen de documentación privada, normativa cambiante o información operativa. Se estudian chunking, embeddings, índices vectoriales, retrievers, rerankers, grounding, citas, freshness y evaluación de sistemas RAG. El caso práctico central es un asistente regulatorio o de políticas internas que devuelve respuestas trazables con fragmentos citados, y cuya calidad se evalúa contra oro humano. Se trabajan herramientas como FAISS y bases vectoriales empresariales, pero el aprendizaje importante es arquitectónico: decidir qué buscar, cuándo recuperar, cómo filtrar y cómo demostrar que la respuesta era defendible. 29

Fuentes base de la unidad. Currículos de UCL, Oxford, King's y Florida; paper original de RAG y documentación de recuperación/vectorización; y documentación de modelos multimodales actuales. 30

Ingeniería, agentes y despliegue

Módulo de ingeniería de modelos, LLMops y decisión tecnológica

Objetivo del módulo. Si el bloque anterior enseña a modelar, este enseña a industrializar. El alumno debe salir sabiendo construir el ciclo de vida completo del sistema: datos, entrenamiento, adaptación, evaluación, despliegue, observabilidad, coste, seguridad operativa y renovación del modelo o del proveedor. Los currículos benchmark muestran indicios claros de esta orientación aplicada, y la documentación de MLOps y despliegue en cloud confirma que ya no basta con entrenar modelos: hay que operar sistemas completos. 31

Tema de ingeniería de datos y gobierno del dataset. El alumno aprende a definir esquemas, calidad, versionado, trazabilidad, lineage, etiquetado, evaluación del sesgo del dataset y criterios de actualización. Se insiste en que el problema de muchos proyectos de IA no está en el modelo, sino en datos ambiguos, mal versionados o que no representan el contexto real de uso. El caso de uso es un pipeline de clasificación documental o predicción de incidencias donde se demuestra cómo cambian resultados y riesgos cuando cambia el dataset. El software que se trabaja incluye almacenamiento reproducible, experiment tracking y prácticas de data contracts. 32

Tema de adaptación de modelos y fine-tuning eficiente. La unidad cubre full fine-tuning solo para entenderlo y centra el aprendizaje en PEFT, LoRA y QLoRA, además de distillation y especialización por tarea. El alumno debe poder responder a cuatro preguntas: cuándo basta el prompting; cuándo hace falta RAG; cuándo conviene ajustar parámetros; y cuándo el coste, el riesgo regulatorio o la disponibilidad de datos desaconsejan el ajuste. Los casos prácticos incluyen clasificación de tickets, extracción estructurada de contratos y asistentes internos especializados, con comparativas entre prompting, RAG y fine-tuning ligero. ³³

Tema de evaluación y observabilidad. Se estudian métricas offline y online, evaluación humana, regression testing, pruebas por dominios, golden datasets y benchmarks especializados como SWE-bench y AgentBench. El objetivo es que el alumno abandone la idea de “funciona porque me gusta la demo” y adopte la lógica de evals reproducibles. En entorno empresarial esto significa definir conjuntos de prueba por riesgo, por tipo de usuario, por severidad y por proceso. El caso práctico es una evaluación comparada de varios modelos y configuraciones sobre un mismo problema, con análisis de precisión, coste, latencia, alucinación, trazabilidad y robustez tras cambios de prompt o recuperador.

Tema de MLOps y LLMOps. Aquí se trabaja CI, CD y CT para ML; model registry; empaquetado; deployment; monitorización; rollback; gestión de entornos; y coordinación entre data science, ingeniería y negocio. En la documentación de Google, Azure y AWS, MLOps aparece como el puente entre desarrollo, despliegue y operaciones del ciclo completo del modelo. El alumno implementa una cadena de entrenamiento y despliegue con tests automáticos, registro de artefactos y monitorización posterior, y aprende a extenderla a sistemas LLM con guardrails, recuperación, caches y observabilidad adicional. ³⁴

Tema de infraestructura y economía del despliegue. Este tema enseña a comparar API gestionada, modelo privado en nube, VPC, inferencia dedicada, despliegue híbrido y despliegue on-premise. Se explica que la decisión depende de sensibilidad del dato, latencia, escala, burstiness, necesidad de personalización, soberanía y coste total de propiedad. El caso de Lenovo, aunque es un escenario concreto y no una ley universal, ilustra bien que bajo utilización alta y sostenida el on-prem puede resultar mucho más barato a varios años; a cambio exige CAPEX, capacidad operativa y gestión del ciclo de hardware. El alumno aprende a leer estos escenarios con prudencia: cuándo pagar elasticidad cloud, cuándo reservar capacidad y cuándo justificar una plataforma propia. ³⁵

Tema de decisión entre soluciones de IA. En lugar de enseñar “la mejor IA” como una lista cerrada y efímera, el máster enseña un marco de decisión. Para razonamiento complejo, coding y workflows de varios pasos, las documentaciones actuales de Anthropic ³⁶, OpenAI y Google sitúan en cabeza sus familias frontier de reasoning; OpenAI recomienda gpt-5.4 para razonamiento complejo y distingue variantes mini y nano para latencia/coste, Anthropic presenta Claude Opus 4.7 como su modelo general disponible más capaz, y Google describe Gemini 3.1 Pro como su modelo de razonamiento más avanzado con contexto de 1M tokens. Para despliegues con máxima soberanía y API compatible en infraestructura propia, la documentación de Mistral AI ³⁷ muestra opciones de self-deployment mediante vLLM, TensorRT-LLM y TGI. El alumno aprende a elegir por caso de uso: razonamiento profundo, coste/latencia, contexto largo, multimodalidad, tool use, privacidad, self-hosting y madurez del stack. ³⁸

Fuentes base de la unidad. Documentación de MLOps en Google, Azure y AWS; despliegue y self-hosting en Mistral; documentación de frontier models y razonamiento en OpenAI, Anthropic y Google; y escenarios de coste de infraestructura. ³⁹

Módulo de arquitecturas de IA agéntica, automatización y skills

Objetivo del módulo. Este bloque enseña a pasar del “modelo que responde” al “sistema que actúa”. No se trata de romantizar la autonomía, sino de diseñarla con límites. El alumno aprende anatomía del agente, coordinación, memoria, herramientas, validación, autorización y control económico. La relevancia del tema está respaldada por la literatura reciente sobre orquestación multiagente y por la emergencia de frameworks y protocolos específicos para producción. 40

Tema de anatomía del agente. Un agente empresarial se enseña como combinación de percepción, estado, planificación, memoria, herramientas, política de decisión y observabilidad. El estudiante diferencia memoria de contexto corto frente a memoria persistente; diferencia tool calling de workflow fijo; y aprende que un agente sin scaffolding seguro se comporta más como una demo frágil que como una pieza fiable de proceso. El caso práctico es un asistente de operaciones que consulta documentación, crea tickets y solicita aprobación humana si detecta baja confianza o riesgo alto. 40

Tema de patrones de orquestación. El máster trabaja patrones como planner-executor, supervisor-worker, reviewer-critic, researcher-writer, router especializado y swarm contenido. El aprendizaje clave es saber cuándo un problema exige un flujo determinista y cuándo se beneficia de autonomía local. La documentación de CrewAI es muy clara en este punto: para producción conviene partir de un flow que gestione estado y lógica general, y usar crews cuando una subtask realmente necesita un equipo de agentes autónomos. Esa idea se convierte en una regla didáctica del programa: primero control, luego autonomía. 41

Tema de frameworks, protocolos y skills. El alumno compara frameworks de orquestación y entiende para qué sirve cada capa: framework de workflow, framework multiagente, protocolo de herramientas, protocolo entre agentes y catálogo de skills reutilizables. Un skill se define en el programa como una capacidad reusable y gobernable empaquetada —por ejemplo, “validar NIF”, “consultar inventario”, “clasificar reclamación”, “comparar cláusulas”— que puede ser llamada por un agente o por un workflow determinista. El punto no es dominar todas las librerías del mercado, sino entender el patrón: estado, interfaz, permisos, telemetría, límites y trazabilidad. 40

Tema de automatización empresarial con IA. Aquí se enseña a integrar IA con BPM, RPA, ERP, CRM, ticketing, correo, repositorios documentales y APIs internas. El alumno diseña automatizaciones donde la IA no sustituye al proceso, sino que lo acelera con clasificación, extracción, priorización, resumen, decisión asistida o ejecución condicionada. Los casos prácticos incluyen mesas de ayuda, compras, legal ops, compliance documental y codificación de tareas de ingeniería. El criterio central siempre es el mismo: autonomía proporcional al riesgo y evidencia proporcional al impacto. 40

Tema de gobierno específico de agentes. Los agentes requieren gobierno adicional porque amplían superficie de ataque, permisos y gasto. Por eso el alumno diseña límites de presupuesto, scopes de herramienta, allowlists, registros de auditoría, checkpoints humanos y mecanismos de anulación. Este tema enlaza después con seguridad, pero se introduce ya aquí para que el alumno entienda que agencia no es un atributo técnico aislado, sino un riesgo de diseño. 40

Fuentes base de la unidad. Paper de orquestación multiagente y documentación oficial de CrewAI; las demás fuentes de frameworks y protocolos se incluyen en la bibliografía final como ampliación comparativa. 40

Seguridad, gobernanza y transformación

Módulo de seguridad, gobierno del dato y marco regulatorio

Objetivo del módulo. Este módulo enseña a pensar en la IA como sistema expuesto a amenazas, obligaciones de cumplimiento y fallos socio-técnicos. No basta con “poner un guardrail”; el alumno debe aprender a modelar la amenaza, priorizar el riesgo y diseñar controles organizativos y técnicos. La necesidad es evidente en OWASP para LLMs, en NIST para riesgos de IA y aprendizaje adversarial, en la arquitectura emergente de los agentes y en el despliegue gradual del marco europeo. ⁴²

Tema de amenazas específicas de LLM y agentes. Se estudian prompt injection directa e indirecta, jailbreaks, exfiltración de datos, tool misuse, permisos excesivos, outputs inseguros y abuso de contexto. OWASP considera la prompt injection y el poisoning entre riesgos nucleares, y Microsoft documenta técnicas específicas de detección de jailbreak para servicios de IA. El alumno trabaja con una batería de ataques sobre un asistente RAG y sobre un agente con herramientas, y aprende a distinguir mitigación superficial de mitigación arquitectónica. Un ejemplo real útil para docencia es el incidente documentado en la AI Incident Database, que permite discutir cómo un vector aparentemente menor puede derivar en consecuencias operativas relevantes. ⁴³

Tema de aprendizaje adversarial y poisoning. La seguridad no se limita al prompt. Se enseña data poisoning, model poisoning, evasión, extracción, manipulación de datasets, supply chain, manipulación de recuperadores y corrupción de memoria persistente. NIST ha publicado una taxonomía y terminología específicas para aprendizaje automático adversarial, y el curso la usa para dar vocabulario preciso al alumno. El caso práctico consiste en demostrar cómo cambia un sistema al contaminar datos de entrenamiento, ejemplos de recuperación o políticas de herramienta. ⁴⁴

Tema de controles técnicos de seguridad. El alumno diseña segmentación, zero trust para IA, sandboxing, secretos, control de acceso por rol, revisión humana, DLP, filtrado de entrada y salida, allowlists de herramientas, verificación semántica y observabilidad de abuso. Se revisan servicios comerciales como Guardrails en Bedrock, capacidades de safety en Vertex y detección de jailbreak en Azure, pero el aprendizaje importante es independiente del proveedor: ningún servicio elimina por sí mismo la obligación de diseñar arquitectura segura. Se incluye además la advertencia de Cloud Security Alliance sobre la posibilidad de que integraciones MCP mal gobernadas abran vectores de ejecución remota. ⁴⁵

Tema de privacidad, dato y despliegue seguro. El alumno aprende a comparar la postura de privacidad y uso de datos de los proveedores comerciales, a decidir entre retención, no-retención y residencia, y a traducirlo en políticas internas. La documentación pública de proveedores deja claro que hay diferencias materiales entre plataformas en residencia, retención, uso para entrenamiento, aislamiento y opciones enterprise. El caso docente consiste en comparar un despliegue API gestionado, una opción VPC/tenant enterprise y un self-hosting, y justificar la decisión según sensibilidad del dato y riesgo regulatorio. ⁴⁶

Tema de AI Act, NIST e ISO. El alumno estudia el marco europeo y aprende a leer calendario, obligaciones y órganos de gobierno. A fecha de hoy, las prohibiciones y la obligación de alfabetización en IA ya aplican, las reglas para GPAI aplican desde agosto de 2025, el grueso restante del AI Act aplica desde el 2 de agosto de 2026 y ciertas obligaciones ligadas al artículo 6(1) arrancan en agosto de 2027; además, el código de práctica GPAI publicado en 2025 ofrece un instrumento voluntario para transparencia, copyright y safety/security. En paralelo, el máster enseña el RMF de National Institute of Standards and Technology ⁴⁷ —GOVERN, MAP, MEASURE, MANAGE— y el AIMS de International Organization for Standardization ⁴⁸, que ISO define como un sistema para establecer, implementar, mantener y mejorar de forma continua la gestión responsable de IA. El alumno no memoriza siglas: aprende a convertirlas en políticas, inventario, evaluación, formación, supervisión humana, documentación, respuesta a incidentes y revisión ejecutiva. ⁴⁹

Tema de instituciones y gobierno operativo. El marco europeo no se enseña como texto muerto. El alumno revisa el papel de la European Commission ⁵⁰, la AI Office, las autoridades nacionales, el AI Pact, la alfabetización y los sandboxes regulatorios. Con eso aprende a construir un mapa práctico de cumplimiento: qué debe saber el equipo, qué debe documentarse, qué proveedores deben aportar evidencia y qué indicadores debe revisar el comité de IA. ⁵¹

Fuentes base de la unidad. OWASP, documentación de seguridad de plataformas, NIST AI RMF y taxonomía AML, e instrumentos oficiales del AI Act y del GPAI Code of Practice. ⁵²

Módulo de estrategia de negocio, adopción y gestión del cambio

Objetivo del módulo. La ambición aquí es clara: formar a un líder de iniciativas de IA, no solo a un implementador técnico. El módulo integra estrategia, operating model, priorización de casos de uso, rediseño de procesos, talento, formación, patrocinio ejecutivo y resistencia al cambio. Las fuentes de AWS, Azure, Moveworks y la literatura aplicada sobre adopción muestran que la creación de valor depende tanto de la arquitectura organizativa como de la técnica. ⁵³

Tema de estrategia y cartera de casos de uso. El alumno aprende a construir un mapa de oportunidades cruzando valor esperado, riesgo, disponibilidad de dato, criticidad operativa y madurez del proceso. Se trabaja con el marco Path-to-Value de AWS y con estrategias de adopción cloud para IA. El objetivo no es producir una lista de ideas, sino una cartera priorizada con hipótesis de ROI, requisitos de validación, restricciones regulatorias y decisión build-buy-partner. El caso práctico central es una empresa media que debe decidir por dónde empezar entre copilotos, RAG regulatorio, automatización documental, forecasting y agentes internos. ⁵⁴

Tema de operating model y gobierno empresarial. El alumno diseña centros de excelencia, equipos de producto, comités de IA, ownership de datos, ownership de modelos y relación entre negocio, seguridad, legal y tecnología. Aprende cuándo centralizar, cuándo federar y cómo evitar que la organización se llene de pilotos inconexos. Este tema aterriza la parte técnica en procesos de decisión: catálogo de proveedores, evaluación periódica, líneas rojas, criterios de aprobación, gobernanza del backlog y financiación de iniciativas. ⁵⁵

Tema de cambio, capacitación y resistencia. El alumno estudia resistencia organizativa, alfabetización, champions, patrocinio ejecutivo, comunicación, rediseño de roles y microlearning. La alfabetización ya forma parte del marco europeo y, al mismo tiempo, la literatura aplicada sobre adopción muestra que ignorar la preparación humana bloquea o ralentiza proyectos técnicamente viables. El caso práctico es una implantación de asistente interno y automatización documental donde se debe diseñar el plan de formación, la estrategia de comunicación, los indicadores de adopción, el circuito de feedback y la gestión de miedos sobre sustitución. ⁵⁶

Tema de compras, proveedores y arquitectura de decisión. El alumno aprende a negociar condiciones de datos, SLA, residencia, soporte, trazabilidad, límites de uso, supervisión, auditoría y salida. También aprende a decidir cuándo mantener proveedor multipolar, cuándo evitar lock-in y cuándo justificar un stack propio. El resultado esperado es que pueda defender ante dirección por qué un caso requiere API frontier, otro requiere despliegue propio y otro no requiere IA generativa en absoluto. ⁵⁷

Tema de capstone integrador. El trabajo final no debe ser un paper abstracto. Debe ser una iniciativa de IA de empresa con dossier completo: planteamiento de problema, modelo de datos, baseline sin IA, elección tecnológica, arquitectura, plan de seguridad, cumplimiento, coste, experimentación, evals,

MLOps/LLMOps, métricas de negocio, plan de cambio y roadmap de escalado. La defensa debe realizarse ante un tribunal mixto técnico-ejecutivo. Ese formato es coherente con la orientación práctica de los programas revisados y con las necesidades reales de adopción. 58

Fuentes base de la unidad. AWS Path-to-Value, Azure Cloud Adoption Framework for AI, literatura aplicada sobre cambio y resistencia, y el marco europeo de alfabetización y preparación organizativa.

59

Glosario operativo

Modelado y razonamiento. Token: unidad mínima en la que el modelo segmenta el texto; no equivale siempre a palabra ni a carácter. **Embedding:** representación vectorial densa de un texto, imagen u objeto usada para comparación semántica. **Context window:** cantidad de información que el modelo puede considerar en una interacción. **Reasoning token:** token interno de deliberación usado por ciertos modelos de razonamiento antes de emitir la respuesta visible; en OpenAI ocupa contexto y computa en coste. **Attention:** mecanismo que pondera qué partes de la secuencia importan más para calcular la siguiente representación. **Transformer:** arquitectura basada en atención que domina el procesamiento de lenguaje y gran parte de los modelos fundacionales actuales. **Prompt:** instrucción de entrada diseñada para controlar tarea, formato y comportamiento. **In-context learning:** capacidad del modelo para adaptarse a ejemplos o instrucciones dadas en el propio contexto. **Chain of Thought:** andamiaje de prompting que induce pasos intermedios de razonamiento. **Tree of Thoughts:** extensión del razonamiento paso a paso a ramas alternativas y selección de caminos. **RAG:** arquitectura que combina recuperación externa y generación para responder con información actual o privada. **Fine-tuning:** adaptación de un modelo base a una tarea o dominio. **PEFT:** familia de técnicas de ajuste eficiente de parámetros. **LoRA y QLoRA:** variantes prácticas para personalización con menos coste de memoria y cómputo. 60

Ingeniería y despliegue. MLOps: prácticas para automatizar y gobernar el ciclo de vida de modelos de ML. **LLMOps:** extensión de MLOps a sistemas con LLM, prompting, recuperación, guardrails y observabilidad conversacional. **CI/CD/CT:** integración continua, despliegue continuo y entrenamiento continuo. **Model registry:** repositorio gobernado de versiones de modelos y metadatos. **Lineage:** trazabilidad de datos, código, parámetros y artefactos. **Drift:** cambio entre los datos o el comportamiento observado y el contexto con el que se entrenó o validó el sistema. **Latency:** tiempo de respuesta. **Throughput:** capacidad de procesamiento por unidad de tiempo. **Quantization:** reducción de precisión numérica para abaratar inferencia. **vLLM y TGI:** motores de serving usados para desplegar LLMs con alto rendimiento. **Self-hosting:** despliegue del modelo en infraestructura propia o controlada por la empresa. **Zero data retention:** configuración o política de un servicio para minimizar o eliminar retención del contenido procesado. 61

Agentes y automatización. Agente: sistema que percibe contexto, razona, consulta memoria, usa herramientas y ejecuta acciones hacia un objetivo. **Tool calling:** capacidad de invocar funciones, APIs o herramientas externas desde el modelo. **Workflow:** secuencia definida de pasos con estado y reglas; puede o no incluir agentes. **Orquestación:** coordinación de varios componentes, tareas o agentes dentro de un sistema. **Memory:** persistencia selectiva de contexto útil más allá de un turno. **State:** información operacional de la ejecución en curso. **Skill:** capacidad reusable, gobernable y auditable que encapsula una acción concreta para un agente o workflow. **Supervisor pattern:** patrón donde un agente coordinador delega subtareas. **Planner-executor:** patrón donde un componente planifica y otro ejecuta. **Human in the loop:** punto de control humano antes, durante o después de una acción relevante. **MCP:** protocolo de conexión entre modelos y herramientas/contextos. **A2A:** protocolo de comunicación entre agentes. 40

Riesgo, seguridad y gobernanza. Prompt injection: manipulación de entradas o contextos para alterar el comportamiento del modelo. **Jailbreak:** intento de eludir restricciones de seguridad o política del sistema. **Data poisoning:** contaminación de datos para inducir sesgos, errores o puertas traseras. **Model poisoning:** alteración del proceso o artefacto del modelo para degradar seguridad o fiabilidad. **Exfiltración:** salida no autorizada de información sensible. **Least privilege:** principio de conceder solo los permisos mínimos necesarios. **Sandboxing:** aislamiento de ejecución para reducir impacto de fallos o abuso. **Guardrail:** control técnico que filtra, restringe o valida entradas, salidas o acciones. **TEVV:** testing, evaluation, verification and validation. **AI RMF:** marco de NIST para gobernar, mapear, medir y gestionar riesgos de IA. **AIMS / SGIA:** sistema de gestión de IA según ISO 42001. **GPAI:** general-purpose AI, categoría relevante en el AI Act para modelos de propósito general. **High-risk AI system:** sistema sujeto a obligaciones reforzadas por su impacto potencial. **Regulatory sandbox:** entorno supervisado para pruebas regulatorias. **AI literacy:** capacidad organizativa para comprender, usar y supervisar IA de forma responsable. ⁶²

Fuentes directas

La siguiente lista prioriza currículos oficiales, documentación primaria, marcos regulatorios, estándares, papers y guías técnicas directamente accesibles desde la propia URL. Las primeras referencias sirven para benchmark de programas; las siguientes para fundamentos técnicos, despliegue, agentes, seguridad, gobierno y cambio organizativo. ⁶³

1. <https://gradright.com/masters-ms-in-artificial-intelligence/>
2. <https://aidegreeprograms.org/rankings/best-ai-masters-programs/>
3. <https://www.timeshighereducation.com/world-university-rankings/2025/subject-ranking/computer-science>
4. <https://timesofindia.indiatimes.com/education/news/top-5-us-colleges-in-data-science-and-artificial-intelligence-according-to-qs-subject-wise-rankings-2025/articleshow/119262980.cms>
5. <https://msaii.cs.cmu.edu/curriculum>
6. <https://www.ed.ac.uk/studying/postgraduate/degrees/index.php?r=site/view&edition=2024&id=107>
7. <https://fora.aa.ufl.edu/docs/38/2022-2023/Binder.Create%20MS%20Artif%20Intelligence%20Systems.pdf>
8. <https://www.aionlinecourse.com/blog/best-masters-in-artificial-intelligence-ai-programs-in-the-usa-top-universities-for-ai-in-2025>
9. <https://courseoptions.com/blog/masters-computer-science-uk-top-programs>
10. <https://msais.eng.ufl.edu/curriculum/>
11. <https://cs.stanford.edu/degrees/mscs/programsheets/21-22/MSCS-2022-AI.pdf>
12. <https://www.cs.ox.ac.uk/files/15054/MSc%20Handbook%2025-26.pdf>
13. <https://www.ucl.ac.uk/prospective-students/graduate/taught-degrees/data-science-and-machine-learning-msc>
14. <https://www.kcl.ac.uk/study/postgraduate-taught/courses/artificial-intelligence-msc/teaching>
15. <https://ethz.ch/en/studies/master/degree-programmes/engineering-sciences/data-science.html>
16. <https://www.sydney.edu.au/courses/subject-areas/spec/data-science-and-ai.html>
17. <https://handbook.monash.edu/2026/courses/C6007>
18. <https://www.ijcai.org/proceedings/2025/1195.pdf>
19. <https://arxiv.org/html/2502.11269v1>

20. <https://arxiv.org/abs/2401.01040>
21. <https://arxiv.org/pdf/1907.08194v1>
22. <https://arxiv.org/abs/1706.03762>
23. <https://arxiv.org/abs/1810.04805>
24. <https://arxiv.org/abs/2106.09685>
25. <https://arxiv.org/abs/2305.14314>
26. <https://arxiv.org/abs/2005.11401>
27. <https://github.com/facebookresearch/faiss>
28. <https://docs.pinecone.io/guides/get-started/overview>
29. <https://milvus.io/docs>
30. <https://huggingface.co/docs/tokenizers>
31. <https://developers.openai.com/api/docs/guides/reasoning>
32. <https://developers.openai.com/api/docs/guides/reasoning-best-practices>
33. <https://docs.cloud.google.com/vertex-ai/generative-ai/docs/thinking>
34. <https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/3-1-pro>
35. <https://arxiv.org/html/2601.13671v1>
36. <https://arxiv.org/abs/2505.13516>
37. <https://arxiv.org/abs/2505.19591>
38. <https://www.pwc.com/us/en/about-us/newsroom/press-releases/pwc-launches-ai-agent-operating-system-enterprises.html>
39. <https://appstekcorp.com/blog/design-patterns-for-agentic-ai-and-multi-agent-systems/>
40. <https://venturebeat.com/infrastructure/agentic-design-patterns-the-missing-link-between-ai-demos-and-enterprise>
41. <https://www.datacamp.com/tutorial/crewai-vs-langgraph-vs-autogen>
42. <https://www.datacamp.com/blog/ai-agent-frameworks>
43. <https://modelcontextprotocol.io/docs/getting-started/intro>
44. <https://a2a-protocol.org/latest/>
45. <https://github.com/modelcontextprotocol/servers>
46. <https://docs.crewai.com/en/introduction>
47. <https://swebench.com/>
48. <https://github.com/THUDM/AgentBench>
49. <https://paperswithcode.com/dataset/agentbench>
50. <https://developers.openai.com/api/docs/models>
51. <https://platform.openai.com/docs/models/compare>
52. <https://openai.com/api/pricing/>
53. <https://openai.com/business-data/>
54. <https://openai.com/enterprise-privacy/>
55. <https://developers.openai.com/api/docs/guides/your-data>
56. <https://platform.claude.com/docs/en/about-claude/models/overview>
57. <https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models>
58. <https://docs.mistral.ai/deployment/self-deployment>
59. https://github.com/meta-llama/llama-models/blob/main/models/llama3_1/MODEL_CARD.md
60. <https://docs.together.ai/docs/deployment-options>
61. <https://lenovopress.lenovo.com/lp2225-on-premise-vs-cloud-generative-ai-total-cost-of-ownership-2025-edition>
62. <https://www.deloitte.com/us/en/insights/topics/technology-management/tech-trends/2026/ai-infrastructure-compute-strategy.html>
63. <https://aws.amazon.com/ec2/pricing/on-demand/>

64. <https://azure.microsoft.com/en-us/pricing/calculator/>
65. <https://cloud.google.com/compute/vm-instance-pricing>
66. <https://docs.cloud.google.com/architecture/mlops-continuous-delivery-and-automation-pipelines-in-machine-learning>
67. <https://learn.microsoft.com/en-us/azure/machine-learning/concept-model-management-and-deployment?view=azureml-api-2>
68. <https://aws.amazon.com/what-is/mlops/>
69. <https://docs.cloud.google.com/vertex-ai/docs/start/introduction-mlops>
70. <https://aws.amazon.com/sagemaker/ai/mlops/>
71. <https://troj.ai/blog/the-2025-owasp-top-10-for-llms>
72. <https://genai.owasp.org/llmrisk/llm01-prompt-injection/>
73. <https://genai.owasp.org/llmrisk/llm042025-data-and-model-poisoning/>
74. <https://learn.microsoft.com/en-us/azure/ai-services/content-safety/concepts/jailbreak-detection>
75. <https://cloudsecurityalliance.org/blog/2025/11/25/mcp-can-be-rce-for-you-and-me>
76. <https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.100-2e2025.pdf>
77. <https://incidentdatabase.ai/cite/473/>
78. <https://aws.amazon.com/bedrock/guardrails/>
79. <https://cloud.google.com/security/securing-ai>
80. <https://docs.cloud.google.com/vertex-ai/generative-ai/docs/learn/safety-overview>
81. <https://learn.microsoft.com/en-us/azure/ai-foundry/responsible-ai/openai/data-privacy>
82. <https://artificialintelligenceact.eu/implementation-timeline/>
83. <https://digital-strategy.ec.europa.eu/en/policies/regulatory-framework-ai>
84. <https://digital-strategy.ec.europa.eu/en/policies/ai-office>
85. <https://digital-strategy.ec.europa.eu/en/policies/ai-act-governance-and-enforcement>
86. <https://digital-strategy.ec.europa.eu/en/policies/contents-code-gpai>
87. <https://digital-strategy.ec.europa.eu/en/faqs/general-purpose-ai-models-ai-act-questions-answers>
88. <https://digital-strategy.ec.europa.eu/en/policies/ai-pact>
89. <https://digital-strategy.ec.europa.eu/en/faqs/ai-literacy-questions-answers>
90. <https://www.iso.org/standard/42001>
91. <https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.100-1.pdf>
92. <https://airc.nist.gov/airmf-resources/playbook/>
93. <https://www.nist.gov/publications/artificial-intelligence-risk-management-framework-generative-artificial-intelligence>
94. <https://aws.amazon.com/blogs/machine-learning/navigating-the-generative-ai-journey-the-path-to-value-framework-from-aws/>
95. <https://learn.microsoft.com/en-us/azure/cloud-adoption-framework/ai/strategy>
96. <https://www.moveworks.com/us/en/resources/blog/enterprise-change-management-best-practices>
97. https://wjarr.com/sites/default/files/fulltext_pdf/WJARR-2023-1556.pdf
98. <https://www.regent.edu/wp-content/uploads/2025/01/Regent-Research-Roundtables-2025-Artificial-Intelligence-Frank.pdf>
99. <https://www.jmsr-online.com/article/ai-adoption-in-hr-resistance->

readiness-and-the-role-of-change-management-401/
100. <https://aws.amazon.com/bedrock/data-protection/>

1 2 7 40 <https://arxiv.org/abs/2601.13671>

<https://arxiv.org/abs/2601.13671>

3 8 20 42 43 48 52 62 <https://genai.owasp.org/llmrisk/llm01-prompt-injection/>

<https://genai.owasp.org/llmrisk/llm01-prompt-injection/>

4 38 57 <https://developers.openai.com/api/docs/models>

<https://developers.openai.com/api/docs/models>

5 14 21 26 33 37 <https://msais.eng.ufl.edu/curriculum/>

<https://msais.eng.ufl.edu/curriculum/>

6 44 <https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.100-2e2025.pdf>

<https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.100-2e2025.pdf>

9 63 <https://gradright.com/masters-ms-in-artificial-intelligence/>

<https://gradright.com/masters-ms-in-artificial-intelligence/>

10 16 17 23 <https://cs.stanford.edu/degrees/mscs/programsheets/21-22/MSCS-2022-AI.pdf>

<https://cs.stanford.edu/degrees/mscs/programsheets/21-22/MSCS-2022-AI.pdf>

11 13 15 31 47 50 58 <https://msaii.cs.cmu.edu/curriculum>

<https://msaii.cs.cmu.edu/curriculum>

12 24 25 30 <https://www.ucl.ac.uk/prospective-students/graduate/taught-degrees/data-science-and-machine-learning-msc>

<https://www.ucl.ac.uk/prospective-students/graduate/taught-degrees/data-science-and-machine-learning-msc>

18 <https://arxiv.org/abs/2401.01040>

<https://arxiv.org/abs/2401.01040>

19 <https://arxiv.org/pdf/1706.03762>

<https://arxiv.org/pdf/1706.03762>

22 27 36 60 <https://developers.openai.com/api/docs/guides/reasoning>

<https://developers.openai.com/api/docs/guides/reasoning>

28 <https://docs.anthropic.com/en/docs/about-claude/models>

<https://docs.anthropic.com/en/docs/about-claude/models>

29 <https://arxiv.org/abs/2005.11401>

<https://arxiv.org/abs/2005.11401>

32 <https://learn.microsoft.com/en-us/azure/machine-learning/concept-model-management-and-deployment?view=azureml-api-2>

<https://learn.microsoft.com/en-us/azure/machine-learning/concept-model-management-and-deployment?view=azureml-api-2>

34 39 61 <https://docs.cloud.google.com/architecture/mlops-continuous-delivery-and-automation-pipelines-in-machine-learning>

<https://docs.cloud.google.com/architecture/mlops-continuous-delivery-and-automation-pipelines-in-machine-learning>

35 <https://lenovopress.lenovo.com/lp2225.pdf>

<https://lenovopress.lenovo.com/lp2225.pdf>

41 <https://docs.crewai.com/en/introduction>

<https://docs.crewai.com/en/introduction>

45 <https://aws.amazon.com/bedrock/guardrails/>

<https://aws.amazon.com/bedrock/guardrails/>

46 <https://openai.com/business-data/>

<https://openai.com/business-data/>

49 <https://artificialintelligenceact.eu/implementation-timeline/>

<https://artificialintelligenceact.eu/implementation-timeline/>

51 <https://digital-strategy.ec.europa.eu/en/policies/ai-office>

<https://digital-strategy.ec.europa.eu/en/policies/ai-office>

53 54 59 <https://aws.amazon.com/blogs/machine-learning/navigating-the-generative-ai-journey-the-path-to-value-framework-from-aws/>

<https://aws.amazon.com/blogs/machine-learning/navigating-the-generative-ai-journey-the-path-to-value-framework-from-aws/>

55 <https://learn.microsoft.com/en-us/azure/cloud-adoption-framework/ai/>

<https://learn.microsoft.com/en-us/azure/cloud-adoption-framework/ai/>

56 <https://digital-strategy.ec.europa.eu/en/faqs/ai-literacy-questions-answers>

<https://digital-strategy.ec.europa.eu/en/faqs/ai-literacy-questions-answers>