

Tipos de IA: simbólica, estadística, generativa, agéntica

Módulo 0 · Introducción Estratégica a la IA

Los cuatro paradigmas de la IA moderna, cuándo usar cada uno y cómo combinarlos en arquitecturas híbridas empresariales.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Tipos de IA: simbólica, estadística, generativa, agéntica

Cuando en una empresa alguien dice "necesitamos IA", en realidad está diciendo cuatro cosas distintas al mismo tiempo sin saberlo. Podría necesitar un motor de reglas que aplique política de negocio de forma auditable (IA simbólica). Podría necesitar un modelo que prediga el riesgo de impago de un cliente (IA estadística). Podría necesitar un asistente que redacte informes o responda preguntas en lenguaje natural (IA generativa). O podría necesitar un sistema que ejecute tareas de múltiples pasos de forma autónoma (IA agéntica). Confundir estos cuatro paradigmas es la causa raíz de la mayoría de los proyectos mal diseñados.

Este tema construye el mapa mental que permite elegir correctamente: qué paradigma resuelve qué tipo de problema, cuáles son sus ventajas y limitaciones, y cómo se combinan en arquitecturas híbridas que son la norma en sistemas empresariales maduros.

Los cuatro paradigmas de la IA

1. IA Simbólica: razonar con reglas explícitas

La IA simbólica representa el conocimiento como símbolos, reglas y relaciones lógicas explícitas. Un sistema experto médico que diagnostica enfermedades aplicando árboles de decisión clínica, un motor de reglas bancario que evalúa solicitudes de crédito según políticas definidas por expertos, o una ontología que representa las relaciones entre conceptos de un dominio son ejemplos de IA simbólica. Su fortaleza principal es la auditabilidad total: cada decisión se puede rastrear hasta la regla exacta que la produjo, lo que es un requisito legal en muchos sectores regulados.

Su limitación es la escala y la adaptabilidad: escribir y mantener miles de reglas manualmente es caro y frágil. No aprende de los datos por sí mismo. Cuando el entorno cambia, las reglas deben actualizarse manualmente. Para problemas bien definidos con políticas estables (cálculo de impuestos, validación de formularios, aplicación de contratos), la IA simbólica sigue siendo la herramienta correcta. La clave es no descartarla por "anticuada" cuando es la solución más robusta para el problema.

2. IA Estadística / Machine Learning: aprender de datos

El machine learning aprende patrones directamente de los datos sin que un programador codifique las reglas explícitamente. Un modelo de gradient boosting que predice el riesgo de abandono de clientes aprende qué combinaciones de variables (historial de compras, frecuencia de contacto, quejas previas) se asocian con el abandono, directamente de los datos históricos, sin que nadie le explique esas relaciones. Su fortaleza es la escala, la adaptabilidad y la capacidad de capturar relaciones complejas que serían imposibles de codificar manualmente.

El machine learning clásico (regresión, árboles de decisión, SVM, gradient boosting, clustering) domina los problemas con datos estructurados: tablas de transacciones, métricas de clientes, sensores industriales, datos financieros. Para estos problemas, a menudo supera a los LLMs en

precisión, coste e interpretabilidad.

3. IA Generativa: crear contenido nuevo

Los modelos generativos aprenden la distribución estadística de los datos y pueden generar nuevas muestras de esa distribución. Los LLMs aprenden la distribución del lenguaje humano y generan texto nuevo. Los modelos de difusión aprenden la distribución de las imágenes y generan imágenes nuevas. Esta capacidad de generación es lo que hace a estos modelos útiles para: redacción de contenido, resumen de documentos, traducción, generación de código, síntesis de informes y respuesta a preguntas en lenguaje natural.

La limitación estructural clave es que los modelos generativos producen lo que es estadísticamente probable, no lo que es verificablemente verdad. Esto produce alucinaciones: texto fluido y convincente que es factualmente incorrecto. Las arquitecturas RAG (que se estudiarán en el Módulo 7) son la respuesta técnica más efectiva para reducir este riesgo en entornos empresariales.

4. IA Agéntica: actuar de forma autónoma

Los sistemas agénticos combinan un modelo de razonamiento (normalmente un LLM) con herramientas externas y una arquitectura de planificación que les permite ejecutar tareas de múltiples pasos de forma autónoma. Un agente de IA no solo responde preguntas: puede buscar información en bases de datos, redactar documentos, enviar notificaciones, ejecutar código y tomar decisiones en función de los resultados intermedios. La frontera entre sistemas agénticos y automatización robótica de procesos (RPA) está en la capacidad de adaptación: los agentes manejan variabilidad y casos no previstos; el RPA sigue flujos predefinidos.

SECCIÓN 3 · CÓMO FUNCIONA: NIVEL TÉCNICO CLARO

Arquitecturas híbridas: combinando paradigmas

En la práctica, los sistemas empresariales más efectivos combinan varios paradigmas. La arquitectura neuro-simbólica es el ejemplo más claro: un componente de ML o LLM procesa datos no estructurados (texto, imagen) y extrae entidades y patrones; una capa simbólica aplica reglas de negocio auditables sobre esas entidades. Esto combina la capacidad de comprensión del ML con la trazabilidad del sistema experto.

Un ejemplo concreto: un sistema de tramitación de siniestros. La red neuronal (componente generativo/estadístico) procesa el formulario escaneado, extrae el tipo de siniestro, las partes involucradas y los importes. Una capa simbólica aplica las reglas de la póliza: umbrales de aprobación automática, requisitos documentales, escalado obligatorio a revisor humano. El LLM puede generar la comunicación al cliente en lenguaje natural. Si hay seguimiento de múltiples pasos (solicitar documentación adicional, verificar con peritos, actualizar el sistema), se añade un componente agéntico.

Esta arquitectura es más robusta que un LLM puro porque las reglas de negocio están explícitamente codificadas y auditables. Si la regulación cambia, se actualiza la capa simbólica sin reentrenar el modelo. Si el modelo comete un error de extracción, la capa simbólica actúa como red de seguridad adicional.

Ejemplos por paradigma en empresa

- Simbólico en producción: los motores de reglas de Drools o IBM ODM que aplican políticas de precios, elegibilidad de seguros o validación fiscal en tiempo real. Proceden de la IA clásica y siguen siendo el corazón de muchos sistemas bancarios y aseguradores críticos.
- ML estadístico en producción: los modelos de scoring de riesgo de crédito (FICO, modelos de morosidad), los sistemas de detección de fraude en tarjetas (Visa, Mastercard procesan millones de transacciones por segundo con modelos de anomalía), y los sistemas de recomendación de Netflix o Spotify.
- Generativo en producción: GitHub Copilot (generación de código), Harvey AI (asistente legal), Nabla (notas clínicas para médicos), el asistente de Duolingo que adapta el nivel del contenido en tiempo real.
- Agéntico en producción: Devin de Cognition (agente de ingeniería de software autónomo), los agentes de soporte de Sierra que resuelven tickets de clientes con consultas a múltiples sistemas, los workflows de automatización de compliance en firmas de servicios financieros.

Errores frecuentes al elegir el paradigma

Error 1: Usar LLM para datos estructurados. Si el problema es predecir el churn de clientes con una tabla de 50 variables, gradient boosting es más preciso, más barato y más interpretable que cualquier LLM. Los LLMs no son optimizadores de datos tabulares.

Error 2: Usar ML estadístico para texto libre. Si el problema implica comprender o generar texto en lenguaje natural, los LLMs son cualitativamente superiores a los clasificadores de texto clásicos para la mayoría de los casos de uso actuales.

Error 3: Descartar la IA simbólica como "anticuada". En sectores regulados con requisitos estrictos de explicabilidad (banca, seguros, salud), las reglas auditables son un requisito, no una opción. Los sistemas neuro-simbólicos que combinan ML con reglas explícitas son la arquitectura correcta.

Error 4: Saltar directamente a agentes sin necesidad. La IA agéntica amplía la superficie de riesgo, el coste y la complejidad. Para muchos problemas que se presentan como "necesitamos un agente", basta con un flujo determinista con un LLM en un paso específico.

Marco de decisión: qué paradigma para cada problema

Ante cualquier problema empresarial, el proceso de selección del paradigma correcto sigue estas preguntas en orden. Primero: ¿el problema tiene reglas conocidas, estables y auditables? Si sí → IA simbólica o motor de reglas. Segundo: ¿el problema implica predicción sobre datos estructurados históricos? Si sí → ML estadístico (gradient boosting, regresión, clasificación). Tercero: ¿el problema requiere comprensión o generación de lenguaje natural, código o imágenes? Si sí → IA generativa (LLMs, modelos de difusión). Cuarto: ¿el problema requiere

ejecutar múltiples pasos con herramientas externas de forma adaptativa? Si sí → IA agéntica.

En la práctica, muchos problemas empresariales requieren varios paradigmas combinados. El ejercicio práctico es tomar un proceso real de tu organización y descomponerlo: ¿qué parte es predicción estructurada? ¿Qué parte requiere comprensión de texto? ¿Qué parte necesita aplicar reglas de negocio? ¿Qué parte podría automatizarse de forma agéntica con control humano en los puntos críticos?

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

Conexiones con el resto del máster

- Módulo 1: profundiza en cada paradigma desde la perspectiva histórica y filosófica. Los transformers, la atención y la tokenización son la arquitectura técnica detrás de la IA generativa.
- Módulos 3 y 4: desarrollan la IA estadística (ML clásico) y la IA generativa (deep learning) con toda su profundidad técnica.
- Módulo 10: los sistemas agénticos son el desarrollo más completo del paradigma agéntico: arquitectura, memoria, herramientas, frameworks y patrones de orquestación.
- Módulo 12: la elección del paradigma determina la superficie de riesgo. Los agentes tienen más vectores de ataque que un clasificador. Los LLMs tienen vulnerabilidades de prompt injection que no existen en los sistemas simbólicos.

SECCIÓN 8 · RESUMEN EJECUTIVO

Resumen ejecutivo

Existen cuatro paradigmas de IA con características distintas: simbólico (reglas auditables, baja adaptabilidad), estadístico (aprendizaje de datos estructurados, alta precisión en predicción), generativo (comprensión y generación de lenguaje y contenido, con riesgo de alucinación) y agéntico (ejecución autónoma de múltiples pasos, máxima potencia y máxima complejidad de gobierno). El paradigma correcto depende del tipo de problema, no de la moda tecnológica. Las arquitecturas híbridas neuro-simbólicas, que combinan ML con reglas explícitas, son la solución más robusta para sectores regulados. El principio guía es: usa el paradigma más simple que resuelva el problema con los requisitos de calidad, coste y explicabilidad requeridos.