

Historia y paradigmas de la IA

Módulo 1 · Fundamentos Ontológicos y Razonamiento de Máquinas

Los 70 años de la IA: del simbolismo a los LLMs, ciclos de invierno y las lecciones aplicables a proyectos de empresa hoy.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Historia y paradigmas de la IA

La inteligencia artificial no nació con ChatGPT. Lleva más de setenta años siendo construida, abandonada, relanzada y reinventada. Comprender esa historia no es un ejercicio académico: es la forma más rápida de entender por qué los sistemas actuales funcionan como funcionan, por qué tienen las limitaciones que tienen, y qué lecciones de los fracasos pasados son directamente aplicables a los proyectos de empresa de hoy.

Cada vez que la IA ha alcanzado un pico de expectativas y luego ha sufrido un "invierno" —una caída en la financiación y el interés— ha sido porque las promesas superaron a las capacidades reales. El ciclo del hype de Gartner describe este patrón con precisión clínica. En 2025 estamos posiblemente en la cima de otro pico de expectativas, el mayor de la historia. Conocer los ciclos anteriores permite razonar con más criterio sobre cuánto de lo actual es sólido y cuánto es espejismo.

Los grandes períodos de la historia de la IA

1943–1956: El nacimiento de las ideas fundacionales

En 1943, McCulloch y Pitts publicaron el primer modelo matemático de una neurona artificial, demostrando que redes de neuronas simples podían, en principio, computar cualquier función lógica. En 1950, Alan Turing publicó "Computing Machinery and Intelligence" y propuso el Test de Turing como criterio de inteligencia. En la conferencia de Dartmouth de 1956, John McCarthy acuñó el término "inteligencia artificial" y se estableció el programa de investigación de la IA simbólica como campo formal.

1956–1974: El primer optimismo y sus límites

Los primeros programas de IA —el Logic Theorist, el General Problem Solver, ELIZA— impresionaron a investigadores y financiadores. El optimismo era extremo: Minsky predijo en 1967 que el problema de la IA estaría resuelto en una generación. Sin embargo, los sistemas de IA de la época solo funcionaban en problemas de juguete. Al escalar a problemas reales, la explosión combinatoria hacía imposible la búsqueda en espacios de estados grandes. El primer invierno llegó en los años 70 cuando los financiadores cortaron los fondos.

1974–1980: Los sistemas expertos y el segundo optimismo

Los sistemas expertos —programas que codificaban el conocimiento de expertos humanos en forma de reglas si-entonces— revivieron la IA. MYCIN diagnosticaba infecciones bacterianas con precisión comparable a médicos expertos. R1/XCON configuraba pedidos de hardware de DEC ahorrando millones al año. El segundo invierno llegó a finales de los 80 cuando quedó claro que mantener estas bases de conocimiento era prohibitivamente caro y frágil.

1986–2012: El aprendizaje automático y el backpropagation

La redescubierta del algoritmo de backpropagation en 1986 (Rumelhart, Hinton, Williams) hizo entrenable por primera vez redes neuronales multicapa. Pero el verdadero cambio llegó con el

ML estadístico en los 90s y 2000s: Support Vector Machines, gradient boosting, métodos probabilísticos. La IA dejó de intentar programar el conocimiento y empezó a aprender de los datos. Este período produjo los sistemas que hoy son el núcleo invisible de los motores de búsqueda, los sistemas antifraude y las recomendaciones de Netflix.

2012–2017: La revolución del deep learning

En 2012, AlexNet de Krizhevsky ganó el concurso ImageNet con un margen brutal sobre los métodos clásicos, usando redes convolucionales profundas entrenadas en GPUs. Ese resultado demostró que el deep learning, dado suficiente datos y cómputo, podía superar a cualquier sistema diseñado manualmente en reconocimiento de imagen. Los años siguientes vieron el mismo patrón aplicarse a voz, texto, y finalmente juegos (AlphaGo, 2016).

2017–2025: La era del Transformer

En 2017 Google publicó "Attention Is All You Need", introduciendo la arquitectura Transformer. En 2018, BERT demostró que el preentrenamiento a gran escala sobre texto y el fine-tuning en tareas específicas producía resultados de vanguardia en casi todos los benchmarks de NLP. En 2020, GPT-3 mostró que escalar el Transformer a 175.000 millones de parámetros producía capacidades emergentes sorprendentes. En 2022, ChatGPT democratizó el acceso y produjo el mayor boom de adopción de la historia de la IA.

SECCIÓN 3 · CÓMO FUNCIONA

Los tres paradigmas fundamentales y sus principios técnicos

Paradigma simbólico: conocimiento como reglas

En el paradigma simbólico, el conocimiento se representa explícitamente como símbolos, hechos y reglas lógicas. Un motor de inferencia aplica esas reglas para derivar nuevas conclusiones. La fortaleza es la interpretabilidad total y la garantía de corrección lógica. La debilidad es la fragilidad ante la incertidumbre, la escala y los casos no previstos.

Paradigma conexionista: conocimiento como pesos

En el paradigma conexionista, el conocimiento no se programa explícitamente sino que emerge del ajuste de millones de parámetros numéricos (pesos de conexiones entre neuronas artificiales) mediante optimización sobre datos de entrenamiento. La fortaleza es la capacidad de aprender representaciones complejas directamente de los datos. La debilidad histórica fue la opacidad y la necesidad de grandes volúmenes de datos y cómputo.

Paradigma estadístico/probabilístico: conocimiento como distribuciones

El paradigma estadístico modela el conocimiento como distribuciones de probabilidad sobre variables. Los modelos de lenguaje son esencialmente distribuciones de probabilidad sobre secuencias de tokens: $P(\text{token_siguiente} \mid \text{tokens_anteriores})$. Esto permite razonamiento bajo incertidumbre y aprendizaje sin supervisión explícita, pero produce sistemas que generan lo probable en lugar de lo verdadero.

La historia en casos concretos

- MYCIN (1972): sistema experto para diagnóstico de infecciones bacterianas. 600 reglas si-entonces, precisión del 69% vs 65% de médicos en estudios comparativos. Nunca se desplegó clínicamente por problemas de responsabilidad legal.
- Deep Blue (1997): derrota a Kasparov en ajedrez usando búsqueda alfa-beta con evaluación heurística. No aprende, no razona: evalúa 200 millones de posiciones por segundo. Es IA simbólica con búsqueda masiva.
- AlexNet (2012): error en ImageNet del 15.3% vs 26.2% del segundo clasificador. Entrenado en GPUs con 60 millones de parámetros. Inició el boom del deep learning.
- ChatGPT (2022): 100 millones de usuarios en 2 meses, el crecimiento más rápido de cualquier producto de software de la historia. Construido sobre GPT-3.5 con RLHF para hacer el modelo más útil y menos peligroso.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: "La IA actual es fundamentalmente distinta de todo lo anterior." No lo es. Los LLMs son la aplicación a escala masiva de ideas que tienen entre 30 y 70 años. La arquitectura Transformer generaliza mecanismos de atención que existían en los años 90. El backpropagation es de 1986. Lo nuevo es la escala y la accesibilidad.

Error 2: "Los inviernos de la IA no pueden repetirse." Pueden. Las expectativas actuales sobre IA agéntica y AGI son extraordinariamente altas. Si los proyectos de IA agéntica en empresa no producen el ROI esperado, un nuevo ciclo de decepción es posible. Gestionar expectativas con datos reales es la mejor protección.

Error 3: "El paradigma simbólico está muerto." No lo está. Los sistemas de reglas, los motores de ontologías y los grafos de conocimiento siguen siendo la arquitectura correcta para muchos problemas empresariales, especialmente cuando la explicabilidad es un requisito regulatorio.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Lecciones históricas aplicables hoy

La primera lección es que la IA no es lineal: tiene ciclos de optimismo y decepción. Para gestionar proyectos de IA, hay que ser conservador en las promesas y generoso en los criterios de éxito parcial. Los proyectos que prometen "resolver el problema" suelen fracasar; los que prometen "mejorar métricas específicas en un proceso concreto" suelen tener éxito.

La segunda lección es que la escala no resuelve todos los problemas. Cada paradigma tiene limitaciones estructurales que la escala no elimina: los sistemas simbólicos no escalan bien a la variabilidad del mundo real; los sistemas conexionistas no garantizan corrección lógica; los sistemas estadísticos producen lo probable, no lo verdadero. Las mejores arquitecturas híbridas reconocen y aprovechan esta complementariedad.

La tercera lección es que los datos son más importantes que los modelos. En casi todos los períodos de la historia de la IA, las mejoras más grandes vinieron de mejores datos o más

datos, no de mejores algoritmos. Esto sigue siendo verdad en 2025: la calidad del dataset de entrenamiento o el corpus de RAG determina la calidad del sistema más que la elección del modelo.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M1-T2 (IA Simbólica): profundiza en el paradigma simbólico que domina desde los 50s hasta los 80s.
- M1-T3 (IA Conexionista): es el desarrollo del paradigma que triunfa con AlexNet en 2012 y con los Transformers desde 2017.
- M3 (ML Clásico): el período 1990-2012 en que el ML estadístico domina antes del deep learning.
- M4 (Deep Learning): el período 2012-hoy en que el conexionismo a gran escala se convierte en el paradigma dominante.

SECCIÓN 8 · RESUMEN EJECUTIVO

La IA tiene 70 años de historia con tres grandes paradigmas: simbólico (conocimiento como reglas explícitas), conexionista (conocimiento como pesos aprendidos de datos) y estadístico/probabilístico (conocimiento como distribuciones). Los ciclos de optimismo-decepción (inviernos de la IA) son un patrón recurrente cuando las expectativas superan las capacidades. Los LLMs actuales son la aplicación a escala masiva del paradigma conexionista con optimización estadística, no una ruptura conceptual con el pasado. Las lecciones históricas más útiles: los datos importan más que los modelos, las arquitecturas híbridas son más robustas que los paradigmas puros, y las promesas sobredimensionadas producen backlash.