

Introducción al razonamiento en modelos modernos

Módulo 1 · Fundamentos Ontológicos y Razonamiento de Máquinas

Chain of Thought, reasoning tokens, modelos o1/o3 y la economía del razonamiento extendido en sistemas empresariales.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Introducción al razonamiento en modelos modernos

En septiembre de 2024, OpenAI publicó el modelo o1, presentado como el primer modelo de "razonamiento" diseñado explícitamente para pensar antes de responder. A diferencia de GPT-4o, que genera la respuesta directamente, o1 produce una cadena interna de razonamiento antes de emitir la respuesta visible. Los benchmarks fueron impresionantes: o1 supera al 89% de los participantes en concursos de programación competitiva, obtiene resultados de nivel PhD en física y química, y resuelve problemas matemáticos complejos que los modelos anteriores fallaban sistemáticamente.

Pero el razonamiento en IA no empezó con o1. La técnica de Chain of Thought prompting, publicada por Wei et al. en 2022, ya demostró que pedir a los modelos que pensasen paso a paso mejoraba significativamente su rendimiento en razonamiento. Los modelos modernos de razonamiento son, en esencia, la internalización y escalado de esta intuición: entrenar al modelo para que la cadena de pensamiento sea un comportamiento automático en lugar de requerir instrucción explícita.

Razonamiento en IA: definición y tipos

Razonamiento deductivo: de reglas a conclusiones

El razonamiento deductivo parte de premisas generales y deriva conclusiones específicas mediante reglas lógicas. "Todos los contratos de más de 1M€ requieren aprobación del CFO. Este contrato es de 1.5M€. Por lo tanto, este contrato requiere aprobación del CFO." Los LLMs pueden realizar razonamiento deductivo simple bien, pero fallan en cadenas deductivas largas o en silogismos que requieren precisión lógica estricta.

Razonamiento inductivo: de ejemplos a reglas

El razonamiento inductivo generaliza de ejemplos específicos a reglas generales. Es exactamente lo que hace el machine learning: aprender patrones de datos. Los LLMs también realizan razonamiento inductivo implícito a través del in-context learning: dados varios ejemplos en el prompt, infieren el patrón y lo aplican a nuevos casos.

Razonamiento matemático y formal: el campo de prueba

El razonamiento matemático es el campo de prueba favorito para los modelos de razonamiento porque los resultados son verificables. La serie o1/o3 de OpenAI mostró capacidades de resolución de problemas matemáticos a nivel olímpico. Los modelos de razonamiento de Google (Gemini con thinking) y Anthropic (Claude con extended thinking) también muestran mejoras significativas en benchmarks matemáticos. El campo AIMO (AI Mathematical Olympiad) documenta este progreso de forma sistemática.

Razonamiento sobre código: el caso de uso más maduro

El razonamiento sobre código es posiblemente el caso de uso más maduro para los modelos de razonamiento. El código tiene propiedades únicas: es verificable (puede ejecutarse), tiene

estructura lógica explícita, y los errores son detectables automáticamente. SWE-bench documenta el rendimiento de los modelos en resolución de issues reales de GitHub. Los mejores modelos de razonamiento en 2025 resuelven más del 50% de los issues de SWE-bench, una tarea que requiere entender código existente, razonar sobre el bug, y generar el parche correcto.

SECCIÓN 3 · CÓMO FUNCIONA

Los mecanismos técnicos del razonamiento extendido

Chain of Thought: el fundamento

Wei et al. (2022) demostraron que añadir "Vamos a razonar paso a paso" (Let's think step by step) al final de un prompt mejoraba el rendimiento en tareas de razonamiento aritmético y simbólico significativamente en modelos grandes (>100B parámetros). La razón técnica: al forzar al modelo a generar pasos intermedios, cada token de razonamiento actúa como contexto adicional para los tokens siguientes. El modelo "se prepara" para la respuesta final con más información de razonamiento disponible.

Reasoning tokens: el CoT internalizado

Los modelos de razonamiento como o1/o3 de OpenAI generan reasoning tokens internos antes de la respuesta visible. La documentación de OpenAI explica que estos tokens son generados durante el proceso de inferencia como un "espacio de trabajo" interno, ocupan la ventana de contexto y se facturan como output tokens. El modelo se entrena específicamente con RL para usar este espacio de trabajo de forma efectiva en tareas de razonamiento complejo.

Google Cloud Vertex AI documenta un "thinking budget" configurable en sus modelos Gemini con capacidades de razonamiento: se puede especificar cuántos tokens de razonamiento interno están disponibles. Más presupuesto de razonamiento permite explorar más caminos y produce mejores resultados en tareas complejas, a cambio de más latencia y coste.

SECCIÓN 4 · EJEMPLOS REALES

- o3 en benchmarks matemáticos: en el AIME 2024 (American Invitational Mathematics Examination), o3 obtuvo el 96.7% de precisión. El examen está diseñado para los mejores estudiantes de matemáticas de secundaria de EE.UU. El nivel de razonamiento demostrado es comparable al de estudiantes en las olimpiadas matemáticas nacionales.
- Análisis de contratos complejos: un sistema que usa Claude Opus con extended thinking para revisar contratos de fusiones y adquisiciones puede identificar cláusulas de riesgo con múltiples interdependencias que requieren razonamiento multi-paso. Un modelo estándar podría identificar cláusulas individuales, pero no razonar sobre sus interacciones.
- Planificación de proyectos con dependencias complejas: dado un proyecto con 50 tareas, dependencias entre ellas, recursos limitados y plazos contractuales, un modelo de razonamiento puede encontrar un plan factible mientras un modelo estándar produce planes con inconsistencias en las dependencias.
- Diagnóstico de bugs en sistemas complejos: un bug que involucra una condición de carrera entre tres servicios en un sistema distribuido requiere razonar sobre ejecución concurrente,

estado compartido y timing. Un modelo de razonamiento extendido puede seguir el hilo lógico de forma más efectiva que un modelo estándar.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: "El razonamiento extendido resuelve todos los problemas difíciles." No. Las tareas que requieren acceso a información no disponible en el contexto (datos recientes, información privada) no se benefician del razonamiento extendido: el modelo simplemente razona más sobre información incorrecta o ausente. El razonamiento extendido solo ayuda cuando toda la información necesaria está disponible.

Error 2: "Pedir al modelo que razone siempre mejora el resultado." Para tareas simples y bien definidas (clasificación, extracción de datos con formato claro, respuestas a preguntas con información directamente en el contexto), añadir razonamiento explícito puede añadir verbosidad sin mejorar la precisión, y aumenta el coste.

Error 3: "El razonamiento de los LLMs es equivalente al razonamiento humano." El razonamiento de los LLMs es generación estadística de tokens de "pensamiento". No hay metacognición genuina, no hay consciencia del error en tiempo real, no hay la capacidad de decidir estratégicamente cuándo aplicar esfuerzo cognitivo. Las analogías con el Sistema 2 humano son útiles como analogías, no como descripciones precisas.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

La guía práctica para usar razonamiento extendido en sistemas empresariales: usa razonamiento extendido cuando la tarea requiere múltiples pasos de inferencia que dependen unos de otros, cuando hay que evaluar múltiples hipótesis o estrategias antes de comprometerse con una respuesta, cuando el error en el razonamiento tiene consecuencias costosas (análisis jurídico, diagnóstico técnico, planificación estratégica), o cuando el rendimiento del modelo estándar en evaluación es claramente insuficiente para el caso de uso.

No uses razonamiento extendido cuando: la tarea tiene una respuesta directa con información disponible en el contexto, el volumen de llamadas hace el coste prohibitivo, la latencia es crítica (las respuestas de modelos de razonamiento son más lentas), o el benchmark de evaluación no muestra mejora significativa para ese tipo de tarea específica.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M1-T4 (Sistema 1 vs Sistema 2): el razonamiento extendido es la implementación técnica de la analogía del Sistema 2.
- M6 (Ingeniería de Prompts): Chain of Thought, Tree of Thoughts y las técnicas de razonamiento multi-paso son el desarrollo técnico de lo introducido aquí.
- M8 (LLMOps): el test-time compute y la gestión del coste del razonamiento son aspectos operativos centrales de LLMOps.

SECCIÓN 8 · RESUMEN EJECUTIVO

Los modelos de razonamiento modernos (o1/o3/o4 de OpenAI, Claude con extended thinking, Gemini con thinking budget) generan tokens internos de deliberación antes de producir la respuesta visible. Esto mejora significativamente el rendimiento en tareas de

razonamiento matemático, lógico y multi-paso, pero tiene un coste de 5-100x respecto a modelos estándar. La decisión de usar razonamiento extendido debe basarse en evidencia de evaluación para el caso de uso específico, no en la intuición de que "más razonamiento es mejor". El proceso correcto: evaluar con modelo simple, escalar solo si la evaluación muestra déficit, documentar la diferencia coste-calidad.