

Máster en Inteligencia Artificial
para Liderazgo Técnico y Transformación Empresarial

Probabilidad y estadística aplicada

Módulo 2 · Matemáticas y Fundamentos Técnicos de IA

Distribuciones, teorema de Bayes, calibración, A/B testing y evaluación estadística rigurosa de modelos de IA.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Probabilidad y estadística aplicada a IA

Los modelos de IA no producen certezas: producen distribuciones de probabilidad. Un clasificador de riesgo de crédito produce $P(\text{impago} \mid \text{características del cliente})$. Un LLM produce $P(\text{próximo token} \mid \text{contexto})$. Un modelo de detección de fraude produce $P(\text{fraude} \mid \text{características de la transacción})$. Entender la probabilidad y la estadística no es solo entender los números que producen estos modelos: es entender cuánto confiar en ellos, cuándo fallan sistemáticamente y cómo demostrar que funcionan con rigor.

Un estudio a gran escala sobre más de 5.000 agentes de soporte que usaban IA generativa (documentado en la literatura de adopción empresarial 2025) encontró una mejora promedio del 15% en tickets resueltos por hora. Ese "15%" no viene de ningún lado: viene de una comparación estadística cuidadosa entre grupos de tratamiento y control. Sin estadística, no hay forma de distinguir si el 15% es real o es varianza aleatoria. La estadística es la herramienta que convierte observaciones en evidencia.

Los conceptos fundamentales de probabilidad y estadística para IA

Distribuciones de probabilidad: el lenguaje de la incertidumbre

Una distribución de probabilidad asigna probabilidades a los posibles valores de una variable aleatoria. La distribución gaussiana (normal) es la más ubicua en estadística: modela muchos fenómenos naturales y tiene propiedades matemáticas que la hacen tratable analíticamente. La distribución binomial modela el número de éxitos en n ensayos independientes. La distribución de Bernoulli es el caso $n=1$: una variable que puede ser 0 o 1. La distribución softmax, que convierte un vector de logits en una distribución de probabilidad sobre categorías, es la distribución de salida de casi todos los clasificadores y LLMs.

Teorema de Bayes: actualizar creencias con evidencia

El teorema de Bayes es la regla fundamental del razonamiento bajo incertidumbre: $P(H|E) = P(E|H) \times P(H) / P(E)$. $P(H)$ es la probabilidad a priori de la hipótesis H (antes de ver la evidencia). $P(E|H)$ es la verosimilitud: la probabilidad de observar la evidencia E si H es verdadera. $P(E)$ es la evidencia normalizada. $P(H|E)$ es la probabilidad a posteriori: lo que creemos sobre H después de ver E .

En la práctica empresarial, el teorema de Bayes aparece en: filtros de spam ($P(\text{spam} \mid \text{palabras del email})$), sistemas de detección de fraude ($P(\text{fraude} \mid \text{características de la transacción})$), diagnóstico médico asistido ($P(\text{enfermedad} \mid \text{síntomas y pruebas})$), y clasificadores de riesgo que se actualizan con nueva información a medida que llega.

Calibración: cuando las probabilidades significan algo

Un modelo bien calibrado es aquel cuyas probabilidades predichas reflejan las frecuencias reales de los eventos. Si el modelo predice 80% de probabilidad de impago para un conjunto de

clientes, y realmente impagan el 80% de ellos, el modelo está bien calibrado en ese rango. La curva de calibración (reliability diagram) visualiza esta relación: en el eje X, las probabilidades predichas agrupadas en bins; en el eje Y, la fracción real de casos positivos en cada bin. Un modelo perfectamente calibrado tiene puntos sobre la diagonal.

La calibración importa especialmente en decisiones empresariales que usan el umbral de probabilidad para tomar acciones. Si el modelo dice 70% de probabilidad de abandono y tratamos de retener a esos clientes con una campaña costosa, pero realmente solo el 40% de ellos habrían abandonado, estamos desperdiciando recursos. La calibración isotónica o de Platt son técnicas de postprocesamiento que ajustan las probabilidades para mejorar la calibración.

SECCIÓN 3 · CÓMO FUNCIONA

Estadística en evaluación de modelos de IA

Intervalos de confianza y tests de hipótesis

Cuando comparas dos modelos y el modelo A tiene un F1 de 0.87 y el modelo B tiene un F1 de 0.85, ¿es A realmente mejor o es varianza aleatoria del conjunto de test? Un test de hipótesis estadístico (como el test de McNemar para clasificadores) responde esa pregunta. La hipótesis nula H_0 es que ambos modelos tienen el mismo rendimiento; el p-valor mide la probabilidad de obtener la diferencia observada si H_0 es verdadera. Si $p < 0.05$, rechazamos H_0 y concluimos que la diferencia es estadísticamente significativa.

Los intervalos de confianza del 95% dicen: si repitiéramos el experimento muchas veces, el 95% de los intervalos calculados contendrían el valor verdadero del parámetro. Para el F1 de un clasificador estimado sobre un conjunto de test de 1000 ejemplos, el intervalo de confianza es aproximadamente ± 0.03 . Esto significa que una diferencia de F1 de 0.02 entre dos modelos no es estadísticamente significativa.

A/B testing para sistemas de IA en producción

El A/B testing (también llamado test de Champion/Challenger en algunos sectores) es el método estándar para evaluar si un nuevo sistema de IA es mejor que el actual en producción. El tráfico se divide aleatoriamente entre el sistema actual (A) y el nuevo (B). Después de un período suficiente para acumular estadísticas, se comparan las métricas de negocio (resolución de tickets, conversión, satisfacción) con un test estadístico para determinar si la diferencia es significativa.

SECCIÓN 4 · EJEMPLOS REALES

- FICO Score y calibración: el scoring de crédito de FICO está diseñado para ser calibrado por rango de score. Un score de 700-720 debería predecir una tasa de impago específica basada en décadas de datos. La regulación (Fair Credit Reporting Act) obliga a que las probabilidades sean creíbles y explicables.
- Evaluación de LLM con intervalos de confianza: cuando se publican benchmarks comparando modelos (MMLU, HellaSwag, etc.), los resultados con pocos ejemplos de evaluación tienen intervalos de confianza amplios. Un modelo con 79.5% vs 78.3% de precisión puede no ser estadísticamente mejor si el test se hizo con solo 200 ejemplos.

- A/B test de chatbot de soporte: Klarna ejecutó un A/B test entre su chatbot de IA y agentes humanos. Con suficiente volumen (miles de conversaciones), pudieron demostrar con significancia estadística que el chatbot resolvía los mismos tipos de consultas con satisfacción equivalente y en menor tiempo.
- Calibración de modelos de detección de fraude: Visa y Mastercard calibran sus modelos de detección de fraude para que las probabilidades predichas sean creíbles. Sin calibración, los umbrales de decisión (bloquear transacciones por encima de cierta probabilidad) están mal configurados y producen demasiados falsos positivos (clientes legítimos bloqueados) o demasiados falsos negativos (fraudes no detectados).

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: "La precisión del modelo es la métrica que importa." En problemas desbalanceados (fraude: 0.1% de positivos, abandono: 5% de positivos), un modelo que siempre predice "no fraude" tiene 99.9% de precisión. La precisión es una métrica inútil para problemas desbalanceados. Las métricas correctas son precision, recall, F1, ROC-AUC y PR-AUC.

Error 2: "Un p-valor de 0.04 prueba que el resultado es real." El p-valor mide la probabilidad de los datos bajo la hipótesis nula, no la probabilidad de que la hipótesis alternativa sea verdadera. Un p-valor de 0.04 con un test de potencia insuficiente o múltiples comparaciones puede ser un falso positivo. El tamaño del efecto y el intervalo de confianza son más informativos que el p-valor solo.

Error 3: "El modelo funciona porque tiene buen rendimiento en el test set." El test set mide el rendimiento en la distribución de datos con la que fue creado. Si la distribución en producción difiere (distributional shift), el modelo puede fallar silenciosamente. La monitorización continua del rendimiento en producción es necesaria.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

La aplicación práctica más inmediata es implementar la evaluación estadística correcta para tu proyecto de IA. El flujo: primero, define las métricas correctas para el problema antes de entrenar el modelo. Para clasificación binaria desbalanceada: PR-AUC como métrica principal. Para clasificación multiclase: macro F1 para dar igual peso a clases raras. Para regresión: MAE para errores comprensibles, RMSE si los errores grandes son muy costosos.

Segundo, construye un conjunto de test estratificado que represente la distribución real de casos en producción, incluyendo los casos raros (anomalías, idiomas minoritarios, productos de nicho) que suelen ser los que más importan. Tercero, evalúa la calibración con `calibration_curve` de `sklearn` para modelos que produzcan probabilidades. Si la calibración es mala, aplica calibración isotónica o de Platt como postprocesamiento.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M3 (ML Clásico): todos los modelos de clasificación y regresión son modelos probabilísticos. La evaluación estadística rigurosa es parte central de la práctica de ML clásico.

- M8 (Evaluación continua): los tests A/B y la monitorización estadística del rendimiento en producción son el desarrollo operativo de lo aprendido aquí.
- M1-T6 (Lógica probabilística): la estadística bayesiana y la actualización de creencias con evidencia son el fundamento teórico de la IA probabilística.

SECCIÓN 8 · RESUMEN EJECUTIVO

La probabilidad y la estadística son el lenguaje de la evaluación rigurosa de IA. Los modelos producen distribuciones de probabilidad; la calibración mide si esas probabilidades son creíbles. Los tests de hipótesis determinan si las diferencias entre modelos son estadísticamente significativas o solo varianza aleatoria. La precisión (accuracy) es una métrica inadecuada para problemas desbalanceados: usar F1, ROC-AUC o PR-AUC. Los A/B tests son el método estándar para demostrar que un nuevo sistema de IA mejora métricas de negocio en producción. Sin estadística, los resultados de IA son observaciones; con estadística, son evidencia.