

Funciones de coste y optimización (Gradient Descent)

Módulo 2 · Matemáticas y Fundamentos Técnicos de IA

MSE, Cross-Entropy, Focal Loss y el paisaje de pérdida: elegir la función correcta y entender que aprende realmente el modelo.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Funciones de coste y Gradient Descent

Toda la inteligencia de una red neuronal se codifica en sus parámetros. Esos parámetros no se programan manualmente: se aprenden minimizando una función de coste que mide cuánto se equivoca el modelo en los datos de entrenamiento. La función de coste es el puente entre "lo que el modelo predice" y "lo que debería predecir", y el Gradient Descent es el algoritmo que navega ese paisaje matemático buscando el punto mínimo.

La elección de la función de coste no es trivial: determina qué tipo de errores el modelo penaliza más, qué tipo de salida produce y cómo se comporta el entrenamiento. Un sistema de detección de fraude que usa la función de coste equivocada puede aprender a minimizar el número de errores globales pero ignorar los errores más costosos (los fraudes no detectados). Entender las funciones de coste es entender qué está aprendiendo realmente el modelo.

Las funciones de coste más importantes en IA

Mean Squared Error (MSE): el estándar de la regresión

$MSE = (1/n) \times \sum (y_{\text{real}} - y_{\text{prediccion}})^2$, donde y_{real} es el valor real y $y_{\text{prediccion}}$ es la predicción del modelo. Penaliza los errores grandes de forma cuadrática: un error de 2 tiene un coste de 4, un error de 4 tiene un coste de 16. Esto hace a MSE sensible a outliers: un único ejemplo con error muy grande puede dominar el entrenamiento. Para problemas donde los errores grandes son muy costosos (predicción de demanda donde el stockout es catastrófico), MSE es la función correcta. Para problemas donde todos los errores tienen costes similares, MAE (Mean Absolute Error) es más robusta.

Cross-Entropy Loss: el estándar de la clasificación y los LLMs

Para clasificación binaria: $BCE = -(y \cdot \log(p) + (1-y) \cdot \log(1-p))$, donde y es la etiqueta real (0 o 1) y p es la probabilidad predicha. Para clasificación multiclase: $CE = -\sum y_{\text{real}} \cdot \log(p_{\text{prediccion}})$. La cross-entropy penaliza fuertemente las predicciones confidentes incorrectas: predecir 99% de probabilidad para la clase incorrecta produce un coste de $-\log(0.01) \approx 4.6$, mucho mayor que predecir 60% para la clase incorrecta ($-\log(0.4) \approx 0.9$). Esto incentiva al modelo a ser honesto sobre su incertidumbre.

Para los LLMs, la función de coste de preentrenamiento es la cross-entropy sobre la predicción del siguiente token: el modelo aprende a asignar alta probabilidad al token que realmente aparece en el corpus. Minimizar esta pérdida sobre billones de tokens es lo que produce las capacidades lingüísticas de los LLMs.

Otras funciones de coste relevantes en empresa

Focal Loss (Lin et al., 2017): modifica la cross-entropy para reducir el peso de los ejemplos fáciles (los que el modelo ya clasifica bien con alta confianza) y enfocar el aprendizaje en los difíciles. Es especialmente útil para problemas de detección de objetos y clasificación con desbalance extremo de clases.

Hinge Loss: usada en Support Vector Machines (SVM). Penaliza ejemplos que están dentro del margen de separación. Produce clasificadores con máximo margen que tienden a generalizar mejor en algunos problemas de clasificación binaria.

KL Divergence: mide la distancia entre dos distribuciones de probabilidad. Aparece en el entrenamiento de VAEs (Variational Autoencoders) y en RLHF, donde se usa como regularización para que el modelo alineado no se aleje demasiado del modelo base.

SECCIÓN 3 · CÓMO FUNCIONA

El paisaje de pérdida y los mínimos locales

La función de coste define un "paisaje de pérdida" (loss landscape) sobre el espacio de todos los posibles valores de los parámetros del modelo. El objetivo del entrenamiento es encontrar el punto más bajo de ese paisaje. Para modelos simples (regresión lineal), el paisaje es un paraboloide convexo con un único mínimo global que el Gradient Descent encuentra de forma garantizada. Para redes neuronales profundas, el paisaje es altamente no-convexo, con miles de millones de dimensiones y millones de mínimos locales.

La buena noticia (descubierta empíricamente) es que los mínimos locales de las redes profundas tienden a tener valores de pérdida similares al mínimo global para redes suficientemente grandes. El verdadero problema no son los mínimos locales sino las mesetas (saddle points y plateaus) donde el gradiente es casi cero y el entrenamiento se estanca. Las técnicas de momentum (como en Adam) ayudan a escapar de estas mesetas.

SECCIÓN 4 · EJEMPLOS REALES

- Detección de fraude con Focal Loss: un sistema de detección de fraude bancario con 0.1% de tasa de fraude usa Focal Loss con $\gamma=2$. Esto hace que los ejemplos fáciles (transacciones claramente legítimas que el modelo ya clasifica bien) contribuyan poco al gradiente, y que el aprendizaje se enfoque en los casos difíciles donde el modelo todavía se equivoca.
- GPT preentrenamiento con cross-entropy: durante el preentrenamiento de GPT sobre 300.000 millones de tokens, la cross-entropy sobre el siguiente token cae de ~10 bits (predicción al azar sobre un vocabulario de 50K) a ~2-3 bits (perplexidad de ~4-8). Cada bit de reducción en la pérdida corresponde a una mejora sustancial en la capacidad predictiva del modelo.
- MSE vs MAE en forecasting de ventas: una empresa de retail eligió RMSE (raíz de MSE) como función de coste para su modelo de forecasting porque los errores grandes en predicción de demanda (stockout o exceso de inventario) son desproporcionadamente costosos. Al cambiar a MAE encontraron que el modelo producía forecasts más conservadores pero con menos errores catastróficos en SKUs de alta rotación.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: "La función de coste de entrenamiento mide el rendimiento real del modelo." No. La función de coste mide lo que se optimiza en el entrenamiento, que es una proxy del rendimiento real. Un modelo puede tener una pérdida de validación muy baja y aun así

tener un rendimiento inaceptable en métricas de negocio si la función de coste no captura lo que realmente importa.

Error 2: "Minimizar la pérdida de entrenamiento es el objetivo." No. El objetivo es minimizar la pérdida de generalización (en datos no vistos). Un modelo puede tener pérdida de entrenamiento cercana a cero y pérdida de validación alta (overfitting). La pérdida de entrenamiento es solo una herramienta diagnóstica, no el objetivo final.

Error 3: "Puedo usar cualquier función de coste diferenciable." La función de coste debe ser apropiada para el tipo de output del modelo. Usar MSE para clasificación produce un modelo que aprende a predecir valores en $[0,1]$ en lugar de probabilidades calibradas. Usar cross-entropy para regresión no tiene sentido matemático.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

La guía de selección de función de coste para proyectos empresariales: regresión con outliers tolerables → MSE; regresión con todos los errores igualmente costosos → MAE; clasificación binaria → Binary Cross-Entropy; clasificación multiclase → Categorical Cross-Entropy; clasificación con desbalance extremo → Focal Loss o weighted cross-entropy (asignar mayor peso a la clase minoritaria); ranking → Pairwise losses o Listwise losses.

Para el caso de las clases desbalanceadas (el más común en empresa: fraude, anomalías, abandono de clientes, defectos de fabricación), la weighted cross-entropy asigna un peso mayor a los ejemplos de la clase minoritaria: $\text{loss_weighted} = \sum w_i \times \text{CE}_i$, donde w_i es el peso del ejemplo i . En sklearn, el parámetro `class_weight="balanced"` calcula automáticamente estos pesos inversamente proporcionales a la frecuencia de cada clase.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M2-T2 (Cálculo): las funciones de coste son las funciones que el descenso de gradiente minimiza. Sin la función de coste, no hay gradiente que calcular.
- M2-T3 (Estadística): la elección de la función de coste tiene implicaciones estadísticas directas: MSE produce estimadores de la media condicional; MAE produce estimadores de la mediana condicional; BCE produce probabilidades calibradas si el modelo está bien especificado.
- M3 (ML Clásico) y M4 (Deep Learning): cada modelo tiene su función de coste específica: MSE para regresión lineal, BCE para regresión logística, cross-entropy para clasificación multiclase y LLMs.

SECCIÓN 8 · RESUMEN EJECUTIVO

La función de coste es el objetivo que el entrenamiento minimiza y determina qué errores penaliza más el modelo. MSE es el estándar para regresión (sensible a outliers). Cross-Entropy es el estándar para clasificación y LLMs (penaliza fuertemente predicciones confidentes incorrectas). Focal Loss aborda el desbalance extremo de clases reduciendo el peso de los ejemplos fáciles. La selección incorrecta de la función de coste produce modelos que optimizan la métrica equivocada. El paisaje de pérdida de las redes profundas no es convexo, pero los mínimos locales tienden a ser de calidad similar al global para redes suficientemente grandes.