

Espacios vectoriales semánticos

Módulo 2 · Matemáticas y Fundamentos Técnicos de IA

La geometría del significado: k-NN, clustering semántico, aritmética vectorial, espacios multimodales y aplicaciones empresariales.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Espacios vectoriales semánticos

Una vez que entiendes que el significado puede representarse como un punto en un espacio de alta dimensión, se abre un mundo de operaciones poderosas: medir similitud entre conceptos con precisión matemática, encontrar el vecino más cercano en millones de documentos en milisegundos, descubrir la estructura semántica latente de un corpus, visualizar territorios de significado en dos dimensiones, o detectar cuando un nuevo texto es anómalo respecto al corpus conocido.

El concepto de espacio vectorial semántico va más allá de los embeddings de texto: los mismos principios se aplican a imágenes (CLIP de OpenAI mapea texto e imágenes al mismo espacio), audio (Whisper produce representaciones vectoriales del habla), código (GitHub Copilot usa embeddings de código), usuarios y productos (en sistemas de recomendación), y cualquier entidad que pueda ser representada con atributos. Los espacios vectoriales semánticos son la geometría universal de la IA moderna.

La geometría del significado

Estructura del espacio: dimensiones y distancias

Un espacio vectorial semántico de d dimensiones es un espacio euclidiano (o de Hilbert para espacios de dimensión infinita) donde cada punto representa una entidad (palabra, frase, documento, imagen) y la distancia entre puntos refleja la disimilitud semántica. Las dimensiones del espacio no tienen interpretación semántica individual: la semántica emerge de la estructura relacional entre los puntos, no de las dimensiones individuales.

Las métricas de distancia y similitud más importantes son: similitud coseno (mide el ángulo entre vectores, ignorando la magnitud, estándar para embeddings de texto), distancia euclídea (mide la distancia absoluta, más sensible a la magnitud que el coseno), distancia de Manhattan (suma de diferencias absolutas, más robusta a outliers que la euclídea), y distancia de Mahalanobis (normaliza por la varianza de cada dimensión, útil cuando las dimensiones tienen escalas diferentes).

Espacios multimodales: texto e imagen en el mismo espacio

CLIP (Contrastive Language-Image Pre-Training, OpenAI 2021) entrenó dos encoders (uno para texto, uno para imágenes) de forma que representaciones de texto e imagen del mismo concepto queden cerca en el espacio compartido. Esto permite búsqueda semántica de imágenes por descripción textual ("una puesta de sol sobre el mar con colores cálidos") o clasificación zero-shot de imágenes sin ejemplos etiquetados de la clase objetivo.

Los modelos multimodales actuales como GPT-4o, Claude Sonnet y Gemini producen representaciones conjuntas de texto, imagen y en algunos casos audio y vídeo en el mismo espacio semántico latente. Esto es lo que permite a estos modelos razonar sobre documentos que combinan texto e imágenes, comparar el contenido de una imagen con una descripción

textual, o transcribir y analizar audio simultáneamente.

SECCIÓN 3 · CÓMO FUNCIONA

Operaciones en espacios vectoriales semánticos

Vecinos más cercanos: la operación fundamental

La búsqueda de vecinos más cercanos (k-Nearest Neighbors, k-NN) en el espacio de embeddings es la operación que sustenta la búsqueda semántica. Dado un vector de consulta q , encontrar los k vectores más similares en un corpus de n vectores. La búsqueda exacta es $O(n \times d)$ donde d es la dimensionalidad, inviable para millones de documentos con latencias de milisegundos. Los algoritmos de búsqueda aproximada como HNSW (Hierarchical Navigable Small World Graphs) logran latencias de 1-5ms con recall del 95-99% en corpus de millones de documentos.

Clustering semántico: descubrir estructura latente

El clustering en espacios de embeddings descubre grupos de documentos semánticamente similares sin supervisión. K-means es el algoritmo más usado: asigna cada vector al centroide más cercano, actualiza los centroides, y repite hasta convergencia. DBSCAN descubre clusters de forma arbitraria y es más robusto cuando los clusters tienen tamaños muy diferentes. Reducir la dimensionalidad con UMAP o PCA antes del clustering mejora la calidad de los clusters al eliminar las dimensiones de baja varianza.

Analogías y operaciones aritméticas

La aritmética en espacios de embeddings revela relaciones semánticas estructurales. El ejemplo clásico de Word2Vec, $\text{vector}(\text{"rey"}) - \text{vector}(\text{"hombre"}) + \text{vector}(\text{"mujer"}) \approx \text{vector}(\text{"reina"})$, muestra que la relación "monarca masculino $\rightarrow$ monarca femenino" está codificada como un vector de desplazamiento consistente en el espacio. Estas propiedades se usan para: completar analogías en sistemas de evaluación de modelos de lenguaje, transferir estilos ("texto en tono formal" = $\text{texto_actual} + \text{desplazamiento_formalidad}$), y realizar operaciones de edición semántica.

SECCIÓN 4 · EJEMPLOS REALES

- CLIP en búsqueda de imágenes: Pinterest usa CLIP para permitir búsqueda de imágenes por descripción textual. El usuario escribe "vestido rojo de fiesta elegante" y el sistema busca las imágenes cuyo embedding esté más cerca del embedding de esa descripción en el espacio CLIP.
- Detección de anomalías semánticas en documentos: un sistema de compliance que indexa contratos con embeddings puede detectar contratos anómalos calculando la distancia de cada nuevo contrato al centroide del cluster de contratos del mismo tipo. Contratos con distancia anormalmente alta son candidatos a revisión humana.
- Clustering de feedback de clientes: Amazon procesa millones de reviews de productos, genera embeddings y aplica clustering para identificar las dimensiones de satisfacción (calidad del producto, velocidad de entrega, embalaje, atención al cliente) y los problemas más frecuentes en cada una, sin necesidad de etiquetar cada review.

- Búsqueda semántica en código: GitHub Copilot Chat permite buscar funciones en un repositorio por descripción funcional ("función que calcula el descuento de un cliente premium") en lugar de por nombre. El sistema genera embeddings de todas las funciones del repositorio y busca por similitud semántica.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: "La distancia coseno mide lo mismo en todos los modelos." No. La similitud coseno de 0.85 entre dos textos significa cosas muy distintas según el modelo de embedding. Un modelo entrenado en texto general puede producir similitudes altas entre textos temáticamente distintos en un dominio especializado. Siempre calibra los umbrales de similitud con ejemplos del dominio.

Error 2: "Puedo mezclar embeddings de diferentes modelos en el mismo índice." No. Los embeddings de diferentes modelos (incluso de la misma familia con diferentes versiones) no son compatibles: están en espacios distintos. Mezclarlos produce búsquedas sin sentido. El índice vectorial debe ser consistente con el modelo de embedding.

Error 3: "La visualización UMAP 2D muestra la estructura real del espacio." La visualización en 2 dimensiones preserva las relaciones locales pero distorsiona las relaciones globales. Lo que parece "lejos" en la visualización puede ser cercano en el espacio de alta dimensión. Usa la visualización para exploración cualitativa, no para conclusiones cuantitativas.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

El proyecto más impactante para experimentar con espacios vectoriales semánticos en empresa: construir un explorador visual del espacio semántico de tus documentos internos. Pasos: generar embeddings de 500-2000 documentos con text-embedding-3-small, reducir a 2D con UMAP (pip install umap-learn), colorear por categoría o departamento, e implementar una interfaz de búsqueda que muestre los vecinos más cercanos de cualquier punto. Esta herramienta de exploración semántica tiene valor tanto para entender la estructura del conocimiento de la empresa como para identificar gaps y redundancias.

Para sistemas de detección de anomalías semánticas, el flujo es: generar embeddings de todos los documentos históricos (contratos, tickets, emails), calcular el centroide por tipo de documento, definir un umbral de distancia basado en el percentil 95 de las distancias históricas, y marcar automáticamente los nuevos documentos que superen ese umbral para revisión. Este sistema detecta documentos atípicos en minutos en lugar de requerir revisión manual exhaustiva.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M2-T6 (Embeddings): los espacios vectoriales semánticos son el contexto matemático en el que los embeddings operan.
- M2-T1 (Álgebra lineal): las operaciones en espacios vectoriales (similitud coseno, distancias, PCA, k-NN) son álgebra lineal aplicada.
- M7 (RAG): el espacio semántico de embeddings es el mecanismo de recuperación del RAG. Entender su geometría permite optimizar la estrategia de chunking e indexación.

Los espacios vectoriales semánticos son la geometría de la IA moderna: espacios de alta dimensión donde la proximidad entre puntos refleja similitud semántica. Las operaciones fundamentales son: k-NN para búsqueda semántica, clustering para descubrimiento de estructura latente, aritmética vectorial para analogías y operaciones de estilo, y visualización con UMAP/t-SNE para exploración cualitativa. Los espacios multimodales (CLIP, GPT-4o) mapean texto, imagen y audio al mismo espacio semántico. Aplicaciones empresariales de alto valor: exploración visual de corpus, detección de anomalías semánticas, clustering de feedback, y búsqueda de código por descripción funcional.