

Introducción a la teoría de la información

Módulo 2 · Matemáticas y Fundamentos Técnicos de IA

Entropía, cross-entropy, perplexity, divergencia KL e información mutua: los fundamentos matemáticos de los LLMs y su evaluación.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Introducción a la teoría de la información

En 1948, Claude Shannon publicó "A Mathematical Theory of Communication", un paper que fundó la teoría de la información y cambió para siempre la forma en que pensamos sobre transmisión, almacenamiento y procesamiento de información. Shannon definió conceptos fundamentales como la entropía (cuánta información hay en un mensaje), la capacidad de un canal de comunicación, y los límites teóricos de la compresión. Estos conceptos, que parecían abstractos en 1948, son hoy los fundamentos matemáticos de los LLMs.

La función de coste que entrena a todos los LLMs (la cross-entropy loss) es un concepto de teoría de la información. La perplejidad (la métrica estándar para comparar modelos de lenguaje) es teoría de la información. La divergencia KL que aparece en RLHF y en los modelos generativos es teoría de la información. Entender estos conceptos no es un lujo académico: es entender qué miden las métricas de evaluación de los LLMs y qué significa que un modelo sea "bueno".

Los conceptos fundamentales de la teoría de la información

Entropía: medir la incertidumbre

La entropía de Shannon de una distribución de probabilidad P es $H(P) = -\sum_i p_i \log_2(p_i)$, donde la suma es sobre todos los posibles resultados i con probabilidad p_i . $H(P)$ mide la cantidad media de información (en bits, si el logaritmo es base 2) necesaria para describir un resultado de P . Una distribución completamente uniforme (todos los resultados igualmente probables) tiene la máxima entropía: es la distribución más "sorpresiva" o más "incierto". Una distribución determinista (un resultado con probabilidad 1) tiene entropía 0: no hay sorpresa ni incertidumbre.

En el contexto de los LLMs, la entropía de la distribución sobre el vocabulario en cada paso de generación mide cuán incierto está el modelo sobre el siguiente token. Alta entropía = el modelo tiene muchas opciones plausibles = la situación es ambigua. Baja entropía = el modelo está seguro de qué viene a continuación = el texto es predecible. La temperatura en la generación de LLMs modifica directamente la entropía: temperatura baja $\rightarrow$ baja entropía $\rightarrow$ respuestas más deterministas; temperatura alta $\rightarrow$ alta entropía $\rightarrow$ más variedad y creatividad.

Cross-Entropy: medir la discrepancia entre distribuciones

La cross-entropy entre una distribución real P y una distribución predicha Q es $H(P, Q) = -\sum_i p_i \log_2(q_i)$. Mide cuántos bits son necesarios (en media) para codificar resultados de P usando el código óptimo para Q . Si Q es perfectamente igual a P , $H(P, Q) = H(P)$ (la entropía de P). Si Q es diferente de P , $H(P, Q) > H(P)$: necesitamos más bits porque estamos usando el código equivocado.

En el entrenamiento de LLMs, P es la distribución empírica del texto real (el siguiente token es el que aparece en el corpus) y Q es la distribución predicha por el modelo. La cross-entropy loss mide cuánto se aleja la predicción del modelo de la realidad del corpus. Minimizar la cross-entropy es exactamente "hacer que el modelo prediga bien el siguiente token", que es el objetivo del preentrenamiento de los LLMs.

Perplejidad: la métrica de calidad de los modelos de lenguaje

La perplejidad (perplexity) de un modelo de lenguaje es la exponencial de la cross-entropy: $PPL = 2^{H(P,Q)}$ (en bits) o $PPL = e^{H(P,Q)}$ (en nats). Intuitivamente, la perplejidad mide cuántas opciones equivalentes tiene el modelo en cada paso de generación: una perplejidad de 50 significa que el modelo está, en media, "igualmente sorprendido" por el siguiente token como si tuviera que elegir uniformemente entre 50 opciones. Una perplejidad de 4 significa que efectivamente elige entre ~ 4 opciones equivalentes.

La perplejidad de los LLMs modernos en texto en inglés es de $\sim 3-7$ para los mejores modelos. Para comparación, un modelo que elige uniformemente sobre un vocabulario de 50.000 tokens tendría perplejidad 50.000. La reducción de perplejidad a medida que escalan los modelos es una de las evidencias más claras del progreso del preentrenamiento.

SECCIÓN 3 · CÓMO FUNCIONA

Divergencia KL e información mutua: las otras métricas clave

Divergencia KL: medir la diferencia entre distribuciones

La divergencia KL de P respecto a Q es $D_{KL}(P||Q) = \sum p \log(p/q)$. No es simétrica ($D_{KL}(P||Q) \neq D_{KL}(Q||P)$ en general) y siempre es ≥ 0 , con $D_{KL} = 0$ si y solo si $P = Q$. Mide la "información extra" necesaria para codificar muestras de P usando el código óptimo para Q en lugar del código óptimo para P .

La divergencia KL aparece directamente en RLHF (Reinforcement Learning from Human Feedback): el objetivo del entrenamiento de alineación es maximizar la recompensa humana mientras se minimiza la divergencia KL con el modelo base. La penalización KL evita que el modelo alineado se aleje demasiado del modelo base, preservando sus capacidades generales mientras mejora su comportamiento en las dimensiones que importan para la alineación.

Información mutua: cuánto saben dos variables la una de la otra

La información mutua $I(X;Y)$ mide cuánta información comparte la variable X con la variable Y : $I(X;Y) = H(X) + H(Y) - H(X,Y)$. Si X e Y son independientes, $I(X;Y) = 0$: conocer X no dice nada sobre Y . Si X e Y son completamente dependientes (una determina la otra), $I(X;Y) = H(X) = H(Y)$: conocer una es lo mismo que conocer la otra.

La información mutua tiene aplicaciones directas en selección de características: una característica que tiene alta información mutua con la etiqueta objetivo es muy informativa para la predicción. Los tests de independencia basados en información mutua son más potentes que los tests de correlación lineal para relaciones no lineales.

SECCIÓN 4 · EJEMPLOS REALES

- Comparación de modelos con perplejidad: GPT-2 (124M parámetros, 2019) tiene perplejidad ~35 en WikiText-103. GPT-3 (175B parámetros, 2020) tiene perplejidad ~20. Los modelos actuales más capaces tienen perplejidades de ~5-10. Cada reducción sustancial de perplejidad corresponde a un salto cualitativo en capacidades.
- KL en RLHF: el entrenamiento de InstructGPT (el precursor de ChatGPT, descrito en el paper de OpenAI de 2022) usa una penalización KL entre el modelo RL y el modelo SFT base. El coeficiente β de la penalización KL controla cuánto puede desviarse el modelo alineado del base: β alto $\rightarrow$ modelo más conservador, más parecido al base; β bajo $\rightarrow$ modelo más libre de optimizar la recompensa, más riesgo de "reward hacking".
- Entropía para detectar incertidumbre: un sistema de diagnóstico médico asistido puede usar la entropía de la distribución de salida del modelo como señal de incertidumbre. Si la entropía es alta (el modelo tiene muchas opciones plausibles), el caso es ambiguo y debe escalarse a revisión humana. Si la entropía es baja (el modelo está seguro), el diagnóstico puede procesarse con mayor autonomía.
- Information gain en árboles de decisión: el algoritmo ID3 para construir árboles de decisión selecciona en cada nodo la característica que maximiza la ganancia de información (la reducción de entropía de la etiqueta al conocer el valor de la característica). Esto garantiza que cada división del árbol sea lo más informativa posible.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: "Perplejidad baja siempre significa mejor modelo para usar en producción." La perplejidad mide la capacidad predictiva del modelo en texto genérico similar al corpus de evaluación. Un modelo con menor perplejidad puede ser peor en tareas específicas si el corpus de evaluación no representa esas tareas. La perplejidad es necesaria pero no suficiente para evaluar un LLM.

Error 2: "La divergencia KL es una distancia entre distribuciones." No técnicamente: la KL divergence no es simétrica. $D_{KL}(P||Q) \neq D_{KL}(Q||P)$. La distancia de Jensen-Shannon (la media de las dos divergencias KL simétricas) sí es una métrica de distancia, y se usa en GANs y en algunos sistemas de evaluación de distribuciones.

Error 3: "La entropía de la distribución de salida mide la confianza del modelo." La entropía mide la dispersión de la distribución, no si la respuesta es correcta. Un modelo puede tener baja entropía (estar seguro) y estar equivocado (alucinando con confianza). La calibración mide si la confianza del modelo corresponde a la precisión real.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Las aplicaciones prácticas más inmediatas de la teoría de la información en proyectos empresariales de IA son tres. Primera: usar la perplejidad para comparar modelos y seleccionar el más adecuado para un caso de uso específico. Si tienes dos candidatos para un clasificador de texto y los datos de evaluación son suficientes, la perplejidad en el corpus de dominio es una métrica complementaria a la precisión que puede revelar cuál modelo "entiende" mejor el dominio.

Segunda: usar la entropía de la distribución de salida como señal de incertidumbre en sistemas de decisión. En lugar de solo usar la predicción del modelo, calcular la entropía de la distribución sobre las clases y escalar a revisión humana cuando la entropía supera un umbral. Esto es especialmente valioso en sistemas de alto riesgo donde los errores de confianza son costosos.

Tercera: usar la información mutua para selección de características. La librería scikit-learn implementa `mutual_info_classif` y `mutual_info_regression`, que calculan la información mutua entre cada característica y la variable objetivo. Seleccionar las características con mayor información mutua es más robusto que la correlación lineal para problemas con relaciones no lineales.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M2-T4 (Funciones de coste): la cross-entropy loss es un concepto de teoría de la información aplicado a la optimización de modelos.
- M1-T11 (Limitaciones LLMs): la temperatura, la entropía de la distribución de salida y la calibración son conceptos de teoría de la información que explican las limitaciones y el comportamiento de los LLMs.
- M6 (Ingeniería de Prompts): la temperatura, top-p y top-k son parámetros que controlan la distribución de probabilidad sobre el vocabulario en la generación. Entender su efecto requiere entender entropía.

SECCIÓN 8 · RESUMEN EJECUTIVO

La teoría de la información (Shannon, 1948) es el fundamento matemático de las métricas clave de los LLMs. La entropía mide la incertidumbre de una distribución (bits necesarios para codificar resultados). La cross-entropy mide la discrepancia entre la distribución real y la predicha (la función de coste de los LLMs). La perplejidad es la exponencial de la cross-entropy: el número efectivo de opciones en cada paso (modelos buenos: ~5-10; azar sobre 50K tokens: 50.000). La divergencia KL mide la diferencia entre distribuciones y aparece en RLHF como regularización. La información mutua mide la dependencia entre variables: base de la selección de características. Aplicaciones prácticas: evaluación de modelos, detección de incertidumbre, selección de características, ajuste de temperatura.