

Tipos de aprendizaje: supervisado, no supervisado y refuerzo

Módulo 3 · Machine Learning Clásico

Los tres paradigmas del ML, cuándo aplicar cada uno y cómo los LLMs los combinan en sus tres fases de entrenamiento.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Tipos de aprendizaje: supervisado, no supervisado y por refuerzo

El 80% del machine learning en empresa es aprendizaje supervisado. Esta afirmación, respaldada por arquitectos de sistemas de ML con décadas de experiencia en producción, no es un juicio de valor sino una observación empírica. Cuando una empresa quiere predecir el churn de clientes, detectar fraude en transacciones, clasificar tickets de soporte o predecir la demanda de inventario, está planteando un problema de aprendizaje supervisado. Entender en qué categoría cae tu problema es el primer y más importante paso antes de elegir cualquier algoritmo.

Los LLMs modernos, que parecen magia, son en realidad la combinación de los tres tipos de aprendizaje. El preentrenamiento usa self-supervised learning (aprendizaje no supervisado estructurado). El fine-tuning de instrucciones usa aprendizaje supervisado. El RLHF (Reinforcement Learning from Human Feedback) usa aprendizaje por refuerzo. Entender estos tres paradigmas no es solo relevante para ML clásico: es entender los cimientos sobre los que se construyen los sistemas de IA más sofisticados del mundo.

Los tres paradigmas en profundidad

Aprendizaje supervisado: aprender de ejemplos etiquetados

En el aprendizaje supervisado, el modelo aprende de un conjunto de ejemplos donde cada ejemplo tiene una entrada (features o variables predictoras) y una salida correcta conocida (etiqueta o target). El modelo ajusta sus parámetros para que, dado el input, produzca un output lo más cercano posible al target correcto. Hay dos grandes familias de problemas supervisados: clasificación (la salida es una categoría discreta: spam/no spam, fraude/legítimo, tipo de diagnóstico) y regresión (la salida es un valor numérico continuo: precio de una casa, demanda esperada, probabilidad de churn).

La calidad del aprendizaje supervisado depende fundamentalmente de la calidad y cantidad de los datos etiquetados. Etiquetar datos puede ser costoso (requiere expertos del dominio) y lento. Por eso el aprendizaje semi-supervisado combina un pequeño conjunto de datos etiquetados con un gran conjunto de datos no etiquetados: el modelo aprende la estructura de los datos del conjunto grande y la supervisión específica del conjunto pequeño. Esta técnica produce resultados significativamente mejores que el supervisado puro cuando los datos etiquetados son escasos.

Aprendizaje no supervisado: encontrar estructura sin etiquetas

En el aprendizaje no supervisado, el modelo recibe únicamente los inputs sin ninguna etiqueta. El objetivo no es predecir una variable específica sino descubrir la estructura intrínseca de los datos: grupos naturales (clustering), representaciones comprimidas (reducción de dimensionalidad), relaciones entre variables (modelos de densidad), o anomalías (ejemplos que no encajan en ningún patrón conocido).

Las aplicaciones empresariales del aprendizaje no supervisado son más abundantes de lo que parece: segmentación de clientes sin categorías predefinidas, detección de anomalías en transacciones o en logs de sistemas, compresión de representaciones para sistemas de recomendación, y descubrimiento de tópicos en grandes colecciones de documentos. A diferencia del supervisado, no hay una métrica de error directa: la evaluación de los resultados requiere juicio del dominio.

Aprendizaje por refuerzo: aprender de las consecuencias de las acciones

En el aprendizaje por refuerzo (RL), un agente aprende a tomar decisiones en un entorno recibiendo señales de recompensa o penalización por sus acciones. No hay un dataset de ejemplos correctos: el agente explora el espacio de acciones, observa las consecuencias, y ajusta su política (la función que mapea estados a acciones) para maximizar la recompensa acumulada a largo plazo. El problema se formaliza como un Proceso de Decisión de Markov (MDP): estados, acciones, transiciones y función de recompensa.

En empresa, el RL tiene aplicaciones directas en optimización de inventario y cadena de suministro (Amazon usa RL para los robots de sus almacenes), optimización de campañas de marketing (decidir qué anuncio mostrar a cada usuario en cada momento), y gestión de energía en centros de datos (DeepMind redujo el consumo energético de los centros de datos de Google un 40% con RL). El RL también es la base de RLHF, el proceso que hace que los LLMs sean útiles y seguros.

SECCIÓN 3 · CÓMO FUNCIONA

La mecánica técnica de cada paradigma

En aprendizaje supervisado, el ciclo es: dividir los datos en entrenamiento y test, entrenar el modelo sobre el entrenamiento (minimizando la función de pérdida con descenso de gradiente u otros optimizadores), evaluar sobre el test con métricas apropiadas (precisión, recall, AUC-ROC, MAE, RMSE según el tipo de problema), y desplegar en producción con monitorización de drift.

En aprendizaje no supervisado, el ciclo de clustering es: elegir el algoritmo (k-means, DBSCAN, clustering jerárquico), elegir el número de clusters (silhouette score, elbow method), ajustar el modelo a los datos, interpretar los clusters con estadísticas descriptivas y conocimiento del dominio, y validar con expertos que los clusters tienen sentido de negocio. No hay métrica de "error correcto/incorrecto": la validez de los clusters es una cuestión de utilidad para el negocio.

En aprendizaje por refuerzo, el ciclo es: definir el espacio de estados (qué información describe la situación), el espacio de acciones (qué puede hacer el agente), y la función de recompensa (qué comportamiento se quiere incentivar). Entrenar el agente mediante interacción con el entorno (real o simulado), típicamente con algoritmos como Q-learning, PPO (Proximal Policy Optimization) o SAC (Soft Actor-Critic). Evaluar la política aprendida en condiciones de producción. El diseño de la función de recompensa es el paso más crítico y más difícil: una función de recompensa mal diseñada puede producir comportamientos inesperados que técnicamente maximizan la recompensa pero no el objetivo real (reward hacking).

SECCIÓN 4 · EJEMPLOS REALES

- Supervisado en producción: el sistema de scoring de crédito de BBVA usa gradient boosting con 200+ variables para predecir la probabilidad de impago de cada solicitante. Clasificación binaria supervisada con datos históricos de millones de préstamos etiquetados con su resultado (impago/no impago).
- No supervisado en producción: Netflix identifica "taste clusters" (grupos de usuarios con preferencias similares) sin que nadie haya definido esas categorías de antemano. El clustering no supervisado sobre el historial de visualización produce segmentos que guían las decisiones de producción de contenido.
- Refuerzo en producción: los robots de almacén de Amazon aprenden a optimizar rutas de picking mediante RL, reduciendo el tiempo medio de picking un 15-25% respecto a los algoritmos heurísticos estáticos. El entorno es simulado durante el entrenamiento y luego el modelo se despliega en el almacén real.
- RLHF en LLMs: el proceso de entrenamiento de ChatGPT usa RL para hacer que el modelo maximice la preferencia humana. Humanos evalúan pares de respuestas, un reward model aprende a predecir esas preferencias, y el LLM se entrena con PPO para producir respuestas que maximizan el reward model con una penalización KL respecto al modelo base.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Usar aprendizaje no supervisado cuando en realidad tienes etiquetas. Si tienes datos históricos con resultados conocidos (clientes que abandonaron vs los que no), usar clustering no supervisado para segmentar clientes es menos efectivo que un modelo supervisado de churn. El aprendizaje no supervisado es para cuando genuinamente no tienes etiquetas, no para evitar el trabajo de usarlas.

Error 2: Subestimar la dificultad del aprendizaje por refuerzo en aplicaciones reales. El RL requiere definir cuidadosamente la función de recompensa, el espacio de estados y el espacio de acciones. Una función de recompensa mal especificada puede producir comportamientos perversos. Además, el RL necesita miles o millones de iteraciones de exploración, lo que requiere un entorno simulado antes de desplegar en producción.

Error 3: Asumir que el aprendizaje semi-supervisado siempre mejora el supervisado puro. El semi-supervisado mejora cuando los datos no etiquetados son representativos de la distribución real del problema. Si los datos no etiquetados tienen una distribución diferente a los etiquetados, el semi-supervisado puede degradar el rendimiento.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Para identificar el tipo de aprendizaje correcto para un caso de uso, el proceso de decisión es: primero, ¿tienes datos históricos con el resultado que quieres predecir etiquetado? Si sí, considera supervisado. Si no, considera no supervisado para exploración o refuerzo para optimización de decisiones. Segundo, ¿el problema requiere predicción (supervisado) o descubrimiento (no supervisado)? Tercero, ¿el objetivo es optimizar una política de decisión que se aplica de forma secuencial con retroalimentación del entorno (refuerzo)?

Un ejercicio práctico de alto valor: toma los diez procesos con mayor coste o mayor fricción en tu organización y clasifica cada uno en el paradigma correcto. Para cada proceso supervisado, identifica si ya tienes datos etiquetados históricos. Para cada proceso no supervisado, identifica qué estructura quieres descubrir y cómo validarás que los resultados tienen sentido. Este ejercicio produce un mapa de oportunidades de ML bien tipificado que guía la priorización de proyectos.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M3-T2 (Modelos clásicos): los algoritmos de regresión, árboles y SVM son modelos de aprendizaje supervisado.
- M5 (LLMs): los LLMs combinan los tres paradigmas: preentrenamiento self-supervised, fine-tuning supervisado, y RLHF.
- M10 (Agentes): los agentes autónomos aplican principios del aprendizaje por refuerzo (política, recompensa, exploración/explotación) de forma más general.

SECCIÓN 8 · RESUMEN EJECUTIVO

El 80% del ML en empresa es supervisado: aprender de ejemplos etiquetados para predecir clasificaciones o valores. El no supervisado descubre estructura sin etiquetas (clustering, anomalías, reducción de dimensionalidad). El refuerzo aprende políticas de decisión maximizando recompensa acumulada (robótica, optimización de procesos, RLHF en LLMs). Los LLMs combinan los tres. La clave práctica: identifica claramente el tipo de problema antes de elegir el algoritmo. La función de recompensa en RL y la calidad de las etiquetas en supervisado son los dos componentes más determinantes de la calidad del sistema resultante.