

# Feature Engineering

## Módulo 3 · Machine Learning Clásico

---

Transformaciones numericas, encoding de categoricas, features temporales, leakage y la regla del 80/20 para construir los predictores correctos.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales  
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

## Feature Engineering

Andrew Ng, uno de los investigadores de IA más influyentes del mundo, afirmó que "coming up with features is difficult, time-consuming, and requires expert knowledge. Applied machine learning is basically feature engineering". Esta afirmación, que puede sonar anticuada en la era de los LLMs que aprenden representaciones automáticamente, sigue siendo completamente válida para el 80% del ML en empresa: los sistemas sobre datos tabulares donde los datos son columnas de una tabla con variables numéricas y categóricas.

El feature engineering es el proceso de transformar los datos brutos en representaciones que los modelos pueden aprender mejor. Un buen feature captura el mecanismo causal o la señal relevante de forma que el modelo puede reconocerla. La diferencia entre un modelo mediocre y uno excelente sobre los mismos datos frecuentemente no está en el algoritmo sino en la calidad de los features que se le presentan.

## Los tipos de transformaciones de features

### Transformaciones numéricas: ajustar distribuciones y escalas

Muchos modelos (SVM, regresión logística, k-NN) asumen que las variables están en escalas similares. La normalización (escalar a media 0, desviación 1) o la normalización min-max (escalar al rango [0,1]) elimina el sesgo de escala. La transformación logarítmica de variables con distribución sesgada hacia la derecha (ingresos, precios, valores de transacciones) reduce el impacto de los outliers y hace la distribución más parecida a una gaussiana, facilitando el aprendizaje de modelos lineales.

La binarización y la discretización convierten variables continuas en categóricas. Discretizar "edad" en rangos (18-25, 26-35, 36-50, 51+) puede ser útil cuando la relación con el target no es monótona en toda la escala. La creación de features polinomiales ( $x^2$ ,  $x_1 \times x_2$ ) captura interacciones y no-linealidades que los modelos lineales no pueden aprender directamente.

### Encoding de variables categóricas

Las variables categóricas (país, tipo de producto, categoría de cliente) no pueden usarse directamente en la mayoría de los algoritmos de ML. One-hot encoding convierte una variable con N categorías en N variables binarias (una por categoría). Es simple pero puede producir matrices muy dispersas con vocabularios grandes. Label encoding asigna un entero a cada categoría: solo adecuado para variables ordinales (bajo/medio/alto) donde el orden tiene significado.

Target encoding reemplaza cada categoría por la media del target en esa categoría. Es muy efectivo pero propenso a leakage si no se aplica correctamente (hay que calcular la media del target de entrenamiento para cada categoría, no de todo el dataset). CatBoost implementa una versión robusta de target encoding con permutación ordenada que evita el leakage automáticamente.

## Features temporales: extraer señal del tiempo

Las fechas y horas en bruto no son útiles directamente como variables numéricas. Las transformaciones útiles incluyen: componentes de la fecha (año, mes, día, hora, día de la semana, semana del año, día del mes), indicadores de festivos y periodos especiales, diferencias temporales (tiempo desde el último evento, tiempo hasta el próximo evento esperado), y estadísticas de ventana temporal (media, máximo, recuento de eventos en los últimos 7/30/90 días). Estas transformaciones son el corazón del feature engineering para sistemas de detección de fraude, predicción de churn y forecasting de demanda.

## Features de dominio: el conocimiento del experto codificado

Los features más poderosos suelen ser los que codifican conocimiento de dominio específico. En scoring de riesgo crediticio, el "debt-to-income ratio" (ratio deuda sobre ingresos) es un feature calculado que los analistas de crédito llevan décadas usando. En detección de fraude, la "velocidad de transacciones" (número de transacciones en la última hora) es un signal que los analistas de fraude conocen como indicador de comportamiento sospechoso. Traducir ese conocimiento experto en features matemáticos es el núcleo del feature engineering de dominio.

### SECCIÓN 3 · CÓMO FUNCIONA

---

## El proceso sistemático de feature engineering

El proceso comienza con análisis exploratorio de datos (EDA): visualizar la distribución de cada variable, identificar valores nulos y outliers, calcular correlaciones con el target, y buscar relaciones bivariadas. Este análisis guía las transformaciones necesarias.

Feature selection identifica qué variables son realmente útiles: información mutua con el target, coeficientes de correlación de Pearson o Spearman, feature importance de Random Forest, o SHAP values. Eliminar variables irrelevantes o redundantes reduce el ruido, mejora la generalización y reduce el tiempo de entrenamiento.

Automated Feature Engineering (AutoFE) con herramientas como Featuretools genera automáticamente features de orden superior (features calculadas sobre relaciones entre tablas, estadísticas de ventana temporal, features de agregación) que los analistas humanos pueden no haber considerado. Es especialmente útil con datos relacionales (múltiples tablas con claves foráneas).

### SECCIÓN 4 · EJEMPLOS REALES

---

- Feature engineering en detección de fraude bancario: las señales más poderosas no son los datos del cliente sino el comportamiento en contexto. "¿Es este importe atípico respecto a los últimos 30 días de este cliente?" (z-score del importe vs historial), "¿Cuántas transacciones ha habido en los últimos 60 minutos?" (velocidad), "¿El país de esta transacción coincide con el país habitual del cliente?" (geolocalización). Ninguna de estas features existe en bruto en la base de datos; todas son calculadas.
- Target encoding en e-commerce: encoding de la categoría del producto por la tasa de devolución media histórica de esa categoría. Una categoría con 30% de devoluciones tiene un encoding muy distinto a una con 3%. Este feature calculado predice las devoluciones

futuras mucho mejor que el one-hot encoding de la categoría.

- Features temporales en forecasting de demanda en retail: día de la semana (el lunes se vende menos que el viernes), semana del mes (el efecto del cobro de nóminas), festivos y eventos especiales (Black Friday, Navidad), y lag features (la demanda de hace una semana como predictor de la demanda esta semana). Estos features capturan los patrones temporales que son la esencia del forecasting.

## SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

---

Error 1: Feature leakage. Incluir en el modelo información que no estaría disponible en producción en el momento de la predicción. Es el error más costoso porque el modelo parece excelente en evaluación y falla en producción. La pregunta de verificación es: "¿esta información estaría disponible en el momento exacto en que el modelo hace la predicción en producción?"

Error 2: Normalizar antes de dividir train/test. Si normalizas con la media y desviación del dataset completo (incluyendo test), estás filtrando información del test al entrenamiento. La normalización debe calcularse sobre el conjunto de entrenamiento y aplicarse al test con los parámetros del entrenamiento.

Error 3: Crear demasiados features sin selección. Un dataset con 1.000 features donde la mayoría son ruido estadístico puede degradar el rendimiento del modelo por la maldición de la dimensionalidad. Feature selection sistemática (información mutua, SHAP, eliminación iterativa de features de baja importancia) es tan importante como la creación de features.

## SECCIÓN 6 · APLICACIÓN PRÁCTICA

---

El framework práctico de feature engineering en cinco pasos: 1) EDA: analizar distribuciones, correlaciones y valores nulos. 2) Transformaciones básicas: log de variables sesgadas, normalización, encoding de categóricas. 3) Features de dominio: codificar el conocimiento experto en variables calculadas. 4) Features temporales: si hay datos de tiempo, extraer componentes temporales y ventanas deslizantes. 5) Feature selection: eliminar features con baja información mutua con el target o alta correlación con otros features (multicolinealidad).

Herramientas clave: pandas para manipulación de datos, scikit-learn para preprocessing (StandardScaler, OneHotEncoder, LabelEncoder), category\_encoders para encoding avanzado (target encoding, binary encoding), Featuretools para automated feature engineering, y SHAP para evaluar la importancia de los features calculados.

## SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

---

- M3-T2 (Modelos clásicos): el feature engineering prepara los datos para los modelos de gradient boosting y regresión.
- M3-T5 (Evaluación): las métricas de evaluación permiten comparar qué features y transformaciones mejoran el modelo.
- M3-T7 (Interpretabilidad): SHAP values evalúan la importancia de los features diseñados y guían la selección.

Feature engineering es transformar datos brutos en representaciones que los modelos pueden aprender mejor. Las transformaciones clave: normalización y log para datos numéricos, one-hot/target encoding para categóricas, componentes temporales y ventanas deslizantes para fechas. Los features de dominio (ratio deuda-ingresos, velocidad de transacciones) son los más informativos. Feature leakage es el error más costoso: incluir información no disponible en producción. La regla del 80/20: el 80% del valor viene del 20% de los features, identifícalos con SHAP y centra el trabajo en ellos. Normaliza solo sobre train, aplica a test.