

Evaluación de modelos: accuracy, precision, recall, F1

Módulo 3 · Machine Learning Clásico

La matriz de confusion, AUC-ROC, AUC-PR, metricas de regresion y por que accuracy sola es siempre insuficiente en clases desbalanceadas.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Evaluación de modelos: métricas que importan

Un banco desplegó un modelo de detección de fraude con un 99.5% de precisión. Parecía excepcional. Hasta que alguien calculó que el 99.7% de las transacciones no eran fraudulentas. Un modelo que simplemente dijera "no fraude" para todo tendría 99.7% de precisión sin aprender nada. El modelo real con 99.5% era peor que el baseline trivial. Esta historia, que se repite en decenas de proyectos de empresa cada año, ilustra el problema más frecuente en evaluación de modelos: usar la métrica incorrecta.

La elección de las métricas de evaluación correctas es tan importante como la elección del algoritmo. Las métricas deben alinearse con el objetivo real del negocio, tener en cuenta el desbalance de clases cuando existe, y distinguir entre los tipos de errores con sus diferentes costes. Este tema proporciona el toolkit completo para evaluar correctamente cualquier modelo de clasificación o regresión en el contexto empresarial.

La matriz de confusión: el fundamento de todas las métricas

La matriz de confusión para clasificación binaria organiza las predicciones en cuatro cuadrantes: verdaderos positivos (TP: predicho positivo, era positivo), falsos positivos (FP: predicho positivo, era negativo), verdaderos negativos (TN: predicho negativo, era negativo), y falsos negativos (FN: predicho negativo, era positivo). Todas las métricas de clasificación son combinaciones de estos cuatro números.

Accuracy = $(TP+TN)/(TP+TN+FP+FN)$: el porcentaje de predicciones correctas. Es completamente engañosa en clases desbalanceadas. Si el 99% de los ejemplos son de clase negativa, un modelo que predice siempre negativo tiene 99% de accuracy sin haber aprendido nada útil.

Precision = $TP/(TP+FP)$: de todos los que predicho como positivos, ¿qué fracción realmente era positiva? Mide qué tan confiables son las predicciones positivas. Alta precisión = pocos falsos positivos = cuando el modelo dice "positivo", casi siempre tiene razón.

Recall (Sensibilidad, TPR) = $TP/(TP+FN)$: de todos los que realmente son positivos, ¿qué fracción detecté? Mide la cobertura de la clase positiva. Alto recall = pocos falsos negativos = el modelo detecta la mayoría de los positivos reales.

F1 = $2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$: la media armónica de precisión y recall. Es un balance entre las dos, especialmente útil cuando hay desbalance de clases y ambas métricas importan.

Las métricas avanzadas y cuándo usarlas

AUC-ROC: la métrica estándar para clasificación

La curva ROC (Receiver Operating Characteristic) representa el tradeoff entre TPR (recall) y FPR (tasa de falsos positivos = $FP/(FP+TN)$) a todos los umbrales posibles. El área bajo la curva (AUC-ROC) es una métrica de ranking: mide la probabilidad de que el modelo asigne una puntuación mayor a un positivo aleatorio que a un negativo aleatorio. AUC=0.5 es clasificación aleatoria; AUC=1.0 es perfecta. Es la métrica más robusta al desbalance de clases y la más usada en comparación de modelos de clasificación.

AUC-PR: mejor que ROC para clases muy desbalanceadas

La curva Precision-Recall muestra el tradeoff entre precisión y recall a todos los umbrales. El AUC-PR (o Average Precision) es especialmente informativo cuando la clase positiva es muy rara (menos del 1%). En detección de fraude con tasas de 0.01%, AUC-ROC puede ser engañosamente alto incluso para modelos mediocres. AUC-PR es más discriminativo en estos casos extremos.

RMSE y MAE: para regresión

RMSE (Root Mean Square Error) = $\sqrt{(\sum(\hat{y}-y)^2)/n}$: penaliza errores grandes cuadráticamente. Útil cuando los errores grandes son especialmente costosos. MAE (Mean Absolute Error) = $\sum|\hat{y}-y|/n$: penaliza todos los errores de forma lineal. Más robusto a outliers. MAPE (Mean Absolute Percentage Error) = $\sum|\hat{y}-y|/y/n \times 100\%$: el error en porcentaje, intuitivo para negocio pero problemático cuando y puede ser cercano a cero.

Métricas específicas de negocio

Las métricas de ML estándar deben complementarse siempre con métricas de negocio que cuantifiquen el impacto real del modelo. En detección de fraude: importe total de fraude detectado, importe de fraude no detectado (FN), importe de transacciones legítimas bloqueadas (FP). En churn prediction: valor de vida de los clientes retenidos gracias al modelo menos el coste de las acciones de retención. En forecasting: coste del exceso de inventario + coste de stock-out. Estas métricas de negocio son las que justifican el ROI del proyecto de ML.

SECCIÓN 4 · EJEMPLOS REALES

- Fraude bancario (clases muy desbalanceadas): con 0.1% de fraude, accuracy es completamente inútil (99.9% prediciendo siempre no fraude). Las métricas correctas son: $recall@precision=95\%$ (¿qué porcentaje del fraude detectas manteniendo 95% de precisión?), y $coste\ total = FN \times importe_medio_fraude + FP \times coste_revisión_manual$. El umbral se calibra para minimizar esta función de coste de negocio.
- Diagnóstico médico (recall crítico): en un sistema de screening de cáncer, un FN (paciente con cáncer no detectado) tiene consecuencias mucho más graves que un FP (paciente sano con biopsia innecesaria). El modelo debe optimizarse para recall muy alto (detectar el 99%+ de los positivos) aunque eso implique baja precisión (muchos FP) y alto coste en revisiones.
- Predicción de demanda (MAPE vs RMSE): Zara mide el rendimiento de su modelo de forecasting con dos métricas: MAPE para comparación entre productos de distinto volumen de ventas, y valor monetario del exceso de inventario + stock-out para medir el impacto económico real. Solo la segunda conecta directamente con el P&L.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Reportar solo accuracy en clases desbalanceadas. Reportar accuracy del 99% en un problema con 1% de positivos es casi siempre señal de un modelo que no funciona. Cualquier presentación de resultados de clasificación debe incluir la distribución de clases y las métricas apropiadas para ese desbalance.

Error 2: Elegir el umbral de clasificación sin criterio de negocio. El umbral por defecto de 0.5 raramente es el óptimo para un caso de uso real. Calcula la curva precision-recall, determina el coste relativo de FP vs FN para el negocio, y elige el umbral que minimiza el coste total esperado.

Error 3: No separar métricas de evaluación por subgrupos. Un modelo con AUC-ROC de 0.92 puede tener AUC-ROC de 0.95 en el grupo mayoritario y 0.75 en un subgrupo minoritario. Evaluar solo la métrica global oculta este sesgo. El AI Act europeo y el GDPR requieren evaluación de equidad por grupos protegidos en sistemas de alto riesgo.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

El protocolo de evaluación correcto para un proyecto de ML en empresa: primero, define las métricas antes de entrenar el modelo (no después de ver los resultados). Segundo, calcula la distribución de clases y elige las métricas apropiadas (AUC-ROC y AUC-PR para clasificación con desbalance, RMSE o MAE para regresión). Tercero, evalúa el modelo baseline (regla heurística o modelo trivial) para tener un punto de referencia. Cuarto, evalúa por subgrupos relevantes para el negocio y para las obligaciones regulatorias. Quinto, calcula la métrica de negocio real (coste total, ROI) además de las métricas técnicas.

Para reportar los resultados a stakeholders no técnicos: transforma las métricas técnicas en lenguaje de negocio. "AUC-ROC de 0.95" no dice nada a un director comercial. "El modelo detecta el 80% del fraude mientras que el sistema anterior detectaba el 45%, reduciendo las pérdidas por fraude en un 35%" sí tiene impacto.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M2-T3 (Probabilidad y estadística): la calibración probabilística es una dimensión adicional de evaluación, especialmente relevante para sistemas de scoring.
- M3-T6 (Validación cruzada): las métricas de evaluación deben calcularse con validación cruzada para estimar correctamente el rendimiento real.
- M13 (Gobernanza): el AI Act requiere evaluación de equidad y sesgo por grupos protegidos para sistemas de alto riesgo.

SECCIÓN 8 · RESUMEN EJECUTIVO

Accuracy es engañosa en clases desbalanceadas. Las métricas correctas para clasificación son: precisión (qué tan confiables son los positivos), recall (qué fracción de los positivos se detectan), F1 (balance), AUC-ROC (ranking general), y AUC-PR (para clases muy raras). Para regresión: RMSE (penaliza errores grandes), MAE (robusto a outliers). Traduce siempre las métricas técnicas a métricas de negocio. Evalúa por subgrupos. Define las métricas antes de entrenar, no después. El umbral de clasificación se calibra según el coste relativo de FP vs FN para el negocio concreto.