

Validación Cruzada

Módulo 3 · Machine Learning Clásico

K-fold, stratified, time series CV, protocolo de test set sagrado y como evitar los errores de leakage que contaminan las estimaciones de rendimiento.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Validación cruzada

Un equipo de data science presenta al comité de dirección un modelo de predicción de churn con AUC-ROC de 0.89. El comité aprueba el proyecto. En producción, el modelo tiene AUC-ROC de 0.71. ¿Qué ocurrió? La evaluación se había hecho sobre un único split train/test que, por azar estadístico, favorecía al modelo. Con datos escasos, un solo split puede producir estimaciones muy optimistas o pesimistas dependiendo de qué ejemplos caen en train y cuáles en test.

La validación cruzada (cross-validation, CV) resuelve este problema de forma elegante: en lugar de hacer un único split, hace múltiples splits y promedia los resultados. Produce estimaciones del rendimiento real más robustas y con intervalos de confianza explícitos. Es el estándar de facto para la evaluación de modelos de ML en proyectos serios, especialmente con datasets de tamaño moderado.

Los métodos de validación cruzada

K-Fold Cross-Validation: el método estándar

K-fold CV divide los datos en K partes (folds) de igual tamaño. Entrena K modelos: el modelo i se entrena en los K-1 folds restantes y se evalúa en el fold i. Promedia las K métricas de evaluación. El resultado es una estimación del rendimiento esperado del modelo en datos nuevos, con una medida de variabilidad (la desviación estándar de las K métricas). K=5 o K=10 son los valores estándar. K mayor produce estimaciones más precisas pero requiere más tiempo de cómputo.

Stratified K-Fold: para clases desbalanceadas

En problemas con clases desbalanceadas, el k-fold estándar puede producir folds donde la clase minoritaria está muy poco representada o ausente. Stratified k-fold garantiza que cada fold mantiene la misma proporción de clases que el dataset original. Es el método estándar para clasificación con desbalance.

Leave-One-Out (LOO): máxima precisión, máximo coste

LOO es un caso extremo de k-fold donde $k=n$ (número de ejemplos): cada ejemplo es el conjunto de test de un modelo. Produce la estimación menos sesgada del rendimiento real pero requiere entrenar n modelos, lo que es impracticable con datasets grandes. Solo se usa con datasets muy pequeños (decenas de ejemplos).

Time Series Cross-Validation: respetando el orden temporal

Para datos de series temporales, el k-fold estándar es incorrecto: puede usar datos del futuro para predecir el pasado (leakage temporal). Time series CV usa validación walk-forward o expanding window: siempre entrena solo sobre el pasado y evalúa sobre el futuro inmediato, avanzando la ventana de evaluación paso a paso. Es el método correcto para forecasting de demanda, predicción financiera y cualquier problema donde el tiempo importa.

CV para selección de modelos e hiperparámetros

El uso más común de CV en la práctica es para selección de modelos e hiperparámetros: dado un espacio de hiperparámetros (profundidad del árbol de 1 a 10, learning rate de 0.001 a 0.1, etc.), CV estima el rendimiento de cada configuración de hiperparámetros y selecciona la que produce el mejor rendimiento en validación. Este proceso (CV para selección de hiperparámetros) es la alternativa correcta al grid search simple, que no tiene en cuenta la variabilidad estadística de las estimaciones.

El protocolo correcto completo: divide los datos en train+val (80-90%) y test (10-20%). Aplica CV solo sobre train+val para selección de modelos e hiperparámetros. Entrena el modelo final con los mejores hiperparámetros sobre todo train+val. Evalúa una única vez sobre test para obtener la estimación no sesgada del rendimiento real. El test set es sagrado: solo se usa una vez al final.

Nested CV es la alternativa cuando el dataset es demasiado pequeño para separar un test set externo: el loop exterior evalúa el rendimiento del modelo; el loop interior selecciona los hiperparámetros. Es más robusto pero más costoso computacionalmente. Para datasets de más de 10.000 ejemplos, el protocolo de test set externo es preferible.

SECCIÓN 4 · EJEMPLOS REALES

- Evaluación de modelo de scoring en banca: con un dataset de 50.000 préstamos históricos, se aplica stratified 10-fold CV para evaluar el modelo de scoring de riesgo. El resultado es $AUC-ROC = 0.84 \pm 0.02$ (media $\pm$ desviación estándar sobre los 10 folds). El intervalo de confianza del 95% para el rendimiento real es aproximadamente [0.80, 0.88]. Este rango es lo que el comité de riesgo debe usar para la decisión de despliegue, no el número puntual.
- Time series CV en forecasting de demanda retail: para un modelo de predicción de demanda semanal, se usa CV walk-forward con ventanas de entrenamiento de 52 semanas y evaluación en las 4 semanas siguientes, avanzando de 4 en 4 semanas a lo largo de 3 años de datos. El resultado es el MAPE medio y su varianza a lo largo de los períodos de evaluación, dando una estimación realista del rendimiento en producción.
- Comparación estadística de modelos con CV: dado que LightGBM con CV produce $AUC = 0.87 \pm 0.015$ y Random Forest produce 0.84 ± 0.020 , la diferencia es estadísticamente significativa (test de Wilcoxon, $p < 0.05$). Esto justifica el despliegue de LightGBM a pesar de ser más complejo.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Hacer CV después de preprocessing sobre todo el dataset. Si normalizas los datos, seleccionas features o aplicas target encoding usando estadísticas de todo el dataset (incluyendo los folds de test de CV), estás introduciendo leakage. Todo el preprocessing debe hacerse dentro del fold de entrenamiento de CV. Los pipelines de sklearn garantizan esto cuando están correctamente configurados.

Error 2: Usar el mismo test set para múltiples iteraciones de desarrollo. Si miras los resultados del test set, ajustas el modelo, vuelves a mirar el test set, y repites, has contaminado el test set. Con suficientes iteraciones, puedes ajustar el modelo al test set por azar estadístico. Separa el test set al principio y úsalo solo una vez al final.

Error 3: Ignorar la varianza entre folds. $AUC = 0.87 \pm 0.03$ es muy distinto a $AUC = 0.87 \pm 0.001$. El primero indica alta variabilidad del rendimiento (el modelo es inestable, posiblemente con alta varianza). El segundo indica rendimiento muy consistente. Solo reportar la media sin la varianza oculta información crítica.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

En sklearn, la implementación estándar es `cross_val_score(model, X, y, cv=StratifiedKFold(n_splits=5), scoring="roc_auc")`. Para un pipeline completo con preprocessing, usar Pipeline de sklearn para encapsular todo en un único objeto que puede pasarse a `cross_val_score` sin riesgo de leakage. Para time series, usar `TimeSeriesSplit(n_splits=5)` en lugar de `KFold`.

Para selección de hiperparámetros con CV integrada, sklearn proporciona `GridSearchCV` y `RandomizedSearchCV` que aplican automáticamente CV para evaluar cada configuración de hiperparámetros. Para búsqueda bayesiana más eficiente, Optuna con `cross_val_score` como función objetivo es el estándar actual.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M3-T4 (Evaluación): las métricas de evaluación se calculan en cada fold de CV para producir estimaciones robustas.
- M3-T5 (Bias-variance): la varianza entre folds de CV es una medida directa de la varianza del modelo.
- M8 (LLMOps): la evaluación continua en producción de LLMs requiere conjuntos de evaluación robustos y protocolos similares a CV.

SECCIÓN 8 · RESUMEN EJECUTIVO

La validación cruzada produce estimaciones del rendimiento más robustas que un único split train/test, promediando k evaluaciones sobre diferentes particiones de los datos. K-fold estándar ($k=5$ o $k=10$), stratified k-fold para clases desbalanceadas, y time series CV walk-forward para series temporales son los tres métodos principales. El protocolo correcto: CV sobre train+val para selección de modelos e hiperparámetros, test set externo sagrado para evaluación final una única vez. Reporta siempre media $\pm$ desviación estándar de las métricas de CV, no solo la media. Todo el preprocessing debe estar dentro del fold de entrenamiento para evitar leakage.