

Arquitecturas Modernas de Deep Learning

Módulo 4 · Deep Learning

Transformers decoder, ViT, modelos de difusion, MoE, Flash Attention, cuantizacion y como evaluar arquitecturas para tu caso de uso especifico.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Arquitecturas Modernas de Deep Learning

En 2017 el Transformer rompió con 30 años de arquitecturas basadas en CNNs y RNNs para NLP. En 2021 los Vision Transformers (ViT) comenzaron a aplicar la misma idea a visión artificial. En 2022 los modelos fundacionales multimodales (CLIP, Flamingo) comenzaron a conectar texto e imagen en el mismo espacio de representación. En 2023 los modelos de difusión se convirtieron en el estándar para generación de imagen y vídeo. En 2024 los State Space Models (Mamba) surgieron como alternativa eficiente a los Transformers para secuencias largas.

Este tema es un mapa de las arquitecturas que importan en 2025 y una guía para entender qué hace especial a cada una y cuándo elegirla. No es un tutorial de implementación: es la comprensión estratégica que permite evaluar nuevas publicaciones, entender las capacidades de los modelos frontier, y tomar decisiones de arquitectura informadas.

El paisaje actual de arquitecturas

Transformers decoder-only: la arquitectura de los LLMs

GPT-2, GPT-3, GPT-4, Llama, Mistral, Claude, Gemini: todos son Transformers decoder-only. Procesan la secuencia de izquierda a derecha con masked self-attention (cada token solo ve los anteriores), y generan el siguiente token autoregresivamente. La escala (de 1B a 1T parámetros) es lo que produce las capacidades emergentes. Las innovaciones recientes en esta arquitectura incluyen: Grouped Query Attention (GQA, reduce el coste de inferencia compartiendo heads de K y V entre grupos de Q heads), Rotary Positional Encoding (RoPE, mejora la generalización a secuencias más largas que las del entrenamiento), y arquitecturas MoE (Mixture of Experts, activa solo una fracción de los parámetros para cada token, aumentando la capacidad total sin aumentar el coste de inferencia).

Vision Transformers (ViT): atención aplicada a imágenes

ViT divide la imagen en patches de 16×16 píxeles, convierte cada patch en un token (vector de embeddings), y aplica un Transformer estándar. La clave es que el self-attention global permite al modelo capturar relaciones entre cualquier par de patches independientemente de su distancia espacial, a diferencia de las CNNs que están limitadas por el campo receptivo local. Con suficientes datos de preentrenamiento, ViT supera a las CNNs en benchmarks de gran escala. Con datos limitados, las CNNs siguen siendo superiores gracias a sus inductive biases.

Modelos de difusión: generación de alta calidad

Los modelos de difusión (Stable Diffusion, DALL-E 3, Sora) aprenden a invertir un proceso de adición gradual de ruido gaussiano. El entrenamiento consiste en aprender a predecir el ruido añadido a una imagen en cada paso de difusión. La generación consiste en comenzar con ruido puro y aplicar iterativamente el proceso de denoising, guiado opcionalmente por un texto de condicionamiento. La calidad visual de los modelos de difusión supera a las GANs en la

mayoría de los benchmarks y su entrenamiento es más estable.

Modelos Multimodales: conectar texto, imagen y más

Los modelos multimodales como CLIP (OpenAI, 2021) aprenden embeddings conjuntos de texto e imagen: la representación del texto "un gato naranja durmiendo" está cerca de la representación de una foto de un gato naranja durmiendo. Esta alineación entre modalidades permite búsqueda de imagen por texto, clasificación zero-shot, y es la base de los modelos de visión-lenguaje como LLaVA, GPT-4V y Claude. Los modelos más recientes (Gemini 1.5, GPT-4o) integran texto, imagen y audio en una arquitectura unificada con ventanas de contexto de 1M tokens.

SECCIÓN 3 · CÓMO FUNCIONA

Las innovaciones técnicas que marcan diferencia

Flash Attention y eficiencia de atención

Flash Attention (Dao et al., 2022) reimplementa el mecanismo de atención para operar en tiles (bloques) que caben en SRAM (memoria rápida de GPU) en lugar de HBM (memoria lenta). El resultado matemático es idéntico pero la velocidad de cómputo aumenta 2-4x y el uso de memoria cae de $O(n^2)$ a $O(n)$. Flash Attention 2 y 3 mejoran adicionalmente la eficiencia y son el estándar en todos los frameworks de entrenamiento e inferencia de LLMs modernos.

Mixture of Experts (MoE): escalar capacidad sin escalar coste

En una arquitectura MoE, la capa feed-forward de cada bloque del Transformer es reemplazada por múltiples "experts" (sub-redes), y una función de routing (gating network) elige dinámicamente qué 2-4 experts activar para cada token. El modelo tiene la capacidad total de todos los experts (parámetros totales: 8x el modelo denso equivalente) pero el coste de cómputo por token es el de solo 2-4 experts activos. GPT-4 se cree que usa MoE. Mixtral de Mistral es un modelo MoE de código abierto.

Quantización: reducir el tamaño sin pérdida significativa

Quantización representa los pesos del modelo con menor precisión numérica: FP32 $\rightarrow$ FP16 (mitad del tamaño), FP16 $\rightarrow$ INT8 (un cuarto), INT8 $\rightarrow$ INT4 (un octavo). GGUF (formato del ecosistema llama.cpp) y GPTQ son los formatos estándar para modelos quantizados. Llama 3 70B en FP16 requiere 140 GB de VRAM; en GGUF Q4 requiere ~35 GB. La pérdida de calidad con INT8 es <1% para la mayoría de las tareas; con INT4 es de 1-5% según la tarea. Esto hace posible desplegar modelos grandes en hardware de coste razonable.

SECCIÓN 4 · EJEMPLOS REALES

- Mixtral 8x7B (Mistral AI): MoE con 8 experts de 7B cada uno, 46.7B parámetros totales pero coste de inferencia equivalente a un modelo de 12.9B. Supera a Llama 2 70B en la mayoría de benchmarks con 6x menos cómputo de inferencia. Open source y auto-hosteable.
- Stable Diffusion 3 (Stability AI): modelo de difusión de última generación que usa un Transformer (Diffusion Transformer, DiT) en lugar de la UNet clásica. Genera imágenes de

alta calidad con mejor comprensión de texto y mejor coherencia física que versiones anteriores.

- SigLIP (Google): sucesor de CLIP entrenado con sigmoid loss en lugar de contrastive loss. Produce embeddings de imagen-texto de mayor calidad para zero-shot classification y retrieval, y es el encoder visual de muchos modelos multimodales modernos.
- DINO v2 (Meta): Vision Transformer preentrenado con self-supervised learning (sin etiquetas). Produce embeddings de imagen de alta calidad que transfieren bien a cualquier tarea de visión downstream con pocas imágenes etiquetadas.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Creer que la arquitectura más nueva siempre es la mejor para tu caso de uso. Las arquitecturas frontier están optimizadas para datasets masivos y cómputo masivo. Para fine-tuning con datasets pequeños (<10K ejemplos), una CNN o un BERT pueden funcionar igual o mejor que un modelo de última generación con mucho menos coste.

Error 2: Ignorar la cuantización. Desplegar Llama 3 70B en FP16 requiere 2 GPUs H100 (160GB VRAM). El mismo modelo en Q4 cabe en una sola GPU de gama media. Para inferencia de producción con presupuesto limitado, la cuantización INT8 o Q4 es casi siempre la solución correcta con pérdida de calidad mínima.

Error 3: Confundir el número de parámetros con la calidad. Mixtral 8x7B (47B parámetros totales) supera a Llama 2 70B en muchos benchmarks pero tiene menor coste de cómputo de inferencia (12.9B activos). El número de parámetros activos por token es más relevante para el coste de inferencia que el total de parámetros.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Para mantenerse al día con arquitecturas modernas sin perderse en el ruido, el hábito más productivo es: seguir el leaderboard de LMSYS Chatbot Arena (rendimiento en conversación real), los benchmarks de MMLU y HELM para capacidad general, y SWE-bench para código. Estos benchmarks permiten comparar arquitecturas con un criterio estandarizado. Hugging Face Open LLM Leaderboard consolida los benchmarks más relevantes para modelos open source.

Para implementar modelos modernos: Hugging Face Transformers soporta prácticamente todas las arquitecturas relevantes con una API unificada (AutoModel, AutoTokenizer, from_pretrained). Para cuantización: llama.cpp para modelos GGUF en CPU/GPU local, bitsandbytes para cuantización INT8/INT4 en PyTorch, GPTQ para cuantización post-entrenamiento de alta calidad.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M1-T8 (Transformer): la arquitectura base de la mayoría de los modelos descritos aquí.
- M5 (LLMs): los LLMs son Transformers decoder-only a escala masiva, con las optimizaciones de GQA, RoPE y MoE descritas aquí.
- M9 (Infraestructura): la cuantización y las opciones de despliegue (vLLM, llama.cpp, TGI) permiten implementar modelos modernos con hardware limitado.

Las arquitecturas modernas de deep learning convergen en variantes del Transformer: decoder-only para LLMs (GPT, Llama, Mistral), encoder-only para embeddings y clasificación (BERT, RoBERTa), ViT para visión, modelos de difusión para generación de imagen, y modelos multimodales que integran todas las modalidades. Las innovaciones clave son: Flash Attention (2-4x más rápido), MoE (más capacidad con menos cómputo activo), cuantización (reducir VRAM 4-8x con pérdida mínima). Para mantenerse al día: LMSYS Chatbot Arena y HF Open LLM Leaderboard como referencias. Evalúa siempre en tu caso de uso específico con tu golden dataset.