

Máster en Inteligencia Artificial
para Liderazgo Técnico y Transformación Empresarial

Procesamiento del Lenguaje Natural

Módulo 5 · NLP y Modelos de Lenguaje (LLMs)

Clasificación, extracción, generación y comprensión: el mapa de tareas NLP y la guía de selección de herramientas en 2025.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Procesamiento del Lenguaje Natural (NLP)

El lenguaje es el medio por el que los humanos acumulan y transmiten conocimiento. Los contratos de una empresa, los correos de los clientes, los informes técnicos, las notas clínicas, las sentencias judiciales: todo eso es texto no estructurado que hasta hace poco era inutilizable para los sistemas informáticos sin un enorme trabajo manual previo. El NLP (Natural Language Processing) es el campo que hace que las máquinas puedan procesar, entender y generar texto humano de forma útil.

El NLP ha experimentado la mayor transformación de cualquier subcampo de la IA en los últimos diez años. En 2012, el estado del arte en clasificación de texto eran los SVMs sobre TF-IDF. En 2018, BERT redefinió todos los benchmarks con preentrenamiento bidireccional. En 2020, GPT-3 mostró capacidades emergentes de few-shot learning. En 2022, ChatGPT democratizó el acceso a LLMs conversacionales. En 2025, los modelos frontier (GPT-4, Claude, Gemini) son herramientas de propósito general capaces de razonamiento complejo sobre texto. Entender la evolución de este campo es esencial para saber qué herramienta usar para cada tarea.

Las tareas fundamentales de NLP

Clasificación de texto: asignar categorías

La clasificación de texto asigna una o más categorías a un documento. Análisis de sentimiento (positivo/negativo/neutro), detección de spam, clasificación de tickets de soporte, categorización de noticias, y detección de idioma son todos problemas de clasificación de texto. Es la tarea de NLP más común en empresa y la que tiene más ROI directo: clasificar automáticamente miles de emails, tickets o documentos que antes requerían revisión manual.

Extracción de información: encontrar datos estructurados en texto

La extracción de información identifica entidades y relaciones específicas en el texto. Named Entity Recognition (NER) extrae personas, organizaciones, fechas, importes, ubicaciones. La extracción de relaciones identifica cómo se relacionan esas entidades ("Empresa X adquirió Empresa Y por Z millones en fecha W"). La extracción de eventos detecta acciones y participantes. Estas tareas son la base de los sistemas de procesamiento de contratos, facturas, expedientes médicos y documentos legales.

Generación de texto: producir lenguaje natural

La generación de texto incluye resumen (condensar documentos largos), traducción automática (convertir texto entre idiomas), generación de respuestas (chatbots, asistentes), completado de código, y generación de informes. Los LLMs modernos han unificado todas estas tareas bajo una única arquitectura: cualquier tarea de generación se formula como "dado este texto de entrada, genera el texto de salida correcto".

Comprensión del lenguaje: entender el significado

La comprensión del lenguaje incluye preguntas y respuestas (QA), inferencia textual (¿esta hipótesis se sigue de este texto?), análisis de coherencia discursiva, resolución de correferencias y comprensión de instrucciones. Los LLMs son extraordinariamente buenos en estas tareas cuando la información necesaria está disponible en el contexto.

SECCIÓN 3 · CÓMO FUNCIONA

El pipeline NLP clásico vs el enfoque moderno con LLMs

El pipeline NLP clásico (pre-2018)

El pipeline clásico de NLP tenía múltiples etapas secuenciales: tokenización (dividir en palabras o subpalabras), normalización (lowercase, eliminación de stopwords, stemming o lematización), representación vectorial (TF-IDF, Word2Vec), y modelo de clasificación o extracción. Cada etapa era un componente separado, y los errores se acumulaban a través del pipeline. Este enfoque sigue siendo relevante cuando los datos son escasos, el dominio es muy técnico, o los recursos computacionales son muy limitados.

El enfoque moderno con Transformers (post-2018)

Los Transformers preentrenados han simplificado radicalmente el pipeline: tokenización + modelo de Transformer preentrenado + fine-tuning (o prompting) para la tarea específica. En lugar de múltiples componentes especializados, hay un único modelo general que aprende a resolver cualquier tarea de texto dado suficiente preentrenamiento y ejemplos de la tarea. Esto reduce el time-to-production de meses a días para la mayoría de las tareas de NLP.

Con LLMs y prompting, el pipeline se simplifica aún más: el mismo modelo sin fine-tuning puede resolver docenas de tareas diferentes con instrucciones adecuadas. Esto permite explorar rápidamente si una tarea es técnicamente viable antes de invertir en un pipeline de fine-tuning especializado.

SECCIÓN 4 · EJEMPLOS REALES

- Clasificación de tickets de soporte (Zendesk, Salesforce): clasificar automáticamente los tickets entrantes en categorías (técnico, facturación, cancelación) y asignarlos al equipo correcto. BERT fine-tuneado en 3.000 tickets etiquetados produce accuracy de 93% frente al 78% del clasificador TF-IDF+SVM anterior.
- Extracción de entidades en contratos (DocuSign, Ironclad): NER especializado para extraer partes firmantes, fechas de vigencia, cláusulas de rescisión, obligaciones de confidencialidad. Reduce el tiempo de revisión de contratos de horas a minutos con tasas de error comparables a la revisión humana.
- Resumen de noticias para analistas financieros (Bloomberg, Reuters): LLMs que resumen automáticamente artículos de prensa relevantes para carteras específicas, filtrando por empresa, sector y tipo de evento. Un analista puede revisar el equivalente a 10x más noticias en el mismo tiempo.
- Traducción automática en e-commerce internacional (Alibaba, Amazon): modelos de traducción neuronal que permiten a vendedores en China listar productos para mercados europeos y americanos con calidad comparable a traductores humanos para texto de

producto estándar.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Usar NLP clásico (TF-IDF + SVM) cuando hay modelos preentrenados disponibles. Para la mayoría de las tareas de clasificación o extracción de texto en 2025, BERT fine-tuneado o un LLM con prompting superará al pipeline clásico con el mismo o menor esfuerzo de desarrollo.

Error 2: Ignorar el idioma del corpus de preentrenamiento. Los modelos preentrenados mayoritariamente en inglés (BERT base, GPT) tienen peor rendimiento en otros idiomas. Para español, francés, alemán u otros idiomas, usa modelos multilingües (mBERT, XLM-R) o modelos preentrenados específicamente en ese idioma (BETO para español, CamemBERT para francés).

Error 3: Asumir que los LLMs son la solución para cualquier tarea de NLP. Para clasificación de texto en producción con decenas de millones de documentos al día, el coste de inferencia de un LLM grande puede ser prohibitivo. Un modelo BERT distilado fine-tuneado en el dominio puede ser 100x más barato y casi igual de preciso para tareas de clasificación estándar.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

La guía de selección de herramientas para tareas de NLP: ¿es una tarea de clasificación con pocas clases y muchos datos etiquetados? → BERT/DistilBERT fine-tuneado (rápido, barato en inferencia). ¿Es una tarea de clasificación con pocas clases pero pocos datos etiquetados? → LLM con few-shot prompting o zero-shot. ¿Es una tarea de generación (resumen, respuesta, redacción)? → LLM con prompting (gpt-4o-mini para alto volumen, GPT-4 o Claude para alta calidad). ¿Es búsqueda semántica o RAG? → modelo de embedding especializado + base vectorial + LLM.

Para empezar rápido en cualquier tarea de NLP: Hugging Face Transformers con pipeline de alto nivel (from transformers import pipeline) permite probar clasificación, NER, resumen, traducción y QA con dos líneas de código y modelos preentrenados de estado del arte. Es el punto de partida correcto para cualquier exploración de viabilidad antes de invertir en un pipeline de producción.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M5-T2 (BERT vs GPT): los dos paradigmas de modelos que dominan el NLP moderno.
- M7 (RAG): los sistemas RAG son la aplicación más transformadora de NLP en empresa, combinando búsqueda semántica con generación contextualizada.
- M6 (Ingeniería de prompts): el prompting es la interfaz principal para usar LLMs en tareas de NLP sin fine-tuning.

SECCIÓN 8 · RESUMEN EJECUTIVO

NLP es el campo que permite a las máquinas procesar texto humano. Las tareas principales son clasificación, extracción de información, generación y comprensión. El enfoque moderno (Transformers preentrenados + fine-tuning o prompting) ha

simplificado radicalmente los pipelines NLP clásicos. En 2025: BERT para clasificación/extracción en producción de alto volumen (barato en inferencia); LLMs para generación, few-shot y tareas complejas; modelos de embedding para búsqueda semántica. Hugging Face pipeline es el punto de partida correcto para cualquier prototipo de NLP. Para idiomas distintos del inglés: usar modelos multilingües o específicos del idioma.