

Modelos tipo BERT vs GPT

Módulo 5 · NLP y Modelos de Lenguaje (LLMs)

Encoder bidireccional vs decoder autoregresivo: cuándo usar BERT, GPT, T5 y cómo el tipo de tarea determina la arquitectura correcta.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Modelos tipo BERT vs GPT: encoder vs decoder

En 2018 Google publicó BERT y OpenAI publicó GPT-1. Ambos eran Transformers preentrenados sobre texto masivo. Ambos rompieron todos los benchmarks de NLP anteriores. Y sin embargo eran fundamentalmente distintos: BERT leía en ambas direcciones (bidireccional), GPT leía solo de izquierda a derecha (unidireccional). Esa diferencia arquitectónica, que parece un detalle técnico menor, tiene consecuencias profundas en qué tipo de tareas cada modelo hace bien y cuál es el caso de uso correcto para cada uno.

Entender la diferencia BERT vs GPT no es solo de interés histórico: es la comprensión que permite elegir el modelo correcto para cada caso de uso empresarial. En 2025, la familia GPT (modelos generativos) domina la conversación pública, pero los modelos BERT y sus variantes (RoBERTa, DistilBERT, DeBERTa, Sentence-BERT) siguen siendo la elección estándar para clasificación, NER, y embeddings de texto de alta calidad en sistemas de producción de alto volumen.

Las diferencias arquitectónicas fundamentales

BERT: encoder bidireccional para comprensión

BERT (Bidirectional Encoder Representations from Transformers, Google, 2018) usa solo el componente encoder del Transformer original. El encoder procesa toda la secuencia simultáneamente, con self-attention bidireccional: cada token puede atender a todos los tokens de la secuencia, tanto anteriores como posteriores. Esto le da a BERT una comprensión contextual mucho más rica que los modelos unidireccionales.

BERT se preentrena con dos objetivos: Masked Language Modeling (MLM), donde el 15% de los tokens se enmascaran aleatoriamente y el modelo debe predecirlos usando el contexto en ambas direcciones; y Next Sentence Prediction (NSP), donde el modelo debe determinar si dos oraciones son consecutivas en el texto original. BERT base tiene 12 capas, 12 cabezas de atención y 110M parámetros. BERT large tiene 24 capas y 340M parámetros.

GPT: decoder autoregresivo para generación

GPT (Generative Pre-trained Transformer, OpenAI, 2018) usa solo el componente decoder del Transformer original con masked self-attention causal: cada token solo puede atender a los tokens anteriores, no a los posteriores. Esto lo hace incapaz de "ver el futuro" durante el procesamiento, pero lo hace ideal para la generación autoregresiva: genera el texto token a token, condicionando cada nuevo token en todos los anteriores.

GPT se preentrena con un único objetivo: predicción del siguiente token (language modeling causal). Dado un texto, el modelo debe predecir el token que sigue a cada posición. Este objetivo simple, aplicado a escala masiva (GPT-3 usa 175B parámetros y 300B tokens de entrenamiento), produce las capacidades emergentes de few-shot learning, razonamiento y generación que hacen a los LLMs tan versátiles.

T5, BART y los modelos encoder-decoder

T5 (Text-to-Text Transfer Transformer, Google, 2020) usa la arquitectura encoder-decoder completa. Reformula todas las tareas de NLP como problemas de texto-a-texto: clasificación, traducción, resumen, QA y cualquier otra tarea se expresa como "dado este texto de entrada, genera este texto de salida". BART (Denoising Autoencoder for Sequence-to-Sequence Pre-training) es similar: preentrenado corrompiendo texto de diversas formas y aprendiendo a reconstruirlo. Son especialmente buenos para tareas de transformación secuencia-a-secuencia como resumen y traducción.

SECCIÓN 3 · CÓMO FUNCIONA

Preentrenamiento: MLM vs Language Modeling causal

MLM (BERT): el modelo recibe una secuencia con el 15% de tokens enmascarados ([MASK]) y debe predecirlos. Porque puede "ver" todos los tokens restantes en ambas direcciones, aprende representaciones contextuales muy ricas. La desventaja es que el objetivo de preentrenamiento no corresponde directamente a ninguna tarea downstream: el modelo nunca ve tokens [MASK] en producción.

Language Modeling Causal (GPT): el modelo predice el siguiente token dado todos los anteriores. Este objetivo corresponde directamente a la generación de texto, lo que hace al modelo naturalmente bueno en esa tarea. También produce in-context learning emergente: el modelo aprende a reconocer patrones en el contexto y aplicarlos a nuevos problemas, lo que es la base del prompting few-shot.

RoBERTa, DistilBERT y la familia BERT moderna

RoBERTa (Robustly Optimized BERT Pretraining, Facebook, 2019) mostró que BERT estaba significativamente subentrenado. Con más datos, batch sizes más grandes, más tiempo de entrenamiento y sin NSP, RoBERTa supera a BERT en todos los benchmarks. DistilBERT es una versión destilada de BERT: 40% menos parámetros, 60% más rápido, 97% del rendimiento de BERT. Es la elección estándar para producción de alto volumen. DeBERTa usa disentangled attention (separa el contenido de la posición en la atención) y en 2021 superó a los LLMs mucho más grandes en los benchmarks SuperGLUE.

En 2024-2025, los modelos de la familia BERT han seguido evolucionando: ModernBERT (diciembre 2024) es una actualización de BERT con técnicas modernas (RoPE, Flash Attention, ventana de contexto de 8192 tokens) que supera a RoBERTa en todos los benchmarks manteniendo la eficiencia de los encoders. Para embeddings, E5, BGE y GTE son encoders BERT-like optimizados específicamente para la tarea de embedding semántico.

SECCIÓN 4 · EJEMPLOS REALES

- BERT en motores de búsqueda (Google): Google implementó BERT en su motor de búsqueda en 2019, mejorando la comprensión de las consultas de búsqueda en lenguaje natural. En lugar de buscar palabras clave exactas, el sistema entiende el significado de la consulta en contexto.

- Análisis de sentimiento de reseñas con DistilBERT (Amazon, Trustpilot): procesamiento de millones de reseñas de productos al día para análisis de sentimiento. DistilBERT fine-tuneado es 6x más rápido que BERT completo con solo 3% de pérdida de precisión, haciendo viable el procesamiento masivo en tiempo real.
- GPT-4 para generación de código (GitHub Copilot): modelo de la familia GPT que genera código token a token condicionado en el contexto del archivo, comentarios y código anterior. La generación autoregresiva es fundamental: cada token de código se genera condicionado en todo lo anterior.
- T5 para resumen de documentos jurídicos (LexisNexis): modelo encoder-decoder que resume sentencias judiciales largas preservando los puntos legales clave. La arquitectura encoder-decoder es más adecuada que un decoder puro para resumen controlado donde se necesita comprensión completa del documento de entrada.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Usar GPT para embeddings de texto cuando BERT es superior. Los modelos GPT, al ser causales, producen representaciones que incorporan solo el contexto anterior, no el posterior. Para embeddings semánticos de calidad, los modelos BERT/encoder bidireccionales producen representaciones más ricas. Los modelos de embedding de OpenAI (text-embedding-3) son modelos encoder, no GPT.

Error 2: Usar BERT para generación de texto libre. BERT no puede generar texto de forma autoregresiva; es solo un encoder. Para generación de respuestas, resumen o cualquier tarea generativa, necesitas un decoder (GPT) o encoder-decoder (T5, BART).

Error 3: Ignorar los límites de contexto de BERT. BERT base y la mayoría de sus variantes tienen un límite de 512 tokens. Documentos más largos deben segmentarse o usar un modelo con ventana de contexto mayor (Longformer, ModernBERT con 8K tokens). Enviar un documento de 2.000 tokens a BERT base simplemente truncará el texto sin warning, produciendo resultados silenciosamente incorrectos.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Matriz de decisión para selección de modelo en NLP: tarea de clasificación (sentimiento, categoría, intención) → DistilBERT fine-tuneado para alto volumen, o LLM con few-shot para bajo volumen y alta variedad de clases. Extracción de entidades (NER, extracción de campos específicos) → BERT/RoBERTa fine-tuneado con formato BIO o LLM con output estructurado. Búsqueda semántica y RAG → modelo de embedding tipo E5 o BGE. Resumen → T5/BART fine-tuneado o LLM para alta calidad. Generación de texto libre → GPT family o Claude.

Para el fine-tuning de BERT en clasificación con Hugging Face: `from transformers import AutoModelForSequenceClassification, AutoTokenizer, Trainer, TrainingArguments`. Carga el modelo con `from_pretrained`, configura `TrainingArguments` con los hiperparámetros correctos (`learning_rate=2e-5`, `per_device_train_batch_size=16`, `num_train_epochs=3`), y entrena con el `Trainer` estándar. El proceso completo para un clasificador binario con 3.000 ejemplos toma menos de 30 minutos en una GPU.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M1-T8 (Transformer): BERT y GPT son variantes del Transformer original que usan solo el encoder o solo el decoder respectivamente.
- M4-T5 (Transfer learning): el preentrenamiento de BERT y GPT y su posterior fine-tuning es el ejemplo más emblemático de transfer learning en NLP.
- M5-T3 (Pretraining vs fine-tuning): profundiza en las diferencias entre el objetivo de preentrenamiento de BERT y GPT y cómo afectan al fine-tuning.

SECCIÓN 8 · RESUMEN EJECUTIVO

BERT (encoder bidireccional, MLM) comprende el texto en ambas direcciones: ideal para clasificación, NER, embeddings y QA. GPT (decoder causal, language modeling) genera texto autoregresivamente: ideal para generación, resumen, traducción y razonamiento. T5/BART (encoder-decoder) combinan comprensión completa con generación: ideales para transformaciones controladas de texto. En 2025: DistilBERT/RoBERTa para clasificación en alto volumen (100-500x más barato que LLMs). ModernBERT para la mejor calidad encoder con contexto largo. LLM frontier (GPT-4, Claude) para tareas complejas o de baja frecuencia. La elección depende del tipo de tarea y el balance coste-calidad.