

Pretraining vs Fine-tuning

Módulo 5 · NLP y Modelos de Lenguaje (LLMs)

Las fases de desarrollo de LLMs, catastrophic forgetting, RLHF y el árbol de decisión entre prompting, RAG y fine-tuning.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Pretraining vs Fine-tuning en LLMs

OpenAI gastó cientos de millones de dólares en el preentrenamiento de GPT-4. Tú puedes fine-tunar GPT-4 por decenas de dólares por hora de GPU. Esta asimetría económica es la que hace que el fine-tuning sea la estrategia correcta para el 99.9% de las organizaciones: aprovechar el conocimiento masivo acumulado en el preentrenamiento y adaptar el comportamiento del modelo a las necesidades específicas de la organización con una fracción mínima del coste.

Pero entender la diferencia entre preentrenamiento y fine-tuning va más allá de la economía: es entender qué aprende el modelo en cada fase, por qué el fine-tuning puede degradar capacidades (catastrophic forgetting), por qué la calidad de los datos de fine-tuning importa más que la cantidad, y cuándo el fine-tuning es la solución correcta frente a otras alternativas como el prompting avanzado o el RAG.

Las dos fases del desarrollo de LLMs

Preentrenamiento: aprender sobre el mundo

El preentrenamiento es la fase en la que el modelo aprende representaciones generales del lenguaje y del conocimiento del mundo procesando cantidades masivas de texto con aprendizaje auto-supervisado. Para GPT-family, el objetivo es predicción del siguiente token: dado el texto anterior, predice el siguiente token. Para BERT, el objetivo es MLM: predice los tokens enmascarados usando el contexto completo. Este proceso, repetido sobre billones o trillones de tokens, es lo que produce las capacidades emergentes de razonamiento, conocimiento y comprensión del lenguaje.

Los recursos necesarios para el preentrenamiento son masivos. Llama 3 70B fue preentrenado sobre 15.6 billones de tokens usando más de 16.000 GPUs H100 durante meses. El coste en hardware de nube equivalente es de decenas a cientos de millones de dólares. El resultado es un modelo base (base model) que tiene conocimiento general pero no sigue instrucciones de forma confiable: si le dices "resume este documento", puede empezar a generar más texto similar al documento en lugar de un resumen.

Instruction tuning: aprender a seguir instrucciones

El instruction tuning (o supervised fine-tuning, SFT) es el proceso que convierte un modelo base en un asistente útil. Se hace fine-tuning sobre pares (instrucción, respuesta ideal) que demuestran el comportamiento deseado: instrucciones claras y respuestas de calidad. Con decenas de miles de ejemplos de alta calidad, el modelo aprende a reconocer el formato instrucción-respuesta y a seguir instrucciones de forma confiable. Alpaca (Stanford, 2023) demostró que incluso 52.000 instrucciones de calidad moderada son suficientes para transformar el comportamiento de Llama.

RLHF: aprender de las preferencias humanas

RLHF (Reinforcement Learning from Human Feedback) añade una capa adicional al instruction tuning: en lugar de aprender solo de ejemplos correctos, el modelo aprende a maximizar las preferencias humanas. Evaluadores humanos comparan pares de respuestas y expresan cuál prefieren. Un reward model aprende a predecir esas preferencias. El LLM se ajusta con RL (típicamente PPO o DPO) para producir respuestas que maximizan el reward model con una penalización KL que mantiene el modelo cerca del comportamiento del SFT. RLHF es lo que hace a ChatGPT y Claude seguros y útiles, no solo precisos.

SECCIÓN 3 · CÓMO FUNCIONA

Catastrophic forgetting y cómo evitarlo

El catastrophic forgetting ocurre cuando el fine-tuning sobre un nuevo dataset degrada las capacidades aprendidas durante el preentrenamiento. El modelo "olvida" su conocimiento general para memorizar los patrones específicos del nuevo dataset. Es especialmente problemático con datasets de fine-tuning pequeños y sesgados, tasas de aprendizaje demasiado altas, o cuando el fine-tuning se hace sobre demasiadas épocas.

Las estrategias para mitigar el catastrophic forgetting: usar tasas de aprendizaje muy bajas (1e-5 a 5e-5 para LLMs, 10-100x menores que en preentrenamiento). LoRA mantiene los pesos originales congelados y solo añade pequeños adaptadores, eliminando el riesgo de sobrescribir el conocimiento original. El data mixing mezcla ejemplos del nuevo dominio con ejemplos del dominio general en el fine-tuning para preservar las capacidades generales. El regularization via KL divergence penaliza los cambios grandes respecto al modelo base.

La evaluación del catastrophic forgetting es tan importante como la evaluación del rendimiento en la tarea de fine-tuning: evalúa el modelo fine-tuneado en benchmarks generales (MMLU, HellaSwag) además de en el dataset específico para detectar degradaciones en capacidades generales.

SECCIÓN 4 · EJEMPLOS REALES

- Llama 3 70B base vs Llama 3 70B Instruct: el modelo base genera continuaciones de texto pero no sigue instrucciones. El modelo Instruct ha sido sometido a SFT + RLHF: sigue instrucciones, mantiene el formato correcto, se niega a generar contenido dañino, y produce respuestas útiles y bien estructuradas. La misma arquitectura, capacidades muy distintas por el fine-tuning.
- Código Llama: fine-tuning especializado de Llama 3 sobre código. Entrenado sobre ~500B tokens de código de GitHub, produce código de mucha mayor calidad que Llama 3 base sin esta especialización. El fine-tuning de dominio sobre datos relevantes mejora significativamente el rendimiento en ese dominio.
- BioBERT y ClinicalBERT: BERT fine-tuneado sobre texto biomédico y texto clínico respectivamente. Aunque BERT base puede hacer NER en texto médico, estos modelos especializados mejoran el F1 en NER médico en 5-15 puntos porcentuales por la relevancia del dominio de preentrenamiento adicional.
- DPO (Direct Preference Optimization) como alternativa a RLHF: DPO simplifica el proceso de RLHF eliminando la necesidad de un reward model separado. Entrena directamente el

LLM para preferir las respuestas buenas sobre las malas usando pares de preferencia. Más estable y fácil de implementar que PPO-based RLHF.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Pensar que el fine-tuning siempre mejora el modelo. El fine-tuning con datos de baja calidad puede degradar el modelo. La evaluación post fine-tuning debe incluir tanto la tarea específica como benchmarks generales para detectar regresiones.

Error 2: Confundir instrucción tuning con preentrenamiento de dominio. Si el objetivo es que el modelo tenga más conocimiento de un dominio específico (terminología técnica, conceptos de nicho), el continued pretraining sobre texto del dominio es más efectivo que el instruction tuning. El instruction tuning mejora el comportamiento; el continued pretraining mejora el conocimiento.

Error 3: Usar demasiadas épocas en fine-tuning. Con LLMs, 1-3 épocas sobre el dataset de fine-tuning son típicamente suficientes. Más épocas producen sobreajuste al dataset de fine-tuning y mayor catastrophic forgetting. Monitoriza la pérdida de validación y para cuando empiece a subir.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

El árbol de decisión entre prompting, RAG y fine-tuning: ¿el problema es de formato o comportamiento (el modelo sabe hacer la tarea pero no la presenta como quieres)? → instruction tuning con 500-2.000 ejemplos del formato deseado. ¿El problema es de conocimiento actualizado o privado (el modelo no sabe sobre tus datos internos)? → RAG. ¿El problema es de conocimiento de dominio especializado (terminología, conceptos de nicho)? → continued pretraining o fine-tuning de dominio. ¿El problema es simplemente que el prompt no es suficientemente claro o específico? → optimizar el prompt primero antes de invertir en fine-tuning.

Para evaluar el catastrophic forgetting después del fine-tuning, el proceso mínimo viable es: evalúa en un subset de MMLU (100-500 preguntas de múltiple choice de conocimiento general) antes y después del fine-tuning. Una caída de más del 2-3% indica catastrophic forgetting significativo que requiere ajustar la estrategia de fine-tuning (menor LR, LoRA, data mixing).

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M4-T6 (Fine-tuning de modelos): la implementación técnica del fine-tuning con LoRA, QLoRA y el framework Hugging Face TRL.
- M6 (Ingeniería de prompts): el prompting avanzado es la alternativa al fine-tuning cuando los datos son escasos o el comportamiento deseado se puede especificar con instrucciones.
- M8 (LLMOps): el versionado de modelos fine-tuneados, el regression testing y el monitoring de degradación son aspectos operativos del fine-tuning en producción.

SECCIÓN 8 · RESUMEN EJECUTIVO

El preentrenamiento enseña al modelo conocimiento general del mundo con aprendizaje auto-supervisado sobre billones de tokens. El instruction tuning convierte un modelo base en un asistente con pares instrucción-respuesta (decenas de miles, alta calidad). El

RLHF/DPO refina el comportamiento con preferencias humanas (miles de comparaciones). El catastrophic forgetting ocurre cuando el fine-tuning sobrescribe el conocimiento del preentrenamiento: prevenirlo con LR baja, LoRA, pocas épocas y data mixing. La regla de oro: 500 ejemplos de alta calidad > 5.000 de baja calidad. Antes de fine-tunear: prueba prompting avanzado y RAG; fine-tunea solo cuando sea necesario para formato, comportamiento específico o dominio muy especializado.