

Limitaciones: alucinaciones y sesgos

Módulo 5 · NLP y Modelos de Lenguaje (LLMs)

Tasas reales de alucinación, causas estructurales, mitigaciones efectivas (RAG, CoT, self-consistency) y evaluación de sesgo en sistemas de alto riesgo.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Limitaciones de los LLMs: alucinaciones y sesgos

En 2026, una revisión sistemática de sistemas de NLP publicada en PMC documenta que las alucinaciones aparecen en el 31.4% de las interacciones reales con LLMs, subiendo al 60% en dominios complejos. Un estudio de 2025 encontró que los LLMs alucinan en 1 de cada 5 consultas de búsqueda. Las tasas de alucinación en benchmarks específicos (TruthfulQA) son superiores al 50% para los modelos base sin mitigaciones. El problema es real, medido, y tiene consecuencias directas para el diseño de sistemas de IA en producción.

Las alucinaciones y los sesgos son las dos limitaciones estructurales más importantes de los LLMs y las que más afectan a la confianza de los sistemas en producción. Este tema los aborda con precisión: qué son, por qué ocurren, cómo se miden, y cuáles son las estrategias de mitigación efectivas.

Alucinaciones: tipología y causas

Alucinaciones extrínsecas vs intrínsecas

Las alucinaciones extrínsecas son afirmaciones que no pueden verificarse ni contradecirse con las fuentes de referencia: el modelo inventa información no presente en ninguna fuente. Las alucinaciones intrínsecas son afirmaciones que contradicen directamente las fuentes disponibles en el contexto: el modelo contradice lo que está en el documento que se le ha proporcionado. Las extrínsecas son más difíciles de detectar porque requieren verificación contra conocimiento externo.

Las causas técnicas de las alucinaciones

Los LLMs alucinan por varias razones relacionadas con su naturaleza estadística. Primera: el modelo aprende a generar texto que suena correcto, no a verificar hechos. Cuando la "respuesta que suena correcta" y la "respuesta factualmente correcta" divergen, el modelo puede elegir lo primero. Segunda: el conocimiento del modelo no está distribuido uniformemente: tiene mucho conocimiento sobre temas frecuentes en internet y poco sobre temas raros o especializados. En los temas poco representados, genera lo más plausible estadísticamente aunque sea incorrecto. Tercera: el sobreconfinamiento (sycophancy): el modelo tiende a generar respuestas que se alinean con las expectativas implícitas del usuario, incluso si esas expectativas son incorrectas.

Sesgos: los prejuicios aprendidos del corpus

Los LLMs aprenden los sesgos presentes en sus datos de entrenamiento: sesgos de género (asociar ciertas profesiones con ciertos géneros), sesgos culturales (perspectiva anglocéntrica en cuestiones culturales y políticas), sesgos de representación (grupos minoritarios menos representados o con representaciones estereotipadas), y sesgos ideológicos (la distribución de perspectivas políticas en el corpus de entrenamiento). Estos sesgos se manifiestan en las predicciones del modelo de formas que pueden ser sutiles y difíciles de detectar.

Estrategias de mitigación efectivas

RAG: anclar las respuestas en fuentes verificables

RAG (Retrieval-Augmented Generation) es la mitigación más efectiva para alucinaciones de conocimiento: en lugar de depender de la memoria paramétrica del modelo, el sistema recupera documentos relevantes y los incluye en el contexto, pidiendo al modelo que base su respuesta solo en esa información. Con grounding efectivo, la tasa de alucinación en tareas de recuperación de información cae por debajo del 2% según evaluaciones de OpenAI. Las citas a los fragmentos fuente permiten verificar cada afirmación.

Chain of Thought: razonamiento paso a paso para reducir errores

CoT prompting reduce significativamente los errores de razonamiento al forzar al modelo a externalizar sus pasos intermedios. Un estudio PMC de 2025 documentó que las estrategias de prompting estructurado como CoT reducen las alucinaciones en un 22 puntos porcentuales en promedio. Sin embargo, paradójicamente, los modelos de razonamiento extendido (que usan CoT implícito) pueden tener mayores tasas de alucinación en preguntas factuales complejas porque la mayor longitud de generación ofrece más superficie para la deriva factual.

Self-consistency: verificación mediante múltiples muestras

Self-consistency (Wang et al., 2022) genera múltiples respuestas independientes para la misma pregunta y selecciona la respuesta por mayoría. Si el 7 de 10 muestras producen la misma respuesta, hay alta confianza en esa respuesta. Si las respuestas varían mucho, hay alta incertidumbre y el caso debe escalar a revisión humana. Es más costoso (requiere k llamadas en lugar de 1) pero produce estimaciones de confianza más fiables que la respuesta única.

Detección de alucinaciones: herramientas y métricas

La detección automática de alucinaciones es un campo activo. FactScore (Min et al., 2023) evalúa las afirmaciones factuales de un texto verificando cada una contra una base de conocimiento. SelfCheckGPT usa la consistencia entre múltiples muestras del mismo modelo como señal de confiabilidad. RAGAS incluye "faithfulness" como métrica: qué fracción de las afirmaciones del output están respaldadas por el contexto recuperado. Estas herramientas permiten monitorizar la tasa de alucinación en producción de forma continua.

SECCIÓN 4 · EJEMPLOS REALES

- Caso Mata vs Avianca (2023): abogados presentaron ante el tribunal federal del Sur de Nueva York un escrito citando seis casos judiciales inexistentes generados por ChatGPT. Los casos tenían nombres, fechas, partes y resúmenes plausibles pero eran completamente ficticios. El juez impuso sanciones económicas. La lección: los documentos jurídicos requieren human-in-the-loop y verificación contra bases de datos jurídicas reales.
- Sesgos de género en reclutamiento con IA: Amazon discontinuó en 2018 un sistema de screening de CVs con ML que había aprendido sesgos históricos de contratación, penalizando CVs con palabras como "mujeres" o con estudios en universidades femeninas. Aunque fue un sistema de ML clásico, el mismo problema aplica a LLMs: un LLM entrenado

en datos históricos de contratación reproduciría esos mismos sesgos.

- Morgan Stanley RAG system: el asistente de conocimiento de Morgan Stanley sobre 100.000 documentos de research financiero usa RAG con citas obligatorias. Cada afirmación en la respuesta incluye la referencia al documento fuente y el fragmento específico. Esto reduce drásticamente las alucinaciones y permite que los asesores verifiquen cualquier información antes de usarla con clientes.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Creer que los modelos más grandes no alucinan. Los modelos más grandes alucinan menos en dominios bien representados en el entrenamiento, pero pueden alucinar más con confianza en dominios poco representados. El tamaño del modelo no elimina las alucinaciones; las desplaza a los dominios donde la representación de datos es menor.

Error 2: Pensar que el RAG elimina completamente las alucinaciones. El RAG reduce drásticamente las alucinaciones de conocimiento, pero el modelo puede aún alucinar en la síntesis (afirmar algo que no está en los documentos recuperados, o distorsionar lo que sí está). La evaluación de faithfulness (¿el output está fundamentado en el contexto?) sigue siendo necesaria incluso con RAG.

Error 3: Ignorar los sesgos en aplicaciones con impacto en personas. Los LLMs tienen sesgos medibles por género, etnia y otras variables. En aplicaciones donde las decisiones del modelo afectan a personas (screening de CVs, scoring de crédito, evaluación de reclamaciones), los sesgos deben evaluarse explícitamente y mitigarse. El AI Act europeo requiere evaluación de sesgo para sistemas de alto riesgo.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

El framework de mitigación de alucinaciones por nivel de riesgo. Para aplicaciones de bajo riesgo (entretenimiento, ideas, borradores): prompting con instrucciones de admitir incertidumbre ("si no estás seguro, di que no lo sabes"), evaluación manual periódica de la tasa de alucinación. Para aplicaciones de riesgo medio (soporte al cliente, asistente de conocimiento interno): RAG con citas obligatorias, evaluación continua de faithfulness con RAGAS, escalado a humano para casos de baja confianza. Para aplicaciones de alto riesgo (legal, médico, financiero): RAG + human-in-the-loop obligatorio para cualquier afirmación factual, self-consistency para estimación de confianza, evaluación de sesgo por subgrupos.

Para detectar y medir sesgos en tu sistema LLM: construye un conjunto de evaluación de equidad con pares de prompts que solo difieren en variables protegidas (género, etnia, edad). Evalúa si el modelo produce respuestas sistemáticamente distintas para grupos diferentes. Usa herramientas como Fairlearn o IBM AI Fairness 360 para medir y cuantificar los sesgos detectados.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M7 (RAG): la solución arquitectónica principal para alucinaciones de conocimiento.
- M12 (Seguridad): las alucinaciones son también un vector de riesgo de seguridad cuando se explotan deliberadamente.

- M13 (Gobernanza): el AI Act requiere evaluación de sesgo para sistemas de alto riesgo.

SECCIÓN 8 · RESUMEN EJECUTIVO

Las alucinaciones (generar información incorrecta con confianza) aparecen en el 31% de las interacciones reales y hasta el 60% en dominios complejos. Las causas son estructurales: los LLMs generan lo estadísticamente plausible, no lo verificadamente correcto. Las mitigaciones más efectivas son: RAG con citas (reduce alucinaciones de conocimiento a <2%), CoT para reducir errores de razonamiento, self-consistency para estimar confianza, y system prompt con instrucción explícita de admitir ignorancia. Los sesgos son patrones aprendidos del corpus que deben evaluarse explícitamente en aplicaciones con impacto en personas. El AI Act requiere evaluación de equidad en sistemas de alto riesgo.