

Reducción de Alucinaciones mediante Prompting

Módulo 6 · Ingeniería de Prompts

Instrucciones de incertidumbre, grounding, citas, verificación antes de responder y evaluación con RAGAS en producción.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Reducción de Alucinaciones mediante Prompting

Las alucinaciones son el problema número uno que los profesionales reportan al desplegar LLMs en producción. El módulo 5 las analizó como limitación estructural. Este tema aborda la perspectiva del prompt engineer: qué técnicas de diseño de prompts reducen la tasa de alucinaciones sin recurrir a RAG o fine-tuning. Estas técnicas son especialmente relevantes cuando el sistema usa un LLM con conocimiento paramétrico (sin RAG) o cuando el RAG no recupera la información relevante para un caso específico.

Un estudio de 2025 publicado en Nature documentó que las estrategias de prompting estructurado reducen las alucinaciones en una media de 22 puntos porcentuales. No son una solución completa (el RAG es más efectivo para el conocimiento factual), pero son una capa adicional de defensa valiosa y de bajo coste de implementación.

Las técnicas de prompting que reducen alucinaciones

Instrucción explícita de admitir incertidumbre

La forma más directa de reducir alucinaciones es instruir explícitamente al modelo a admitir cuando no sabe algo. "Si no tienes suficiente información para responder con confianza, di explícitamente que no tienes esa información. Es preferible una respuesta incompleta pero honesta que una respuesta inventada que parezca completa." Los LLMs bien alineados (Claude, GPT-4, Gemini) responden bien a esta instrucción. La honestidad sobre la incertidumbre es un comportamiento que se puede inducir vía prompting.

Grounding explícito: "responde solo basándote en X"

Cuando proporcionas documentos de referencia o contexto en el prompt, instruir explícitamente al modelo a basar su respuesta solo en esa información reduce las alucinaciones de conocimiento: "Basándote únicamente en el siguiente documento, responde a la pregunta. Si la respuesta no se encuentra en el documento, di explícitamente que la información no está disponible." Esto es la base del RAG, pero también funciona como patrón de prompting cuando el contexto se proporciona directamente.

Solicitar citas y fuentes

Pedir al modelo que cite la fuente específica de cada afirmación factual ("para cada afirmación, indica en qué parte del documento te basas") crea dos beneficios: hace más probable que el modelo solo afirme lo que realmente está en el documento (porque necesita poder citar la fuente), y hace visible cuándo está alucinando (si cita una fuente que no existe o indica la parte incorrecta del documento).

Preguntas de verificación antes de la respuesta

Para respuestas de alta importancia, instruir al modelo a verificar su respuesta antes de finalizarla: "Antes de dar tu respuesta final, verifica: (1) ¿Cada afirmación está basada en información del contexto? (2) ¿Hay alguna afirmación que no puedas verificar? Si es así,

márcala como no verificada o elimínala." Este auto-cuestionamiento estructurado reduce las alucinaciones en la respuesta final.

SECCIÓN 3 · CÓMO FUNCIONA

Técnicas avanzadas de reducción de alucinaciones

CoT con verificación de hechos

CoT reduce las alucinaciones de razonamiento (errores en el proceso deductivo) pero no necesariamente las alucinaciones de conocimiento (afirmar hechos incorrectos). Una extensión útil es CoT con verificación de hechos: después de generar el razonamiento, el modelo verifica explícitamente cada afirmación factual contra el contexto disponible. "Después de razonar paso a paso, revisa tu razonamiento y marca con [VERIFICADO] cada afirmación que está explícitamente apoyada por el contexto, y con [NO VERIFICADO] cada afirmación que depende de tu conocimiento interno."

Decir "no sé" vs generar algo plausible

Los LLMs tienen un sesgo estadístico hacia generar algo (completar el texto) en lugar de admitir ignorancia. Este comportamiento se puede revertir parcialmente con calibración de prompting. Técnicas: few-shot con ejemplos donde el modelo dice "no tengo suficiente información para responder esto", instrucción de sistema que explicita que las respuestas incompletas son preferibles a las inventadas, y penalización implícita de la sobre-confianza en la descripción del rol.

Separación entre hechos y opinión/inferencia

Instruir al modelo a separar explícitamente hechos (afirmaciones verificables) de inferencias (conclusiones derivadas de hechos) de opiniones (juicios de valor): "En tu respuesta, distingue entre (1) hechos que puedes verificar en el contexto, (2) inferencias razonables basadas en esos hechos, y (3) tu opinión o valoración. Marca cada afirmación con [HECHO], [INFERENCIA] u [OPINIÓN]." Esta estructura hace transparente el nivel de certeza de cada parte de la respuesta.

SECCIÓN 4 · EJEMPLOS REALES

- Asistente de knowledge base empresarial: system prompt incluye "Si la respuesta no está en los documentos proporcionados, responde: No tengo información sobre este tema en la base de conocimiento disponible. No inventes información que no esté explícitamente en los documentos." La tasa de respuestas incorrectas pero confiables cae del 23% al 4% con esta instrucción.
- Sistema de QA médico: las respuestas incluyen siempre la distinción [BASADO EN EVIDENCIA] vs [INFERENCIA CLÍNICA] vs [OPINIÓN DEL SISTEMA]. Los médicos reportan que esta transparencia aumenta su confianza en el sistema porque les permite evaluar el nivel de certeza de cada parte de la recomendación.
- Agente de investigación financiera: se le instruye a no estimar valores numéricos que no se encuentran explícitamente en los documentos recuperados, sino a declarar que el dato no está disponible en las fuentes consultadas. Esto reduce los errores de proyección inventada

que anteriormente producían análisis financieros incorrectos.

- Chatbot legal: al responder preguntas sobre jurisprudencia, el modelo incluye una advertencia cuando una afirmación sobre un caso específico no está citada en los documentos de contexto: "NOTA: La afirmación sobre el caso X no está en los documentos proporcionados y puede no ser exacta. Verificar con fuentes primarias."

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Creer que las instrucciones de honestidad son suficientes para sistemas críticos. Las instrucciones reducen las alucinaciones pero no las eliminan. Para sistemas donde las alucinaciones tienen consecuencias graves (diagnóstico médico, asesoramiento legal, análisis financiero para inversión), las instrucciones de prompting deben complementarse con RAG, verificación automática de afirmaciones, y revisión humana.

Error 2: Instrucciones de honestidad demasiado agresivas que producen over-refusal. Si el modelo se instruye a decir "no sé" demasiado frecuentemente, puede volverse inútil para preguntas donde sí tiene la información. Calibra el umbral de incertidumbre con tu golden dataset para encontrar el equilibrio entre alucinación y over-refusal.

Error 3: Olvidar que la honestidad declarada no garantiza honestidad real. Un modelo puede generar la frase "No tengo suficiente información para afirmar esto con certeza" y después proceder a inventar información de forma convincente en la misma respuesta. Evalúa la reducción de alucinaciones con métricas concretas, no solo con la presencia de frases de admisión de incertidumbre.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Template de system prompt anti-alucinación para sistemas de QA con documentos: "Eres un asistente que responde preguntas basándose únicamente en los documentos proporcionados. Reglas: (1) Si la respuesta está en los documentos, cita el fragmento relevante antes de responder. (2) Si la respuesta no está en los documentos, responde exactamente: No encuentro información sobre [tema] en los documentos disponibles. (3) Si solo tienes información parcial, responde lo que puedes verificar y declara explícitamente qué aspectos no puedes responder. (4) Nunca inventes información que no esté en los documentos."

Para medir la efectividad de las técnicas anti-alucinación: construye un dataset de evaluación específico para alucinaciones con tres tipos de preguntas: preguntas con respuesta en el contexto (verdaderos positivos esperados), preguntas sin respuesta en el contexto (el modelo debería decir "no sé"), y preguntas con respuesta parcial en el contexto (el modelo debería responder parcialmente y declarar las lagunas). Mide la tasa de respuesta correcta en cada categoría.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M5-T8 (Alucinaciones): este tema provee las técnicas de prompting para mitigar el problema estructural analizado en el módulo 5.
- M7 (RAG): el grounding explícito en documentos de contexto es el principio de RAG aplicado a nivel de diseño de prompt.

- M8 (LLMOps): RAGAS y otras métricas de evaluación de alucinaciones son herramientas de monitorización continua en producción.

SECCIÓN 8 · RESUMEN EJECUTIVO

Las técnicas de prompting anti-alucinación reducen la tasa de alucinaciones en una media de 22 puntos porcentuales (estudio Nature 2025). Las más efectivas son: instrucción explícita de admitir incertidumbre, grounding explícito ("responde solo basándote en X"), solicitud de citas y fuentes, preguntas de verificación antes de la respuesta final, y separación de hechos/inferencias/opiniones. No reemplazan al RAG para el conocimiento factual, pero son una capa complementaria de bajo coste. Evalúa la efectividad con un dataset de tres tipos: preguntas con respuesta, sin respuesta, y con respuesta parcial en el contexto. Herramienta de producción: RAGAS para monitorización automática de faithfulness.