

Búsqueda Semántica e Híbrida

Módulo 7 · Sistemas RAG y Gestión del Conocimiento

Dense search, BM25, búsqueda híbrida con RRF, reranking y query transformation: el pipeline de recuperación óptimo.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Búsqueda Semántica e Híbrida

La búsqueda semántica es el corazón de cualquier sistema RAG. Cuando un usuario pregunta "¿cuáles son los procedimientos para solicitar vacaciones?", un sistema de búsqueda por palabras clave podría no encontrar el documento correcto si este usa el término "permisos retribuidos" en lugar de "vacaciones". La búsqueda semántica encuentra el documento por significado, no por palabras exactas. Sin embargo, la búsqueda semántica pura tiene sus propias limitaciones: falla con acrónimos, códigos de producto, nombres propios, y términos técnicos muy específicos que necesitan coincidencia exacta.

La búsqueda híbrida combina lo mejor de ambos mundos y es el estado del arte en 2025 para sistemas RAG de producción. El estudio BlendedRAG de IBM Research (abril 2024) demostró experimentalmente que combinar búsqueda vectorial, búsqueda sparse (BM25), y búsqueda de texto completo produce mejores resultados que cualquier método por separado. En 2025, el semantic chunking mejora el recall hasta un 9% adicional y el reranking añade un 10-30% de mejora en precisión.

Los tres tipos de búsqueda en RAG

Búsqueda densa (vector search): captura el significado

La búsqueda densa convierte la consulta en un vector de embedding y encuentra los vectores más cercanos en el índice por similitud coseno o producto punto. Captura la similitud semántica: "permisos retribuidos" y "vacaciones" son cercanos en el espacio vectorial porque aparecen en contextos similares. Es excelente para preguntas conceptuales donde el usuario puede expresar la misma idea con vocabulario distinto al del documento.

Búsqueda sparse (BM25): captura los términos exactos

BM25 (Best Match 25) es el algoritmo de recuperación de información más establecido. Puntúa los documentos por la frecuencia de los términos de la consulta en el documento, normalizado por la longitud del documento y el inverso de la frecuencia en el corpus. Es excelente para términos exactos: acrónimos (GDPR, ISO 27001), nombres de productos, versiones de software, códigos internos. Falla cuando la consulta usa vocabulario distinto al del documento.

Búsqueda híbrida: combinar dense y sparse

La búsqueda híbrida ejecuta ambas búsquedas en paralelo y combina sus resultados. Las técnicas de fusión más comunes son: Reciprocal Rank Fusion (RRF), que asigna puntuaciones basadas en el ranking relativo de cada resultado en cada búsqueda (simple, robusto, no requiere calibración de pesos); y Linear Combination, que suma las puntuaciones normalizadas de ambas búsquedas con pesos configurables (mejor rendimiento cuando los pesos están bien calibrados). RRF es el más usado por su robustez sin necesidad de calibración.

Reranking: el paso final que más mejora la precisión

¿Qué es el reranking y por qué importa?

La búsqueda híbrida recupera los top-K candidatos (típicamente K=20-50). Pero los primeros resultados de la búsqueda vectorial no siempre son los más útiles para responder la pregunta. El reranking aplica un modelo más sofisticado (cross-encoder) que considera la consulta y cada documento de forma conjunta para producir una puntuación de relevancia más precisa. Los top-5 rerankeados suelen ser significativamente más relevantes que los top-5 directos de la búsqueda. El coste adicional de reranking es 50-100ms de latencia, que se añade al tiempo de búsqueda.

Los modelos de reranking más usados en 2025: Cohere Rerank (API, \$2/1M tokens): excelente calidad, fácil de integrar. Cross-Encoder de Hugging Face (ms-marco-MiniLM-L-6-v2): open source, buena calidad, requiere GPU para latencia baja. Voyage AI Rerank: mejor calidad que Cohere en algunos dominios especializados. El reranking añade 10-30% de mejora en precisión (MRR@10) sobre la búsqueda sin reranking.

Query transformation: mejorar la consulta antes de recuperar

Las consultas de los usuarios no siempre están formuladas de forma óptima para la búsqueda. Query transformation aplica transformaciones a la consulta antes de buscar: query expansion (añadir términos relacionados), query rewriting (reformular en términos del dominio), HyDE (Hypothetical Document Embedding: generar un documento hipotético que respondería la pregunta y buscar por similitud a ese documento), y multi-query (generar múltiples variaciones de la consulta y fusionar los resultados).

SECCIÓN 4 · EJEMPLOS REALES

- Búsqueda híbrida en base de conocimiento legal: cuando un abogado busca "incumplimiento contrato suministros", la búsqueda densa captura documentos sobre responsabilidad contractual y penalizaciones aunque no usen esas palabras exactas. La búsqueda BM25 captura documentos que mencionan explícitamente "incumplimiento" y "suministros". La combinación produce el mejor recall.
- Reranking en sistema de soporte técnico: la búsqueda recupera 20 documentos de la knowledge base. El reranker evalúa cada uno en relación a la consulta específica y reordena. El resultado: el documento exactamente relevante (que antes estaba en posición 8) sube a posición 1. La resolución del ticket mejora significativamente.
- HyDE en sistemas de investigación científica: el usuario pregunta "¿cómo afecta la temperatura a la velocidad de reacción enzimática?". HyDE genera un párrafo hipotético de un paper científico que respondería esta pregunta y busca por similitud a ese párrafo hipotético, capturando mejor el tipo de contenido relevante que la búsqueda directa sobre la consulta del usuario.
- Multi-query RAG para preguntas ambiguas: la pregunta "¿cuánto cuesta el producto?" puede referirse al precio de lista, al precio con descuento, al precio de importación, o al coste total de propiedad. Multi-query genera 3-4 variaciones de la consulta orientadas a cada interpretación y fusiona los resultados.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Recuperar K demasiado pequeño. K=3 puede ser suficiente para preguntas simples pero insuficiente para preguntas que requieren síntesis de múltiples fuentes. Con reranking, recuperar K=20-50 y reranquear a los top-5 es mejor que recuperar solo K=5. El coste adicional de recuperar 20 en lugar de 5 es mínimo en bases vectoriales modernas.

Error 2: Ignorar la calidad de la consulta. Los usuarios del sistema no siempre formulan preguntas claras. Un sistema RAG robusto incluye una etapa de query understanding que detecta consultas ambiguas, muy cortas, o mal formuladas, y las mejora o solicita clarificación antes de buscar.

Error 3: No evaluar la cobertura vs la precisión en la búsqueda. Un sistema puede tener alta precisión (los chunks que recupera son relevantes) pero baja cobertura (no recupera todos los chunks relevantes). La métrica correcta para evaluar la recuperación es el recall@K: de todos los chunks relevantes para esta pregunta, ¿cuántos están en el top-K recuperado?

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Implementación de búsqueda híbrida con Qdrant: Qdrant soporta búsqueda híbrida nativamente con fusión de RRF. Define un índice con vectores densos (embedding) y vectores sparse (BM25 o SPLADE). En cada búsqueda, ejecuta ambas búsquedas y fusiona con RRF. El resultado es un ranking combinado que aprovecha las ventajas de ambos métodos. Alternativamente, LangChain y LlamaIndex tienen retrievers híbridos que ejecutan búsqueda vectorial y BM25 en paralelo y fusionan los resultados.

Para implementar reranking con Cohere: `from cohere import Client. client = Client(api_key). response = client.rerank(model="rerank-english-v3.0", query=user_query, documents=retrieved_chunks, top_n=5)`. El resultado es una lista de los 5 chunks más relevantes reordenados por el modelo de reranking. La integración con LangChain es CohereRerank como reranker en la cadena de recuperación.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M7-T2 (Bases vectoriales): las bases vectoriales como Qdrant y Weaviate implementan la búsqueda híbrida nativamente.
- M7-T5 (Arquitectura RAG completa): la búsqueda semántica e híbrida es el componente de recuperación en el pipeline RAG completo.
- M7-T7 (Evaluación RAG): context recall y context precision son las métricas que miden directamente la calidad de la búsqueda.

SECCIÓN 8 · RESUMEN EJECUTIVO

La búsqueda densa captura similitud semántica pero falla en términos exactos. La búsqueda sparse (BM25) captura términos exactos pero falla en preguntas conceptuales. La búsqueda híbrida combina ambas con RRF y es el estándar de producción (demostrado por IBM BlendedRAG 2024). El reranking (Cohere, Voyage AI) añade 10-30% de mejora en precisión con 50-100ms de latencia adicional. El pipeline

optimizado: hybrid search top-50 → reranking top-5 → insertar en prompt. Query transformation mejora consultas ambiguas o mal formuladas. Métrica de evaluación: recall@5 (¿cuántos chunks relevantes están en el top-5 recuperado?).