

Evaluación de Sistemas RAG

Módulo 7 · Sistemas RAG y Gestión del Conocimiento

RAGAS: faithfulness, answer relevancy, context recall y precision. Evaluacion offline y monitorizacion continua en produccion.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Evaluación de Sistemas RAG

Un sistema RAG tiene dos componentes que pueden fallar de forma independiente: el retriever (¿recupera los documentos correctos?) y el generador (¿genera una respuesta fiel al contexto recuperado?). Evaluar solo la calidad de la respuesta final oculta qué componente está fallando y por qué. Un sistema que genera respuestas incorrectas puede hacerlo porque recupera documentos irrelevantes, o porque alucina sobre documentos relevantes, o ambas. Sin métricas separadas para retrieval y generación, el diagnóstico es imposible.

RAGAS (Retrieval Augmented Generation Assessment, arXiv:2309.15217, presentado en EACL 2024) es el framework de referencia para evaluación de sistemas RAG sin necesidad de anotaciones humanas extensas. Procesa más de 5 millones de evaluaciones al mes para empresas como AWS, Microsoft, Databricks y Moody's. Su conjunto de métricas cubre tanto la calidad del retrieval como la calidad de la generación.

Las métricas RAGAS

Faithfulness: ¿la respuesta está fundamentada en el contexto?

Faithfulness mide qué fracción de las afirmaciones en la respuesta está respaldada por el contexto recuperado. El proceso: 1) identificar todas las afirmaciones en la respuesta, 2) verificar si cada afirmación puede inferirse del contexto recuperado. Faithfulness = afirmaciones soportadas / total de afirmaciones. Un score de 0.9 significa que el 90% de las afirmaciones en la respuesta están respaldadas por los documentos recuperados. Las afirmaciones no soportadas son potenciales alucinaciones.

Answer Relevancy: ¿la respuesta responde la pregunta?

Answer Relevancy mide qué tan relevante es la respuesta para la pregunta del usuario. El proceso: generar N preguntas que el LLM haría a alguien que hubiera dado esa respuesta, calcular la similitud coseno entre las preguntas generadas y la pregunta original. Un score alto indica que la respuesta está orientada a responder la pregunta original, no a desviar o responder otra cosa.

Context Recall: ¿la recuperación cubre la respuesta correcta?

Context Recall mide qué fracción de la respuesta correcta (ground truth) puede atribuirse al contexto recuperado. Requiere una respuesta de referencia. Context Recall = afirmaciones de la referencia que pueden atribuirse al contexto / total de afirmaciones de la referencia. Un score bajo indica que el retrieval no está recuperando toda la información necesaria para responder correctamente.

Context Precision: ¿los documentos recuperados son relevantes?

Context Precision mide qué fracción de los documentos recuperados son realmente útiles para responder la pregunta. Evalúa la eficiencia del retrieval: un sistema que recupera 10 documentos de los cuales solo 2 son relevantes tiene baja precisión. Alta precisión significa que

el retriever es selectivo y no introduce ruido en el contexto.

SECCIÓN 3 · CÓMO FUNCIONA

Implementación y uso de RAGAS en producción

Instalación: `pip install ragas`. Las métricas principales son: Faithfulness, AnswerRelevancy, ContextRecall, ContextPrecision. Para evaluarlas sin ground truth (reference-free): Faithfulness y AnswerRelevancy no requieren respuesta de referencia. Para ContextRecall y ContextPrecision, se necesitan respuestas de referencia o se pueden usar respuestas generadas por un LLM más capaz como proxy.

El proceso de evaluación con RAGAS: construye un dataset de evaluación con 50-200 pares (pregunta, contextos_recuperados, respuesta_generada, respuesta_referencia_opcional). Ejecuta las métricas sobre el dataset. Analiza los casos de bajo rendimiento para identificar dónde falla el sistema. Itera sobre el chunking, el retrieval, o el prompt de generación según el diagnóstico.

Métricas de latencia y coste para producción

Además de la calidad, un sistema RAG en producción debe monitorizar: latencia de retrieval (target: <100ms), latencia de generación (función del modelo LLM y del número de tokens), latencia end-to-end (target: <3 segundos para uso conversacional), coste por consulta (embedding de la consulta + retrieval + reranking + LLM), y throughput (consultas por segundo para dimensionar la infraestructura).

SECCIÓN 4 · EJEMPLOS REALES

- Evaluación pre-despliegue de KB-RAG (empresa tecnológica): RAGAS sobre 200 preguntas del golden dataset. Resultado inicial: Faithfulness 0.72, ContextRecall 0.65. Diagnóstico: el chunking está fragmentando contexto relevante (baja recall) y el LLM está añadiendo información no en el contexto (baja faithfulness). Acciones: aumentar el tamaño del chunk de 256 a 512 tokens (mejora recall a 0.81), añadir instrucción anti-alucinación en el prompt (mejora faithfulness a 0.89). Resultado post-iteración: sistema listo para producción.
- Monitorización continua en producción (fintech): se evalúa una muestra aleatoria del 5% de las consultas en producción con RAGAS diariamente. Cuando Faithfulness cae por debajo de 0.80 en la muestra diaria, se dispara una alerta. Causas típicas de degradación: documentos desactualizados en el corpus, cambio en el tipo de preguntas que hacen los usuarios, o regresión en la calidad del LLM generador.
- A/B testing de estrategias de chunking (media company): comparación de fixed-size vs semantic chunking usando RAGAS sobre el mismo golden dataset. Semantic chunking: ContextRecall 0.81 vs 0.74 con fixed-size (+9.5%). ContextPrecision: 0.83 vs 0.79. La mejora justifica la complejidad adicional del semantic chunking para el corpus de artículos de prensa.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Evaluar solo la calidad de la respuesta final (end-to-end) sin las métricas de componente. Si la respuesta final es incorrecta, sin métricas separadas de retrieval y generación es imposible saber si el problema está en el retrieval (ContextRecall baja) o en la generación (Faithfulness baja). Las métricas de componente son imprescindibles para el diagnóstico.

Error 2: Golden dataset demasiado fácil o no representativo. Un golden dataset con solo preguntas simples con respuesta directa en el corpus puede dar scores RAGAS muy altos que no se traducen en buen rendimiento con las preguntas reales de los usuarios. Incluye preguntas difíciles, ambiguas, y de síntesis en el golden dataset.

Error 3: No monitorizar en producción, solo evaluar antes del despliegue. El corpus cambia, los patrones de consulta de los usuarios evolucionan, y los modelos LLM pueden cambiar de comportamiento. La evaluación pre-despliegue es necesaria pero no suficiente. Implementa evaluación continua en producción con muestreo.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Implementación mínima de RAGAS para evaluación offline: `from ragas import evaluate, from ragas.metrics import faithfulness, answer_relevancy, context_recall, context_precision`. Construye el dataset con `Dataset.from_dict({"question": [...], "answer": [...], "contexts": [...], "ground_truth": [...]})`. Ejecuta `result = evaluate(dataset, metrics=[faithfulness, answer_relevancy, context_recall, context_precision])`. El resultado es un DataFrame con los scores por métrica para cada ejemplo.

Para monitorización en producción: implementa un sampler que selecciona el 5-10% de las consultas reales. Para cada consulta muestreada, guarda la pregunta, los contextos recuperados, y la respuesta generada. Ejecuta RAGAS diariamente sobre las consultas muestreadas del día anterior. Almacena los scores en una serie temporal. Define alertas cuando cualquier métrica cae por debajo del umbral mínimo de aceptación.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M5-T7 (Evaluación de LLMs): RAGAS es la aplicación de los principios de evaluación de LLMs al caso específico de sistemas RAG.
- M8 (LLMOps): la evaluación continua con RAGAS en producción es un componente central de LLMOps para sistemas RAG.
- M6-T9 (Reducción de alucinaciones): Faithfulness de RAGAS mide directamente la tasa de alucinación en el contexto de RAG.

SECCIÓN 8 · RESUMEN EJECUTIVO

RAGAS (arXiv:2309.15217, EACL 2024) es el framework estándar de evaluación de sistemas RAG. Sus métricas principales son: Faithfulness (¿la respuesta está fundamentada en el contexto?), Answer Relevancy (¿la respuesta responde la pregunta?), Context Recall (¿el retrieval cubre la información necesaria?), Context Precision (¿los documentos recuperados son relevantes?). La interpretación de diagnóstico: Faithfulness baja → LLM alucina; Context Recall baja → retrieval incompleto; Context Precision baja → retrieval ruidoso. Implementación: `pip install ragas`.

Monitoriza en producción muestreando el 5-10% de consultas diariamente. DeepEval es una alternativa más customizable.