

GraphRAG y Técnicas Avanzadas de RAG

Módulo 7 · Sistemas RAG y Gestión del Conocimiento

GraphRAG local vs global search, RAPTOR, Multimodal RAG y el árbol de decisión para elegir la variante correcta.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

GraphRAG y Técnicas Avanzadas de RAG

El RAG estándar basado en chunks de texto tiene una limitación fundamental: el "blinkered chunk effect" (efecto del chunk con anteojeras). Un chunk extraído de un documento largo pierde el contexto que le da significado: sin saber quién es el personaje principal de la novela, el fragmento donde "ella toma una decisión crítica" no tiene sentido. En documentos empresariales complejos (informes anuales, expedientes de cliente con múltiples interacciones, bases de código con dependencias entre módulos), esta limitación produce recuperaciones que contienen información técnicamente correcta pero semánticamente incompleta.

GraphRAG de Microsoft (publicado en 2024, open-sourced a mediados de 2024, más de 10.000 estrellas en GitHub en pocas semanas) propone una arquitectura radicalmente distinta: construir un grafo de entidades y relaciones sobre el corpus completo y usar ese grafo como base de recuperación. En lugar de recuperar chunks por similitud vectorial, GraphRAG navega el grafo para encontrar las entidades y relaciones más relevantes para la consulta.

GraphRAG: recuperación basada en grafos de conocimiento

Cómo funciona GraphRAG

GraphRAG tiene dos fases. La fase de indexación: procesa todos los documentos del corpus, extrae entidades (personas, organizaciones, conceptos, productos) y relaciones entre ellas usando un LLM, construye un grafo de conocimiento donde los nodos son entidades y las aristas son relaciones, y genera descripciones de comunidades de entidades relacionadas (usando el algoritmo Leiden para detección de comunidades). La fase de consulta: convierte la consulta en una búsqueda en el grafo, recupera las entidades y relaciones relevantes, y usa el contexto del grafo (incluyendo las relaciones entre entidades) para fundamentar la respuesta.

Local vs Global search en GraphRAG

GraphRAG tiene dos modos de búsqueda. Local search navega el grafo de entidades cercanas a las entidades mencionadas en la consulta: "¿Cuáles son las subsidiarias de la empresa X?" recupera el nodo "empresa X" y sus conexiones de tipo "subsidiaria". Produce respuestas precisas sobre entidades específicas. Global search usa las descripciones de comunidades para responder preguntas de alto nivel que requieren síntesis de todo el corpus: "¿Cuáles son los principales temas estratégicos en los informes anuales de los últimos 5 años?" navega las comunidades temáticas del grafo.

Cuándo GraphRAG supera al RAG estándar

GraphRAG supera al RAG estándar en preguntas que requieren razonamiento sobre relaciones entre entidades (¿quién conoce a quién?, ¿qué empresas compiten en el mismo segmento?), en preguntas de síntesis global sobre todo el corpus (¿cuáles son los temas principales?), y en corpus narrativos densos (novelas, expedientes, historiales médicos) donde el contexto de una

entidad está distribuido a lo largo de múltiples documentos. El RAG estándar sigue siendo mejor para preguntas simples de recuperación de hechos y para casos donde la latencia y el coste son críticos (GraphRAG es significativamente más caro en la fase de indexación).

SECCIÓN 3 · CÓMO FUNCIONA

Técnicas avanzadas adicionales

RAPTOR: resúmenes jerárquicos para mejor síntesis

RAPTOR (Recursive Abstractive Processing for Tree-Organized Retrieval, Sarthi et al., 2024) construye un árbol de resúmenes jerárquicos sobre el corpus: agrupa chunks similares, genera resúmenes de cada grupo, luego agrupa los resúmenes y genera resúmenes de resúmenes, creando múltiples niveles de abstracción. Cuando llega una consulta, recupera información de todos los niveles del árbol según la necesidad: detalles específicos de chunks individuales para preguntas concretas, y resúmenes de alto nivel para preguntas de síntesis. Mejora significativamente el rendimiento en preguntas que requieren información de múltiples partes del corpus.

Multimodal RAG: texto, imágenes y tablas

Los documentos empresariales no son solo texto: contienen tablas, gráficos, diagramas, e imágenes. El RAG estándar basado en texto pierde esta información. Multimodal RAG incluye el procesamiento de imágenes y tablas en el pipeline. Las imágenes se pueden describir con un modelo de visión-lenguaje y la descripción se indexa junto con el texto. Las tablas pueden convertirse a markdown o a formato JSON para preservar la estructura. NVIDIA reporta una mejora del 80% en interpretación de gráficos con multimodal RAG.

RAG con reranking cross-encoder

Los rerankers cross-encoder (como ms-marco-MiniLM) evalúan cada par (consulta, documento) de forma conjunta en lugar de generar embeddings independientes. Esto es más preciso pero más lento que el ranking basado en similitud de embeddings. El proceso estándar: retrieval rápido con bi-encoder para top-50, reranking preciso con cross-encoder para top-5. El reranking añade 10-30% de mejora en precisión (MRR@10) con 50-100ms de latencia adicional.

SECCIÓN 4 · EJEMPLOS REALES

- GraphRAG en análisis de noticias (empresa de media): corpus de 100.000 artículos de noticias sobre el sector energético. GraphRAG construye un grafo de empresas, directivos, regulaciones, y eventos. La consulta "¿cómo está cambiando el panorama de los operadores de redes de gas en Europa?" navega el grafo para identificar todas las empresas relevantes, sus adquisiciones recientes, y los cambios regulatorios, produciendo una respuesta de síntesis imposible con RAG estándar.
- RAPTOR en documentación técnica extensa (empresa de software): documentación de un sistema con 5.000 páginas distribuidas en 200 módulos interdependientes. RAPTOR construye resúmenes por módulo y luego resúmenes de grupos de módulos relacionados. Las consultas sobre la arquitectura general usan los resúmenes de alto nivel; las consultas sobre APIs específicas usan los chunks detallados.

- Multimodal RAG en análisis financiero (banco de inversión): informes anuales de empresas con tablas de resultados financieros y gráficos de evolución. El RAG estándar perdía la información de las tablas. Multimodal RAG convierte las tablas a markdown y describe los gráficos, indexando todo. Las consultas sobre métricas financieras específicas ahora recuperan los datos de las tablas correctamente.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Aplicar GraphRAG a todos los corpus sin evaluar si el RAG estándar es suficiente. GraphRAG tiene un coste de indexación significativo y latencia de consulta mayor. Para preguntas simples de recuperación de hechos en corpus bien estructurados, el RAG estándar con búsqueda híbrida y reranking produce resultados comparables con mucho menor coste.

Error 2: Asumir que la calidad del grafo de entidades es siempre alta. La extracción de entidades y relaciones por LLM introduce errores: entidades mal identificadas, relaciones incorrectas, y relaciones faltantes. La calidad del grafo GraphRAG depende de la calidad del corpus y del LLM de extracción. Valida siempre la calidad del grafo con una muestra antes de indexar todo el corpus.

Error 3: No evaluar GraphRAG vs RAG estándar en tu caso de uso específico. GraphRAG no es universalmente mejor que RAG estándar. Evalúa ambas opciones sobre tu golden dataset y elige la que produce mejor calidad para tu tipo de preguntas y tu presupuesto de coste y latencia.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Para experimentar con GraphRAG: instala microsoft/graphrag (pip install graphrag). Configura el pipeline con tu LLM de extracción (GPT-4o-mini es un buen balance calidad/coste para la extracción de entidades), tu corpus de documentos, y los parámetros de clustering. Ejecuta la indexación (puede tomar horas y costar decenas de dólares para corpus grandes). Evalúa la calidad de las respuestas en tu golden dataset comparando con RAG estándar.

Para multimodal RAG: usa docling o unstructured.io para parsear PDFs con preservación de tablas y extracción de imágenes. Para las imágenes, usa un modelo de visión-lenguaje (GPT-4V, Claude Sonnet, Gemini) para generar descripciones. Indexa tanto el texto como las descripciones de imágenes y el contenido de tablas en formato markdown. El pipeline de ingesta es más complejo pero produce significativamente mejor calidad para documentos ricos en contenido no textual.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M1-T7 (Grafos de conocimiento): GraphRAG construye y navega grafos de conocimiento sobre el corpus.
- M7-T5 (Arquitectura RAG completa): GraphRAG y RAPTOR son variantes avanzadas de la arquitectura RAG base.
- M10 (Agentes): los agentes pueden usar GraphRAG como herramienta de recuperación para razonamiento sobre relaciones entre entidades.

GraphRAG (Microsoft, 2024) construye un grafo de entidades y relaciones sobre el corpus y recupera por navegación del grafo en lugar de por similitud vectorial. Supera al RAG estándar en preguntas sobre relaciones entre entidades y en síntesis global. Local search para entidades específicas; global search para preguntas de panorama general. Coste de indexación alto (múltiples llamadas LLM). RAPTOR construye resúmenes jerárquicos para preguntas multi-nivel. Multimodal RAG incluye tablas e imágenes en el índice (+80% en interpretación de gráficos). El árbol de decisión: preguntas simples → RAG estándar; relaciones entre entidades → GraphRAG; multi-nivel → RAPTOR; tablas/imágenes → Multimodal.