

Ciclo de Vida de Modelos LLM en Producción

Módulo 8 · Ingeniería de Modelos y LLMOps

Fases del ciclo de vida, cinco pilares de observabilidad, SLOs, checklist de despliegue y plataformas LLMOps 2025.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Ciclo de Vida de Modelos LLM en Producción

El 85% de los proyectos de IA fracasan según Gartner. La causa más frecuente no es técnica: es operativa. Los equipos construyen un modelo que funciona en el notebook, lo despliegan en producción sin infraestructura de monitorización, y descubren los problemas cuando los usuarios se quejan. LLMOps (Large Language Model Operations) es el conjunto de prácticas, herramientas, y procesos que hacen que los sistemas LLM funcionen de forma fiable, escalable, y mejorable en producción.

LLMOps es una especialización de MLOps adaptada a las características únicas de los modelos de lenguaje: comportamiento no determinista (el mismo input puede producir outputs distintos), outputs difíciles de evaluar automáticamente (la calidad del texto no se puede medir con una sola métrica), coste basado en tokens (el coste varía con el volumen de texto procesado), y vulnerabilidades específicas (prompt injection, alucinaciones, sesgos). Un estudio de 2025 estimó que las alucinaciones de LLMs costaron a las empresas más de 67.4 billones de dólares en pérdidas durante 2024.

Las fases del ciclo de vida de un sistema LLM

Fase 1: Diseño y selección del modelo

La primera fase define los requisitos del sistema: qué tareas debe resolver, qué latencia es aceptable, cuál es el presupuesto de coste por consulta, cuáles son los requisitos de privacidad y compliance, y qué volumen de consultas se espera. Con estos requisitos, se selecciona el modelo base (modelo frontier via API vs modelo open source autohosteado), el enfoque de adaptación (prompting vs RAG vs fine-tuning vs combinación), y el stack tecnológico.

Fase 2: Desarrollo y evaluación

La fase de desarrollo incluye el diseño del prompt o del pipeline RAG, la construcción del golden dataset de evaluación (50-500 casos representativos), el fine-tuning si es necesario, y la evaluación rigurosa sobre el golden dataset con métricas apropiadas para el caso de uso. Esta fase debe producir una línea base de rendimiento documentada que servirá como referencia para detectar regresiones en producción.

Fase 3: Despliegue

El despliegue incluye la configuración del servidor de inferencia (vLLM, TGI, o API de proveedor), la configuración del entorno de producción (variables de entorno, secretos, rate limiting), el despliegue gradual (canary deployment, shadow mode), y la verificación de que el sistema funciona correctamente bajo condiciones reales antes de la apertura completa.

Fase 4: Monitorización y mejora continua

La fase de producción es la más larga y la más crítica. Incluye: logging de todas las interacciones (inputs, outputs, latencia, coste), evaluación continua de calidad (muestra del 5-10% con métricas automáticas o LLM-as-judge), detección de drift (cambio en la distribución

de inputs o degradación de la calidad), alertas basadas en umbrales de SLO, y el ciclo de mejora (identificar los casos de peor rendimiento → iterar el prompt o el sistema → evaluar → re-desplegar).

SECCIÓN 3 · CÓMO FUNCIONA

Los cinco pilares de la observabilidad LLM

La observabilidad LLM de alta calidad se construye sobre cinco pilares. Primero, la evaluación continua de outputs: muestrear y evaluar regularmente la calidad de las respuestas con métricas automáticas y LLM-as-judge. Segundo, el tracing distribuido: capturar cada paso del pipeline (retrieval, reranking, prompt construction, LLM call, post-processing) con tiempos y contenidos para diagnóstico. Tercero, la optimización de prompts: versionar los prompts y trackear el impacto de cada cambio en las métricas de calidad. Cuarto, la monitorización RAG: seguir métricas de faithfulness, context recall y context precision en sistemas RAG. Quinto, la gestión del ciclo de vida: versionado de modelos, rollback capabilities, y gestión del drift.

Los SLOs (Service Level Objectives) son los compromisos de calidad del sistema que definen qué constituye un servicio aceptable. Para un sistema LLM típico, los SLOs incluyen: latencia P99 < 3s, disponibilidad > 99.5%, tasa de errores < 0.1%, faithfulness > 0.85 (para sistemas RAG), y tasa de alucinaciones < 5%. Cuando un SLO se viola, se dispara una alerta y el on-call engineer investiga y actúa.

SECCIÓN 4 · EJEMPLOS REALES

- Ciclo de vida de un chatbot de soporte (empresa de software B2B): fase de diseño (selección de GPT-4o-mini + RAG sobre documentación), desarrollo (prompt engineering + golden dataset de 200 tickets), despliegue (canary 5% del tráfico durante 1 semana), producción con monitorización de LangSmith (tracing + LLM-as-judge sobre muestra del 5%). Ciclo de mejora mensual: análisis de los 50 casos de peor rating → identificación de problemas comunes → actualización de prompts o del corpus RAG → evaluación → despliegue.
- Gestión del drift en modelo de clasificación de documentos legales: monitorización diaria de la distribución de tipos de documentos recibidos. Cuando la distribución cambia significativamente respecto al baseline (nuevo tipo de contrato que el sistema no había visto), se dispara una alerta. El equipo añade ejemplos del nuevo tipo al golden dataset, actualiza el fine-tuning, y redespiega.
- Rollback en producción (empresa fintech): actualización del modelo base de gpt-4o a gpt-4o-2025-04 provocó degradación del 8% en la métrica de faithfulness del sistema RAG financiero. El sistema de monitorización detectó la degradación en 4 horas. Rollback al modelo anterior en 15 minutos. Análisis post-mortem: el nuevo modelo seguía las instrucciones de un prompt de formato específico de forma distinta; se requirió actualizar el prompt antes de re-desplegar el nuevo modelo.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: No versionar los prompts junto con el código. Un cambio de prompt es un cambio de sistema que puede mejorar o degradar el rendimiento. Sin versionado en Git con hash

de commit, es imposible reproducir el estado exacto del sistema en cualquier momento histórico o hacer rollback a una versión específica del prompt.

Error 2: Monitorizar solo la latencia y el coste, no la calidad. Los dashboards técnicos de latencia y disponibilidad no capturan si el sistema está produciendo respuestas útiles o correctas. La calidad del output debe monitorizarse con métricas semánticas. Sin monitorización de calidad, el sistema puede degradarse silenciosamente durante semanas antes de que los usuarios se quejen.

Error 3: Despliegue big-bang en lugar de gradual. Desplegar un cambio al 100% del tráfico inmediatamente elimina la capacidad de detectar problemas antes de que afecten a todos los usuarios. El canary deployment (5% del tráfico al nuevo sistema, comparar métricas con el sistema actual antes de escalar) es el estándar mínimo.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

El checklist de LLMOps para lanzar un sistema LLM a producción: golden dataset construido y documentado, línea base de métricas de calidad establecida, logging habilitado (inputs, outputs, latencia, tokens, coste), tracing configurado (LangSmith, Langfuse, o similar), alertas configuradas sobre SLOs críticos, proceso de rollback documentado y probado, prompt versionado en Git, proceso de mejora continua documentado (quién revisa los logs, con qué frecuencia, qué métricas trigger acciones).

Para implementar el ciclo de mejora continua: establece una cadencia de revisión (semanal para sistemas críticos, mensual para sistemas internos). En cada revisión: descarga los últimos 1.000 outputs del sistema, filtra los 50 con peor rating (usuario o LLM-as-judge), agrupa por tipo de problema, identifica si el problema está en el retrieval, el prompt, o el modelo, define una acción correctiva específica, evalúa el impacto en el golden dataset antes de desplegar.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M8-T7 (Observabilidad LLMOps): profundiza en las herramientas de tracing y monitorización.
- M5-T7 (Evaluación de LLMs): el golden dataset y las métricas de evaluación son el corazón del ciclo de vida LLM.
- M7-T7 (Evaluación RAG): RAGAS es la herramienta de evaluación continua para sistemas RAG en producción.

SECCIÓN 8 · RESUMEN EJECUTIVO

LLMOps es MLOps adaptado a las características únicas de los LLMs: comportamiento no determinista, métricas semánticas, prompts como código, y vulnerabilidades específicas. El ciclo de vida tiene cuatro fases: diseño (requisitos + selección), desarrollo (prompt/RAG/fine-tuning + evaluación), despliegue (canary), y producción (monitorización + mejora continua). Los cinco pilares de observabilidad: evaluación continua, tracing distribuido, versionado de prompts, monitorización RAG, y gestión del ciclo de vida. Las plataformas de referencia: LangSmith, Langfuse, W&B; Weave, Braintrust. El 85% de los proyectos de IA fracasan; LLMOps es la disciplina que cierra esa brecha.