

Cloud vs On-Premise para IA

Módulo 9 · Infraestructura y Despliegue

TCO comparado, break-even, estrategia híbrida, proveedores GPU especializados y el proceso de decision.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Cloud vs On-Premise para IA: la Decisión Estratégica

La decisión de alojar sistemas de IA en cloud o en infraestructura propia es una de las más estratégicas que enfrentan las organizaciones en 2025. El gasto en infraestructura de hardware de IA alcanzó 47.4 billones de dólares en 2024, un 97% de incremento interanual (IDC). El 55% de las empresas evitan al menos algunos casos de uso de IA por preocupaciones de seguridad de datos (Deloitte). El 57% cita la privacidad de datos como el mayor inhibidor de la adopción de IA (IBM). Y el 68% de las compañías con IA en producción han adoptado alguna forma de estrategia híbrida (Deloitte 2023 Technology Industry Outlook).

Esta decisión no es binaria ni permanente. Es una decisión que evoluciona con el volumen de uso, los requisitos regulatorios, las capacidades del equipo, y el estado del mercado de hardware. En 2025, el mercado de GPU cloud se ha democratizado: proveedores especializados como CoreWeave, Lambda Labs, y Runpod ofrecen H100 a \$2.10-\$3/hora, 50-70% más barato que los hiperscalares. Pero la infraestructura propia puede ser más económica a largo plazo con alta utilización sostenida.

Los tres modelos de despliegue

Cloud pública (API de proveedor)

El modelo más simple: usar APIs de OpenAI, Anthropic, Google, o Mistral. Cero inversión en infraestructura, cero mantenimiento, acceso inmediato a los modelos más capaces. El coste es variable (por token) y escala linealmente con el uso. La privacidad de datos es la mayor preocupación: los datos del usuario se procesan en servidores del proveedor. Para muchas organizaciones en sectores regulados (salud, finanzas, legal), esto puede ser un bloqueante o requerir contratos específicos de procesamiento de datos (DPA).

Cloud de GPU especializado (modelo auto-hosteado en cloud)

El punto medio: alquilar GPUs en la nube (AWS, GCP, Azure, o proveedores especializados como CoreWeave, Lambda Labs, Runpod) y desplegar modelos open source con vLLM o TGI. Control total sobre el modelo y los datos, coste previsible (por hora de GPU), sin CAPEX de hardware. Los proveedores especializados ofrecen H100 desde \$2.10/hora, A100 desde \$1.50/hora. La latencia de aprovisionamiento es de minutos a horas. Sin coste de personal de infraestructura para mantenimiento físico.

On-premise (infraestructura propia)

El mayor control y potencialmente el menor coste a largo plazo. Requiere inversión CAPEX significativa: un servidor con 8x H100 cuesta \$250.000-\$400.000, más infraestructura de soporte (red, almacenamiento, cooling). Los costes operativos anuales son el 20-35% del CAPEX (electricidad, cooling, mantenimiento). El mayor coste oculto: el personal. Un ingeniero de infraestructura GPU a coste cargado cuesta \$75.000-\$100.000/año; en tres años, \$225.000-\$300.000, comparables al coste del hardware. Los lead times de hardware son de 2-6

semanas para H100 y 4-8 semanas para H200 en 2025.

SECCIÓN 3 · CÓMO FUNCIONA

El análisis de TCO (Total Cost of Ownership)

Para calcular el TCO de on-premise vs cloud, los componentes son: hardware (CAPEX, amortizado a 3-5 años), electricidad (8x H100 consume ~10kW; a \$0.12/kWh US = \$8.700/año, más 25-40% de cooling), personal (0.5 FTE de ingeniería de infraestructura = \$75.000-\$100.000/año), mantenimiento y reemplazo (GPUs fallan al 5-10% anual; un H100 de reemplazo cuesta \$25.000-\$35.000 y tarda semanas), y oportunidad (meses de lead time de hardware vs acceso inmediato en cloud). Los costes ocultos suelen representar el 40-60% del TCO on-premise (IDC).

La estrategia híbrida es la adoptada por el 68% de las empresas en producción: carga base en on-premise (workloads predecibles, alta utilización sostenida) + burst en cloud (picos de demanda, workloads experimentales, fine-tuning ocasional). Esta estrategia maximiza la utilización del hardware propio (manteniendo >80% para rentabilizar la inversión) mientras gestiona los picos sin sobredimensionar.

Los factores no económicos que determinan la decisión

Más allá del coste, los factores clave son: Regulación y soberanía de datos (el RGPD, el AI Act europeo, HIPAA, PCI-DSS pueden requerir que los datos permanezcan en jurisdicciones específicas). Latencia (on-premise elimina la latencia de red para aplicaciones que requieren <50ms de respuesta). Control del modelo (en cloud API no controlas la versión del modelo, en cloud GPU sí, en on-premise total). Seguridad (un banco puede no poder enviar datos de clientes a APIs de terceros). Capacidades del equipo (on-premise requiere MLOps con expertise en GPU infrastructure; muchos equipos no lo tienen).

SECCIÓN 4 · EJEMPLOS REALES

- Banco europeo (datos altamente regulados): API cloud no es viable por RGPD y regulaciones bancarias (datos de clientes no pueden salir del EEE). On-premise GPU cluster con Llama 3 + vLLM. Inversión: €2.5M en hardware. TCO a 5 años: 40% más barato que alternativa cloud equivalente con las restricciones regulatorias aplicadas. Gestión interna de toda la infraestructura con equipo de MLOps de 3 ingenieros.
- Startup de SaaS de IA (40 empleados, modelo de negocio variable): sin CAPEX, API de OpenAI para el MVP. Al crecer, migración a modelos open source en CoreWeave (H100 a \$2.50/hora) para control de costes. Estrategia híbrida: CoreWeave para producción, OpenAI API para casos de uso que requieren capacidades frontier. Coste mensual 60% menor que full-cloud API con volúmenes de 5M consultas/mes.
- Empresa de manufactura (datos sensibles, alta frecuencia): sistema de visión artificial para control de calidad con latencia <100ms requerida. On-premise es la única opción viable: la latencia de round-trip a cloud introduce 50-200ms inaceptables. Servidor con 2x A100 en la planta de producción, amortizado en 18 meses por reducción de defectos.
- Empresa consultora internacional (workloads variables, 30 proyectos simultáneos): estrategia cloud-first con AWS y Azure, usando reservas de 1 año para los workloads

predecibles (30% descuento vs on-demand) y spot instances para fine-tuning y experimentación (70-90% de descuento). Coste optimizado sin CAPEX.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Calcular el coste de on-premise solo con el precio del hardware. El TCO real incluye: electricidad + cooling (8.700-17.900€/año según región), personal de infraestructura (75.000-100.000€/año/FTE), reemplazos de hardware (5-10% de fallo anual en GPUs), lead times de aprovisionamiento, y el coste de oportunidad de esperar 2-6 semanas para nueva capacidad. El hardware es solo el 40-60% del TCO total.

Error 2: Comparar cloud API (modelo) con on-premise GPU (hardware) sin separar las capas. La comparación correcta separa: (1) modelo (cloud API propietario vs open source), (2) infraestructura (cloud GPU vs on-premise), y (3) software (managed vs self-managed). Cada capa tiene su propia decisión de make vs buy.

Error 3: Asumir que la decisión es definitiva. La estrategia óptima cambia con el volumen, el mercado de GPU (los precios han bajado un 50-70% en proveedores especializados en 2024-2025), y las capacidades del equipo. Revisa la decisión anualmente y mantén la flexibilidad arquitectónica para migrar entre opciones.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

El proceso de decisión cloud vs on-premise: 1) Evalúa los requisitos regulatorios y de privacidad primero (pueden eliminar opciones). 2) Calcula el volumen mensual proyectado de tokens/consultas para los próximos 12 meses. 3) Calcula el TCO de cada opción incluyendo todos los costes (hardware, personal, electricidad, cooling, software). 4) Evalúa las capacidades del equipo: ¿tienes MLOps con expertise en GPU infrastructure? 5) Define la estrategia inicial y los umbrales que triggerán una revisión (volumen x3, cambio regulatorio, nuevo proveedor de GPU).

Para la transición de cloud API a cloud GPU autohosteado (el camino más común): empieza con un proveedor cloud GPU especializado (CoreWeave, Lambda Labs, Runpod) con contratos mensuales sin compromiso. Valida el stack técnico (vLLM + modelo + monitoring) en cloud GPU antes de invertir en on-premise. Cuando el coste mensual en cloud GPU supere los \$50.000-\$100.000 de forma sostenida y tienes alta utilización, evalúa on-premise.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M4-T8 (GPUs): las características técnicas de A100, H100, H200 son la base para entender los costes de hardware.
- M8-T5 (Gestión de tokens y costes): los modelos de coste de API de proveedor vs GPU autohosteado.
- M9-T2 (Arquitecturas de despliegue): las opciones cloud vs on-premise se implementan con arquitecturas específicas.

SECCIÓN 8 · RESUMEN EJECUTIVO

Los tres modelos de despliegue son: API de proveedor (cero CAPEX, privacidad limitada, coste variable), cloud GPU especializado (control total, coste por hora, sin CAPEX), y

on-premise (mayor control y menor coste a largo plazo con alta utilización, pero requiere CAPEX, personal y tiempo). El break-even on-premise vs cloud es a >70-80% de utilización sostenida y horizonte de 3+ años. El TCO on-premise incluye hardware (40-60%), personal (0.5 FTE MLOps), electricidad/cooling, y fallos de GPU (5-10% anual). El 68% adopta estrategia híbrida. Los proveedores GPU especializados (CoreWeave, Lambda, Runpod) son 50-70% más baratos que los hiperscalares.