

Sesgos, Fairness y Auditoría de Modelos de IA

Módulo 13 · Gobernanza, Ética y Regulación

Tipos de sesgo, métricas de fairness, teorema de imposibilidad, FairLearn, AI Fairness 360 y auditoría externa.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Sesgos, Fairness y Auditoría de Modelos de IA

Los sesgos en los sistemas de IA son uno de los riesgos éticos y regulatorios más documentados y más difíciles de eliminar. Un modelo puede producir resultados estadísticamente correctos en el agregado mientras discrimina sistemáticamente a grupos específicos. Esta discriminación algorítmica puede ser accidental (resultado de sesgos en los datos de entrenamiento) o estructural (resultado de las elecciones de diseño del sistema), pero sus consecuencias son igualmente reales para las personas afectadas.

En 2025, la evaluación de fairness y la auditoría de modelos han pasado de ser prácticas voluntarias de best practice a requisitos regulatorios en múltiples contextos: el AI Act requiere evaluación de sesgos para sistemas de alto riesgo (Art. 9 y 10), la Equal Credit Opportunity Act en EE.UU. requiere que los modelos de crédito sean auditables y explicables, y las directivas de contratación pública de varios países exigen auditorías de equidad para sistemas de IA utilizados en decisiones sobre personas.

El ecosistema de sesgos y métricas de fairness

Los tipos de sesgo en IA

Los sesgos en IA provienen de múltiples fuentes. Sesgo de datos históricos: los datos de entrenamiento reflejan desigualdades históricas (el sistema COMPAS aprendió del historial de condenas que refleja desigualdades sistémicas del sistema judicial). Sesgo de representación: los grupos subrepresentados en los datos de entrenamiento tienen peor rendimiento del modelo. Sesgo de medición: las variables usadas como proxy para el concepto real tienen correlación distinta con el concepto en distintos grupos (usar el código postal como proxy de riesgo financiero refleja la segregación residencial). Sesgo de retroalimentación: los outputs del modelo alimentan nuevos datos de entrenamiento amplificando los sesgos iniciales.

Las métricas de fairness: individual vs group

No existe una única definición de fairness que satisfaga todos los casos de uso simultáneamente. Las principales métricas son: Demographic Parity (el porcentaje de outcomes positivos es igual para todos los grupos demográficos). Equalized Odds (las tasas de verdaderos positivos y falsos positivos son iguales para todos los grupos). Predictive Parity (la tasa de precisión es igual para todos los grupos). Individual Fairness (individuos similares reciben tratamientos similares). El teorema de imposibilidad de Kleinberg et al. demuestra que algunas métricas de fairness son matemáticamente incompatibles entre sí: es imposible optimizar Demographic Parity y Predictive Parity simultáneamente cuando las tasas de base son distintas entre grupos. La elección de la métrica de fairness correcta es una decisión ética y de contexto, no técnica.

Proceso de evaluación de fairness y auditoría de modelos

Evaluación de fairness en el desarrollo

El proceso de evaluación de fairness durante el desarrollo del modelo incluye: análisis exploratorio de los datos de entrenamiento (distribución de características sensibles, correlaciones entre características protegidas y la variable objetivo), evaluación de las métricas de fairness elegidas en el dataset de test (disaggregated evaluation: rendimiento del modelo por subgrupo demográfico), y aplicación de técnicas de mitigación si se detectan disparidades inaceptables: pre-processing (reequilibrar los datos), in-processing (ajustar la función de pérdida), o post-processing (ajustar los umbrales de decisión por grupo).

Auditoría externa de modelos

La auditoría externa de modelos es una evaluación independiente del sistema de IA realizada por una tercera parte. Los componentes de una auditoría completa incluyen: evaluación de la documentación del sistema (data cards, model cards, documentación técnica del AI Act), testing de rendimiento y fairness (ejecutar el modelo sobre datasets de evaluación propios del auditor, no proporcionados por el auditado), análisis de la explicabilidad (¿el modelo puede explicar sus decisiones de forma comprensible?), y evaluación del proceso de gobernanza (¿tiene la organización los procesos y controles adecuados?). El resultado es un informe de auditoría que puede usarse para cumplimiento del AI Act, para ISO 42001, o como señal de confianza para los clientes.

Herramientas de evaluación de fairness

Las herramientas open source más utilizadas para evaluación y mitigación de sesgos en modelos de ML son: FairLearn (Microsoft): calcula métricas de fairness para modelos de clasificación y proporciona algoritmos de mitigación. AI Fairness 360 (IBM): más de 70 métricas de fairness y 11 algoritmos de mitigación en una sola librería Python. What-If Tool (Google): análisis interactivo y visual del comportamiento de modelos de ML. Aequitas (University of Chicago): herramienta de auditoría de equidad para sistemas de decision-making. Para sistemas LLM, la evaluación de fairness requiere métricas adicionales: disparidad en la calidad de respuestas para consultas sobre distintos grupos demográficos.

SECCIÓN 4 · EJEMPLOS REALES

- Auditoría del sistema de bienestar infantil de Allegheny County (Pittsburgh, EE.UU.): Allegheny County usa un sistema de scoring de riesgo de malnutrición infantil (AFST) para priorizar las investigaciones de servicios sociales. Una auditoría externa en 2023 encontró que el sistema asignaba puntuaciones más altas a familias que recibían beneficios sociales, lo que correlaciona con la pobreza y, indirectamente, con la raza. La auditoría produjo recomendaciones de mitigación y cambios en los umbrales de decisión, y el condado publicó el informe de auditoría completo, siendo uno de los pocos gobiernos que ha hecho esto.
- Evaluación de fairness de modelos de predicción de riesgo crediticio (banco europeo, sector privado): el banco evaluó su modelo de scoring de crédito con FairLearn y encontró que la tasa de aprobación para solicitantes de crédito era 12 puntos porcentuales más baja para un grupo demográfico específico que para otros con el mismo perfil financiero. Técnica de mitigación aplicada: ajuste de umbrales de decisión por grupo (post-processing). Resultado: disparidad reducida al 2% sin impacto significativo en la rentabilidad del portfolio.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Evaluar solo la accuracy global del modelo sin evaluar la fairness por subgrupos. Una accuracy del 95% en el modelo total puede esconder una accuracy del 60% para un subgrupo que está subrepresentado en el dataset de test. La disaggregated evaluation (rendimiento por subgrupo) es imprescindible para sistemas que toman decisiones sobre personas.

Error 2: Aplicar técnicas de mitigación sin entender el compromiso fairness-accuracy. Las técnicas de mitigación de sesgos frecuentemente producen una ligera reducción de la accuracy global del modelo a cambio de reducir la disparidad entre grupos. Este compromiso debe ser explícito y debe decidirse por el negocio y los responsables de gobernanza, no solo por el equipo técnico.

Error 3: No monitorizar el fairness en producción. Los sesgos pueden aparecer en producción incluso si el modelo parece justo en el dataset de evaluación: la distribución de la población real puede ser distinta a la distribución del dataset de test, produciendo disparidades que no eran visibles pre-despliegue. Monitoriza el fairness en producción con las mismas métricas que usaste en el desarrollo.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

El proceso de evaluación de fairness: step 1 (definir los grupos relevantes): ¿sobre qué grupos demográficos puede el sistema tener impacto diferencial? (género, edad, origen, nivel socioeconómico, discapacidad). Step 2 (seleccionar las métricas): ¿qué definición de fairness es la más adecuada para este caso de uso? Step 3 (evaluar): ejecutar las métricas de fairness sobre el dataset de test stratificado por grupo demográfico. Step 4 (documentar): si hay disparidades, documentarlas con su magnitud y su impacto potencial. Step 5 (decidir): ¿las disparidades son inaceptables? ¿qué técnica de mitigación aplica? Step 6 (re-evaluar): verificar que la mitigación redujo la disparidad sin impacto inaceptable en la accuracy.

Para una auditoría externa: seleccionar un auditor independiente con experiencia específica en el dominio del sistema (no cualquier auditor IT puede auditar un sistema de IA de alto riesgo). El alcance de la auditoría debe estar bien definido antes de comenzar. El auditor debe tener acceso al sistema, a la documentación técnica, a los datos de test (o al menos a un dataset de evaluación independiente), y a los responsables del sistema. El informe de auditoría debe ser público en la medida en que sea posible (especialmente para sistemas de alto riesgo de entidades públicas).

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M13-T6 (Ética en IA): la evaluación de fairness es la operacionalización del principio de justicia.
- M13-T5 (Gobierno del dato): la representatividad de los datos es la primera fuente de sesgos en IA.
- M13-T8 (Auditoría de modelos): este tema cubre las auditorías de fairness específicamente dentro del marco más amplio de la auditoría de modelos.

SECCIÓN 8 · RESUMEN EJECUTIVO

Los sesgos en IA provienen de datos históricos, subrepresentación, proxies sesgados, y retroalimentación. Las métricas de fairness principales son Demographic Parity, Equalized Odds, Predictive Parity, e Individual Fairness. El teorema de imposibilidad muestra que algunas métricas son matemáticamente incompatibles: elegir la métrica de fairness es una decisión ética, no técnica. El proceso de evaluación: definir grupos → seleccionar métricas → evaluar con disaggregated evaluation → documentar → mitigar (pre/in/post-processing) → re-evaluar → monitorizar en producción. Herramientas: FairLearn (Microsoft), AI Fairness 360 (IBM), What-If Tool (Google). La auditoría externa produce un informe independiente para cumplimiento regulatorio y señal de confianza.