

Auditabilidad y Explicabilidad de Modelos de IA

Módulo 13 · Gobernanza, Ética y Regulación

SHAP, LIME, explicabilidad LLMs, CoT y citas RAG, Art.86 AI Act y logging para auditoria.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Auditabilidad y Explicabilidad de Modelos de IA

La explicabilidad de los sistemas de IA responde a una necesidad dual: regulatoria (el AI Act Art. 86 establece el derecho a explicación para decisiones automatizadas de sistemas de alto riesgo; el RGPD Art. 22 establece el derecho a no estar sujeto a decisiones exclusivamente automatizadas con efectos significativos) y operativa (los equipos de datos necesitan entender por qué el modelo produce ciertos outputs para debuggear, mejorar, y confiar en él). La auditabilidad va más allá de la explicabilidad: incluye también la capacidad de verificar que el sistema funciona según lo previsto, que es justo, y que sus outputs son trazables hasta sus inputs y su proceso de generación.

En 2025, la explicabilidad de los LLMs es uno de los problemas abiertos más complejos de la IA. Los modelos de black-box tradicionales (redes neuronales profundas) ya eran difíciles de explicar; los LLMs de miles de millones de parámetros son exponencialmente más opacos. Las técnicas de explicabilidad existentes (LIME, SHAP) son aplicables a algunos aspectos de los LLMs pero no proporcionan una explicación completa de por qué el modelo genera un output específico.

Los tipos de explicabilidad en IA

Explicabilidad local vs global

La explicabilidad local responde a la pregunta: "¿por qué el modelo produjo este output específico para este input específico?" Es la explicabilidad más útil para las personas afectadas por las decisiones del sistema. La explicabilidad global responde a "¿cómo funciona el modelo en general, qué características son más importantes para sus predicciones?" Es más útil para los desarrolladores y auditores. Para sistemas de ML clásico (árboles de decisión, regresión logística), la explicabilidad global está incorporada en el modelo. Para modelos de black-box (redes neuronales, LLMs), se necesitan técnicas post-hoc de explicabilidad.

Técnicas post-hoc de explicabilidad

LIME (Local Interpretable Model-agnostic Explanations): genera una aproximación lineal local del modelo alrededor de una predicción específica para explicar por qué el modelo predijo lo que predijo para ese ejemplo concreto. SHAP (SHapley Additive exPlanations): basado en la teoría de juegos, calcula la contribución de cada feature al output del modelo, garantizando propiedades matemáticas de consistencia. SHAP es el estándar de facto para explicabilidad de modelos de ML en producción. Attention visualization para Transformers: visualizar los patrones de atención de los LLMs proporciona alguna intuición sobre qué tokens del input más influyen en el output, aunque la relación entre atención y causación es compleja.

Explicabilidad en LLMs: el estado del arte en 2025

La explicabilidad de los LLMs es un área de investigación activa pero todavía inmadura. Las técnicas disponibles son: saliency maps (visualizar qué tokens del input tienen mayor influencia

en el output), chain-of-thought como explicabilidad implícita (el razonamiento explícito del modelo puede interpretarse como una forma de explicación), self-explanation (pedir al LLM que explique su propio razonamiento, aunque no garantiza que la explicación sea fidedigna respecto al proceso interno real), y circuit analysis (identificar los circuitos neuronales responsables de comportamientos específicos, campo emergente de la interpretability research de Anthropic y OpenAI). Para aplicaciones de producción, el CoT y las citas de fuentes en sistemas RAG son actualmente las formas más prácticas de explicabilidad en LLMs.

SECCIÓN 3 · CÓMO FUNCIONA

Implementación de explicabilidad en producción

Para sistemas de ML clásico (scoring, clasificación): implementar SHAP para explicaciones locales en producción. Para cada decisión relevante, calcular y almacenar los SHAP values de las features más influyentes. Generar una explicación en lenguaje natural a partir de los SHAP values: "Su solicitud de crédito fue denegada principalmente porque [factor 1] y [factor 2]. Si [factor 1] mejorara, la probabilidad de aprobación aumentaría significativamente." Almacenar las explicaciones junto con las decisiones para el log de auditoría.

Para sistemas LLM en producción: implementar sistemas RAG con citas obligatorias (cada afirmación factual incluye la referencia al documento fuente). Usar CoT en los casos de uso donde la cadena de razonamiento es el valor (análisis, síntesis), no solo el output final. Para sistemas que toman decisiones automatizadas sobre personas, implementar la generación de un "fact sheet" estructurado que explique la decisión en términos de los factores más relevantes. Monitorizar que las explicaciones son comprensibles (feedback de usuarios sobre la utilidad de las explicaciones).

La auditabilidad en la práctica

La auditabilidad implica que un auditor externo puede: verificar que el sistema funciona según lo documentado (comparando el comportamiento real del sistema con la especificación), reproducir los outputs del sistema para inputs específicos (requiere control de versiones de modelos y prompts), y trazar una decisión específica hasta sus inputs y el proceso de generación. Para sistemas LLM, la auditabilidad se consigue mediante: logging completo de inputs y outputs con timestamps, versionado de modelos y prompts en Git, y trazas completas del pipeline (especialmente en sistemas RAG y agénticos).

SECCIÓN 4 · EJEMPLOS REALES

- SHAP en sistema de scoring de préstamos (empresa fintech): el sistema de scoring usa un modelo de Gradient Boosting. Para cada decisión de denegación, SHAP calcula los 3 factores más influyentes en la denegación. El sistema genera automáticamente una carta explicativa en lenguaje natural: "Su solicitud ha sido denegada. Los factores principales que influyeron en esta decisión fueron: (1) historial de pagos recientes, que tiene un impacto negativo significativo; (2) ratio deuda/ingresos por encima del umbral de riesgo." Los clientes pueden solicitar revisión humana con esta carta como punto de partida.
- Citas en sistema RAG para investigación médica: el sistema de RAG sobre literatura médica incluye automáticamente citas a los papers fuente para cada afirmación clínica. Los

médicos pueden verificar directamente cada afirmación leyendo el paper original. Esta capa de auditabilidad aumenta la confianza de los médicos en el sistema y permite detectar casos donde el LLM ha interpretado incorrectamente el paper fuente.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Confundir la explicación post-hoc con la causalidad real del modelo. LIME y SHAP proporcionan aproximaciones de la explicación, no la explicación causal exacta de por qué el modelo produjo el output. Para sistemas de alto riesgo donde la explicación tiene consecuencias legales, es importante comunicar la limitación de las técnicas de explicabilidad post-hoc.

Error 2: Diseñar sistemas LLM para "explicarse a sí mismos" sin garantizar que la auto-explicación es fidedigna. Los LLMs pueden generar explicaciones plausibles de sus outputs que no reflejan el proceso interno real que llevó a esos outputs. Una auto-explicación convincente no es garantía de una explicación correcta.

Error 3: Implementar explicabilidad solo para el regulador, sin que sea útil para las personas afectadas. La explicación del Art. 86 del AI Act debe ser comprensible para la persona afectada, no solo para el auditor técnico. Testea la comprensibilidad de las explicaciones con representantes de los usuarios reales del sistema, no solo con el equipo técnico.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Para implementar SHAP en producción: `pip install shap`. Para modelos de `sklearn/xgboost`: `explainer = shap.Explainer(model, X_train)`; `shap_values = explainer(X_test)`. Las contribuciones de cada feature para cada predicción están en `shap_values.values`. Para el top-3 de features más influyentes en una predicción específica: `sorted_idx = np.argsort(np.abs(shap_values[i].values))[:-1][:3]`. Para generar la explicación en lenguaje natural, usa el nombre de cada feature y la dirección de su contribución (positiva o negativa).

Para el logging de auditoría de un sistema LLM: implementa logging estructurado de cada interacción con: `timestamp`, `user_id` (anónimo o pseudónimo), `session_id`, `prompt_hash` (hash del prompt enviado al LLM, no el prompt completo si contiene datos sensibles), `output_hash`, herramientas invocadas y resultados, duración, modelo y versión. Almacena los logs en un sistema inmutable con retención mínima de 12 meses. Para auditorías, el auditor puede reconstruir cualquier interacción usando el `prompt_hash` y el `modelo+versión+prompt_version` almacenados.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M13-T7 (Sesgos y fairness): la explicabilidad es un componente de la auditoría de fairness.
- M13-T1 (EU AI Act): el Art. 86 establece el derecho a explicación, y el Art. 13 la transparencia para deployers.
- M8-T7 (Observabilidad): el logging para auditabilidad es parte de la observabilidad del sistema.

SECCIÓN 8 · RESUMEN EJECUTIVO

La explicabilidad es un requisito regulatorio (AI Act Art. 86, RGPD Art. 22) y una necesidad operativa. Tipos: local (por qué esta decisión), global (cómo funciona el modelo en general). Técnicas para ML clásico: SHAP (estándar de facto para producción, basado en teoría de juegos) y LIME (aproximación lineal local). Para LLMs: CoT como explicabilidad implícita, citas en RAG, self-explanation (no siempre fidedigna), y mechanistic interpretability (investigación, no producción). El AI Act Art. 86 requiere explicaciones comprensibles para personas no técnicas. La auditabilidad requiere: logging completo inmutable, versionado de modelos y prompts, y trazas del pipeline. Las auto-explicaciones de LLMs deben verificarse, no asumirse como fidedignas.