

Módulo 13 — Gobernanza, Ética y Regulación de la IA

EU AI Act plazos y sanciones, NIST AI RMF, ISO 42001, métricas de equidad, sesgos, auditoría y gobierno del dato.

BLOQUE 1 · EL MARCO REGULATORIO DE LA IA EN 2025

Módulo 13 — Gobernanza, Ética y Regulación de la IA

La regulación de la IA ha pasado de ser una preocupación teórica a una realidad operativa con implicaciones concretas para cualquier organización que desarrolle o despliegue sistemas de IA. El EU AI Act, el primero en su clase a nivel global, está en vigor desde agosto de 2024, con las primeras prohibiciones efectivas desde febrero de 2025 y las obligaciones completas para sistemas de alto riesgo desde agosto de 2026. Al igual que el GDPR se convirtió en el estándar global de privacidad, el AI Act se está convirtiendo en la referencia global de regulación de IA: el Brussels effect está haciendo que empresas en EE.UU. y Asia adopten el estándar europeo para sus operaciones globales.

Más allá de la regulación, la gobernanza y la ética de la IA son competencias estratégicas que determinan si la organización puede escalar la IA de forma sostenible, construir confianza con clientes y reguladores, y aprovechar las oportunidades sin incurrir en los riesgos que las organizaciones sin gobernanza sufrirán. Solo el 14% de las organizaciones aplica garantías de IA a nivel empresarial (ModelOp, 2025). Esta brecha es simultáneamente un riesgo (para las que no tienen gobernanza) y una oportunidad (para las que la construyen y la usan como diferenciador competitivo).

El EU AI Act: estructura y plazos clave

El EU AI Act clasifica todos los sistemas de IA en cuatro categorías según su nivel de riesgo. Riesgo inaceptable (prohibido desde febrero 2025): sistemas de puntuación social, identificación biométrica en tiempo real en espacios públicos para aplicación de la ley, sistemas que usan técnicas subliminales para manipular el comportamiento, predicción de delitos basada en perfilado, inferencia de emociones en el trabajo o educación, y creación de bases de datos de reconocimiento facial por scraping masivo. Riesgo alto (obligaciones completas desde agosto 2026): sistemas en sectores de crédito, empleo, salud, educación, justicia, aplicación de la ley, gestión de infraestructuras críticas, y sistemas de seguridad en productos regulados (dispositivos médicos, vehículos, maquinaria). Los sistemas de alto riesgo necesitan sistema de gestión de riesgos, gobernanza de datos, documentación técnica, registro de logs, supervisión humana, y evaluación de conformidad antes de comercializarse. Riesgo limitado: chatbots deben informar que son IA. Riesgo mínimo: sin obligaciones adicionales. Las multas llegan a 35M EUR o el 7% de la facturación global anual por las infracciones más graves.

NIST AI RMF e ISO 42001: los frameworks de gestión

El NIST AI RMF (enero 2023) es el framework de gestión de riesgos de IA más influyente a nivel global. Sus cuatro funciones son: Govern (estructuras organizativas, políticas, responsabilidades, formación), Map (inventario de IA, AI Impact Assessment, análisis de partes interesadas), Measure (evaluación con las siete características de IA confiable: validez, seguridad, ciberseguridad, privacidad, explicabilidad, equidad, y responsabilidad), y Manage (priorizar riesgos, implementar mitigaciones, documentar decisiones, gestionar riesgos de terceros). El NIST Generative AI Profile (NIST-AI-600-1, julio 2024)

extiende el AI RMF con los 12 riesgos específicos de la IA generativa. ISO/IEC 42001 (2023) es el estándar certificable para la gestión de sistemas de IA, basado en el ciclo PDCA y comparable a ISO 27001 para la seguridad. La certificación ISO 42001 está convirtiéndose en requisito de pre-cualificación en RFPs del sector sanitario, financiero, y público en Europa, y en diferenciador competitivo para proveedores de soluciones de IA.

BLOQUE 2 · ÉTICA, SESGOS, Y AUDITORÍA DE MODELOS

La ética de IA como práctica operativa

De los principios a las métricas: la operacionalización de la ética

La ética de la IA tiene dos dimensiones radicalmente distintas. Los principios de alto nivel (equidad, transparencia, responsabilidad, privacidad, no-maleficencia) son relativamente fáciles de formular y prácticamente todas las organizaciones los tienen escritos en algún documento. La práctica de la ética de IA (¿cómo mides la equidad de tu modelo?, ¿qué es un nivel aceptable de disparate impact?, ¿quién es responsable de revisar las decisiones del sistema cuando un usuario se queja?) es el trabajo difícil que la mayoría de las organizaciones no ha hecho. Las organizaciones que practican la ética de IA tienen equipos con acceso a herramientas de fairness testing (Fairlearn, AIF360), ejecutan tests de equidad en el CI/CD, tienen procesos de reclamación para usuarios afectados, y documentan los compromisos y trade-offs éticos de cada sistema de IA.

Las métricas de equidad técnica cuantifican el nivel de sesgo del modelo. Las métricas principales son: Disparate Impact (ratio de tasas de resultados positivos entre grupos; umbral 0.8 en jurisprudencia de EE.UU.), Equalized Odds (las tasas de verdaderos positivos y falsos positivos deben ser similares entre grupos), Demographic Parity (la tasa de resultados positivos debe ser similar entre grupos), y Counterfactual Fairness (si la raza o el género cambiaran, ¿cambiaría la decisión?). La paradoja de equidad es matemáticamente demostrable: no todas las definiciones de equidad son compatibles entre sí cuando los grupos tienen tasas de base distintas. La decisión de qué métrica aplicar es una decisión de valores de la organización, no una decisión técnica.

Los sesgos más importantes y sus orígenes

Los sesgos en los sistemas de IA tienen múltiples fuentes. En los datos: sesgo de selección (el dataset no representa uniformemente a todos los grupos relevantes), sesgo de medición (los datos no capturan igualmente bien la realidad para todos los grupos), sesgo de etiquetado (los anotadores humanos introducen sus propios sesgos en las etiquetas), y sesgo histórico (los datos reflejan patrones históricos de discriminación). En el modelo: sesgo de optimización (el modelo optimiza métricas globales que pueden ocultar disparidades entre subgrupos), sesgo de proxy (el modelo aprende a usar variables aparentemente neutrales como proxies de atributos protegidos), y sesgo de amplificación (el modelo amplifica los sesgos presentes en los datos). Los casos benchmark son: Amazon recruiting tool (2018, penalizaba CVs con palabras asociadas a mujeres) y Obermeyer et al. en Science (2019, el sistema de gestión sanitaria de EE.UU. asignaba sistemáticamente menos recursos a pacientes afroamericanos que a pacientes blancos con el mismo nivel de necesidad médica).

La auditoría de modelos y el gobierno del dato

La auditoría de modelos evalúa sistemáticamente un sistema de IA en cuatro pilares: rendimiento técnico (precisión por subgrupos demográficos, robustez ante distributional shift), equidad y sesgo (análisis de disparate impact por atributos protegidos, análisis interseccional), seguridad y

ciberseguridad (OWASP LLM Top 10, testing adversarial), y cumplimiento normativo (AI Act, RGPD, regulación sectorial). El model card (Gebru et al., Google, 2019) y el datasheet for datasets son los formatos de documentación estándar para la auditoría. La NYC Local Law 144 (en vigor desde julio 2023) requiere auditorías anuales de sesgo para herramientas de contratación con IA en Nueva York, un precedente regulatorio que se está extendiendo globalmente. El gobierno del dato para IA es la base de todo: el AI Act Artículo 10 requiere que los datos de entrenamiento sean relevantes, representativos, y libres de sesgos inaceptables. Las herramientas son Apache Atlas y OpenMetadata para linaje de datos, Great Expectations para calidad en CI/CD, y Evidently AI para monitorización de dataset drift en producción.

RESUMEN EJECUTIVO DEL MÓDULO 13: El EU AI Act (vigor agosto 2024) es el primer marco regulatorio integral de IA: cuatro categorías de riesgo, prohibiciones desde febrero 2025, obligaciones completas para alto riesgo desde agosto 2026, multas hasta 35M EUR o 7% de facturación global. El Brussels effect lo convierte en estándar global de facto. Los frameworks de gestión son NIST AI RMF (Govern-Map-Measure-Manage, voluntario pero muy referenciado) e ISO 42001 (PDCA, certificable, equivalente a ISO 27001 para IA). La ética de IA práctica se mide con métricas de equidad (disparate impact umbral 0.8, equalized odds), herramientas (Fairlearn, AIF360, SHAP/LIME), y procesos de reclamación. Los sesgos tienen múltiples orígenes en los datos y en el modelo. La auditoría de modelos cubre 4 pilares: rendimiento, equidad, seguridad, y compliance. El gobierno del dato (linaje, calidad, DPIA) es la base del cumplimiento del AI Act Artículo 10.