

Módulo 10 — Sistemas Agénticos y Multi-Agente

Arquitectura de agentes, ReAct, tool use, MCP, A2A, LangGraph, CrewAI, evaluación y human-in-the-loop.

BLOQUE 1 · LA ERA DE LOS AGENTES DE IA

Módulo 10 — Sistemas Agénticos y Multi-Agente

Durante los primeros años de la era LLM, los sistemas de IA eran fundamentalmente reactivos: el usuario enviaba un mensaje, el modelo respondía, la interacción terminaba. Los sistemas agénticos rompen este paradigma. Un agente de IA es un sistema basado en LLM que puede razonar sobre un objetivo, planificar los pasos necesarios para alcanzarlo, ejecutar acciones en el mundo real a través de herramientas, observar los resultados, y ajustar el plan si es necesario. Esta capacidad de actuar de forma autónoma durante múltiples pasos para alcanzar objetivos complejos es cualitativamente distinta de los chatbots convencionales y representa la transformación más significativa del campo en 2024-2025.

El mercado de agentes de IA se estima en 5.4 billones de dólares en 2024 y se proyecta a 50.3 billones en 2030, con un CAGR del 45%. El 79% de las organizaciones reportan algún nivel de adopción de agentes de IA en 2025, y el 50% de las empresas que usan IA generativa planean desplegar agentes autónomos para 2027 (Deloitte). La diferencia entre un LLM y un agente es la diferencia entre una calculadora y un piloto: uno computa respuestas, el otro navega hacia objetivos.

Arquitectura de un agente: los cuatro componentes

Un agente de IA se define por cuatro capacidades. Percepción: el agente recibe inputs del entorno (texto, código, resultados de herramientas, imágenes, outputs de otros agentes) que le informan del estado actual del mundo y del progreso hacia su objetivo. Razonamiento y planificación: el LLM central analiza el estado actual, evalúa el progreso hacia el objetivo, identifica el próximo paso que maximiza la probabilidad de éxito, y genera la justificación (Thought) de esa decisión. Acción mediante herramientas: el agente ejecuta acciones en el mundo real a través de herramientas (búsqueda web, ejecución de código, llamadas a APIs, lectura y escritura de archivos, interacción con sistemas empresariales). Memoria: el agente mantiene el estado a través de múltiples pasos (memoria a corto plazo en el contexto de la conversación) y potencialmente a través de múltiples sesiones (memoria a largo plazo en bases de datos externas).

El ciclo fundamental de un agente es el patrón ReAct (Reasoning + Acting): Thought (razonamiento sobre qué hacer), Action (invocar una herramienta), Observation (procesar el resultado de la herramienta), y repetir hasta que el agente considera el objetivo alcanzado o se alcanza el límite de iteraciones. Este patrón simple pero poderoso es la base de prácticamente todos los sistemas agénticos en producción en 2025.

El espectro de autonomía: de asistente a agente autónomo

Los sistemas agénticos no son todos igualmente autónomos. El espectro va desde los sistemas que ejecutan una sola herramienta en una sola llamada al LLM (como un chatbot que puede buscar en la

web), hasta los agentes que ejecutan planes de decenas de pasos durante horas sin intervención humana. La autonomía correcta para cada caso de uso depende de la confianza en el sistema (evaluada empíricamente en producción), el riesgo de las acciones disponibles (las acciones irreversibles requieren mayor supervisión), y los requisitos regulatorios del sector.

BLOQUE 2 · HERRAMIENTAS, MEMORIA, Y PLANIFICACIÓN

Los componentes avanzados de los sistemas agénticos

Tool use y function calling: la interfaz con el mundo

Las herramientas son la forma en que los agentes actúan en el mundo. La implementación técnica es el function calling (también llamado tool calling): el LLM, en lugar de responder con texto, responde con una invocación de función estructurada (nombre de la herramienta + argumentos en JSON). El sistema externo ejecuta la función real y devuelve el resultado al LLM, que lo incorpora en su razonamiento para el próximo paso. Este mecanismo está implementado nativamente en todos los modelos frontier. El protocolo MCP (Model Context Protocol, Anthropic, noviembre 2024) se ha convertido en el estándar de la industria para exponer herramientas de forma reutilizable: más de 1.000 servidores MCP open source están disponibles en 2025 para los sistemas empresariales más comunes.

Las herramientas se clasifican por su nivel de riesgo: herramientas de recuperación (lectura de datos, búsqueda web, consulta de bases de datos: bajo riesgo, ejecutar autónomamente), herramientas de ejecución de código (Python sandbox, scripts: riesgo medio, ejecutar en entorno sandboxed), y herramientas de acción en sistemas externos (enviar emails, modificar bases de datos, hacer pagos: alto riesgo, requieren HITL para acciones irreversibles o de alto impacto). El principio de mínimo privilegio aplica a las herramientas del agente: cada agente debe tener acceso solo a las herramientas estrictamente necesarias para su tarea específica.

Memoria en sistemas agénticos

La memoria de los agentes tiene cuatro tipos con características distintas. Memoria a corto plazo (buffer de conversación): el historial de la sesión actual en el contexto del LLM. Es inmediata pero limitada por la ventana de contexto. Memoria episódica: logs de interacciones pasadas almacenados en una base vectorial y recuperados por similitud a la situación actual. Permite al agente recordar preferencias del usuario y evitar repetir errores. Memoria semántica: conocimiento factual sobre el dominio, el usuario, o la organización, almacenado en bases de datos estructuradas o en RAG. Memoria procedimental: cómo hacer las cosas, codificada en el system prompt o aprendida a partir de la experiencia. La gestión del buffer de conversación (para evitar que el contexto se sature con información irrelevante) y la implementación de memoria persistente entre sesiones son dos desafíos de ingeniería importantes en sistemas agénticos de producción.

Planificación: de objetivo a pasos ejecutables

La planificación es la capacidad de descomponer un objetivo complejo en pasos ejecutables con las herramientas disponibles. Los dos enfoques principales son Plan and Execute (el agente genera el plan completo antes de ejecutar ningún paso: más predecible y auditable pero frágil si las condiciones cambian durante la ejecución) y ReAct iterativo (el agente decide el siguiente paso en cada iteración basándose en el estado actual: más adaptable pero puede perder el hilo del objetivo global). La técnica Reflexion (Shinn et al., 2023) mejora la planificación añadiendo un paso de reflexión después de cada fallo: el agente genera una justificación verbal de qué salió mal y produce un plan revisado, mejorando

significativamente la tasa de éxito en tareas complejas.

BLOQUE 3 · SISTEMAS MULTI-AGENTE Y FRAMEWORKS

Coordinación de múltiples agentes en sistemas complejos

Los patrones de coordinación multi-agente

Los sistemas multi-agente (MAS) coordinan múltiples agentes especializados para tareas que ninguno podría resolver de forma individual. El patrón más común es el orquestador-subagentes: un agente orquestador recibe el objetivo de alto nivel, lo descompone en subtareas, las asigna a subagentes especializados, y sintetiza los resultados. Los subagentes son especialistas en dominios específicos (análisis financiero, investigación legal, generación de código) y tienen sus propios conjuntos de herramientas. Otros patrones son: el pipeline secuencial (el output de un agente es el input del siguiente), el debate y verificación (múltiples agentes proponen soluciones y un árbitro selecciona la mejor), y el patrón con handoffs (un agente transfiere el control a otro cuando detecta que el nuevo agente es más adecuado para la tarea actual).

El protocolo A2A (Agent-to-Agent, Google, abril 2025) define el estándar para la comunicación entre agentes de distintos frameworks, complementando a MCP. Junto con MCP para el acceso a herramientas, A2A está construyendo la infraestructura del "internet de los agentes": un ecosistema donde agentes especializados de distintos proveedores y frameworks pueden colaborar de forma estandarizada sin integración custom.

LangGraph, CrewAI, AutoGen: los frameworks de producción

LangGraph (LangChain, 2024) modela los workflows agénticos como grafos de estado: los nodos son funciones Python que procesan el estado del agente, las aristas son transiciones entre nodos (condicionales o incondicionales). El estado es un objeto explícito que fluye entre nodos, lo que hace el sistema completamente observable e inspeccionable. Las características de producción de LangGraph son únicas: checkpointing nativo del estado (puede pausar y reanudar el agente, incluyendo después de reinicios del servidor), streaming granular de cada paso, y human-in-the-loop integrado. CrewAI organiza los agentes con roles, objetivos, y backstories, optimizado para el prototipado rápido de sistemas multi-agente. AutoGen (Microsoft) organiza los agentes como participantes en una conversación de debate y verificación. Los SDKs nativos de OpenAI (marzo 2025) y Anthropic permiten integración nativa con los modelos de cada proveedor.

Evaluación de sistemas agénticos

Evaluar sistemas agénticos es más complejo que evaluar LLMs de chat porque los outputs son secuencias de acciones, no respuestas únicas. Las métricas principales son: task completion rate (porcentaje de tareas completadas correctamente, evaluado con un golden task set de 20-100 tareas representativas), trajectory evaluation (evaluación de cada paso de la secuencia de acciones, no solo el resultado final), eficiencia (número de pasos y tokens por tarea: un agente que resuelve la tarea en 5 pasos es mejor que uno que la resuelve en 50), y error crítico rate (porcentaje de fallos que causan daños irreversibles: la métrica de seguridad más importante). Los benchmarks de referencia son SWE-bench (resolución de issues de GitHub real: los mejores agentes resuelven el 40-50% en 2025), GAIA (tareas del mundo real con herramientas), y AgentBench (benchmark multi-dominio).

RESUMEN EJECUTIVO DEL MÓDULO 10: Los agentes de IA son LLMs que pueden razonar, planificar, usar herramientas, y persistir estado para alcanzar objetivos complejos de forma autónoma. El mercado se proyecta a \$50.3B en 2030. Los cuatro componentes son: percepción, razonamiento/planificación, acción mediante herramientas, y memoria. El ciclo ReAct (Thought-Action-Observation) es la base de todos los sistemas agénticos. MCP (noviembre 2024, 1000+ servidores) y A2A (abril 2025) son los protocolos de interoperabilidad del ecosistema agéntico. Los frameworks para producción son: LangGraph (control máximo, checkpointing), CrewAI (prototipos rápidos con roles), AutoGen (debate entre agentes), y los SDKs nativos de OpenAI/Anthropic. La evaluación usa golden task sets + trajectory evaluation + error crítico rate. Human-in-the-loop para acciones irreversibles es imprescindible; mínimo privilegio en herramientas previene daños.