

Módulo 1 — Fundamentos Ontológicos y Razonamiento en IA

Naturaleza del conocimiento LLM, Chain of Thought, Tree of Thoughts, ReAct, alucinaciones y calibración.

BLOQUE 1 · POR QUÉ LOS FUNDAMENTOS IMPORTAN

Módulo 1 — Fundamentos Ontológicos y Razonamiento en IA

Existe una tentación comprensible, especialmente en un campo que evoluciona tan rápido como la IA, de saltar directamente a las herramientas y frameworks más recientes sin detenerse en los fundamentos conceptuales. Esta tentación debe resistirse. Los profesionales de IA que no entienden cómo razonan los LLMs, cuáles son sus límites epistémicos fundamentales, y cuándo fallan de formas predecibles cometen errores costosos en producción: construyen sistemas que alucinan con confianza, aplican la herramienta de razonamiento incorrecta para el problema, o diseñan prompts que producen resultados inconsistentes bajo variaciones del input.

Este módulo aborda las preguntas más fundamentales sobre la naturaleza del razonamiento en los LLMs: ¿qué es lo que realmente "saben" los modelos de lenguaje?, ¿razonan o predicen?, ¿pueden distinguir entre lo que saben y lo que no saben?, ¿cómo se representan el conocimiento y la incertidumbre en un sistema estocástico basado en predicción de tokens?. Estas preguntas no son puramente filosóficas: tienen implicaciones directas sobre cómo diseñar sistemas de IA que sean fiables, honemos, y seguros.

La naturaleza del "conocimiento" en los LLMs

Los LLMs no tienen conocimiento en el sentido en que los humanos lo tienen. No tienen una base de datos de hechos estructurada que pueden consultar. Lo que tienen es una comprensión estadística masiva del texto humano: patrones de co-ocurrencia de palabras y conceptos que, cuando se combinan con la predicción del siguiente token, producen respuestas que parecen conocimiento pero son, más precisamente, inferencias estadísticas sobre qué texto sería plausible dado el contexto.

Esta distinción es crítica para entender las alucinaciones: cuando un LLM genera un hecho incorrecto con total confianza, no está "mintiendo" en el sentido humano. Está produciendo el texto estadísticamente más plausible dado su contexto de entrenamiento, y ese texto resulta ser incorrecto. El modelo no tiene un mecanismo interno que le diga "esto es un hecho verificado" versus "esto es algo que parece plausible estadísticamente". La calibración (la correlación entre la confianza expresada y la corrección real) es una propiedad que se puede medir y mejorar, pero ningún modelo actual está perfectamente calibrado.

Razonamiento vs predicción de tokens: el debate fundamental

El debate sobre si los LLMs realmente "razonan" o simplemente "predicen" es uno de los más activos en la investigación de IA. La postura que considera que los LLMs solo predicen tokens y no razonan genuinamente señala que los modelos pueden fallar en problemas de razonamiento trivialmente simples que cualquier humano resolvería, que su rendimiento en tareas de razonamiento es muy

sensible a la formulación del problema (variaciones aparentemente superficiales en el prompt pueden producir respuestas completamente distintas), y que los errores que cometen frecuentemente no tienen el patrón de errores de razonamiento humanos sino el de errores estadísticos.

La postura alternativa señala que los modelos más grandes demuestran capacidades emergentes de razonamiento que los modelos más pequeños no tienen, que las técnicas de prompting como Chain of Thought (pedir al modelo que razone paso a paso antes de dar la respuesta) mejoran significativamente el rendimiento en tareas de razonamiento, y que los modelos de razonamiento como o3 de OpenAI, que generan un "scratchpad" de razonamiento antes de producir la respuesta, demuestran capacidades de resolución de problemas muy superiores a los modelos estándar. La verdad parece ser que los LLMs tienen algo funcionalmente similar al razonamiento sin ser idéntico al razonamiento humano.

BLOQUE 2 · TÉCNICAS DE RAZONAMIENTO AVANZADO

Chain of Thought, Tree of Thoughts, y razonamiento multi-paso

Chain of Thought: el prompting que desbloquea el razonamiento

Chain of Thought (CoT) fue introducido formalmente por Wei et al. (Google Brain, 2022) y representa uno de los avances más importantes en ingeniería de prompts. La idea es simple pero poderosa: en lugar de pedir al modelo que produzca directamente la respuesta a un problema complejo, se le pide que razone paso a paso antes de dar la respuesta. El resultado es un aumento significativo en la corrección de las respuestas para tareas de razonamiento matemático, lógico, y común.

El mecanismo por el que el CoT mejora el rendimiento tiene que ver con la forma en que los modelos generan texto: cada token generado se convierte en parte del contexto que informa los tokens siguientes. Si el modelo genera los pasos intermedios de un razonamiento, esos pasos están disponibles en el contexto cuando genera la conclusión. En contraste, sin CoT, el modelo debe comprimir todo el razonamiento implícitamente en la probabilidad de los tokens de respuesta, un proceso mucho más propenso a errores. Existen dos variantes principales: zero-shot CoT (añadir "Piensa paso a paso" al prompt, lo que es suficiente para activar el razonamiento en modelos suficientemente grandes) y few-shot CoT (proporcionar ejemplos de razonamiento paso a paso en el prompt).

Tree of Thoughts: exploración paralela de caminos de razonamiento

Tree of Thoughts (ToT, Yao et al., 2023) extiende el CoT generando múltiples cadenas de razonamiento en paralelo y evaluando cuál es más prometedora. En lugar de seguir un solo camino de razonamiento hasta el final, ToT explora el árbol de posibles razonamientos, selecciona los nodos más prometedores, y eventualmente converge en la solución más robusta. Es especialmente efectivo para problemas de planificación, puzzles complejos, y situaciones donde la solución requiere explorar múltiples hipótesis.

La implementación de ToT requiere múltiples llamadas al LLM (una para generar las ramas, otra para evaluarlas, otra para seleccionar las más prometedoras), lo que lo hace más costoso y lento que el CoT simple. Sin embargo, para tareas de alto valor donde la precisión importa más que la velocidad, ToT puede producir mejoras significativas. Los modelos de razonamiento como o3 de OpenAI internalizan algo similar a ToT en su proceso de "extended thinking", lo que es una de las razones de su superior

rendimiento en benchmarks de razonamiento.

ReAct: razonamiento y acción entrelazados

ReAct (Reasoning + Acting, Yao et al., 2022) es el patrón de prompting que combina el razonamiento del CoT con la ejecución de acciones externas (búsqueda web, ejecución de código, consulta de APIs). El modelo alterna entre pasos de Thought (razonamiento sobre qué hacer a continuación), Action (invocación de una herramienta externa), y Observation (procesamiento del resultado de la herramienta). Este patrón es la base de la mayoría de los sistemas agénticos actuales: los agentes de IA usan ReAct para razonar sobre qué herramientas usar, cuándo, y cómo interpretar los resultados.

El valor de ReAct sobre el CoT puro es que permite al modelo actualizar su razonamiento basándose en información real del mundo externo, en lugar de confiar únicamente en lo que "sabe" de su entrenamiento. Un agente que puede buscar en la web, ejecutar código, y consultar bases de datos puede realizar tareas para las que un LLM sin herramientas sería completamente incapaz, o produciría alucinaciones al intentarlas con solo su conocimiento paramétrico.

BLOQUE 3 · ONTOLOGÍA Y REPRESENTACIÓN DEL CONOCIMIENTO

Cómo representan el conocimiento los LLMs y qué implica para su uso

Conocimiento paramétrico vs conocimiento en contexto

Los LLMs tienen dos formas de "saber" cosas: el conocimiento paramétrico (lo que está codificado en los pesos del modelo, resultado del entrenamiento) y el conocimiento en contexto (lo que está en el prompt actual, que el modelo puede usar para razonar aunque no esté en sus pesos). El conocimiento paramétrico es estático (no cambia sin reentrenamiento o fine-tuning), puede estar desactualizado (el modelo tiene una fecha de corte de conocimiento), y puede ser incorrecto (el modelo aprendió información incorrecta de los datos de entrenamiento). El conocimiento en contexto es dinámico (puede actualizarse en cada llamada al modelo), siempre actual (si proporcionamos la información correcta), y verificable (podemos controlar qué información proporcionamos).

Esta distinción es la base del patrón RAG (Retrieval-Augmented Generation, Módulo 7): en lugar de confiar en el conocimiento paramétrico potencialmente desactualizado o incorrecto, RAG recupera los documentos relevantes para la consulta del usuario y los pone en el contexto del LLM, que entonces usa ese conocimiento contextual para generar la respuesta. Este patrón produce sistemas más fiables, más actualizables, y más explicables que los que confían exclusivamente en el conocimiento paramétrico.

El problema de la calibración: confianza y corrección

Un sistema bien calibrado expresa confianza alta cuando es correcto y confianza baja cuando es incorrecto. Los LLMs actuales están notoriamente mal calibrados: expresan alta confianza en afirmaciones incorrectas (alucinaciones) y a veces expresan dudas innecesarias sobre afirmaciones que son perfectamente correctas. Esta mala calibración hace que las respuestas del LLM no sean directamente interpretables como indicadores de su corrección.

Las técnicas para mejorar la calibración incluyen: self-consistency (generar múltiples respuestas al mismo prompt con temperatura mayor que cero y seleccionar la que tiene mayor acuerdo entre las muestras), verbal uncertainty quantification (pedir al modelo que exprese explícitamente su nivel de

confianza en un formato estructurado), y factual checking (comparar las afirmaciones del modelo contra fuentes verificables). Ninguna de estas técnicas resuelve el problema completamente, pero combinadas producen sistemas más fiables.

Marcos filosóficos para entender los límites del razonamiento de los LLMs

Tres marcos filosóficos son especialmente útiles para entender los límites del razonamiento de los LLMs. El problema de la habitación china de John Searle plantea que un sistema que manipula símbolos según reglas sintácticas (como un LLM predice tokens) no necesariamente entiende el significado de esos símbolos semánticamente. La distinción entre comprensión y competencia es relevante: los LLMs demuestran competencia impresionante en muchas tareas sin que podamos estar seguros de que "comprenden" en el sentido semántico profundo. El problema del marco (frame problem) en IA es la dificultad de representar lo que permanece igual cuando algo cambia: los LLMs no tienen un modelo del mundo persistente que actualicen dinámicamente, lo que los hace propensos a incoherencias en contextos que requieren seguimiento del estado del mundo. La falacia del stochastic parrot (Bender et al., 2021) sugiere que los LLMs son simplemente máquinas de predicción estadística de texto sin comprensión genuina. Aunque esta visión ha sido criticada como demasiado simplista, captura algo real sobre los límites de la generación estadística de texto.

BLOQUE 4 · PROMPTING COMO INGENIERÍA

De la intuición a la disciplina: la ingeniería del prompt

Por qué el prompting es una ingeniería, no un arte

El "prompting" empezó siendo percibido como algo intuitivo: formular las preguntas correctas para obtener las respuestas correctas. Con el tiempo, ha emergido como una disciplina de ingeniería con principios, técnicas, y mejores prácticas bien documentadas. El Módulo 6 de este máster dedica 9 temas a la ingeniería de prompts; aquí introducimos los principios fundamentales que fundamentan todas esas técnicas.

El principio más fundamental del prompting es que el LLM trata todo el texto del prompt como un contexto estadístico para predecir los tokens siguientes. Cada palabra del prompt influye en la distribución de probabilidad de la respuesta. Esto significa que cambios aparentemente pequeños en el prompt (el orden de las instrucciones, el nivel de detalle, la presencia o ausencia de ejemplos) pueden producir respuestas significativamente distintas. El prompting disciplinado trata estas variables como parámetros a optimizar, no como texto a escribir intuitivamente.

Los principios del prompting efectivo

Los principios del prompting efectivo son: claridad sobre el rol y la tarea (el modelo responde mejor cuando sabe qué tipo de sistema es y qué se espera de él), especificidad del output esperado (cuanto más específico el formato, la longitud, y el estilo del output esperado, más predecible y controlable es el output), uso de ejemplos (few-shot learning: proporcionar ejemplos de inputs y outputs correctos en el prompt mejora la consistencia y la calidad), y separación clara entre instrucciones, contexto, e input (el modelo debe poder distinguir qué son sus instrucciones permanentes, qué es información de contexto, y qué es el input específico de la solicitud actual).

El uso de delimitadores explícitos (XML tags, triple comillas, markdown headers) para separar las secciones del prompt es especialmente importante para sistemas que procesan inputs del usuario: delimitar claramente qué es una instrucción del sistema y qué es input del usuario es la primera línea

de defensa contra los ataques de prompt injection (Módulo 12, Tema 2).

La evaluación de prompts: de la intuición a la métrica

Un aspecto frecuentemente subestimado del prompting disciplinado es la evaluación sistemática: cómo saber si un prompt es mejor que otro. Sin evaluación, el desarrollo de prompts es un proceso de ensayo y error sin dirección clara. Con evaluación, se convierte en un proceso de optimización con una función objetivo clara. La evaluación de prompts requiere: un golden dataset de casos de prueba (inputs representativos con el output esperado correcto), métricas de evaluación (que pueden ser automáticas: coincidencia exacta, puntuación de similaridad semántica, o basadas en un LLM-as-judge), y un proceso de A/B testing entre versiones del prompt. Herramientas como Promptfoo, LangSmith, y Braintrust facilitan este proceso.

BLOQUE 5 · ALUCINACIONES Y FIABILIDAD

Entender, predecir, y mitigar las alucinaciones de los LLMs

Qué son las alucinaciones y por qué ocurren

Las alucinaciones de los LLMs son outputs que son factualmente incorrectos, internamente incoherentes, o no fundamentados en la información proporcionada. Incluyen: hechos incorrectos presentados con confianza (fechas erróneas, referencias bibliográficas inventadas, estadísticas fabricadas), incoherencias internas en respuestas largas (el modelo contradice en el párrafo 5 lo que dijo en el párrafo 2), y faithfulness failures en sistemas RAG (el modelo genera texto que no está fundamentado en los documentos recuperados). Las alucinaciones no son bugs que se pueden corregir: son una consecuencia estructural de cómo funcionan los LLMs. Un sistema entrenado para predecir el texto más plausible producirá texto plausible aunque no sea correcto.

Los factores que aumentan la probabilidad de alucinaciones incluyen: temperatura alta (mayor aleatoriedad en la generación), preguntas sobre hechos específicos que el modelo no conoce bien (fechas exactas, nombres propios oscuros, estadísticas específicas), instrucciones de producir contenido en un formato específico cuando el contenido real no existe (el modelo puede inventar para cumplir el formato), y context length extrema (la atención del modelo se diluye con contextos muy largos, aumentando la probabilidad de incoherencias).

Estrategias de mitigación

Las estrategias principales para reducir las alucinaciones en producción son: RAG (proporcionar al modelo los documentos relevantes reduce su necesidad de depender de su conocimiento paramétrico potencialmente incorrecto), grounding explícito (instruir al modelo a fundamentar sus respuestas exclusivamente en los documentos proporcionados y a indicar cuando la información no está disponible), self-consistency (generar múltiples respuestas y seleccionar la más consistente reduce la varianza de las alucinaciones), y fact-checking automático (un segundo LLM verifica las afirmaciones del primero contra las fuentes proporcionadas).

Ninguna estrategia elimina completamente las alucinaciones. El objetivo de los sistemas de producción no es alcanzar cero alucinaciones (imposible con los LLMs actuales) sino mantener la tasa de alucinaciones dentro de un rango aceptable para el caso de uso específico, y cuando las alucinaciones ocurren, detectarlas y manejarlas apropiadamente antes de que causen daño.

RESUMEN EJECUTIVO DEL MÓDULO 1: Los LLMs no tienen conocimiento en el sentido humano: tienen comprensión estadística de texto que produce inferencias plausibles. El debate razonamiento vs predicción de tokens está activo; la evidencia sugiere capacidades emergentes de razonamiento sin identidad con el razonamiento humano. Las técnicas de razonamiento avanzado son: Chain of Thought (razonamiento paso a paso), Tree of Thoughts (exploración paralela de caminos de razonamiento), y ReAct (razonamiento entrelazado con acción). La distinción entre conocimiento paramétrico (en los pesos) y conocimiento en contexto (en el prompt) es la base del patrón RAG. Los LLMs están mal calibrados: expresan confianza alta en afirmaciones incorrectas (alucinaciones). El prompting es una ingeniería con principios, técnicas de evaluación, y optimización sistemática. Las alucinaciones son estructurales, no bugs corregibles; se mitigan con RAG, grounding, y self-consistency pero no se eliminan completamente.