

Módulo 2 — Matemáticas y Fundamentos Técnicos de la IA

Álgebra lineal, cálculo y backpropagation, estadística y probabilidad, Transformers y métricas de evaluación.

BLOQUE 1 · POR QUÉ LAS MATEMÁTICAS IMPORTAN EN IA

Módulo 2 — Matemáticas y Fundamentos Técnicos de la IA

Existe una línea divisoria clara en el campo de la IA entre los practicantes que entienden las matemáticas subyacentes a las técnicas que usan y los que las usan como cajas negras. Los primeros pueden diagnosticar por qué un modelo no converge durante el entrenamiento, elegir la función de pérdida correcta para su problema, entender por qué un hiperparámetro concreto afecta al comportamiento del modelo de la forma en que lo hace, e interpretar las métricas de evaluación con precisión. Los segundos frecuentemente aplican técnicas incorrectamente, tienen dificultades para diagnosticar problemas, y pueden ser engañados por métricas que parecen buenas pero ocultan problemas reales.

Este módulo no pretende ser un curso de matemáticas completo: es un mapa de los conceptos matemáticos más relevantes para la IA, explicados con énfasis en la intuición y la aplicación práctica en lugar de en la demostración formal. El objetivo es que el lector entienda qué están haciendo los algoritmos de IA matemáticamente, no que sea capaz de derivar teoremas desde primeros principios.

Álgebra lineal: la lengua de las redes neuronales

El álgebra lineal es la rama de las matemáticas que estudia los vectores, las matrices, y las operaciones sobre ellos. Es literalmente la lengua en la que se escribe el código de todas las redes neuronales: los inputs de un modelo de ML son vectores, los parámetros del modelo son matrices, el proceso de forward pass (calcular el output dado un input) es una secuencia de multiplicaciones de matrices, y el proceso de backpropagation (calcular los gradientes para actualizar los parámetros) es una secuencia de operaciones de álgebra lineal. Sin álgebra lineal no hay forma de entender qué está ocurriendo "dentro" de una red neuronal.

Los conceptos más importantes de álgebra lineal para la IA son: vectores y espacios vectoriales (representación de datos e inputs), matrices y multiplicación de matrices (la operación fundamental de las redes neuronales), autovectores y autovalores (cruciales para el análisis de componentes principales, PCA, y para entender la dinámica del entrenamiento), descomposición en valores singulares (SVD, base de LoRA y otros métodos de compresión de modelos), y normas (cómo medir la "magnitud" de un vector, crucial para la regularización).

Cálculo: gradientes y descenso del gradiente

El cálculo diferencial e integral es la herramienta matemática que permite a los algoritmos de ML aprender: el proceso de entrenamiento de una red neuronal es un proceso de optimización que minimiza una función de pérdida ajustando los parámetros del modelo. Esta minimización se hace mediante el descenso del gradiente, que requiere calcular las derivadas parciales de la función de

pérdida con respecto a todos los parámetros del modelo (el gradiente). La regla de la cadena del cálculo es la base matemática del algoritmo de backpropagation, que es cómo se calculan estos gradientes eficientemente en redes con millones o miles de millones de parámetros.

Los conceptos clave de cálculo para la IA son: derivadas (cómo cambia una función ante cambios infinitesimales en su input), derivadas parciales y gradientes (la generalización a funciones de múltiples variables), la regla de la cadena (cómo derivar funciones compuestas, la base de backpropagation), y el descenso del gradiente estocástico (SGD) y sus variantes (Adam, RMSprop, AdamW), que son los algoritmos de optimización que se usan en la práctica.

BLOQUE 2 · ESTADÍSTICA Y PROBABILIDAD

Estadística y probabilidad: el lenguaje de la incertidumbre

Por qué la estadística es inseparable del ML

El machine learning es fundamentalmente estadística aplicada a grandes datos con algoritmos eficientes. Los modelos de ML son estimadores estadísticos: aprenden una función que describe la relación entre inputs y outputs a partir de datos de entrenamiento, con la esperanza de que esa relación se generalice a datos nuevos. Conceptos estadísticos como sesgo y varianza, sobreajuste y subajuste, validación cruzada, intervalos de confianza, y pruebas de hipótesis son tan relevantes para el ML como los conceptos de álgebra lineal y cálculo.

La probabilidad proporciona el marco formal para razonar bajo incertidumbre, que es la condición normal de los sistemas de ML: los modelos no producen respuestas deterministas sino distribuciones de probabilidad sobre los posibles outputs. Los LLMs generan texto muestreando de una distribución de probabilidad sobre los posibles tokens siguientes. Los modelos de clasificación producen probabilidades de pertenecer a cada clase. Los sistemas de detección de anomalías calculan la probabilidad de que un nuevo punto de datos sea "normal" o "anómalo". Entender la probabilidad es entender cómo los modelos representan y comunican la incertidumbre.

Distribuciones de probabilidad y sus usos en IA

Las distribuciones de probabilidad más relevantes para la IA son: la distribución Normal (Gaussiana), que aparece en la inicialización de parámetros, en las suposiciones de muchos modelos estadísticos, y en el análisis de los errores; la distribución Bernoulli y la distribución Binomial, que modelan el resultado de experimentos binarios (clasificación binaria); la distribución Categórica, que es la generalización a múltiples categorías (clasificación multiclase); la distribución Softmax, que convierte las salidas brutas (logits) de una red neuronal en probabilidades que suman 1; y la distribución Uniforme, que se usa para la inicialización aleatoria y para el muestreo aleatorio.

La temperatura en los LLMs es directamente un parámetro que controla la forma de la distribución softmax sobre el vocabulario de tokens: temperatura baja concentra la probabilidad en los tokens más probables (respuestas más deterministas y conservadoras), temperatura alta distribuye la probabilidad más uniformemente (respuestas más diversas y creativas pero más propensas a alucinaciones). Entender esto ayuda a elegir la temperatura correcta para cada caso de uso.

El dilema sesgo-varianza

El dilema sesgo-varianza es uno de los conceptos más fundamentales del ML y es directamente aplicable al comportamiento de los LLMs. Un modelo con alto sesgo tiene suposiciones demasiado simplistas sobre los datos y produce underfitting: funciona mal tanto en los datos de entrenamiento como en los nuevos datos. Un modelo con alta varianza es demasiado sensible a los datos de entrenamiento específicos y produce overfitting: funciona bien en los datos de entrenamiento pero mal en los nuevos datos. El objetivo es encontrar el equilibrio entre sesgo y varianza que maximice la generalización.

En el contexto de los LLMs, la temperatura controla indirectamente este equilibrio: temperatura baja produce alta consistencia (bajo sesgo) pero menor creatividad y diversidad (baja varianza); temperatura alta produce mayor creatividad y diversidad pero respuestas menos fiables. El uso de few-shot examples en el prompt es análogo a un ajuste del sesgo: proporcionar ejemplos del comportamiento deseado sesga al modelo hacia ese tipo de respuesta.

BLOQUE 3 · ARQUITECTURAS DE REDES NEURONALES

De las redes neuronales básicas a los Transformers

El perceptrón y las redes neuronales feedforward

La unidad básica de las redes neuronales artificiales es el neurón artificial (perceptrón), que toma múltiples inputs, los pondera (multiplicación por pesos), suma los resultados, aplica una función de activación no lineal, y produce un output. Las funciones de activación son el ingrediente que da a las redes neuronales su capacidad de modelar relaciones no lineales: sin ellas, una red neuronal de múltiples capas sería equivalente a una red de una sola capa (una transformación lineal). Las funciones de activación más importantes son: ReLU (Rectified Linear Unit), sigmoid, tanh, y GELU (la más usada en los LLMs modernos).

Una red neuronal feedforward (también llamada MLP, Multi-Layer Perceptron) organiza estas neuronas en capas: una capa de input, una o más capas ocultas, y una capa de output. La información fluye en una sola dirección, del input al output, sin ciclos. El proceso de forward pass es una secuencia de multiplicaciones de matrices y aplicaciones de funciones de activación. El proceso de backpropagation calcula los gradientes de la función de pérdida con respecto a todos los pesos del modelo, que se usan para actualizar los pesos en la dirección que minimiza la pérdida.

Redes recurrentes (RNN, LSTM, GRU) y sus limitaciones

Las redes neuronales recurrentes (RNN) fueron durante años el estándar para el procesamiento de secuencias (texto, audio, series temporales) porque tienen una memoria interna que les permite procesar secuencias de longitud variable. Sin embargo, las RNN estándar sufren el problema del desvanecimiento del gradiente: durante el entrenamiento, los gradientes se vuelven extremadamente pequeños cuando se propagan hacia atrás a través de secuencias largas, lo que impide al modelo aprender dependencias de largo alcance en el texto. Las LSTM (Long Short-Term Memory) y las GRU (Gated Recurrent Unit) mitigan este problema con mecanismos de compuertas que controlan el flujo de información, pero siguen teniendo limitaciones fundamentales que los Transformers superaron definitivamente.

La arquitectura Transformer: la revolución de la atención

La arquitectura Transformer, introducida por Vaswani et al. (Google Brain, 2017) en el paper "Attention Is All You Need", representó un cambio de paradigma en el procesamiento de secuencias. En lugar de

procesar los tokens secuencialmente como las RNN, los Transformers procesan todos los tokens en paralelo usando el mecanismo de self-attention: cada token presta "atención" a todos los demás tokens en la secuencia, aprendiendo qué tokens son más relevantes para interpretar su significado en el contexto dado.

El mecanismo de atención es conceptualmente sencillo pero matemáticamente elegante. Para cada token, el Transformer calcula tres vectores: Query (qué busca este token), Key (qué ofrece este token a otros), y Value (qué información aporta este token). La atención de un token sobre todos los demás se calcula como el producto escalar entre su Query y los Keys de todos los demás tokens (normalizado con softmax), ponderado por los Values. El resultado es que tokens con alta afinidad semántica se "atienden" mutuamente con mayor intensidad. La atención multi-cabeza (multi-head attention) ejecuta múltiples mecanismos de atención en paralelo, capturando distintos tipos de relaciones semánticas simultáneamente.

De los Transformers a los LLMs: escalado y emergencia

Los LLMs son Transformers que se han escalado a enormes tamaños (desde cientos de millones hasta billones de parámetros) y entrenados sobre cantidades masivas de texto. El paper "Scaling Laws for Neural Language Models" (Kaplan et al., OpenAI, 2020) estableció que el rendimiento de los LLMs mejora de forma predecible con el tamaño del modelo, la cantidad de datos de entrenamiento, y el poder computacional, siguiendo leyes de potencia. Esto proporcionó la justificación teórica para invertir en modelos cada vez más grandes.

Las capacidades emergentes son quizás el fenómeno más sorprendente del escalado de LLMs: capacidades que no están presentes en modelos pequeños aparecen súbitamente cuando los modelos superan cierto umbral de tamaño. El razonamiento multi-paso, la resolución de analogías, la capacidad de seguir instrucciones complejas, y el aprendizaje in-context son todas capacidades que emergieron en modelos suficientemente grandes. La naturaleza de estas emergencias (si son realmente discontinuidades o artefactos de las métricas usadas para medirlas) es objeto de investigación activa.

BLOQUE 4 · MÉTRICAS Y EVALUACIÓN

Cómo medir el rendimiento de los modelos de IA

Métricas para clasificación

Las métricas de clasificación son las más desarrolladas en ML porque la clasificación (asignar un input a una categoría predefinida) es el tipo de problema más estudiado. Las métricas básicas son: accuracy (porcentaje de predicciones correctas sobre el total), precision (de todos los positivos predichos, qué porcentaje son realmente positivos), recall (de todos los positivos reales, qué porcentaje fueron detectados), y F1-score (media armónica de precision y recall, que equilibra ambas métricas). La elección de la métrica correcta depende del problema: en detección de fraude, el recall (no perderse ningún fraude real) puede ser más importante que la precision (algunos falsos positivos son aceptables); en diagnóstico médico, la precision (no diagnosticar erróneamente como enfermo a alguien sano) puede ser prioritaria.

La matriz de confusión es la herramienta más completa para analizar el rendimiento de un clasificador: muestra los verdaderos positivos, verdaderos negativos, falsos positivos, y falsos negativos. Analizarla permite identificar los tipos específicos de errores que comete el modelo y guiar las mejoras. La curva ROC (Receiver Operating Characteristic) y el AUC (Area Under the Curve) miden el rendimiento del

clasificador a través de todos los posibles umbrales de clasificación, lo que es especialmente útil cuando el umbral óptimo no está fijo.

Métricas para modelos de lenguaje

Evaluar los LLMs es significativamente más difícil que evaluar los modelos de clasificación clásicos porque los outputs son texto libre, no categorías predefinidas. Las métricas automáticas para texto incluyen: Perplexity (mide qué tan bien el modelo predice el texto de prueba; menor perplexity = mejor modelo), BLEU y ROUGE (métricas de similaridad n-gram usadas originalmente para traducción automática y resumen, respectivamente; fáciles de calcular pero correlacionan mal con la calidad percibida por humanos), BERTScore (usa embeddings de BERT para medir la similaridad semántica entre el texto generado y el de referencia; mejor correlación con el juicio humano), y las métricas RAGAS (Faithfulness, Answer Relevancy, Context Precision, Context Recall) específicas para sistemas RAG.

Las limitaciones de las métricas automáticas han llevado al uso creciente de LLM-as-judge: usar un LLM (frecuentemente un modelo frontier como GPT-4 o Claude Opus) para evaluar la calidad de las respuestas de otro LLM. Esta aproximación tiene sus propios sesgos (los LLMs tienden a preferir sus propias respuestas y las respuestas más largas), pero con el diseño correcto de las rúbricas de evaluación y el prompting adecuado, puede proporcionar evaluaciones de calidad comparable a la evaluación humana a una fracción del coste.

RESUMEN EJECUTIVO DEL MÓDULO 2: El álgebra lineal (vectores, matrices, SVD) es la lengua de las redes neuronales. El cálculo diferencial (gradientes, regla de la cadena) es la base del entrenamiento por backpropagation. La estadística y la probabilidad (distribuciones, sesgo-varianza, calibración) proporcionan el marco para razonar sobre la incertidumbre en los modelos de ML. La arquitectura Transformer (2017) revolucionó el procesamiento de secuencias con el mecanismo de self-attention, permitiendo el procesamiento paralelo de todos los tokens. Los LLMs son Transformers escalados que exhiben capacidades emergentes: el escalado predecible de la ley de potencia produjo comportamientos cualitativamente nuevos a ciertos umbrales de tamaño. La evaluación de LLMs es más compleja que la de modelos clásicos; las métricas automáticas (BLEU, ROUGE, BERTScore) tienen limitaciones y se complementan con LLM-as-judge para tareas de texto libre.