

Módulo 4 — Deep Learning

CNNs, backpropagation, optimizadores, preentrenamiento, RLHF, LoRA y QLoRA para fine-tuning eficiente.

BLOQUE 1 · LA REVOLUCIÓN DEL DEEP LEARNING

Módulo 4 — Deep Learning

El deep learning es la tecnología que ha producido los avances más espectaculares en IA de los últimos 15 años: desde el AlexNet que ganó ImageNet en 2012 con un margen sin precedente, hasta los LLMs que dominan el procesamiento del lenguaje natural en 2025. La razón por la que el deep learning ha superado a todos los enfoques anteriores en tantas tareas es su capacidad de aprender representaciones jerárquicas de los datos directamente de los datos brutos, sin necesitar feature engineering manual. Una red neuronal profunda aprende automáticamente qué características son relevantes en los datos y cómo combinarlas para hacer predicciones.

El deep learning no es magia: es álgebra lineal + funciones de activación no lineales + gradiente descendente, aplicados a enormes cantidades de datos y poder computacional. Lo que lo hace difícil de entender intuitivamente es la escala: un LLM moderno tiene miles de millones de parámetros organizados en cientos de capas, procesando secuencias de miles de tokens. Pero los principios básicos son los mismos que en una red neuronal de tres capas y cien parámetros.

La pirámide del deep learning: de los perceptrones a los Transformers

El deep learning es una jerarquía de arquitecturas que se construyen unas sobre otras. En la base están las redes feedforward (MLPs) que pueden aproximar cualquier función continua con suficientes neuronas (teorema de aproximación universal). Sobre ellas, las redes convolucionales (CNNs) añaden la inducción de que las características locales son reutilizables en diferentes posiciones del espacio, lo que las hace especialmente efectivas para imágenes. Las redes recurrentes (RNN, LSTM, GRU) añaden la inducción de que el orden de los elementos en una secuencia importa, lo que las hace efectivas para texto y series temporales. Los Transformers eliminan la necesidad de procesar las secuencias en orden usando self-attention, lo que permite el procesamiento paralelo y captura dependencias de largo alcance sin el problema del desvanecimiento del gradiente. Los LLMs son Transformers escalados que han demostrado capacidades emergentes de razonamiento.

Redes convolucionales (CNN): la revolución de la visión por computadora

Las Redes Neuronales Convolucionales (CNN) son el tipo de red neuronal diseñada específicamente para procesar datos con estructura espacial (imágenes, vídeos, señales de audio) o temporal (series temporales con dependencias locales). La clave de las CNNs es la operación de convolución: un filtro (kernel) de pequeño tamaño se desliza sobre la imagen (o la secuencia), calculando el producto escalar entre el filtro y cada parche de la imagen. El resultado es un mapa de activación que indica dónde aparece el patrón que el filtro detecta. Múltiples filtros aprenden distintos tipos de patrones (bordes horizontales, verticales, diagonales, texturas, formas más complejas en capas más profundas).

Las propiedades que hacen tan efectivas a las CNNs para imágenes son: la compartición de pesos (el mismo filtro se aplica a toda la imagen, reduciendo el número de parámetros), la invariancia a la traslación (el mismo patrón es detectado independientemente de su posición en la imagen), y la

jerarquía de representaciones (las capas más profundas aprenden características más abstractas y de mayor escala a partir de las más simples de las capas anteriores). Arquitecturas CNN icónicas como LeNet, AlexNet, VGG, ResNet, e Inception han definido el estado del arte en clasificación de imágenes en distintos momentos de la historia del deep learning.

BLOQUE 2 · ENTRENAMIENTO DE REDES NEURONALES PROFUNDAS

Los desafíos prácticos del entrenamiento en deep learning

Backpropagation y el cálculo de los gradientes

Backpropagation es el algoritmo que hace posible el entrenamiento de redes neuronales profundas. La idea fundamental es aplicar la regla de la cadena del cálculo para calcular eficientemente los gradientes de la función de pérdida con respecto a todos los parámetros del modelo. El proceso se desarrolla en dos fases: el forward pass (calcular el output del modelo dado un input, almacenando los activations intermedios) y el backward pass (calcular los gradientes propagándolos desde la capa de output hacia las capas anteriores). Los gradientes calculados se usan para actualizar los parámetros en la dirección que reduce la pérdida (descenso del gradiente).

El problema del vanishing gradient (gradiente que se desvanece) es uno de los principales desafíos del entrenamiento de redes profundas: cuando los gradientes se propagan hacia atrás a través de muchas capas, tienden a disminuir exponencialmente, haciendo que las capas más alejadas del output aprendan muy lentamente. Las soluciones incluyen: funciones de activación que evitan la saturación (ReLU y sus variantes, que no saturan para valores positivos), inicialización cuidadosa de los pesos (Xavier/Glorot, He initialization), y conexiones residuales (ResNets), que añaden "atajos" que permiten a los gradientes fluir directamente de las capas posteriores a las anteriores sin pasar por todas las capas intermedias.

Optimizadores: más allá del SGD estándar

El descenso del gradiente estocástico (SGD) en su forma básica actualiza los parámetros usando el gradiente calculado sobre un mini-batch de datos. Aunque SGD funciona, converge lentamente y puede quedar atrapado en óptimos locales o en sillas (saddle points) del espacio de pérdida. Los optimizadores modernos mejoran SGD añadiendo momento (acelera la convergencia en la dirección de descenso constante, reduce las oscilaciones en las direcciones de curvatura alta), tasas de aprendizaje adaptativas (ajustan la tasa de aprendizaje de cada parámetro individualmente basándose en el historial de gradientes), y corrección de sesgo para los estimadores de las estadísticas de los gradientes.

AdamW (Adam con decoupled weight decay) es el optimizador estándar para el entrenamiento de LLMs. Adam combina momento y tasas de aprendizaje adaptativas, y AdamW separa la penalización de weight decay del gradiente para una regularización más efectiva. Para el fine-tuning de LLMs, la tasa de aprendizaje óptima es típicamente mucho menor (10-100x) que para el entrenamiento desde cero, y el uso de un learning rate scheduler (que reduce la tasa de aprendizaje a lo largo del entrenamiento, por ejemplo cosine annealing con warmup) es estándar.

Técnicas de regularización en deep learning

El deep learning tiene sus propias técnicas de regularización específicas. Dropout: durante el entrenamiento, se desactivan aleatoriamente un porcentaje de las neuronas en cada forward pass, forzando a la red a aprender representaciones redundantes que no dependan de ninguna neurona específica. Batch Normalization: normaliza las activaciones de cada capa en cada mini-batch durante el entrenamiento, lo que estabiliza el entrenamiento, permite tasas de aprendizaje más altas, y actúa como regularizador. Layer Normalization: similar a Batch Normalization pero normaliza a través de las features en lugar del batch; es el estándar en los Transformers porque funciona mejor con secuencias de longitud variable. Data Augmentation: generar variaciones artificiales de los datos de entrenamiento (rotaciones, recortes, cambios de brillo para imágenes; sustitución de sinónimos, back-translation para texto) aumenta efectivamente el tamaño del dataset y reduce el overfitting.

BLOQUE 3 · PREENTRENAMIENTO Y FINE-TUNING

Transfer Learning y Fine-Tuning: la estrategia de IA moderna

Por qué el preentrenamiento cambia todo

El paradigma del preentrenamiento más fine-tuning ha transformado radicalmente cómo se desarrollan los modelos de IA. En el paradigma anterior, cada tarea requería entrenar un modelo desde cero con datos etiquetados de esa tarea específica. El preentrenamiento permite entrenar una sola vez un modelo grande sobre enormes cantidades de datos no etiquetados (texto, imágenes, código) para aprender representaciones generales y ricas del mundo, y luego adaptar (fine-tune) ese modelo a tareas específicas con muchos menos datos etiquetados.

Para los LLMs, el preentrenamiento se hace típicamente sobre terabytes de texto de internet (Common Crawl, Wikipedia, libros, código de GitHub) usando la tarea de language modeling (predecir el siguiente token). Este proceso aprende representaciones de palabras, conceptos, relaciones semánticas, estructuras gramaticales, hechos sobre el mundo, y razonamiento lógico implícito. El modelo preentrenado es el "peso bruto" de la inteligencia lingüística que luego puede adaptarse a miles de tareas distintas con fine-tuning.

RLHF: alinear los LLMs con las preferencias humanas

El Reinforcement Learning from Human Feedback (RLHF) es la técnica que transformó los LLMs de generadores de texto en asistentes útiles y seguros. InstructGPT (OpenAI, 2022) demostró que un modelo de 1.3B parámetros entrenado con RLHF superaba en utilidad y seguridad a modelos de 175B parámetros entrenados solo con language modeling. El proceso de RLHF tiene tres fases: primero, fine-tuning supervisado con ejemplos de conversaciones de alta calidad (SFT); segundo, entrenamiento de un modelo de recompensa (RM) que predice qué respuesta prefieren los humanos dado un prompt, usando pares de respuestas con preferencias anotadas por humanos; tercero, optimización del SFT model usando el modelo de recompensa como señal de feedback con el algoritmo PPO (Proximal Policy Optimization).

DPO (Direct Preference Optimization) es una alternativa más simple al RLHF que logra alineamiento similar sin necesidad de entrenar el modelo de recompensa ni usar PPO, simplificando significativamente el pipeline de entrenamiento. Los modelos más recientes (Claude, Llama 3) usan variantes de DPO o técnicas similares para el alineamiento.

Fine-tuning eficiente: LoRA, QLoRA, y PEFT

El fine-tuning completo de un LLM de 70B parámetros requiere decenas de GPUs de alta gama durante días y produce un modelo completo de 140GB que debe desplegarse por separado de la versión base. Las técnicas de PEFT (Parameter-Efficient Fine-Tuning) resuelven este problema ajustando solo una pequeña fracción de los parámetros del modelo. LoRA (Low-Rank Adaptation) es la técnica más popular: en lugar de ajustar directamente los pesos del modelo, añade matrices de bajo rango a las capas de atención del Transformer. Estas matrices son mucho más pequeñas que los pesos originales (típicamente el 0.1-1% del total de parámetros) y capturan la adaptación necesaria para la tarea objetivo. QLoRA (Quantized LoRA) combina LoRA con la cuantización del modelo base en 4-bit, reduciendo dramáticamente los requisitos de memoria y haciendo posible el fine-tuning de modelos de 70B parámetros en una sola GPU de consumo con 24GB de VRAM.

RESUMEN EJECUTIVO DEL MÓDULO 4: Deep learning aprende representaciones jerárquicas de los datos sin feature engineering manual: es la razón de su superioridad en imagen, texto, y audio. Las CNNs son el estándar para visión por computadora gracias a la compartición de pesos, la invarianza a la traslación, y la jerarquía de representaciones. Backpropagation más descenso del gradiente es el mecanismo de aprendizaje; el vanishing gradient se resuelve con ReLU, inicialización correcta, y conexiones residuales. AdamW es el optimizador estándar para LLMs; el learning rate scheduler es imprescindible. El preentrenamiento más fine-tuning es el paradigma dominante: el modelo aprende representaciones generales y se adapta a tareas específicas con muchos menos datos. RLHF y DPO alinean los LLMs con las preferencias humanas. LoRA y QLoRA permiten el fine-tuning eficiente de LLMs grandes con recursos limitados: el 0.1-1% de los parámetros captura la adaptación necesaria.