

Módulo 5 — NLP y Large Language Models

Evolución del NLP, arquitectura de LLMs, capacidades y límites, tokenización, embeddings y casos de uso empresariales.

BLOQUE 1 · LA EVOLUCIÓN DEL PROCESAMIENTO DEL LENGUAJE NATURAL

Módulo 5 — NLP y Large Language Models

El procesamiento del lenguaje natural (NLP) es la disciplina de la IA dedicada a que las máquinas entiendan, interpreten, y generen lenguaje humano. Ha existido como campo desde los años 50, pero los avances de los últimos 5 años han sido tan drásticos que el NLP pre-Transformer y el NLP post-Transformer son casi disciplinas distintas. Entender la evolución histórica es importante para apreciar por qué los LLMs son tan poderosos y cuáles son sus límites fundamentales.

Las primeras aproximaciones al NLP eran basadas en reglas: gramáticas formales, léxicos, y reglas de transformación escritas a mano por lingüistas. Funcionaban bien para tareas muy acotadas pero no escalaban a la variabilidad infinita del lenguaje natural. El machine learning estadístico (Naive Bayes para clasificación de texto, modelos n-gram para el lenguaje, SVMs con TF-IDF para recuperación de información) mejoró el rendimiento y la cobertura pero seguía requiriendo feature engineering manual y no capturaba bien el significado semántico. Los word embeddings (Word2Vec, GloVe) introdujeron la representación distribuida del significado: palabras semánticamente similares tienen vectores cercanos en el espacio de embeddings. BERT (2018) y los modelos de tipo encoder introdujeron los embeddings contextuales: la misma palabra tiene distintas representaciones según el contexto en que aparece. GPT y los modelos de tipo decoder cerraron el ciclo: un modelo capaz de generar texto coherente de forma abierta, que resultó ser la arquitectura más poderosa para el lenguaje natural.

La arquitectura de los LLMs modernos

Los LLMs modernos son Transformers decoder-only entrenados con el objetivo de language modeling autoregresivo: dado un contexto de tokens, predecir el siguiente token. Durante la inferencia, el modelo genera texto token por token, añadiendo cada token generado al contexto para generar el siguiente. Este proceso autoregresivo es la razón de que los LLMs sean lentos para generar textos largos (cada token requiere una pasada completa por el modelo) y de que los errores tempranos en la generación se propaguen y amplíen.

Los componentes principales de un LLM moderno son: el tokenizador (convierte texto a tokens y viceversa), el embedding de tokens (mapea cada token a un vector de alta dimensionalidad), las capas de self-attention multi-cabeza (el corazón del Transformer, que captura las relaciones entre todos los tokens del contexto), las capas feed-forward posición por posición (que aplican transformaciones no lineales a cada posición), la normalización de capas (Layer Norm, que estabiliza el entrenamiento), y la cabeza de lenguaje (proyecta el vector de la última capa al vocabulario y produce las probabilidades del siguiente token). La escala (número de capas, dimensionalidad de los vectores, número de cabezas de atención) determina el número total de parámetros y las capacidades del modelo.

Benchmarks y comparación de modelos

Los benchmarks son la herramienta estándar para comparar modelos de lenguaje. Los más influyentes en 2025 son: MMLU (Massive Multitask Language Understanding, 57 disciplinas académicas, mide el

conocimiento factual), HumanEval y SWE-bench (evaluación de código, mide la capacidad de generar código funcional), GPQA (Graduate-Level Google-Proof Q&A, preguntas de ciencia nivel doctorado diseñadas para ser difíciles de responder con búsqueda web), ARC (Abstract and Reasoning Corpus, razonamiento abstracto y analogías), y HellaSwag (comprensión del sentido común). Los modelos frontier de 2025 (GPT-4o, Claude 3.5/4, Gemini 1.5 Pro) saturan o casi saturan muchos de estos benchmarks, lo que ha llevado a la creación de benchmarks más difíciles que puedan diferenciar mejor las capacidades de los modelos más avanzados.

BLOQUE 2 · CAPACIDADES Y LIMITACIONES DE LOS LLMs

Qué pueden y qué no pueden hacer los LLMs

Las capacidades extraordinarias de los LLMs modernos

Los LLMs modernos tienen capacidades que eran ciencia ficción hace 5 años. La comprensión y generación de texto en múltiples idiomas y estilos es casi perfecta para los idiomas de alta representación en los datos de entrenamiento. La escritura de código funcional en docenas de lenguajes de programación, con debugging, explicación, y documentación, ha transformado la productividad de los desarrolladores. El análisis y resumen de documentos largos (contratos, informes, papers científicos) con ventanas de contexto de 128K-1M tokens permite procesar documentos enteros en una sola llamada. El razonamiento matemático y lógico multi-paso con modelos de razonamiento como o3 alcanza o supera el nivel experto humano en muchos benchmarks. La generación de contenido creativo (ficción, poesía, guiones, publicidad) con coherencia temática y estilística extensa. El aprendizaje en contexto (in-context learning): el modelo puede aprender a realizar tareas nuevas simplemente viendo ejemplos en el prompt, sin fine-tuning.

La capacidad multimodal de los modelos de 2025 es especialmente significativa: modelos como GPT-4o, Claude 3.5 Sonnet, y Gemini 1.5 Pro pueden procesar texto, imágenes, documentos, y en algunos casos audio y vídeo en la misma llamada. Esto abre casos de uso que antes requerían múltiples modelos especializados: un solo modelo puede analizar una imagen de un gráfico, leer la tabla de datos adjunta, y generar un informe narrativo en texto.

Los límites fundamentales y los errores conocidos

Los límites de los LLMs son tan importantes como sus capacidades para un profesional que los aplica en producción. Las alucinaciones son el límite más conocido y más costoso: los modelos generan afirmaciones incorrectas con total confianza, especialmente en hechos específicos (fechas, nombres propios, estadísticas), razonamiento matemático sin herramientas de cálculo, y cuando el modelo no tiene suficiente información pero el formato del prompt invita a generar contenido específico. Los sesgos heredados del corpus de entrenamiento (sesgo de género, sesgo racial, perspectiva anglocéntrica, perspectiva de grupos sociales sobre-representados en internet) pueden producir respuestas discriminatorias o inexactas para grupos subrepresentados. La dependencia del prompt (prompt sensitivity) significa que variaciones aparentemente menores en el prompt pueden producir respuestas muy distintas, lo que dificulta la construcción de sistemas de producción robustos. El límite del contexto (aunque los modelos frontier tienen ventanas de 128K-1M tokens) sigue siendo real: la atención del modelo se diluye con contextos muy largos y puede perder información de las partes más lejanas del contexto.

BLOQUE 3 · TOKENIZACIÓN, EMBEDDINGS, Y SEMÁNTICA

Cómo representan el lenguaje los modelos de IA

Tokenización: de texto a números

Los LLMs no procesan texto directamente: procesan secuencias de tokens, que son fragmentos de texto de tamaño variable (típicamente de 1-4 caracteres para texto en inglés). El tokenizador es el componente que convierte texto a tokens y viceversa. El tokenizador de los LLMs modernos usa el algoritmo BPE (Byte Pair Encoding) o variantes: empieza con todos los caracteres como tokens individuales y fusiona iterativamente los pares de tokens más frecuentes en el corpus de entrenamiento. El resultado es un vocabulario de típicamente 50.000-100.000 tokens que equilibra cobertura (puede tokenizar cualquier texto) con eficiencia (los textos comunes se representan con pocos tokens).

El número de tokens es la unidad de coste y latencia de los LLMs. Entender la tokenización ayuda a gestionar el coste y la latencia: el texto en inglés usa típicamente 1 token por 4 caracteres o aproximadamente 1 token por 0.75 palabras. El texto en idiomas distintos del inglés puede ser significativamente menos eficiente: el chino, el árabe, y el código en ciertos lenguajes de programación pueden usar más tokens por unidad de información. Los números, fechas, y caracteres especiales frecuentemente se tokenizan de forma ineficiente.

Embeddings: el espacio semántico del lenguaje

Los embeddings son representaciones vectoriales de texto (palabras, frases, párrafos, o documentos completos) en espacios de alta dimensionalidad (típicamente 768-4096 dimensiones) donde los textos semánticamente similares tienen vectores cercanos. Son la tecnología fundamental de los sistemas RAG (los documentos y las consultas se representan como vectores y se recuperan por similitud semántica) y del análisis semántico de texto. Los modelos de embedding especializados (text-embedding-3-large de OpenAI, E5 de Microsoft, BGE de BAAI) están optimizados específicamente para producir representaciones vectoriales de alta calidad, a diferencia de los LLMs que están optimizados para generar texto.

La distancia coseno es la métrica estándar para comparar embeddings: mide el ángulo entre dos vectores, siendo 0 para vectores idénticos y 1 para vectores ortogonales. Las bases de datos vectoriales (Qdrant, Pinecone, Weaviate, Chroma, pgvector) almacenan millones de embeddings y permiten búsquedas de similitud eficientes (k-nearest-neighbors aproximado con índices HNSW o IVF). El fine-tuning de modelos de embedding para dominios específicos puede mejorar significativamente la calidad de la recuperación en sistemas RAG: los embeddings genéricos no capturan bien la terminología especializada de dominios como medicina, derecho, o ingeniería.

BLOQUE 4 · APLICACIONES DE NLP EN EMPRESA

Casos de uso de NLP en producción

Clasificación y extracción de información

La clasificación de texto (asignar categorías a documentos de texto) y la extracción de información (extraer entidades, relaciones, y hechos estructurados de texto no estructurado) siguen siendo dos de los casos de uso de NLP más frecuentes en empresa. Los LLMs han simplificado enormemente estos casos de uso: en lugar de entrenar modelos de clasificación específicos con miles de ejemplos etiquetados, se puede usar un LLM con un prompt bien diseñado para clasificar o extraer información

con pocas o ningún ejemplo etiquetado (zero-shot o few-shot). Para casos de uso de alta frecuencia y bajo presupuesto, el fine-tuning de modelos más pequeños (BERT, DistilBERT, DeBERTa) sobre ejemplos etiquetados produce clasificadores muy eficientes en inferencia.

La extracción de información estructurada de documentos (Named Entity Recognition para extraer personas, organizaciones, fechas, importes; Relation Extraction para extraer relaciones entre entidades; Document Parsing para extraer datos de facturas, contratos, formularios) es uno de los casos de uso de mayor impacto económico de la IA en empresa, directamente relacionado con la automatización de procesos documentales (Módulo 11). Los LLMs con function calling son especialmente poderosos para este caso de uso: se les puede pedir que extraigan información y la devuelvan en un schema JSON específico, combinando la comprensión del lenguaje natural con la estructura de datos requerida por los sistemas downstream.

Resumen automático y generación de informes

El resumen automático de documentos largos es uno de los casos de uso de mayor adopción de los LLMs en empresa. Los analistas que pasaban 2 horas leyendo un informe anual de 200 páginas para extraer los puntos clave ahora pueden usar un LLM para obtener un resumen ejecutivo en 2 minutos. Los abogados que revisaban contratos de 50 páginas para identificar cláusulas problemáticas usan RAG sobre los contratos para hacer preguntas específicas. Los periodistas y analistas de mercado que monitorizaban docenas de fuentes de noticias usan LLMs para filtrar, resumir, y sintetizar. La ventana de contexto larga de los modelos modernos (128K-1M tokens) es especialmente relevante para este caso de uso: permite analizar documentos enteros en una sola llamada sin necesidad de chunking.

Traducción automática y comunicación multilingüe

Los LLMs modernos son excelentes traductores para los idiomas más comunes: la calidad de la traducción de GPT-4 y Claude supera a la de herramientas de traducción especializadas como DeepL para la mayoría de los pares de idiomas de alta representación. Más importante, los LLMs no solo traducen literalmente: entienden el contexto, el tono, y las implicaciones culturales, produciendo traducciones más naturales y apropiadas al contexto que los sistemas de traducción anteriores. Para empresas globales, esto abre la posibilidad de comunicación efectiva en decenas de idiomas sin equipos de traductores dedicados.

RESUMEN EJECUTIVO DEL MÓDULO 5: El NLP ha evolucionado de reglas a estadística a embeddings a LLMs. Los LLMs son Transformers decoder-only entrenados con language modeling autoregresivo. Los benchmarks principales son MMLU, HumanEval, SWE-bench, GPQA, y ARC. Las capacidades extraordinarias incluyen: generación de texto multilingüe, código, análisis de documentos, razonamiento con extended thinking, y multimodalidad. Los límites son: alucinaciones (el límite más costoso en producción), sesgo del corpus, sensibilidad al prompt, y dilución de la atención en contextos largos. Tokenización BPE: 1 token por 4 caracteres en inglés; variable en otros idiomas. Los embeddings son representaciones vectoriales semánticas; las bases de datos vectoriales (Qdrant, Pinecone) permiten búsqueda de similitud a escala. Los casos de uso empresariales principales son: clasificación y extracción, resumen de documentos, generación de informes, y traducción multilingüe.