

Panorama actual de modelos y proveedores

Módulo 0 · Introducción Estratégica a la IA

OpenAI, Anthropic, Google, Meta y el ecosistema open source: cómo comparar, elegir y gestionar
proveedores de modelos de IA.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Panorama actual de modelos y proveedores

El mercado de modelos de IA en 2025 es un oligopolio dinámico: cuatro o cinco empresas controlan los modelos frontier más capaces, pero un ecosistema de decenas de modelos open weights (pesos abiertos) ofrece alternativas para self-hosting con niveles de capacidad que hace dos años solo tenían los proveedores comerciales. Las decisiones de qué proveedor y qué modelo usar tienen consecuencias de coste, privacidad, rendimiento y dependencia que se extienden durante años.

El gasto empresarial total en IA generativa fue de 37.000 millones de dólares en 2025. Los tres proveedores de modelos dominantes son OpenAI (con la familia GPT y el nuevo GPT-5), Anthropic (familia Claude) y Google (Gemini). Meta ha convertido Llama en el estándar de facto del open source. Mistral, Cohere y xAI (Grok) completan el panorama de los proveedores significativos.

El ecosistema de modelos: frontier vs open weights

Modelos frontier: máxima capacidad, máxima dependencia

Los modelos frontier son los más capaces del mercado en cada momento. OpenAI tiene la familia GPT-4o y GPT-5 para razonamiento general, y la familia o1/o3/o4 para razonamiento extendido. Anthropic tiene Claude Opus 4 para tareas de máxima complejidad, Claude Sonnet 4 como equilibrio calidad-coste para uso diario, y Claude Haiku para latencia baja y coste mínimo. Google tiene la familia Gemini con contextos de hasta 1 millón de tokens y capacidades nativas de multimodalidad (texto, imagen, audio, vídeo).

La decisión de usar modelos frontier implica aceptar: precios por token (que pueden ser significativos a escala), los datos pasan por la infraestructura del proveedor (con implicaciones de privacidad), dependencia del proveedor para disponibilidad y precios, y actualizaciones de modelo que pueden cambiar el comportamiento del sistema sin aviso.

Modelos open weights: soberanía y coste, a cambio de esfuerzo operativo

Los modelos open weights publican sus pesos (los parámetros del modelo) para uso libre. Llama 3 de Meta (disponible en versiones de 8B, 70B y 405B parámetros), Mistral y Mixtral de Mistral AI, Qwen de Alibaba y Falcon de TII son los más relevantes. Se pueden desplegar en infraestructura propia con frameworks como vLLM, TGI (Text Generation Inference) o TensorRT-LLM, eliminando la dependencia del proveedor y manteniendo los datos dentro del perímetro de la empresa.

La contrapartida es el coste operativo: se necesita hardware (GPUs), capacidad técnica para operar el stack de serving, y mantenimiento del ciclo de hardware. Para organizaciones con requisitos estrictos de privacidad de datos (hospitales, firmas legales, defensa) o con volúmenes de inferencia muy altos, el análisis de coste total de propiedad puede favorecer claramente el self-hosting.

Cómo evaluar y comparar modelos

Dimensiones de evaluación

Comparar modelos requiere evaluar al menos seis dimensiones. Primera: capacidad de razonamiento (benchmarks como MMLU, GPQA, SWE-bench para código). Segunda: latencia (tiempo de respuesta en ms por token generado). Tercera: coste por millón de tokens de entrada y salida. Cuarta: ventana de contexto (longitud máxima de texto que el modelo puede procesar en una sola llamada). Quinta: multimodalidad (¿puede procesar imagen, audio, vídeo además de texto?). Sexta: opciones de privacidad y residencia de datos (¿ofrece el proveedor zero data retention, VPC privada, aislamiento de tenant?).

El modelo correcto para un caso de uso no es el que tiene el mejor benchmark general: es el que tiene el mejor balance entre capacidad suficiente para la tarea, latencia aceptable para el caso de uso, coste sostenible al volumen proyectado, y opciones de privacidad compatibles con las obligaciones regulatorias de la organización.

Estrategia multiproveedores

Las arquitecturas bien diseñadas abstraen el modelo subyacente mediante capas de abstracción (LiteLLM, por ejemplo, permite cambiar entre proveedores con una línea de código). Esto reduce el lock-in y permite aprovechar la competencia entre proveedores: usar el modelo más barato para tareas simples y el más potente solo cuando la calidad lo requiere. Frameworks como LangChain o LlamaIndex implementan esta abstracción a nivel de aplicación.

Decisiones reales de proveedores en empresa

- BBVA y otros bancos europeos: han optado por despliegues de modelos open weights (Llama, Mistral) en infraestructura propia o en Azure/AWS con aislamiento de datos, para cumplir con los requisitos del GDPR y las regulaciones bancarias sobre residencia y tratamiento de datos.
- Startups de SaaS de alto crecimiento: usan Claude Haiku o GPT-4o-mini para procesamiento masivo de texto (clasificación, resumen, extracción) donde el coste por token es crítico, y reservan Claude Opus u o3 para tareas complejas de razonamiento o análisis donde la calidad justifica el sobre coste.
- Firmas de abogados grandes: Harvey AI usa GPT-4 con acuerdos enterprise de zero data retention y contratos de confidencialidad específicos. La privacidad del cliente es un requisito deontológico y legal no negociable.
- Empresas de manufactura con datos industriales sensibles: self-hosting de Llama 3 70B o Mistral en servidores on-premise con GPUs NVIDIA A100 para procesar manuales técnicos, órdenes de trabajo y datos de producción sin que salgan del perímetro corporativo.

Errores frecuentes en la selección de proveedores

Error 1: Elegir el modelo con el mejor benchmark sin evaluar en el caso de uso propio. Los benchmarks miden capacidad general. Tu caso de uso puede tener propiedades específicas (vocabulario de dominio, formato de salida, tipo de razonamiento) que hacen que un modelo "peor" en benchmarks genéricos funcione mejor en tu aplicación concreta.

Error 2: Ignorar la política de privacidad del proveedor. La opción por defecto en las APIs de la mayoría de los proveedores permite retención de datos para mejora del servicio. Para datos sensibles, esto requiere configuración explícita de zero data retention o migración a opciones enterprise, con el consiguiente aumento de coste.

Error 3: Asumir que el proveedor más conocido es el correcto. En 2025 los modelos de Meta (Llama), Mistral y otros proveedores menores compiten de forma muy efectiva con los frontier en muchas tareas, con costes de inferencia que pueden ser un orden de magnitud menores en self-hosting.

Error 4: No planificar la estrategia de salida del proveedor. Los contratos de IA enterprise suelen ser anuales con renovación automática. Si no has diseñado una capa de abstracción, cambiar de proveedor puede requerir reescribir significativas partes del sistema.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Cómo construir tu mapa de proveedores

El primer paso es categorizar tus casos de uso por requisitos: ¿qué nivel de capacidad de razonamiento necesita cada caso? ¿Qué volumen de llamadas se espera? ¿Qué sensibilidad tienen los datos procesados? Con esa clasificación, se puede construir un portfolio de proveedores: un proveedor frontier para las tareas de alta complejidad y bajo volumen, un proveedor de coste optimizado para las tareas de alto volumen y menor complejidad, y opcionalmente una capa de self-hosting para datos sensibles o costes muy altos.

El segundo paso es implementar una capa de abstracción desde el primer día. LiteLLM es el estándar de facto: con una API unificada puedes llamar a OpenAI, Anthropic, Google, Mistral, modelos locales vía Ollama, y decenas de otros proveedores. Esto permite experimentar con nuevos modelos, comparar costes en tiempo real y migrar de proveedor sin refactorizar el código de aplicación.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

Conexiones con el resto del máster

- Módulo 8 (LLMOps): la gestión del ciclo de vida de modelos incluye la decisión de qué modelo usar en cada etapa y cómo actualizar cuando aparecen mejores opciones.
- Módulo 9 (Infraestructura): las opciones de despliegue (API gestionada, VPC, on-premise) y su análisis de coste total de propiedad son el desarrollo completo de la elección de proveedor.
- Módulo 12 (Seguridad): las políticas de privacidad de los proveedores, las opciones de zero data retention y el aislamiento de tenant son decisiones de seguridad tanto como de

elección de proveedor.

SECCIÓN 8 · RESUMEN EJECUTIVO

Resumen ejecutivo

El mercado de modelos está dominado por tres familias frontier (GPT de OpenAI, Claude de Anthropic, Gemini de Google) y un ecosistema open weights liderado por Llama de Meta. La decisión de proveedor no es solo técnica: implica coste, privacidad, dependencia y cumplimiento regulatorio. El modelo correcto es el que tiene capacidad suficiente para la tarea al coste aceptable con las garantías de privacidad requeridas, no el que tiene el benchmark más alto. Las arquitecturas bien diseñadas abstraen el proveedor subyacente mediante capas como LiteLLM para mantener flexibilidad. Para datos sensibles, el self-hosting de modelos open weights puede ser la única opción viable y, a escala, también la más económica.