

Capacidades reales vs limitaciones actuales

Módulo 0 · Introducción Estratégica a la IA

Qué hace bien la IA hoy, por qué alucinan los LLMs, y cómo diseñar sistemas que gestionen las limitaciones estructurales.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Capacidades reales vs limitaciones actuales de la IA

Los LLMs de 2025 superan al humano medio en el bar de la abogacía de EE.UU., aprueban el examen MIR de medicina, obtienen puntuaciones de experto en evaluaciones de física, matemáticas y biología, y resuelven problemas de programación de dificultad competitiva. Al mismo tiempo, pueden inventar citas bibliográficas inexistentes con total confianza, fallar en operaciones aritméticas de tres dígitos, confundir izquierda y derecha en instrucciones espaciales, y ser manipulados con instrucciones ocultas en el contexto.

Esta dualidad no es una contradicción: es la consecuencia de la naturaleza estadística del aprendizaje. Los LLMs son extraordinariamente buenos en tareas que están bien representadas en sus datos de entrenamiento y que tienen una estructura que pueden capturar estadísticamente. Son sistemáticamente malos en tareas que requieren razonamiento simbólico preciso, acceso a información actualizada, o que son inherentemente adversariales.

El mapa honesto de capacidades y limitaciones

Qué hacen bien los LLMs actuales

Comprensión y generación de texto: los LLMs son muy buenos resumiendo documentos largos, extrayendo información estructurada de texto no estructurado, traduciendo entre idiomas, y generando texto en estilos y formatos específicos. La calidad en estas tareas es frecuentemente comparable o superior al humano medio para texto en inglés y en los principales idiomas europeos.

Generación de código: es posiblemente la capacidad más madura. Los modelos actuales pueden generar funciones completas, depurar errores, explicar código existente y migrar entre lenguajes de programación con una competencia que en benchmarks como SWE-bench supera al desarrollador junior en muchas tareas.

Razonamiento sobre problemas complejos con información en el contexto: cuando toda la información necesaria está en el contexto, los modelos de razonamiento (o1, o3, Claude con extended thinking) pueden razonar sobre problemas complejos de matemáticas, lógica, estrategia y planificación con niveles que sorprenden incluso a los investigadores.

Limitaciones estructurales que no desaparecerán fácilmente

Alucinación: los LLMs generan lo que es estadísticamente probable, no lo que es verdad. Cuando no saben algo, a menudo inventan una respuesta plausible en lugar de decir que no saben. Esta limitación es especialmente peligrosa porque las alucinaciones se presentan con el mismo nivel de confianza que las respuestas correctas.

Corte de conocimiento: los modelos tienen una fecha límite de entrenamiento más allá de la cual no saben qué ocurrió. Un modelo con corte en enero de 2025 no sabe nada sobre eventos de febrero de 2025. Esto hace que los LLMs sin acceso a herramientas de búsqueda sean inapropiados para tareas que requieren información actualizada.

Aritmética y razonamiento simbólico preciso: la tokenización numérica hace que los LLMs no procesen los números como valores matemáticos sino como secuencias de tokens. Esto produce errores en operaciones aritméticas que cualquier calculadora resolvería sin fallos. La solución es el tool use: dar al modelo acceso a un intérprete de código o calculadora que ejecute las operaciones con precisión garantizada.

Contexto limitado y pérdida de información: aunque los modelos modernos tienen ventanas de contexto de 100K a 1M tokens, la atención no es uniforme dentro de ese contexto. El fenómeno "lost in the middle" documenta que los modelos prestan menos atención a la información en el centro del contexto que al principio y al final.

SECCIÓN 3 · CÓMO FUNCIONA: NIVEL TÉCNICO CLARO

Por qué existen estas limitaciones: la raíz técnica

La raíz de todas las limitaciones de los LLMs es la misma: son optimizadores estadísticos, no razonadores lógicos. Durante el preentrenamiento, el modelo aprende a predecir el siguiente token minimizando la cross-entropy loss sobre billones de documentos. El resultado es una función que asigna altas probabilidades a los tokens que típicamente siguen a un contexto dado. Cuando ese contexto corresponde a una tarea donde la continuación típica es la respuesta correcta, el modelo funciona bien. Cuando la tarea requiere razonamiento que va más allá de los patrones estadísticos, el modelo puede generar texto fluido que es incorrecto.

Los modelos de razonamiento (o1, o3, Claude con extended thinking) añaden un paso intermedio: generan tokens de "pensamiento" interno antes de producir la respuesta visible. Esto les permite explorar más caminos de razonamiento antes de comprometerse con una respuesta. El resultado es una mejora significativa en tareas de razonamiento complejo, pero no elimina la naturaleza estadística fundamental del proceso: siguen siendo susceptibles a las mismas clases de errores.

SECCIÓN 4 · EJEMPLOS REALES

Ejemplos concretos de capacidades y fallos

- Capacidad real - Klarna: sustituyó el equivalente de 700 agentes de soporte con un asistente de IA que resuelve en 2 minutos lo que antes tardaba 11, con satisfacción de cliente comparable. Caso de uso con texto estructurado, información en el contexto y human-in-the-loop para casos complejos.
- Capacidad real - BioNTech: usa LLMs para acelerar el análisis de literatura científica y la generación de hipótesis en investigación de ARNm. Tareas donde el modelo procesa información existente en su contexto.
- Limitación real - Casos legales inexistentes: abogados han sido sancionados por presentar citas de casos judiciales generadas por ChatGPT que no existían. El modelo generó títulos de casos, números de expediente y resúmenes de sentencias que sonaban plausibles pero eran completamente ficticios.
- Limitación real - Fallos en cálculos financieros: varios sistemas de análisis financiero automatizado han producido errores en cálculos de valoración porque el LLM realizó

operaciones aritméticas incorrectamente. La solución técnica es conectar el LLM a un intérprete de Python que ejecuta los cálculos con precisión total.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Malentendidos sobre capacidades y limitaciones

Error 1: "Si el modelo pasa el examen MIR, es confiable para diagnóstico médico." Pasar un examen de conocimiento teórico es muy distinto a razonar de forma fiable sobre casos clínicos reales con información incompleta, ambigüedad diagnóstica y consecuencias de vida o muerte. Los benchmarks miden conocimiento, no criterio clínico.

Error 2: "Las alucinaciones se resolverán con el próximo modelo." Las alucinaciones son una propiedad emergente de los sistemas estadísticos de generación de texto, no un bug que se puede corregir. Se pueden mitigar con RAG, con prompting estructurado y con evaluación continua, pero no se eliminan. Los sistemas críticos deben diseñarse asumiendo que el modelo puede alucinar.

Error 3: "El modelo de razonamiento siempre es mejor." Los modelos de razonamiento son más capaces en tareas complejas pero son más lentos y más caros. Para clasificación de emails, resumen de documentos cortos o respuestas a preguntas con información en el contexto, un modelo estándar es suficiente y más eficiente.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Cómo evaluar capacidades para tu caso de uso

El proceso correcto para evaluar si un modelo es adecuado para un caso de uso empresarial tiene tres pasos. Primero: construir un conjunto de evaluación (golden dataset) con 50-200 casos representativos que tengan respuesta correcta verificada por expertos del dominio. Incluir casos fáciles, difíciles, y casos extremos. Segundo: ejecutar el modelo sobre ese conjunto y medir las métricas que importan para el caso de uso: precisión en extracción, tasa de alucinación, conformidad con el formato de salida, latencia. Tercero: comparar esas métricas contra los criterios de aceptación del caso de uso y contra los modelos alternativos.

Este proceso, que puede completarse en 1-2 días para un caso de uso bien definido, produce evidencia objetiva sobre si el modelo es adecuado, y establece la línea base contra la que medir mejoras futuras. Sin este proceso, la adopción de IA es fe, no ingeniería.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

Conexiones con el resto del máster

- Módulo 6 (Ingeniería de Prompts): las técnicas de CoT, RAG y structured outputs son respuestas directas a las limitaciones de los LLMs descritas aquí.
- Módulo 7 (RAG): el RAG es la solución arquitectónica al problema del corte de conocimiento y la alucinación sobre información privada.
- Módulo 8 (Evaluación): la construcción de golden datasets y la evaluación continua son la respuesta operativa a la necesidad de medir las limitaciones reales en producción.

- Módulo 12 (Seguridad): la manipulabilidad de los LLMs (jailbreaks, prompt injection) es una limitación estructural con consecuencias de seguridad directas.

SECCIÓN 8 · RESUMEN EJECUTIVO

Resumen ejecutivo

Los LLMs de 2025 son extraordinariamente capaces en tareas de texto, código y razonamiento con información en el contexto, superando al humano medio en muchos benchmarks de conocimiento. Sus limitaciones estructurales son la alucinación (generan lo plausible, no lo verdadero), el corte de conocimiento, la aritmética imprecisa y la degradación de atención en contextos muy largos. Estas limitaciones no son bugs sino consecuencias del paradigma estadístico. El diseño de sistemas empresariales debe asumir estas limitaciones y construir salvaguardas: RAG para conocimiento verificable, intérpretes de código para cálculos, evaluación continua para medir alucinación, y human-in-the-loop para decisiones de alto impacto.