

Limitaciones estructurales de los LLMs

Módulo 1 · Fundamentos Ontológicos y Razonamiento de Máquinas

Alucinación, corte de conocimiento, aritmética imprecisa y lost-in-the-middle: por qué existen y cómo diseñar sistemas que las gestionen.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Limitaciones estructurales de los LLMs

Un abogado fue sancionado en 2023 por presentar ante el tribunal federal del Sur de Nueva York una demanda que citaba seis casos judiciales inexistentes generados por ChatGPT. Un banco europeo descubrió errores en un análisis financiero porque el LLM realizó operaciones aritméticas incorrectamente. Un sistema de atención al cliente generó información sobre políticas de devolución que no existían en el manual de la empresa. Estos no son casos aislados: son síntomas de limitaciones estructurales de los LLMs que no desaparecerán con el siguiente modelo.

Entender estas limitaciones no es pesimismo tecnológico: es ingeniería responsable. Un sistema de IA diseñado con consciencia de las limitaciones del LLM incluye los controles correctos. Un sistema diseñado ignorando estas limitaciones tiene fallos silenciosos esperando a manifestarse en producción con consecuencias costosas.

El catálogo de limitaciones estructurales

1. Alucinación: generar lo plausible, no lo verdadero

La alucinación es la tendencia de los LLMs a generar texto que parece factualmente correcto pero es falso. No es un bug: es una consecuencia directa del paradigma de entrenamiento. Los LLMs aprenden a predecir el siguiente token minimizando la cross-entropy loss sobre texto real. Aprenden a generar texto que suena como texto real. Cuando se les pregunta sobre hechos específicos fuera de sus patrones de entrenamiento, generan lo que suena más probable, que a veces es incorrecto.

La alucinación es especialmente peligrosa porque no va acompañada de señales de incertidumbre: el modelo genera citas bibliográficas inexistentes con el mismo tono confiado con el que genera información correcta. Los sistemas críticos deben diseñarse asumiendo que el modelo puede alucinar y construir mecanismos de detección y mitigación: RAG con citas verificables, evaluación LLM-as-judge, revisión humana en decisiones de alto impacto.

2. Corte de conocimiento: ignorancia sobre el presente

Los LLMs tienen una fecha de corte de conocimiento: el punto hasta el que llegan sus datos de entrenamiento. Un modelo con corte en enero de 2025 no sabe nada sobre eventos de febrero de 2025 en adelante. Para casos de uso que dependen de información actualizada (noticias, precios, legislación reciente, resultados de investigación reciente), un LLM sin herramientas de búsqueda o RAG actualizado es inadecuado.

3. Aritmética imprecisa: el efecto de la tokenización

Los LLMs cometen errores en cálculos aritméticos, especialmente con números grandes o con múltiples pasos de cálculo. La causa técnica es la tokenización: los números se representan como tokens, no como valores matemáticos. "1234567" puede ser un único token; el modelo no tiene acceso a los dígitos individuales a menos que razone explícitamente sobre ellos. La

solución correcta es el tool use: conectar el LLM a un intérprete de código o calculadora que ejecute los cálculos con precisión garantizada.

4. Lost in the Middle: degradación de atención en contextos largos

El fenómeno "lost in the middle" (Liu et al., 2023) documenta que los LLMs rinden peor cuando la información relevante está en el centro del contexto en comparación con cuando está al principio o al final. Experimentos sistemáticos muestran caídas de precisión de hasta 20 puntos porcentuales para información posicionada en el centro de un contexto de 32K tokens frente al mismo modelo con la misma información al principio.

5. Inconsistencia temporal: el mismo modelo, respuestas diferentes

Con temperatura > 0 , el mismo modelo con el mismo input puede producir respuestas diferentes en llamadas distintas. Esto es una propiedad del muestreo aleatorio de la distribución de probabilidad. Para sistemas que requieren consistencia total (auditoría, compliance, decisiones con consecuencias legales), esto es un problema. La solución: temperatura 0 para máximo determinismo, y evaluación de consistencia en el conjunto de evaluación.

SECCIÓN 3 · CÓMO FUNCIONA

Por qué estas limitaciones son estructurales

La raíz técnica de la mayoría de estas limitaciones es la misma: los LLMs son optimizadores estadísticos sobre texto. Aprenden a producir texto que parece correcto (alta probabilidad bajo la distribución del corpus de entrenamiento), no a razonar sobre la verdad de las proposiciones. Un modelo con más parámetros o más datos de entrenamiento alucinará menos en los dominios bien representados en sus datos, pero las alucinaciones no desaparecen; se desplazan a los dominios menos representados o a las preguntas que requieren razonamiento que va más allá de los patrones estadísticos.

SECCIÓN 4 · EJEMPLOS REALES

- Caso Mata vs Avianca (2023): abogados presentaron un escrito con seis casos inexistentes generados por ChatGPT. El juez Castel impuso sanciones monetarias y la corte requirió una explicación formal. El caso se convirtió en el ejemplo más citado de alucinación con consecuencias legales reales.
- Air Canada chatbot (2024): el chatbot de Air Canada prometió a un pasajero una tarifa de duelo que no existía en la política de la empresa. La corte canadiense falló que Air Canada era responsable de las afirmaciones de su chatbot. Coste: indemnización + reputación.
- Sistema RAG bien diseñado (mitigación): Morgan Stanley desplegó un asistente con RAG sobre 100.000 documentos de research financiero. Cada respuesta incluye citas al documento fuente. Si el documento no existe o la cita es incorrecta, es detectable. Esto no elimina las alucinaciones pero las hace visibles y auditables.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: "El modelo de razonamiento no alucina." Los modelos de razonamiento reducen las alucinaciones en tareas donde el razonamiento multi-paso ayuda, pero siguen siendo

sistemas estadísticos. Para información factual fuera de sus patrones de entrenamiento, siguen pudiendo alucinar.

Error 2: "Las alucinaciones son raras." No en todos los dominios. En dominios altamente especializados (derecho en jurisdicciones específicas, regulación reciente, investigación científica de nicho), las tasas de alucinación pueden ser muy altas porque el modelo tiene pocos datos de entrenamiento sobre esos temas.

Error 3: "Con más fine-tuning sobre datos de dominio, el modelo no alucinará." El fine-tuning mejora el rendimiento en dominio pero no elimina la tendencia a alucinar. Un modelo fine-tuned sobre manuales médicos puede alucinar sobre medicamentos o dosis si esas combinaciones no están representadas en sus datos de fine-tuning.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

El diseño de sistemas resilientes a las limitaciones de los LLMs sigue cuatro principios. Primero, asumir que el modelo puede fallar y diseñar el sistema para que los fallos sean detectables. Segundo, usar RAG para anclar respuestas en documentos verificables con citas explícitas. Tercero, implementar evaluación automática continua sobre un golden dataset que incluye casos donde el modelo debería admitir ignorancia. Cuarto, diseñar human-in-the-loop para decisiones de alto impacto.

Para aritmética y cálculos, el principio es siempre usar herramientas: conectar el LLM a un intérprete de Python que ejecute los cálculos. Para información actualizada, usar herramientas de búsqueda web o RAG sobre bases de datos actualizadas en tiempo real. Para consistencia, usar temperatura 0 y documentar cuándo la variabilidad del modelo afecta al resultado.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M7 (RAG): la solución arquitectónica más efectiva para las limitaciones de conocimiento y alucinación.
- M6 (Prompting): las técnicas de prompting como CoT y few-shot son mitigaciones parciales de las limitaciones de razonamiento.
- M8 (LLMOps / Evaluación): la evaluación continua es la respuesta operativa a la necesidad de monitorizar las limitaciones en producción.
- M12 (Seguridad): las limitaciones de los LLMs (manipulabilidad, alucinación) son también vectores de ataque.

SECCIÓN 8 · RESUMEN EJECUTIVO

Las limitaciones estructurales de los LLMs son: alucinación (generan lo plausible, no lo verificado), corte de conocimiento (ignorancia del presente), aritmética imprecisa (la tokenización impide el cálculo numérico preciso), lost-in-the-middle (degradación de atención en el centro de contextos largos), e inconsistencia estocástica (variabilidad entre llamadas). Estas limitaciones son consecuencias estructurales del paradigma, no bugs que se corrigen con el próximo modelo. El diseño correcto asume estos fallos y construye salvaguardas: RAG para conocimiento verificable, herramientas para cálculos, evaluación continua para monitorizar y human-in-the-loop para decisiones críticas.