

Regularización y overfitting

Módulo 2 · Matemáticas y Fundamentos Técnicos de IA

Dilema bias-varianza, L1, L2, Dropout, early stopping y el protocolo de diagnostico y correccion del overfitting.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Regularización y overfitting

Uno de los patrones más consistentes en el machine learning es éste: si entrenas un modelo lo suficiente sobre los datos de entrenamiento, aprenderá a predecir perfectamente cada ejemplo de entrenamiento. Y fallará en producción. Este fenómeno se llama overfitting y es la consecuencia natural del hecho de que los modelos tienen más capacidad de la necesaria para los datos disponibles: en lugar de aprender los patrones generalizables, memorizan el ruido específico de los datos de entrenamiento.

La regularización es el conjunto de técnicas que controlan la complejidad del modelo para prevenir el overfitting. No es un hack ni un truco: es la formalización de un principio estadístico fundamental conocido como la navaja de Ockham: entre dos modelos con el mismo rendimiento predictivo, preferir el más simple. En términos de machine learning: entre dos modelos con la misma pérdida de entrenamiento, preferir el que tiene menores pesos o menor complejidad, porque ese modelo generaliza mejor.

Overfitting, underfitting y el dilema bias-varianza

El dilema bias-varianza

El error de generalización de un modelo se puede descomponer en tres componentes: bias (sesgo), varianza y ruido irreducible. El bias mide cuánto se desvía la predicción esperada del modelo del valor verdadero: un modelo con alto bias tiene supuestos demasiado simples y no captura la complejidad real del problema (underfitting). La varianza mide cuánto varían las predicciones del modelo cuando se entrena sobre diferentes muestras de los datos: un modelo con alta varianza es muy sensible al ruido específico de los datos de entrenamiento (overfitting).

El dilema fundamental es que reducir el bias (hacer el modelo más complejo para capturar más patrones) tiende a aumentar la varianza, y reducir la varianza (simplificar el modelo) tiende a aumentar el bias. La regularización es la herramienta que permite encontrar el balance correcto: añadir suficiente restricción para reducir la varianza sin introducir demasiado bias adicional.

Señales de diagnóstico: curvas de aprendizaje

La curva de aprendizaje (pérdida de entrenamiento y pérdida de validación en función del número de épocas) es el diagnóstico más directo. Overfitting: la pérdida de entrenamiento sigue bajando mientras la de validación sube o se estanca. Underfitting: ambas pérdidas son altas y convergen a un valor similar. Bien ajustado: ambas pérdidas bajan y convergen a valores bajos similares. El gap entre la curva de entrenamiento y la de validación es la medida directa del overfitting.

Las técnicas de regularización más importantes

L2 (Ridge / Weight Decay): penalizar pesos grandes

L2 añade un término de penalización proporcional a la suma de los cuadrados de los pesos a la función de coste: $\text{Loss_total} = \text{Loss_original} + \lambda \times \sum w^2$. El hiperparámetro λ controla la intensidad de la regularización. Gradiente del término L2: $2\lambda w$, que se añade al gradiente normal. Efecto: en cada actualización de pesos, el peso recibe un "decay" adicional que lo empuja hacia cero. Los pesos grandes son penalizados más fuertemente, produciendo pesos más pequeños y distribuidos, lo que equivale a una función más suave con menos varianza. L2 es el estándar en el entrenamiento de LLMs (donde se llama "weight decay").

L1 (Lasso): regularización con sparsidad

L1 añade la suma de los valores absolutos de los pesos: $\text{Loss_total} = \text{Loss_original} + \lambda \times \sum |w|$. A diferencia de L2, L1 produce soluciones sparse: empuja muchos pesos exactamente a cero, efectuando selección de características automática. Esto es útil cuando se cree que solo un subconjunto pequeño de las características es relevante. En la práctica, L1 es más usada en modelos de regresión con muchas características que en redes neuronales profundas (donde Dropout es más común).

Dropout: regularización para redes neuronales

Dropout (Srivastava et al., 2014) desactiva aleatoriamente una fracción p de las neuronas durante cada forward pass del entrenamiento (sus activaciones se ponen a cero). Durante la inferencia, todas las neuronas están activas pero sus salidas se escalan por $(1-p)$ para compensar. El efecto es que el modelo no puede depender de ninguna neurona específica y debe aprender representaciones redundantes y robustas. Empíricamente, Dropout es muy efectivo para prevenir overfitting en redes profundas, especialmente en capas totalmente conectadas.

Early Stopping: detener cuando el modelo empieza a sobreajustar

Early stopping monitoriza la pérdida de validación durante el entrenamiento y detiene el proceso cuando esa pérdida deja de mejorar durante un número predefinido de épocas (paciencia). Es la técnica de regularización más simple y más robusta: no requiere ajustar hiperparámetros adicionales y se adapta automáticamente a cada problema. La clave es definir el conjunto de validación correctamente: debe ser representativo de la distribución de producción pero no usarse para tomar ninguna decisión de modelado (solo para early stopping).

SECCIÓN 4 · EJEMPLOS REALES

- Overfitting en un clasificador de contratos legales: un clasificador entrenado con 500 contratos etiquetados alcanza 98% de precisión en el conjunto de entrenamiento y 71% en el conjunto de test. Señal clara de overfitting. Solución: Dropout de 0.3 en las capas intermedias, weight decay de $1e-4$, early stopping con paciencia de 5 épocas. Resultado: 91% en test, mucho más cercano al rendimiento en entrenamiento.
- Weight decay en GPT: el entrenamiento de los modelos GPT usa AdamW, que es Adam con weight decay explícito, típicamente $\lambda=0.1$. Esto previene que los pesos crezcan sin límite durante el entrenamiento en grandes corpus y contribuye a la estabilidad del entrenamiento a largo plazo.

- Early stopping en fine-tuning de LLMs: en el fine-tuning de un LLM con datos de dominio limitados (500-2000 ejemplos), el overfitting puede ocurrir después de solo 1-3 épocas. El early stopping con paciencia=2 en la pérdida de validación es la salvaguarda estándar.
- L1 en scoring de riesgo con muchas variables: un modelo de scoring crediticio tiene 300 variables candidatas. L1 regularización (Lasso) reduce el modelo a 45 variables con coeficientes no-cero, produciendo un modelo más interpretable y más robusto sin perder precisión significativa.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: "Más regularización siempre es mejor." Demasiada regularización produce underfitting: el modelo es demasiado simple para capturar los patrones reales. El hiperparámetro λ en L1/L2 y la tasa de dropout deben calibrarse con validación cruzada, no maximizarse.

Error 2: "La regularización solo es necesaria para modelos pequeños." Los LLMs también sufren overfitting durante el fine-tuning, especialmente con datasets pequeños. Weight decay, Dropout y early stopping son estándar en el fine-tuning de modelos grandes con datos limitados.

Error 3: "Si el modelo funciona bien en test, no hay overfitting." El conjunto de test puede estar contaminado (data leakage: información del futuro en los datos de entrenamiento, o examples de test que se usaron para tomar decisiones de modelado). La separación estricta temporal y de dominio entre entrenamiento y evaluación es esencial.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

El protocolo de diagnóstico y corrección del overfitting: primero, entrena el modelo sin regularización y monitoriza las curvas de aprendizaje. Si hay overfitting (gap creciente entre train y val loss), aplica correcciones en este orden de simplicidad: early stopping (sin coste adicional), weight decay L2 (añadir un parámetro), Dropout (añadir capas), reducir la capacidad del modelo (menos capas o unidades), y en último lugar obtener más datos.

Para LLMs con fine-tuning, el protocolo específico: usar entre el 10% y el 20% de los datos para validación, activar early stopping con paciencia de 2-3 épocas, usar `weight_decay=0.01` en AdamW, entrenar no más de 3-5 épocas en la mayoría de los casos. Si el dataset tiene menos de 1000 ejemplos, considerar congelar más capas del modelo base (LoRA con rango más bajo) para reducir la capacidad de overfitting.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M3 (ML Clásico): el bias-varianza tradeoff y la regularización son temas centrales del ML clásico (validación cruzada, L1/L2 en regresión y SVM).
- M4 (Deep Learning): Dropout, Batch Normalization y early stopping son técnicas de regularización específicas para redes profundas.
- M8 (Fine-tuning): el overfitting durante el fine-tuning de LLMs con datos limitados es uno de los problemas más comunes que el LLMOps debe gestionar.

SECCIÓN 8 · RESUMEN EJECUTIVO

El overfitting ocurre cuando el modelo memoriza el ruido de los datos de entrenamiento en lugar de aprender patrones generalizables. El dilema bias-varianza formaliza el trade-off entre modelos simples (alto bias, baja varianza) y complejos (bajo bias, alta varianza). Las técnicas de regularización más importantes son: L2/weight decay (penaliza pesos grandes, estándar en LLMs), L1/Lasso (produce sparsidad, útil para selección de características), Dropout (desactiva neuronas aleatoriamente, robusto para redes profundas), y early stopping (detiene el entrenamiento cuando la validación deja de mejorar). El diagnóstico de overfitting se hace con curvas de aprendizaje; la corrección sigue un protocolo de complejidad creciente.