

Interpretabilidad de modelos

Módulo 3 · Machine Learning Clásico

SHAP values, LIME, modelos intrínsecamente interpretables y como cumplir los requisitos del AI Act y GDPR de explicabilidad en decisiones automatizadas.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Interpretabilidad de modelos

En 2024, la Unión Europea exige que los sistemas de IA de alto riesgo que toman decisiones con impacto significativo en personas (crédito, empleo, acceso a servicios públicos) sean explicables. El GDPR ya requería desde 2018 el derecho a una explicación en decisiones automatizadas. En EE.UU., la Equal Credit Opportunity Act obliga a los bancos a comunicar las razones principales de un rechazo crediticio. La interpretabilidad no es una virtud académica: es un requisito legal en muchos contextos y una condición necesaria para la confianza de los usuarios en los sistemas de IA.

Más allá del cumplimiento regulatorio, la interpretabilidad tiene valor operativo directo: un modelo interpretable permite detectar sesgos antes de que causen daño, depurar por qué el modelo comete errores en casos concretos, ganar la confianza de los usuarios del sistema (un médico que entiende por qué el modelo sugiere un diagnóstico confía más en él), y mejorar el modelo identificando qué variables son relevantes y cuáles son espurias.

El espectro de la interpretabilidad

Modelos intrínsecamente interpretables

Algunos modelos son interpretables por diseño: regresión lineal y logística (los coeficientes miden el efecto de cada variable), árboles de decisión de profundidad moderada (las reglas son visualizables), y GAMs (Generalized Additive Models, que modelan el efecto de cada variable con funciones no lineales que se pueden visualizar independientemente). Estos modelos son la primera opción cuando la explicabilidad es un requisito de diseño, aunque a menudo tienen menor precisión que los modelos de black box.

SHAP: interpretabilidad post-hoc para cualquier modelo

SHAP (SHapley Additive exPlanations, Lundberg y Lee, 2017) es el método de interpretabilidad post-hoc más adoptado en la industria. Se basa en los Shapley values de la teoría de juegos cooperativos: trata las variables de entrada como "jugadores" y el modelo como un "juego", y calcula la contribución justa de cada variable a la predicción final considerando todas las posibles combinaciones de variables.

Para una predicción específica, el SHAP value de una variable x_i dice: "esta variable contribuyó en +0.12 unidades a la predicción final respecto a la predicción base (la media del modelo)". Los SHAP values suman exactamente a la diferencia entre la predicción del modelo y la predicción base, lo que les da una propiedad de consistencia matemática que las feature importances basadas en split count no tienen.

LIME: explicaciones locales con modelos sustitutos

LIME (Local Interpretable Model-agnostic Explanations, Ribeiro et al., 2016) crea una explicación local para una predicción específica perturbando el input alrededor de ese punto y ajustando un modelo lineal simple sobre las predicciones del modelo complejo para esas

perturbaciones. El modelo lineal es la "explicación": sus coeficientes indican qué variables son más relevantes localmente.

La ventaja de LIME es su simplicidad conceptual y su aplicabilidad a cualquier modelo (texto, imágenes, tabular). La desventaja es la inestabilidad: pequeños cambios en los parámetros de LIME pueden producir explicaciones muy distintas. SHAP es generalmente más fiable y consistente, por lo que ha desplazado a LIME como el método estándar en la mayoría de los contextos.

SECCIÓN 3 · CÓMO FUNCIONA

SHAP en profundidad: global vs local

SHAP proporciona dos tipos de explicaciones. Las explicaciones locales (por predicción individual) producen un SHAP value por variable para cada ejemplo: "para el cliente #12345, el historial de pagos contribuyó +0.35 al score, el ratio deuda-ingresos contribuyó -0.22, y la antigüedad del cliente contribuyó +0.08". Esto es exactamente lo que se necesita para explicar al cliente por qué fue rechazado o aprobado.

Las explicaciones globales agregan los SHAP values sobre todos los ejemplos del dataset para entender el comportamiento general del modelo: el beeswarm plot muestra la distribución de SHAP values de cada variable para todos los ejemplos, revelando qué variables son más importantes globalmente y cómo cada variable afecta al modelo (positiva o negativamente) según su valor. El summary plot (mean absolute SHAP) da el ranking de importancia global.

TreeSHAP es la implementación de SHAP para gradient boosting y Random Forest: explota la estructura arbórea del modelo para calcular los SHAP values exactos de forma eficiente (en tiempo polinomial en lugar de exponencial para el cálculo exacto). Es la implementación que prácticamente toda la industria usa para XGBoost, LightGBM y CatBoost.

SECCIÓN 4 · EJEMPLOS REALES

- BBVA y la explicación de rechazo de crédito: el Banco Bilbao Vizcaya Argentaria usa SHAP en su sistema de scoring crediticio para generar automáticamente las tres principales razones de rechazo en lenguaje natural: "Su solicitud ha sido rechazada principalmente por: (1) ratio deuda-ingresos superior al 40%, (2) existencia de impagos en los últimos 12 meses, (3) ingresos insuficientes para el importe solicitado". Esto es un requisito del GDPR y de la directiva de crédito al consumo.
- Detección de sesgo en modelos de RRHH: una empresa de tecnología descubrió mediante SHAP que su modelo de screening de CVs asignaba un SHAP value positivo significativo a "Universidad de élite" que correlacionaba con el género (más hombres que mujeres en esas universidades en el dataset histórico). El modelo tenía sesgo de género indirecto. SHAP hizo visible el sesgo que las métricas globales ocultaban.
- Diagnóstico de fallo de modelo en producción: un modelo de predicción de fallo de equipos industriales empezó a dar muchas falsas alarmas después de un mantenimiento. SHAP reveló que la variable "temperatura_sensor_B" había saltado de ser el quinto predictor más importante al primero, con valores atípicamente altos. Diagnóstico: el sensor B había sido calibrado incorrectamente en el mantenimiento. Sin SHAP, el diagnóstico habría tardado

semanas.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Usar la feature importance nativa de XGBoost como sustituto de SHAP. La feature importance de XGBoost (número de splits) es inestable con variables correlacionadas: puede asignar alta importancia a una variable irrelevante si está correlacionada con una variable relevante. SHAP values son matemáticamente más robustos y consistentes y deben preferirse siempre para comunicación de resultados.

Error 2: Confundir importancia SHAP con causalidad. Un SHAP value alto para la variable "código postal" no significa que el código postal cause el resultado. Puede ser que el código postal sea un proxy de otras variables relevantes (nivel socioeconómico, acceso a servicios). La interpretabilidad mide asociación estadística en el modelo, no causalidad en el mundo real.

Error 3: Presentar SHAP values sin contexto estadístico. Un SHAP value de +0.05 para una variable puede ser estadísticamente insignificante si la varianza es alta. Siempre contextualiza los SHAP values con su varianza (el beeswarm plot lo hace automáticamente) y con el rango de la variable de salida.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Para implementar SHAP en un proyecto de XGBoost: instala shap (pip install shap), entrena el modelo (`model = xgb.XGBClassifier().fit(X_train, y_train)`), crea el explainer (`explainer = shap.Explainer(model)`), calcula los SHAP values (`shap_values = explainer(X_test)`), y visualiza con `shap.plots.beeswarm(shap_values)` para el análisis global o `shap.plots.waterfall(shap_values[i])` para un ejemplo individual.

Para sistemas de decisión que deben proporcionar explicaciones al usuario final (decisiones de crédito, scoring de riesgo, priorización de alertas), genera automáticamente las top-3 razones de la predicción usando los 3 SHAP values de mayor magnitud. Traduce los nombres técnicos de las variables a lenguaje comprensible para el usuario ("ratio_deuda_ingresos" → "su nivel de endeudamiento respecto a sus ingresos").

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M3-T2 (Modelos clásicos): SHAP se aplica principalmente a XGBoost, LightGBM y Random Forest.
- M13 (Gobernanza): el AI Act requiere explicabilidad en sistemas de alto riesgo. SHAP es la herramienta técnica principal para implementar esa explicabilidad.
- M8 (LLMOps): la interpretabilidad de LLMs es diferente (attention visualization, probing classifiers) pero el principio de explicabilidad auditoria es el mismo.

SECCIÓN 8 · RESUMEN EJECUTIVO

La interpretabilidad es un requisito legal en muchos contextos (GDPR, AI Act, regulación bancaria) y tiene valor operativo para detectar sesgos y depurar modelos. SHAP (basado en Shapley values de teoría de juegos) es el estándar de la industria para interpretabilidad post-hoc: proporciona explicaciones locales (por predicción individual) y

globales (comportamiento del modelo) para cualquier modelo de ML. TreeSHAP para XGBoost/LightGBM es eficiente y exacto. LIME es una alternativa más simple pero menos estable. Para cumplimiento del AI Act: almacena SHAP values en producción para auditoría. SHAP mide asociación estadística, no causalidad.