

GPUs y Aceleración Hardware para IA

Módulo 4 · Deep Learning

H100 vs A100, Tensor Cores, VRAM, CUDA, entrenamiento e inferencia: decisiones de hardware con consecuencias económicas directas.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

GPUs y Aceleración Hardware para IA

La revolución del deep learning no fue solo una revolución de algoritmos: fue una revolución de hardware. AlexNet en 2012 fue posible no porque el algoritmo fuera radicalmente nuevo, sino porque Krizhevsky implementó CNNs en GPUs NVIDIA, logrando una aceleración de 40-50x respecto a CPU. Desde entonces, el hardware para IA ha evolucionado más rápido que cualquier otra clase de hardware de la historia: la H100 de NVIDIA entrega 30x más rendimiento en modelos transformer que la A100 de 2020.

En 2025, las decisiones de hardware son decisiones estratégicas con consecuencias económicas directas. Una H100 en cloud cuesta \$3-5/hora; una flota de H100s cuesta millones de dólares en CAPEX. La elección correcta entre GPU generaciones, entre cloud y on-premise, y entre NVIDIA y alternativas (AMD, TPUs) puede determinar la viabilidad económica de un proyecto de IA.

Por qué los GPUs son superiores para deep learning

SIMD vs SISD: el principio de la aceleración

Un CPU moderno tiene 8-64 cores diseñados para ejecutar instrucciones secuenciales complejas de forma muy eficiente (SISD: Single Instruction, Single Data). Una GPU moderna tiene miles de cores más simples diseñados para ejecutar la misma instrucción sobre miles de datos simultáneamente (SIMD: Single Instruction, Multiple Data). El entrenamiento y la inferencia de redes neuronales son operaciones masivamente paralelas (multiplicaciones matriciales, operaciones elemento a elemento sobre tensores de millones de elementos), que se benefician enormemente de la arquitectura SIMD de los GPUs.

Un H100 tiene 80 GB de HBM3 con 3.35 TB/s de memoria bandwidth y 3.958 TFLOPS de peak performance en FP8. Un servidor CPU de gama alta tiene ~250 GB/s de bandwidth de RAM. La diferencia de 13x en memory bandwidth es la razón por la que la inferencia de LLMs es tan dramáticamente más rápida en GPU que en CPU.

Tensor Cores: aceleración específica para redes neuronales

Los Tensor Cores son unidades de procesamiento especializadas en operaciones de multiplicación-acumulación de matrices (MMA: Matrix Multiply-Accumulate). Fueron introducidos por NVIDIA en la arquitectura Volta (V100) en 2017. Cada generación los mejora: la H100 tiene Tensor Cores de 4ª generación que soportan FP8, FP16, BF16 y TF32, con hasta 3.958 TFLOPS en FP8. La inmensa mayoría del tiempo de cómputo en entrenamiento e inferencia de LLMs son operaciones MMA, por lo que los Tensor Cores son el componente más crítico.

La evolución de los GPUs de NVIDIA para IA

V100 (Volta, 2017): 16/32 GB HBM2, Tensor Cores 1ª gen, referencia para entrenamiento hasta 2020. A100 (Ampere, 2020): 40/80 GB HBM2e, 2 TB/s bandwidth, 312 TFLOPS BF16. Referencia actual para inferencia y fine-tuning. H100 (Hopper, 2022-2024): 80 GB HBM3, 3.35

TB/s bandwidth, Transformer Engine con FP8, 3.958 TFLOPS FP8. 2-4x más rápido que A100 para modelos transformer. H200 (Hopper, 2024): 141 GB HBM3e, 4.8 TB/s bandwidth. Amplía el contexto posible sin cambiar el die de cómputo. B200 (Blackwell, 2025): arquitectura nueva, ~2x mejora sobre H100 en throughput de transformers.

SECCIÓN 3 · CÓMO FUNCIONA

El ecosistema de hardware y software para IA

CUDA: el sistema operativo de IA en GPU

CUDA (Compute Unified Device Architecture) es el entorno de programación paralela de NVIDIA que permite a los frameworks de IA (PyTorch, TensorFlow, JAX) utilizar los GPUs de NVIDIA. CUDA tiene dos décadas de optimizaciones y un ecosistema de bibliotecas que lo hacen difícilmente sustituible: cuBLAS para álgebra lineal, cuDNN para primitivas de redes neuronales, NCCL para comunicación multi-GPU, TensorRT para inferencia optimizada. Este ecosistema maduro es una ventaja competitiva estructural de NVIDIA que AMD y otros competidores luchan por replicar.

Alternativas: AMD, TPUs y hardware especializado

AMD MI300X (2024) ofrece 192 GB de HBM3 (2.4x la H100) y es competitivo en inference de modelos grandes que requieren mucha VRAM. Su ecosistema ROCm sigue siendo inferior a CUDA pero mejora con cada generación. Google TPUs (Tensor Processing Units) son ASICs diseñados específicamente para multiplicaciones matriciales en modelos de deep learning, ofreciendo excelente eficiencia energética. Disponibles en Google Cloud, son la opción preferida para grandes workloads en GCP. Groq, Cerebras y otros startups de chips de IA ofrecen latencia extremadamente baja para inferencia de LLMs.

Consideraciones de VRAM para diferentes escenarios

La VRAM es el recurso limitante más frecuente en proyectos de deep learning. Las reglas prácticas: un modelo con N parámetros en FP16 necesita $2 \times N$ bytes de VRAM (una GPU A100 80GB cabe hasta 40B parámetros en FP16). Para entrenamiento, multiplicar por 3-4 para incluir gradientes y estados del optimizador. Con QLoRA NF4 + gradient checkpointing, es posible hacer fine-tuning de modelos ~4x más grandes. Estimar la VRAM necesaria antes de contratar hardware evita sorpresas costosas.

SECCIÓN 4 · EJEMPLOS REALES

- OpenAI entrenando ChatGPT en A100: el entrenamiento de los primeros modelos de ChatGPT usó miles de A100s en Azure. La H100 no estaba disponible en ese momento; la A100 era el estándar de facto para preentrenamiento a gran escala.
- Meta Grand Teton (H100 supercluster): sistema con múltiples H100s con 4x el host-to-GPU bandwidth, 2x compute y 2x data network bandwidth respecto al predecesor Zion. Usado para entrenamiento de Llama 3 y modelos de recomendación de Facebook/Instagram.
- Empresa mediana con análisis de coste A100 vs H100: para un workload de fine-tuning de 100 horas en 8 GPUs, A100 en cloud cuesta ~\$1.600 (8x A100 a \$2/h x 100h). H100 cuesta ~\$3.200 (8x H100 a \$4/h x 100h). Pero H100 termina en ~55 horas (2x faster): coste total

~\$1.760. Similar o menor que A100, con el modelo listo antes. Para workloads repetidos, H100 domina claramente.

- Inferencia de Llama 3 70B en producción: en FP16 requiere 2× A100 80GB (160GB). Con cuantización INT8 (bitsandbytes): 1× A100 80GB. Con cuantización Q4 (GGUF): 1× A10 24GB o incluso CPU potente. La elección de hardware para inferencia depende directamente de la cuantización elegida.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Confundir TFLOPS de pico con throughput real. Los TFLOPS declarados por NVIDIA son rendimientos teóricos de pico con una utilización del 100% de los Tensor Cores. La eficiencia real en entrenamiento de LLMs es típicamente 30-50% del pico. Un H100 con 3.958 TFLOPS pico produce 1.000-2.000 TFLOPS reales en entrenamiento.

Error 2: No tener en cuenta el bandwidth de memoria al evaluar GPUs para inferencia. Para la inferencia de LLMs, el bottleneck frecuente no es el cómputo sino la velocidad de carga de pesos desde VRAM. Un GPU con menos TFLOPS pero mayor memory bandwidth puede ser más rápido en inferencia que uno con más TFLOPS y menor bandwidth.

Error 3: Ignorar el overhead de la red de comunicación en clusters multi-GPU. El speedup teórico de N GPUs es Nx. En la práctica, la comunicación de gradientes (allreduce) puede consumir 20-40% del tiempo de entrenamiento en clusters con Ethernet de 25/100 Gbps. InfiniBand o NVLink son esenciales para clusters de más de 8 GPUs con alta eficiencia de scaling.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Para elegir entre A100 y H100 en un proyecto de fine-tuning: si el modelo cabe en una A100 y el tiempo de entrenamiento es tolerable, la A100 es más económica por hora. Si el modelo requiere H100 por VRAM (>80GB) o si los tiempos de entrenamiento son críticos, la H100 es justificable. En todos los casos, calcula el coste total por job (precio por hora × tiempo de entrenamiento × número de GPUs), no solo el precio por hora.

Para inferencia en producción de LLMs: calcula primero el throughput necesario (tokens/segundo para el volumen de consultas esperado) y la latencia requerida (P99 en milisegundos). Con esos requisitos, evalúa opciones: API de proveedor (más flexible, mayor coste variable), GPU en cloud con vLLM (buen equilibrio), o hardware propio con vLLM (mejor economía a escala alta). vLLM con H100 en NVLink puede entregar 20.000-50.000 tokens/segundo en modelos de 70B.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M4-T7 (Entrenamiento a gran escala): el hardware (H100 NVLink, InfiniBand) determina la eficiencia del paralelismo distribuido.
- M9 (Infraestructura y despliegue): las decisiones de GPU cloud vs on-premise son el contenido central del módulo de infraestructura.
- M8 (LLMOps): la monitorización de la utilización de GPU, el coste por token y la latencia son métricas de observabilidad de sistemas de LLM.

Los GPUs son superiores para deep learning por su arquitectura SIMD masiva y sus Tensor Cores especializados en multiplicaciones matriciales. La H100 (Hopper) es el estándar de 2025 con 80GB HBM3, 3.35TB/s bandwidth, Transformer Engine FP8 y 2-4x speedup sobre A100 en LLMs. H200 amplía a 141GB VRAM para contextos muy largos. La VRAM es el recurso limitante: un modelo de N parámetros en FP16 necesita 2N bytes. Con QLoRA NF4, se puede hacer fine-tuning de modelos 4x mayores. CUDA es el ecosistema dominante; ROCm de AMD mejora pero no iguala. Para decisiones de coste: calcula coste total por job, no precio por hora.