

In-Context Learning (ICL)

Módulo 5 · NLP y Modelos de Lenguaje (LLMs)

Zero-shot, few-shot, varianza de orden, ICL dinámico con RAG y cuándo el ICL supera al fine-tuning en eficiencia.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

In-Context Learning (ICL)

En 2020, el paper de GPT-3 "Language Models are Few-Shot Learners" reportó algo sorprendente: un modelo de lenguaje, sin ningún cambio en sus pesos, podía resolver tareas completamente nuevas simplemente incluyendo algunos ejemplos de la tarea en el prompt. Tres ejemplos de traducción inglés-español en el prompt y el modelo traducía. Cuatro ejemplos de clasificación de sentimiento y el modelo clasificaba. Esto se llamó in-context learning (ICL), y fue uno de los hallazgos más influyentes en la historia reciente de la IA.

El in-context learning es la capacidad de los LLMs para adaptarse a nuevas tareas a partir de ejemplos en el contexto sin actualizar los parámetros del modelo. En la práctica empresarial, esto significa que puedes construir un sistema de IA especializado sin datos de entrenamiento etiquetados, sin infraestructura de fine-tuning, y sin tiempo de espera: simplemente describiendo la tarea y proporcionando ejemplos en el prompt.

Los tipos de in-context learning

Zero-shot: ningún ejemplo, solo la descripción de la tarea

En el zero-shot prompting, el LLM recibe solo la descripción de la tarea y el input, sin ningún ejemplo de cómo resolverla. "Clasifica el sentimiento de este tweet como positivo, negativo o neutro: [tweet]." El modelo usa su conocimiento preentrenado para inferir la tarea y resolverla. Funciona bien para tareas de conocimiento general que el modelo ha visto durante el preentrenamiento, pero puede fallar en tareas específicas de dominio o con formatos de output inusuales.

Few-shot: pocos ejemplos demuestran la tarea

En el few-shot prompting, se incluyen 3-10 ejemplos de (input, output correcto) antes del caso a resolver. "Entrada: [tweet positivo] → Salida: positivo. Entrada: [tweet negativo] → Salida: negativo. Entrada: [tweet a clasificar] → Salida:". Los ejemplos demuestran el formato de output, el nivel de detalle esperado, y los matices de la tarea. El few-shot es especialmente efectivo cuando el formato de output es inusual o cuando la definición de las categorías puede ser ambigua.

One-shot: un único ejemplo como guía

El one-shot proporciona un único ejemplo. Es útil cuando el espacio de contexto es limitado o cuando la tarea es suficientemente clara con un solo ejemplo. En general, few-shot supera a one-shot, que supera a zero-shot, pero con rendimientos decrecientes: la mejora de 0 a 3 ejemplos es grande; de 3 a 10 es moderada; de 10 a 100 es pequeña y puede no justificar el coste adicional de tokens.

Qué hace que el ICL funcione bien

La calidad y diversidad de los ejemplos

Los ejemplos en el prompt deben ser representativos de la distribución real del problema. Si todos los ejemplos few-shot son de la misma clase o del mismo tipo, el modelo puede sesgarse. La diversidad de ejemplos mejora la robustez: incluye ejemplos de diferentes categorías, con diferentes longitudes, y que cubran los casos edge que el sistema necesitará manejar.

El orden de los ejemplos importa

El orden de los ejemplos few-shot afecta el rendimiento del modelo, especialmente en modelos más pequeños. Este efecto (varianza de orden) es un problema de calibración: el modelo puede tener sesgos hacia ciertos patrones de orden. Los modelos más grandes son más robustos a este efecto, pero en producción se recomienda siempre evaluar con múltiples órdenes de ejemplos para estimar la varianza.

El trade-off tokens-rendimiento

Más ejemplos en el contexto producen mejor rendimiento hasta un punto, después el beneficio marginal decrece. Pero cada ejemplo añade tokens (coste), latencia, y ocupa espacio del contexto que podría usarse para el documento real. La estrategia óptima es el número mínimo de ejemplos que produce el rendimiento deseado: evalúa con 0, 1, 3, 5 y 10 ejemplos sobre tu golden dataset y elige el punto óptimo de la curva rendimiento/coste.

SECCIÓN 4 · EJEMPLOS REALES

- Extracción de datos de facturas (zero-shot): "Extrae del siguiente texto de factura: importe total, fecha, número de factura y proveedor. Responde en JSON con las claves total, fecha, numero_factura, proveedor. Texto: [texto de factura]." Con un LLM suficientemente capaz, esto funciona bien para facturas estándar sin ningún ejemplo previo.
- Clasificación de incidencias de seguridad (few-shot): el sistema de seguridad de un banco necesita clasificar alertas en "crítica", "alta", "media" o "baja". Con 4 ejemplos en el prompt (uno por categoría) que demuestran el tipo de evidencia que corresponde a cada nivel, el LLM clasifica correctamente el 89% de las nuevas alertas, frente al 71% sin ejemplos.
- Generación de respuestas de soporte en tono corporativo: incluyendo 3-5 ejemplos de respuestas aprobadas por el departamento de comunicación, el LLM genera nuevas respuestas en el estilo y tono específicos de la empresa sin necesidad de fine-tuning.
- Traducción a jerga interna de empresa: una empresa de manufactura tiene términos técnicos propietarios que ningún modelo preentrenado conoce. Con 10 ejemplos en el prompt que mapean terminología estándar a terminología interna, el LLM traduce documentos usando la nomenclatura correcta.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Usar ejemplos de baja calidad o incorrectos en el few-shot. Si los ejemplos en el prompt tienen errores o no son representativos, el modelo aprenderá esos errores. Un ejemplo incorrecto puede degradar el rendimiento más que no tener ningún ejemplo. La calidad de los ejemplos few-shot es tan importante como la calidad de los datos de fine-tuning.

Error 2: No evaluar la varianza del ICL. El rendimiento del ICL puede variar significativamente con diferentes ejemplos o diferentes órdenes de los mismos ejemplos. Evalúa el sistema con múltiples configuraciones de ejemplos (diferentes selecciones aleatorias del pool de ejemplos disponibles) y reporta la media y la varianza, no solo la mejor configuración.

Error 3: Usar ICL cuando el fine-tuning sería más eficiente a escala. Para sistemas de alta frecuencia (millones de llamadas al día), los tokens adicionales de los ejemplos few-shot multiplican el coste. Si el patrón es estable, fine-tunear el modelo elimina la necesidad de repetir los ejemplos en cada llamada, reduciendo el coste significativamente.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

El protocolo práctico para ICL en producción: selecciona un pool de 20-50 ejemplos de alta calidad y representativos. Para cada llamada al sistema, selecciona los k más similares al input actual usando similitud coseno sobre embeddings (dynamic few-shot selection). Esto produce mejores resultados que ejemplos estáticos porque los ejemplos seleccionados siempre son relevantes para el caso actual.

La evaluación del rendimiento del ICL es una curva: evalúa con 0, 1, 3, 5 y 10 ejemplos sobre tu golden dataset. Identifica el punto donde el incremento de rendimiento por ejemplo adicional ya no justifica el coste de tokens. Para la mayoría de las tareas, 3-5 ejemplos bien seleccionados es el óptimo.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M6 (Ingeniería de prompts): el ICL es la base del few-shot prompting, que es una de las técnicas más importantes de la ingeniería de prompts.
- M7 (RAG): el ICL dinámico con recuperación de ejemplos similares es una extensión natural de los sistemas RAG.
- M5-T3 (Pretraining vs fine-tuning): el ICL es la alternativa al fine-tuning cuando los datos son escasos o el overhead de fine-tuning no está justificado.

SECCIÓN 8 · RESUMEN EJECUTIVO

El in-context learning permite a los LLMs adaptarse a nuevas tareas con ejemplos en el prompt sin modificar sus pesos. Zero-shot: solo la descripción de la tarea. Few-shot: 3-10 ejemplos de (input, output correcto). La calidad y diversidad de los ejemplos es más importante que la cantidad. El rendimiento mejora con más ejemplos con retornos decrecientes; evalúa la curva rendimiento/coste para cada caso. La varianza de orden y selección de ejemplos debe medirse, no ignorarse. ICL dinámico (recuperar ejemplos similares al input con RAG) supera al ICL estático. Para sistemas de alta frecuencia, el fine-tuning elimina el coste de tokens de los ejemplos; evalúa si el umbral de escala lo justifica.