

Evaluación de LLMs

Módulo 5 · NLP y Modelos de Lenguaje (LLMs)

MMLU, SWE-bench, TruthfulQA, HELM, BLEU, LLM-as-judge y como construir evaluaciones de dominio que predican el rendimiento real.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Evaluación de LLMs

Los benchmarks generales de LLMs como MMLU han sido prácticamente saturados por los modelos frontier: en 2026, muchos modelos top superan el 90% en MMLU, haciendo imposible distinguir entre ellos con esa métrica. La evaluación correcta de un LLM para empresa no es cuánto puntúa en MMLU sino cuánto rinde en los casos de uso reales con los datos propios.

Este tema cubre el ecosistema completo de evaluación de LLMs: los benchmarks públicos y sus limitaciones, las métricas automáticas y cuándo son insuficientes, la evaluación humana y cuándo es necesaria, y el proceso de construir evaluaciones específicas de dominio que predicen el rendimiento real en producción.

El ecosistema de benchmarks públicos

Benchmarks de conocimiento general

MMLU (Massive Multitask Language Understanding) evalúa conocimiento académico en 57 materias con 14.042 preguntas de múltiple opción. Fue el benchmark de referencia para evaluar el conocimiento general de los LLMs hasta que comenzó a saturarse en 2024. MMLU-Pro es una versión más difícil con preguntas de razonamiento más complejo. GPQA (Graduate-Level Google-Proof Q&A;) contiene preguntas de nivel PhD en biología, física y química que los expertos sin acceso a búsqueda fallan el 34% de las veces.

Benchmarks de razonamiento y código

HumanEval y MBPP evalúan la capacidad de generar código que pasa tests unitarios. SWE-bench evalúa la resolución de issues reales de GitHub. MATH-500 evalúa razonamiento matemático con problemas de competición. AIME 2024 y 2025 son los benchmarks más difíciles de matemáticas actualmente disponibles para modelos frontier. HLE (Humanity's Last Exam), creado con 3.000 preguntas de expertos en 2025, es el benchmark de frontera actual con las preguntas más difíciles de cualquier dominio. En febrero 2026, Claude lidera con 53.1% con acceso a herramientas.

Evaluación de alineamiento y seguridad

TruthfulQA contiene 817 preguntas de 38 categorías diseñadas para provocar alucinaciones y respuestas incorrectas que imitan misconceptions humanos comunes. TruthfulQA reporta tasas de alucinación superiores al 50% para los LLMs de línea base. HELM (Holistic Evaluation of Language Models) evalúa modelos en múltiples dimensiones: precisión, calibración, robustez, equidad, sesgo y toxicidad. Es adecuado para evaluaciones de compliance en aplicaciones reguladas.

Métricas automáticas y sus limitaciones

BLEU y ROUGE: métricas de n-gram overlap

BLEU (Bilingual Evaluation Understudy) mide la precisión de n-gramas: qué fracción de los n-gramas del texto generado aparecen en la referencia. ROUGE mide el recall: qué fracción de los n-gramas de la referencia aparecen en el texto generado. Ambas métricas son baratas de calcular, reproducibles y ampliamente usadas. Sus limitaciones son bien documentadas: no capturan equivalencia semántica (dos textos con el mismo significado pero palabras distintas tienen BLEU/ROUGE bajos), y no evalúan la corrección factual.

BERTScore: similitud semántica con embeddings

BERTScore calcula la similitud coseno entre los embeddings de BERT del texto generado y de la referencia, capturando similitud semántica incluso cuando las palabras son distintas. Tiene mayor correlación con el juicio humano que BLEU/ROUGE pero requiere más cómputo y sigue sin evaluar corrección factual.

LLM-as-judge: usar un LLM para evaluar otro LLM

Una de las innovaciones más prácticas en evaluación de LLMs es usar otro LLM (típicamente uno más capaz) como juez. El LLM juez recibe el contexto, la pregunta, la respuesta del sistema, y opcionalmente una respuesta de referencia, y produce una puntuación o un ranking con justificación. Esto permite evaluación a escala (cientos o miles de respuestas) que sería impracticable con evaluación humana pura. LMSYS Chatbot Arena es el ejemplo más conocido: humanos reales evalúan pares de respuestas de modelos anónimos, produciendo un ranking Elo fiable del rendimiento conversacional real.

Las limitaciones del LLM-as-judge: los LLM jueces pueden tener sesgos hacia respuestas más largas, hacia ciertos estilos, o hacia modelos similares al juez. La correlación entre el juicio del LLM y el juicio humano es alta para tareas generales pero puede degradarse en dominios especializados. Siempre valida la correlación del juicio automático con evaluación humana en una muestra antes de confiar en él para benchmarks de producción.

SECCIÓN 4 · EJEMPLOS REALES

- LMSYS Chatbot Arena: el benchmark más confiable de rendimiento conversacional real. Miles de usuarios humanos evalúan pares de respuestas de modelos anónimos. El ranking Elo resultante es el predictor más fiable del rendimiento en conversación real porque usa preferencias humanas sobre casos reales, no preguntas diseñadas por investigadores.
- Evaluación interna de Harvey AI (LLM legal): Harvey construyó un golden dataset de 500 preguntas legales con respuestas verificadas por abogados del despacho. Evalúan cada nuevo modelo y configuración sobre este dataset antes de desplegar. El score en este dataset predice mucho mejor el rendimiento real en trabajo legal que cualquier benchmark público.
- SWE-bench en selección de modelo para copiloto de código: SWE-bench evalúa la resolución de issues reales de GitHub. Una empresa que busca un LLM para su copiloto de código usó SWE-bench como primer filtro. Los modelos con mejor SWE-bench score mostraron correlación alta con el rendimiento real en el código de la empresa.

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Confiar solo en benchmarks públicos para seleccionar el modelo de producción. Los benchmarks generales no predicen el rendimiento en dominios especializados. Un modelo que lidera en MMLU puede ser superado en tu dominio específico por un modelo más pequeño y barato fine-tuneado en ese dominio. Siempre evalúa sobre datos de tu dominio.

Error 2: Usar BLEU/ROUGE como única métrica para tareas generativas. Estas métricas miden overlap de n-gramas, no calidad. Una respuesta perfectamente correcta pero con sinónimos tendrá BLEU bajo. Una respuesta con las mismas palabras pero orden distinto puede tener BLEU alto aunque sea incoherente. Complementa con evaluación humana o LLM-as-judge.

Error 3: No incluir preguntas negativas en el golden dataset. El golden dataset debe incluir preguntas cuya respuesta correcta es "no sé" o "no tengo información suficiente". Un sistema que alucina en lugar de admitir ignorancia es más peligroso que uno con menor cobertura. Evalúa la tasa de admisión correcta de ignorancia, no solo la precisión en las preguntas que tienen respuesta.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Protocolo de evaluación para sistemas LLM en empresa: construye un golden dataset de 100-500 casos de tu dominio con respuestas correctas verificadas por expertos. Divide en: casos con respuesta disponible (evalúa precisión), casos donde el sistema debería admitir ignorancia (evalúa honestidad), y casos edge difíciles (evalúa robustez). Automatiza la evaluación con LLM-as-judge calibrado. Establece los umbrales mínimos de aceptación para despliegue. Ejecuta la evaluación completa antes de cada despliegue.

Para la calibración del LLM-as-judge: toma una muestra de 100 respuestas y evalúalas tanto con el LLM juez como con evaluadores humanos. Calcula la correlación (Pearson o Kendall tau). Si la correlación es >0.8 , el juicio automático es fiable para ese tipo de tarea. Si es <0.7 , revisa el prompt del juez o considera evaluación humana parcial.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M3-T4 (Evaluación de modelos ML): los mismos principios de golden dataset, métricas apropiadas y evaluación por subgrupos se aplican a los LLMs.
- M8 (LLMOps): la evaluación continua en producción (monitorización de calidad) extiende la evaluación offline al ciclo de vida del sistema.
- M5-T8 (Alucinaciones): TruthfulQA y las métricas de hallucination son el enlace directo entre la evaluación y el problema de alucinación.

SECCIÓN 8 · RESUMEN EJECUTIVO

Los benchmarks públicos (MMLU, HumanEval, SWE-bench, TruthfulQA, HELM) son el punto de partida, no el punto de llegada. MMLU y GSM8K están saturados para modelos frontier. Los mejores predictores de rendimiento real son: LMSYS Chatbot Arena (conversación), SWE-bench (código), HLE (razonamiento difícil). La evaluación de producción correcta usa un golden dataset propio con 100-500 casos del dominio verificados por expertos. LLM-as-judge permite escalar la evaluación si se calibra contra

evaluación humana. Incluye siempre casos donde la respuesta correcta es "no sé" para medir honestidad.