

Evaluación de Sistemas Agénticos

Módulo 10 · Sistemas Agénticos y Multi-Agente

Cuatro dimensiones de evaluación, GAIA, SWE-bench, trayectorias, seguridad y golden datasets de dominio.

1. Introducción · 2. Qué es · 3. Cómo funciona · 4. Ejemplos reales
5. Errores comunes · 6. Aplicación práctica · 7. Relación con módulos · 8. Resumen ejecutivo

Guía de estudio detallada · +2.000 palabras

Evaluación de Sistemas Agénticos

Evaluar un sistema agéntico es fundamentalmente más difícil que evaluar un LLM estándar. Un LLM estándar recibe un prompt y produce una respuesta: la evaluación compara la respuesta con una respuesta de referencia. Un agente toma una secuencia de acciones durante potencialmente decenas de iteraciones: la evaluación debe considerar no solo si completó el objetivo final sino también la eficiencia del camino (número de pasos, tokens usados, tiempo empleado), la seguridad del comportamiento (no tomó acciones no autorizadas), y la robustez ante errores inesperados.

La evaluación de agentes es uno de los campos más activos de la investigación en IA en 2025, con benchmarks específicos emergiendo para diferentes tipos de tareas agénticas: OSWorld (tareas en sistemas operativos, 42.9% para los mejores modelos vs 72.36% humanos), SWE-bench (resolución de issues de GitHub), GAIA (tareas del mundo real con herramientas), y WebArena (navegación web). Ninguno de estos benchmarks es suficiente para evaluar un agente de producción: requieren evaluaciones específicas del dominio y del caso de uso.

Las dimensiones de evaluación de agentes

Tasa de completación de tareas

La métrica más fundamental: ¿el agente completó el objetivo? Para objetivos con criterios de éxito objetivos (el código pasa todos los tests, el informe contiene todos los campos requeridos, la acción fue ejecutada correctamente), la tasa de completación se puede calcular automáticamente. Para objetivos con criterios subjetivos (la calidad del análisis, la utilidad de la respuesta), se necesita evaluación humana o LLM-as-judge.

Eficiencia del proceso

Cuántos pasos, tokens, y tiempo necesitó el agente para completar la tarea. Un agente que completa la tarea en 5 pasos es más eficiente que uno que la completa en 15 pasos. La eficiencia tiene impacto directo en el coste (más pasos = más llamadas al LLM = más tokens = más coste) y en la latencia. La distribución del número de pasos es también informativa: un agente que ocasionalmente necesita 50 pasos para tareas que normalmente requieren 10 tiene un problema de robustez.

Seguridad del comportamiento

¿El agente tomó acciones no autorizadas? ¿Ignoró las instrucciones de human-in-the-loop? ¿Llamó a herramientas destructivas sin confirmación? La evaluación de seguridad del comportamiento requiere un conjunto de pruebas específicamente diseñadas para detectar comportamientos no deseados: intentos de bypass de guardrails, llamadas a herramientas fuera de scope, generación de contenido dañino. Este tipo de evaluación es análoga al red teaming en seguridad.

Robustez ante fallos

¿El agente maneja correctamente los fallos de herramientas, las respuestas inesperadas, y los inputs malformados? Un agente robusto reconoce cuando una herramienta falla, intenta alternativas razonables, y comunica el fallo gracefully si no puede recuperarse. Un agente no robusto puede entrar en bucles, consumir todos los recursos, o producir outputs silenciosamente incorrectos cuando las condiciones no son las esperadas.

SECCIÓN 3 · CÓMO FUNCIONA

Frameworks y herramientas de evaluación

Trajectories-based evaluation

La evaluación basada en trayectorias examina no solo el resultado final sino también la secuencia completa de acciones del agente. Para cada trayectoria capturada, se evalúa: si cada acción fue apropiada dado el estado del mundo en ese momento, si las herramientas se usaron correctamente (argumentos correctos, momento apropiado), si el agente se desvió del objetivo o tomó desvíos innecesarios, y si el agente recuperó correctamente de los errores. Esta evaluación requiere revisar los logs completos de las iteraciones del agente.

LLM-as-judge para evaluación agéntica

Para tasks con criterios de éxito subjetivos, un LLM judge puede evaluar la calidad del output final, la adecuación de las herramientas usadas, y la eficiencia del proceso. El prompt de evaluación agéntica incluye: el objetivo original, la trayectoria completa de acciones, el output final, y los criterios de evaluación. El juez produce una puntuación y una justificación. La calibración del LLM judge con evaluación humana es especialmente importante para agentes, dado que la complejidad de las trayectorias hace que la evaluación sea más difícil que para respuestas de texto simples.

GAIA: el benchmark de referencia para agentes de uso general

GAIA (Mialon et al., 2023, actualizado 2024-2025) es el benchmark de referencia para evaluar agentes en tareas del mundo real que requieren razonamiento, herramientas, y múltiples pasos. Contiene 466 preguntas a tres niveles de dificultad: nivel 1 (agentes actuales alcanzan ~65%), nivel 2 (~45%), y nivel 3 (~25%). Las preguntas requieren: búsqueda web, análisis de imágenes y PDFs, navegación de sitios web, y cálculos. GAIA es el benchmark más representativo del rendimiento real de agentes en tareas de conocimiento del mundo.

SECCIÓN 4 · EJEMPLOS REALES

- Evaluación del agente de investigación de M&A; (banco de inversión): el golden dataset contiene 50 casos de due diligence con informes de referencia elaborados por analistas humanos. La evaluación mide: tasa de completación (¿el agente identificó todos los riesgos del informe de referencia?), precisión factual (¿las afirmaciones del agente son verificables?), y eficiencia (¿número de pasos vs benchmark humano de 3-4 horas?).
- SWE-bench para agente de coding: SWE-bench evalúa si el agente puede resolver issues reales de GitHub en repositorios Python. Los mejores agentes actuales resuelven el 38-45% de los issues. El benchmark es informativo porque los issues son problemas reales, no creados artificialmente para el benchmark.

- Evaluación de seguridad con red team dataset: el equipo de seguridad crea un conjunto de 100 prompts diseñados para provocar comportamientos no deseados en el agente: intentos de extraer el system prompt, peticiones de ejecutar acciones fuera de scope, intentos de bypass de human-in-the-loop. El agente se evalúa en qué porcentaje de estos prompts responde correctamente (rechazando la acción no autorizada o escalando al humano).

SECCIÓN 5 · ERRORES Y MALENTENDIDOS COMUNES

Error 1: Evaluar solo el output final sin revisar la trayectoria. Un agente puede producir el output correcto por las razones incorrectas (siguió un camino incorrecto que, por casualidad, llegó al resultado correcto). La evaluación de la trayectoria detecta fragilidades que no son visibles en el output final.

Error 2: Usar solo benchmarks públicos sin evaluación en el dominio propio. Los benchmarks públicos (GAIA, SWE-bench, OSWorld) no representan el dominio específico de la empresa. Un agente que puntúa bien en GAIA puede tener bajo rendimiento en el caso de uso específico de la empresa si ese caso de uso tiene características distintas a las de GAIA.

Error 3: No evaluar el coste de los agentes fallidos. Un agente que falla después de 30 iteraciones cuesta 30x más que uno que falla rápidamente. Incluye en la evaluación el coste promedio de las tareas fallidas: un sistema que detecta pronto que no puede completar una tarea y lo declara es más económico que uno que sigue intentando.

SECCIÓN 6 · APLICACIÓN PRÁCTICA

Para construir un sistema de evaluación de agentes: define las métricas de éxito para tu dominio (tasa de completación, precisión, eficiencia, seguridad). Construye un golden dataset de 30-100 tareas representativas con criterios de éxito claros. Implementa logging completo de las trayectorias del agente (cada thought, tool call, observation, y output). Evalúa cada trayectoria con LLM-as-judge calibrado con evaluación humana para el 20% de las trayectorias. Monitoriza las métricas en producción con un sampling del 5-10% de las tareas reales.

Para el logging de trayectorias con LangSmith: todas las llamadas al LLM y las ejecuciones de herramientas de un LangGraph o CrewAI agente se registran automáticamente en LangSmith con una variable de entorno. Las trayectorias completas están disponibles para debugging y evaluación. Para evaluación automatizada: usa la API de evaluación de LangSmith para ejecutar LLM-as-judge sobre las trayectorias y almacenar los scores.

SECCIÓN 7 · RELACIÓN CON OTROS MÓDULOS

- M5-T7 (Evaluación de LLMs): los principios de evaluación de LLMs se extienden y complican en la evaluación de agentes.
- M8-T7 (Observabilidad): el logging de trayectorias con LangSmith es la base de la evaluación de agentes.
- M8-T9 (CI/CD): la evaluación automática del agente en CI es el análogo del golden dataset para sistemas LLM.

SECCIÓN 8 · RESUMEN EJECUTIVO

La evaluación de agentes tiene cuatro dimensiones: tasa de completación (objetivo alcanzado), eficiencia (pasos, tokens, tiempo), seguridad del comportamiento (acciones no autorizadas), y robustez ante fallos. Los benchmarks de referencia: GAIA (tareas del mundo real, nivel 1: 65%), SWE-bench (código, 38-45% mejores modelos), OSWorld (SO, 42.9% vs 72.36% humanos). La evaluación basada en trayectorias es más informativa que solo el output final. Golden dataset propio de 30-100 tareas con criterios de éxito claros para cada dominio. LangSmith para logging automático de trayectorias. Incluir el coste de los agentes fallidos en la evaluación.