

Módulo 3 — Machine Learning Clásico

Supervisado vs no supervisado, árboles y ensambles, XGBoost, validación cruzada, overfitting y SHAP.

BLOQUE 1 · EL LUGAR DEL ML CLÁSICO EN 2025

Módulo 3 — Machine Learning Clásico

En la era de los LLMs y la IA generativa, el machine learning clásico (los algoritmos que dominaron la IA antes de la revolución del deep learning) puede parecer obsoleto. Esta percepción es equivocada. Los algoritmos de ML clásico siguen siendo la herramienta correcta para una amplia gama de problemas en producción: son más interpretables que los LLMs, requieren menos datos y poder computacional, son más fáciles de auditar (relevante para el EU AI Act), y tienen décadas de literatura científica sobre su comportamiento, sus límites, y sus mejores prácticas. Además, los conceptos del ML clásico (sobreajuste, validación, feature engineering, regularización) se aplican directamente a los sistemas de deep learning y LLMs.

El profesional de IA competente en 2025 no elige entre ML clásico y LLMs: elige la herramienta correcta para cada problema. Para predecir el churn de clientes con datos tabulares estructurados, un XGBoost bien optimizado superará frecuentemente a un LLM en precisión, velocidad, interpretabilidad, y coste. Para analizar contratos legales en texto libre y extraer cláusulas clave, un LLM con RAG superará ampliamente a cualquier modelo de ML clásico. El mapa del territorio del ML es el instrumento de navegación para estas decisiones.

Aprendizaje supervisado, no supervisado, y por refuerzo

El machine learning se divide en tres grandes paradigmas según la naturaleza de los datos de entrenamiento y el tipo de feedback disponible. Aprendizaje supervisado: el modelo aprende de pares (input, output correcto), donde el output correcto (la etiqueta o label) ha sido proporcionado por humanos. Es el paradigma más común en aplicaciones empresariales: clasificación (¿a qué categoría pertenece este email: spam o no spam?), regresión (¿cuál será el precio de este inmueble?), detección de anomalías (¿esta transacción es fraudulenta?). Aprendizaje no supervisado: el modelo aprende estructura en los datos sin etiquetas. Los casos de uso más comunes son la segmentación de clientes (clustering), la reducción de dimensionalidad (PCA), y la detección de anomalías sin ejemplos de anomalías (uno-class learning). Aprendizaje por refuerzo: el modelo aprende a través de la interacción con un entorno, recibiendo recompensas por acciones beneficiosas y penalizaciones por acciones perjudiciales. Es la base del RLHF (Reinforcement Learning from Human Feedback) que se usa para alinear los LLMs con las preferencias humanas.

El pipeline de ML: de los datos al modelo en producción

Un proyecto de ML clásico sigue un pipeline bien establecido que es relevante incluso para proyectos de LLM. La etapa de análisis exploratorio de datos (EDA) es el primer paso: entender la distribución de los datos, identificar valores faltantes y outliers, y visualizar las relaciones entre variables. Sin EDA, es imposible diseñar un modelo adecuado. La etapa de feature engineering es frecuentemente la que más impacto tiene en el rendimiento del modelo: transformar, combinar, y crear variables a partir de los datos brutos para que el modelo pueda aprender las relaciones relevantes. La selección del modelo y la optimización de hiperparámetros es un proceso iterativo de prueba y evaluación de distintas

arquitecturas y configuraciones. La evaluación con datos de test (separados de los datos de entrenamiento) proporciona la estimación imparcial del rendimiento en producción.

BLOQUE 2 · LOS ALGORITMOS MÁS IMPORTANTES

Regresión, árboles, y ensambles: el toolkit del ML clásico

Regresión lineal y logística: los modelos base

La regresión lineal modela la relación entre una variable de respuesta continua y una o más variables predictoras como una función lineal. Es el modelo más simple de ML supervisado pero proporciona un punto de referencia excelente (baseline) para cualquier problema de regresión: si un modelo más complejo no supera a la regresión lineal, algo está mal (los datos pueden no tener patrones no lineales que el modelo más complejo pueda explotar, o el modelo más complejo está sobreajustando). La regresión logística extiende la regresión lineal a la clasificación binaria mediante la función logística (sigmoid), que mapea los valores lineales a probabilidades entre 0 y 1. A pesar de su nombre, la regresión logística es un algoritmo de clasificación, no de regresión.

Las regularizaciones L1 (Lasso) y L2 (Ridge) son extensiones de la regresión lineal y logística que añaden penalizaciones sobre el tamaño de los pesos, reduciendo el sobreajuste y seleccionando automáticamente las variables más relevantes (L1 produce pesos exactamente iguales a cero para las variables menos relevantes). La regresión con regularización es especialmente útil cuando hay muchas variables predictoras y algunos pueden ser irrelevantes o redundantes.

Árboles de decisión y Random Forests

Los árboles de decisión son modelos altamente interpretables que dividen el espacio de features en regiones rectangulares mediante una secuencia de divisiones binarias basadas en los valores de las variables. Cada nodo interno del árbol representa una condición sobre una variable (e.g., "¿es la edad mayor de 35 años?"), cada rama representa el resultado de esa condición, y cada hoja representa una predicción. Los árboles de decisión son fácilmente interpretables (puedes trazar el camino de una predicción desde la raíz hasta la hoja y entender exactamente qué condiciones se aplicaron), lo que los hace valiosos en dominios regulados donde la explicabilidad es requerida.

La limitación de los árboles individuales es su alta varianza: pequeños cambios en los datos de entrenamiento pueden producir árboles completamente distintos. Los Random Forests resuelven esto mediante el ensamble de múltiples árboles, cada uno entrenado sobre una muestra aleatoria de los datos y las features. El promedio de las predicciones de muchos árboles (cada uno con alta varianza pero poco sesgo) produce un modelo con mucha menor varianza y excelente rendimiento en generalización. Los Random Forests son uno de los algoritmos más robustos del ML clásico y son frecuentemente la primera opción para datos tabulares sin invertir en feature engineering extenso.

Gradient Boosting y XGBoost: el estado del arte en tabular ML

Gradient Boosting es el algoritmo de ML clásico que ha dominado las competiciones de Kaggle durante años para datos tabulares. La idea es construir el modelo de forma iterativa: empezar con un modelo simple (frecuentemente un árbol pequeño), calcular los errores residuales de ese modelo, entrenar un nuevo modelo para predecir esos errores, añadir el nuevo modelo al conjunto, y repetir. Cada nuevo árbol corrige los errores del conjunto anterior. XGBoost, LightGBM, y CatBoost son implementaciones

altamente optimizadas de Gradient Boosting que añaden regularización, manejo de valores faltantes, soporte nativo para variables categóricas, y paralelización del entrenamiento.

En 2025, XGBoost y LightGBM siguen siendo el estado del arte para la mayoría de los problemas de predicción con datos tabulares estructurados: superan frecuentemente a las redes neuronales profundas en velocidad de entrenamiento, interpretabilidad (con SHAP), y rendimiento cuando los datos son de tamaño moderado (menos de 1 millón de filas). Para volúmenes de datos masivos o datos con estructura espacial o temporal compleja, las redes neuronales pueden superarlos.

SVM, k-NN, y algoritmos de clustering

Las Máquinas de Vectores de Soporte (SVM) son algoritmos de clasificación que buscan el hiperplano de máximo margen que separa las clases en el espacio de features. Las SVMs son especialmente efectivas en espacios de alta dimensionalidad y con datos de entrenamiento limitados, lo que las hace populares en bioinformática y análisis de texto (con features TF-IDF). El kernel trick permite a las SVMs modelar fronteras de decisión no lineales sin mapear explícitamente los datos a espacios de alta dimensionalidad. k-NN (k-Nearest Neighbors) es el algoritmo de clasificación más simple conceptualmente: para clasificar un nuevo punto, encuentra los k puntos más cercanos en el conjunto de entrenamiento y asigna la clase mayoritaria. Es altamente interpretable pero no escala bien con grandes datasets (requiere comparar el nuevo punto con todos los puntos de entrenamiento en la inferencia).

Los algoritmos de clustering (k-Means, DBSCAN, Hierarchical Clustering) son los principales algoritmos de aprendizaje no supervisado. k-Means divide los datos en k clusters esféricos de tamaño similar, minimizando la varianza intra-cluster. DBSCAN identifica clusters de forma arbitraria basándose en la densidad de puntos, lo que lo hace adecuado para datos con formas no esféricas y permite identificar puntos de ruido. El Hierarchical Clustering construye una jerarquía de clusters que puede visualizarse como un dendrograma, útil para explorar la estructura de los datos a distintos niveles de granularidad.

BLOQUE 3 · VALIDACIÓN, OVERFITTING, Y MEJORES PRÁCTICAS

La práctica rigurosa del machine learning

El problema del overfitting y cómo detectarlo

El overfitting (sobreajuste) ocurre cuando el modelo aprende los patrones específicos de los datos de entrenamiento tan bien que no generaliza a datos nuevos. Un modelo sobreajustado tiene alta accuracy en los datos de entrenamiento pero baja accuracy en los datos de test. El overfitting es especialmente frecuente con modelos complejos (muchos parámetros) y datasets pequeños. Los síntomas son claros: la curva de aprendizaje muestra que el error de entrenamiento sigue bajando mientras el error de validación empieza a subir.

Las técnicas de regularización (L1, L2, dropout, early stopping, data augmentation) mitigan el overfitting añadiendo penalizaciones por complejidad del modelo o reduciendo artificialmente la capacidad del modelo para memorizar el ruido de los datos de entrenamiento. La selección correcta de la técnica de regularización y de su intensidad (el hiperparámetro de regularización) es una de las decisiones de diseño más importantes en un proyecto de ML.

Validación cruzada y evaluación imparcial

La validación cruzada k-fold es la técnica estándar para estimar el rendimiento de un modelo de ML de forma imparcial. El dataset se divide en k partes (folds) del mismo tamaño. El modelo se entrena k veces, cada vez usando k-1 folds como entrenamiento y 1 fold como validación. El rendimiento promedio sobre los k folds proporciona una estimación más robusta del rendimiento en producción que una sola división entrenamiento/validación. La validación cruzada estratificada garantiza que cada fold mantiene la misma proporción de clases que el dataset original, lo que es especialmente importante para datasets desbalanceados.

El test set contaminado es uno de los errores más frecuentes y graves en proyectos de ML: si cualquier información del test set filtra al proceso de entrenamiento (a través del feature engineering, la normalización, o la selección de modelos), los resultados de evaluación en el test set sobreestiman el rendimiento real en producción. La regla de oro: el test set no se toca hasta el momento final de evaluación del modelo seleccionado, y nunca se usa para tomar decisiones de diseño.

Feature importance, interpretabilidad, y SHAP

La interpretabilidad de los modelos de ML tiene dos dimensiones: la interpretabilidad global (entender qué variables son más importantes para las predicciones del modelo en general) y la interpretabilidad local (entender por qué el modelo hizo una predicción específica para un instance concreto). Los métodos basados en feature importance de los árboles (impurity-based importance, permutation importance) proporcionan interpretabilidad global pero pueden ser engañosos cuando hay variables correlacionadas. SHAP (SHapley Additive exPlanations) proporciona tanto interpretabilidad global como local con garantías matemáticas de consistencia, basándose en la teoría de juegos cooperativos. Es la herramienta de interpretabilidad más usada en ML clásico y es especialmente relevante para el cumplimiento del AI Act (requisito de explicabilidad para sistemas de alto riesgo).

RESUMEN EJECUTIVO DEL MÓDULO 3: El ML clásico sigue siendo la herramienta correcta para datos tabulares estructurados: más interpretable, más eficiente, y frecuentemente más preciso que los LLMs para estos problemas. Los tres paradigmas son: supervisado (clasificación, regresión), no supervisado (clustering, reducción de dimensionalidad), y refuerzo (base del RLHF para LLMs). Los algoritmos más importantes son: regresión lineal/logística (base e interpretable), Random Forests (robusto y versátil), XGBoost/LightGBM (estado del arte en tabular ML), SVM (alta dimensionalidad), y k-Means/DBSCAN (clustering). El overfitting se detecta con curvas de aprendizaje y se mitiga con regularización. La validación cruzada k-fold proporciona estimaciones imparciales del rendimiento. SHAP es la herramienta estándar de interpretabilidad local y global. La elección entre ML clásico y LLMs debe basarse en el tipo de datos, el volumen, los requisitos de interpretabilidad, y el coste.